



1º LISTA DE EXERCÍCIOS – RESPOSTAS ESPERADAS

Disciplina: PAM0466– SISTEMAS INTELIGENTES

Semestre: 2026.1

Docente: PEDRO THIAGO VALÉRIO DE SOUZA

Horário: 3M23 4M45

- 1
 - Supervisionado: Utiliza um conjunto de exemplos de treinamento com entrada e a saída desejada (rótulos). Exemplos: k -NN e certas arquiteturas de redes neurais.
 - Não Supervisionado: O algoritmo busca padrões ou estruturas em dados sem rótulos. Exemplo: Agrupamento de dados (clusterização).
 - Reforço: O aprendizado ocorre por meio de interação com o ambiente, recebendo recompensas ou punições.
- 2
 - (a) Aprendizagem por reforço.
 - (b) Aprendizado não supervisionado.
 - (c) Aprendizado supervisionado.
- 3 No aprendizado em *batch*, o modelo é treinado de uma vez com todo o conjunto disponível. No *on-line*, o sistema aprende de forma incremental, processando amostras de dados conforme elas chegam.
- 4 Parâmetros são internos ao modelo e ajustados durante o treino (ex: os pesos sinápticos em uma rede neural ou os parâmetros da regressão logística). Por sua vez, hiperparâmetros são definidos antes do treinamento (ex: o valor de k no k -NN ou o número de camadas ocultas em uma rede neural).
- 5 Algoritmos baseados em instâncias simplesmente memorizam os dados de treino (ex: k -NN). Algoritmos baseados em modelos constroem uma representação generalizada (modelo) durante o treinamento, armazenando o conhecimento em parâmetros (ex: regressão logística).
- 6
 - Treinamento: Usado para o algoritmo de aprendizado de máquina extrair informações e armazenar conhecimento.
 - Validação: Utilizado para ajuste de hiperparâmetros (ex: encontrar o melhor k do k -NN via validação cruzada).
 - Teste: Usado para avaliar o desempenho final do modelo em dados que ele nunca viu.
- 7
 - Linearidade: a relação entre as variáveis y e x é linear ou aproximadamente linear.
 - Independência dos erros: Os erros (ϵ) são independentes entre si. Isso significa que o erro de uma observação não deve depender do erro de outra observação.
 - Homocedasticidade: a variância dos erros deve permanecer constante para todos os valores observados de x .
 - Normalidade dos Erros: os erros devem seguir uma distribuição normal.
- 8 O R^2 indica a proporção da variância da variável dependente que é explicada pelo modelo de regressão. Um R^2 muito próximo de 1 pode indicar *overfitting*.
- 9 Ao penalizar o quadrado dos coeficientes, a regularização Ridge força o modelo a manter os pesos menores e mais distribuídos, evitando que uma única variável tenha influência excessiva e torne o modelo complexo demais.
- 10 O parâmetro α controla a intensidade da regularização. Se $\alpha = 0$, não há regularização (modelo padrão). Se $\alpha \rightarrow \infty$, a penalidade é tão alta que os pesos tendem a zero.

- 11 Evita que atributos com escalas maiores (ex: salários vs. altura) dominem o ajuste dos parâmetros do modelo, garantindo que todos os atributos contribuam de forma equilibrada.
- 12 A regularização Lasso tem a capacidade de zerar coeficientes de variáveis irrelevantes, realizando uma seleção automática de atributos, o que a regularização Ridge não faz.
- 13 Não. Em bases desbalanceadas (ex: detectar uma doença rara em 1% da população), um modelo que diz que ninguém está doente terá 99% de acurácia, mas será inútil. Métricas como Precisão, *Recall* ou *F1-Score* seriam mais adequadas.
- 14 Representa a capacidade do modelo de distinguir entre classes. $AUC = 0,5$ indica um modelo sem poder discriminativo (equivalente a um chute aleatório), enquanto $AUC = 1,0$ indica um modelo perfeito.
- 15 Consiste em dividir os dados em K partes, treinando em $K-1$ e validando na parte restante, repetindo o processo K vezes. Isso permite avaliar o desempenho do modelo de forma mais robusta e ajustar hiperparâmetros com base na média dos resultados de validação.
- 16 O k -NN não constrói modelo, apenas memoriza os dados. A regressão logística armazena o conhecimento em parâmetros do modelo. No cenário proposto, a regressão logística seria mais adequada, pois o k -NN pode ser lento e exigir muita memória em conjuntos grandes.
- 17
 - Calcular a distância entre a nova amostra e os exemplos de treino.
 - Identificar os k vizinhos mais próximos (ordenando as distâncias).
 - Contar os votos das classes desses vizinhos e atribuir a classe majoritária à nova amostra.
- 18 É a capacidade da rede, após o treinamento, de estimar respostas corretas para casos que ela ainda não conhece (dados novos).
- 19 Limita a saída do neurônio a valores razoáveis. A introdução de não linearidades é crucial pois neurônios são tipicamente não lineares, permitindo que a rede aprenda relações complexas que modelos lineares não conseguem captar.
- 20 Uma rede de camada simples possui apenas camada de entrada e camada de saída. Já uma rede de múltiplas camadas inclui uma ou mais camadas ocultas entre a entrada e a saída, permitindo a modelagem de relações mais complexas.
- 21 A rede *Perceptron* possui uma arquitetura *feedforward* de camada única, composta por n entradas. O seu vetor de pesos sinápticos aceita valores reais, enquanto o seu vetor de entradas pode ser composto tanto por valores reais quanto binários. A saída final da rede é binária.
- 22 É um aprendizado supervisionado baseado na regra de Hebb. Os pesos são atualizados conforme a expressão: $\mathbf{w} \leftarrow \mathbf{w} + \eta (y_d^{(k)} - y) \mathbf{x}^{(k)}$. O ajuste ocorre proporcionalmente aos sinais de entrada se a saída da rede (y) não for coincidente com a saída desejada $y_d^{(k)}$; caso sejam iguais, os pesos permanecem inalterados.
- 23 O teorema estabelece que o *Perceptron* só consegue classificar padrões que sejam linearmente separáveis. Se os dados não forem linearmente separáveis (ou seja, se não puderem ser divididos por um hiperplano), a rede divergirá e o processo de treinamento não chegará ao fim.
- 24 A diferença fundamental reside no ponto da rede onde o erro é calculado. Na rede *Perceptron*, o erro baseia-se na saída final binária (y) da rede após a função de ativação. Na rede *Adaline*, o erro é calculado entre a resposta desejada e o potencial de ativação (u), que é o valor analógico do combinador linear antes da função de ativação.
- 25 A rede *Perceptron* admite qualquer hiperplano que separe as classes; como existem infinitas retas possíveis para separar dados linearmente separáveis, os pesos finais não são únicos. Já o *Adaline* busca minimizar a

soma dos erros quadráticos (através do gradiente descendente), convergindo para um ponto de mínimo $\mathbf{w}^*$ que tende a ser único, resultando em um hiperplano ótimo específico.

- 26** O *Adaline* utiliza o erro quadrático médio (MSE) como critério de parada. O algoritmo para quando a diferença absoluta do EQM entre duas épocas consecutivas é menor ou igual a uma precisão requerida (ϵ).
- 27** A constante η (taxa de aprendizagem) controla a velocidade e estabilidade. Para valores muito grandes, o treinamento é rápido, mas sujeito a instabilidades e oscilações. Para valores muito pequenos, o processo torna-se muito lento, embora mais estável e suave.
- 28** Não é possível aplicar o *Perceptron* para resolver este problema, pois essas amostras não são linearmente separáveis por uma única reta.