UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO
CENTRO MULTIDISCIPLINAR PAU DOS FERROS
DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA

1º LISTA DE PROJETOS

Disciplina: PAM0466– SISTEMAS INTELIGENTES **Semestre:** 2026.2

Docente: PEDRO THIAGO VALÉRIO DE SOUZA **Horário:** 23M45

Atenção: Para cada uma dos problemas apresentados, pede-se, como entrega, os códigos utilizados para construção do modelo de inteligência artificial, disponibilizados em um repositório público (GitHub, GitLab, etc.), juntamente com um relatório (em arquivo `.md`) contendo as análises solicitadas por cada problema. O projeto deve ser realizado de forma **individual**, com posterior defesa em data marcada na sala do professor. Os códigos podem ser desenvolvidos em qualquer linguagem de programação.

Problema 1 – Regressão Linear para Previsão de Produção de Energia em uma Usina de Ciclo Combinado

Uma usina termoelétrica de ciclo combinado (UTCC) é uma instalação de alta eficiência que combina turbinas a gás e a vapor para gerar eletricidade. Ela reaproveita o calor dos gases de exaustão da turbina a gás (ciclo Brayton) para produzir vapor em uma caldeira, acionando uma segunda turbina (ciclo Rankine), aumentando significativamente o rendimento. A principal vantagem é a eficiência energética, que pode chegar a 60%, reduzindo as emissões de gases de efeito estufa.

Embora apresente alta eficiência, o principal desafio técnico no uso de uma usina UTCC reside na integração, sincronização e operação conjunta de dois ciclos termodinâmicos distintos (ciclo Brayton e ciclo Rankine) para funcionar de forma eficiente. Assim sendo, a potência elétrica de saída (PE) é altamente sensível às condições ambientais.

Neste projeto, você deve construir um modelo matemático de regressão linear múltipla para prever a produção de energia baseando-se em sensores ambientais, permitindo a otimização do despacho energético.
Para realizar o treinamento do nosso modelo, utilizamos o *dataset* UCI CCPP (disponível em `https://archive.ics.uci.edu/ml/datasets/Combined+Cycle+Power+Plant`). O *dataset* contém 9.568 amostras coletadas ao longo de 6 anos. Cada amostra possui as seguintes variáveis:

- AT (*Ambient Temperature*): Temperatura em °C. Afeta a densidade do ar e a eficiência da combustão.
- V (*Exhaust Vacuum*): Vácuo de escape em cm Hg. Relacionado à pressão na turbina a vapor.
- AP (*Ambient Pressure*): Pressão atmosférica em mbar.
- RH (*Relative Humidity*): Umidade relativa em percentagem.
- PE (*Net Hourly Electrical Energy Output*): A variável alvo em MW (MegaWatts).

Realize as seguintes tarefas utilizando o *dataset* fornecido:

1. Calcule a correlação entre as variáveis independentes (AT, V, AP, RH) e a variável dependente (PE). Quais variáveis parecem ter maior influência na produção de energia?
2. Calcule a correlação entre as variáveis independentes (AT, V, AP, RH) entre si. Existe alguma relação forte entre elas? Se sim, isso pode indicar multicolinearidade.
3. Construa um modelo de regressão linear múltipla utilizando as variáveis independentes (AT, V, AP, RH) para prever a variável dependente (PE). Divida os dados em treino (80%) e teste (20%).
4. Avalie o desempenho do modelo utilizando métricas como R^2, RMSE e MAE. O modelo é adequado para prever a produção de energia? Justifique sua resposta.

Realize o pré-processamento dos dados, incluindo a normalização ou padronização das variáveis independentes, tratamento de valores ausentes e divisão dos dados em conjuntos de treino e teste.

Problema 2 – Regressão Logística para Previsão de Doenças Cardíacas

Doenças cardiovasculares são a principal causa de morte no mundo, responsáveis por cerca de 18 milhões de óbitos por ano segundo a OMS. O diagnóstico precoce é determinante para o sucesso do tratamento. Existe, portanto, uma necessidade real de ferramentas capazes de estimar o risco de um paciente com base em dados clínicos simples, coletados em consulta de rotina. É nesse contexto que o aprendizado de máquina pode contribuir. Um modelo de classificação treinado com dados históricos de pacientes diagnosticados é capaz de aprender quais combinações de variáveis clínicas estão associadas à presença de doença cardíaca e aplicar esse aprendizado a novos pacientes.

Neste projeto, você é convidado a construir um modelo utilizando regressão logística para prever a presença de doença cardíaca com base em um conjunto de dados clínicos.

O projeto utiliza o dataset Heart Disease Cleveland (UCI Machine Learning Repository – disponível em `https://archive.ics.uci.edu/dataset/45/heart+disease`), com registros de 303 pacientes e 13 variáveis clínicas. Os diagnósticos foram confirmados por cateterismo cardíaco, o que garante rótulos confiáveis. As variáveis incluem:

- `age` — idade do paciente em anos;
- `sex` — sexo biológico (1 = masculino, 0 = feminino);
- `cp` — tipo de dor no peito: angina típica (1), atípica (2), não anginosa (3) ou assintomático (4);
- `trestbps` — pressão arterial em repouso em mmHg;
- `chol` — colesterol sérico total em mg/dl;
- `fbs` — glicemia em jejum acima de 120 mg/dl (1 = sim, 0 = não);
- `restecg` — resultado do ECG em repouso: normal (0), alteração na onda ST-T (1) ou hipertrofia ventricular (2);
- `thalach` — frequência cardíaca máxima atingida no teste de esforço;
- `exang` — angina induzida por exercício (1 = sim, 0 = não);
- `oldpeak` — depressão do segmento ST durante o esforço, indicador de isquemia;
- `slope` — inclinação do segmento ST no pico do esforço: ascendente (1), plano (2) ou descendente (3);
- `ca` — número de artérias coronárias com obstrução visível na fluoroscopia (0 a 3);
- `thal` — cintilografia de tálio: normal (3), defeito fixo / infarto prévio (6) ou defeito reversível / isquemia ativa (7);

A saída é a variável `target`, que indica o diagnóstico original de 0 a 4, binarizado para 0 (sem doença) e 1 (com doença) antes do treinamento.

Realize as seguintes tarefas utilizando o *dataset* fornecido:

1. Treinar um modelo de `LogisticRegression` do `scikit-learn` utilizando os dados de treino, com os seguintes parâmetros: `solver='liblinear'`, `random_state=42` e `max_iter=1000`. Indique quantas iterações foram necessárias para a convergência do modelo.
2. Avaliar o modelo utilizando os dados de teste e calcular as seguintes métricas: Acurácia, Precisão, Recall, F1-score e Curva ROC com valor de AUC.

Realize o pré-processamento dos dados, incluindo a normalização ou padronização das variáveis independentes, tratamento de valores ausentes, divisão dos dados em conjuntos de treino e teste e binarização das variáveis alvo.

Problema 3 – Classificação de Qualidade de Vinhos Utilizando k-NN

A indústria vinícola depende historicamente de avaliações humanas — caras, lentas e subjetivas. Um modelo preditivo de qualidade tem aplicações diretas no controle de lotes antes do engarrafamento, na precificação e na certificação de denominação de origem por órgãos reguladores. Na pesquisa enológica (ciência que estuda a produção, conservação e análise de vinhos), ele também ajuda a identificar quais variáveis químicas mais influenciam a percepção de qualidade, orientando decisões de produção.

Plataformas como a Vivino (`https://www.vivino.com/BR/pt-BR/`) já utilizam *machine learning* com esse objetivo. No Brasil, o contexto do Vale do São Francisco — maior polo de vinhos tropicais do mundo, localizado aqui no Nordeste — torna o problema especialmente próximo e motivador para nossa realidade.

Neste projeto, você é convidado a construir um modelo de classificação de vinhos em três categorias de qualidade (baixa, média e alta) a partir de um conjunto de dados químicos utilizando o k-NN (*k-Nearest Neighbors*).

O projeto utiliza o arquivo `winequality-red.csv` do *dataset* Wine Quality (`https://archive.ics.uci.edu/ml/datasets/Wine+Quality`). O *dataset* foi criado por Paulo Cortez et al. (Universidade do Minho, Portugal) e publicado em 2009. Ele reúne 1.599 amostras de vinho tinto da região do Vinho Verde, no noroeste de Portugal. Cada amostra foi submetida a testes laboratoriais que geraram 11 atributos físico-químicos — como acidez fixa, acidez volátil, teor de ácido cítrico, açúcar residual, cloretos, dióxido de enxofre, densidade, pH, sulfatos e teor alcoólico. O rótulo de qualidade (`quality`) é um valor inteiro de 0 a 10 atribuído por *sommeliers* em avaliações cegas, representando a mediana de pelo menos três avaliações humanas.

Realize as seguintes tarefas utilizando o *dataset* fornecido:

1. Preparação dos dados: carregue o *dataset* e recodifique a variável `quality` em três classes: notas ≤ 5 como *ruim*, 6–7 como *médio* e ≥ 8 como *bom*. Em seguida, normalize todos os atributos utilizando Min-Max ou *Z-score*. Justifique por que a normalização é uma etapa obrigatória para o k-NN.
2. Divisão treino/teste: divida os dados em 80% para treino e 20% para teste, utilizando divisão estratificada para garantir que a proporção das três classes seja mantida em ambos os conjuntos.
3. Treinamento e escolha do k: treine o modelo para diferentes valores de k (ex: 1, 3, 5, 7, 11) utilizando validação cruzada de 5 *folds* sobre o conjunto de treino. Plote a acurácia média em função de k e escolha o valor com melhor desempenho. O que acontece com o modelo para valores muito baixos e muito altos de k?
4. Avaliação do modelo: utilizando o conjunto de teste, calcule a matriz de confusão e as métricas de acurácia, precisão, *recall* e F1-*score* para cada classe. Responda: Entre quais classes o modelo erra com mais frequência?

Problema 4 – Classificação de Risco de Crédito Utilizando Árvores de Decisão

A concessão de crédito é uma das decisões mais sensíveis do sistema financeiro: aprovar um cliente inadimplente gera prejuízo direto, mas recusar um bom pagador significa perda de receita e exclusão financeira. Diferentemente de outras aplicações de *machine learning*, aqui não basta acertar, é preciso justificar a decisão. A LGPD (Lei 13.709/2018), em seu Art. 20, assegura ao titular o direito de solicitar a revisão de decisões tomadas exclusivamente com base em tratamento automatizado, o que torna modelos interpretáveis especialmente valiosos nesse domínio.

É exatamente esse o apelo da árvore de decisão: o modelo aprendido pode ser lido como um conjunto de regras de produção, uma explicação que um analista, um cliente ou um auditor consegue compreender sem conhecimento de estatística. No Brasil, iniciativas como o Cadastro Positivo, o Open Finance e programas de microcrédito produtivo orientado como o Crediamigo, do Banco do Nordeste, dependem de avaliações de risco em larga escala, tornando o problema próximo da nossa realidade.

Neste projeto, você é convidado a construir um modelo de classificação de solicitantes de crédito em duas categorias de risco (bom pagador e mau pagador) a partir de dados cadastrais e financeiros, utilizando uma Árvore de Decisão (*Decision Tree*).

O projeto utiliza o arquivo `german.data` do *dataset* Statlog (German Credit Data) (`https://archive.ics.uci.edu/dataset/144/statlog+german+credit+data`). O *dataset* foi doado por Hans Hofmann (Universidade de Hamburgo, Alemanha) em 1994 e reúne 1.000 solicitações de crédito reais de um banco alemão. Cada amostra é descrita por 20 atributos: 7 numéricos e 13 categóricos. Entre os atributos, temos duração do empréstimo em meses, valor solicitado, histórico de crédito, finalidade do empréstimo, saldo em conta corrente, tempo de emprego atual, idade, número de créditos ativos e existência de garantias. O rótulo indica se o cliente representou, de fato, um bom risco (700 amostras) ou um mau risco (300 amostras) de crédito.

Observação: os atributos categóricos do arquivo `german.data` aparecem codificados (`A11`, `A12`, ...), com o significado de cada código descrito no arquivo `german.doc`. Alternativamente, a versão com rótulos legíveis pode ser obtida diretamente via:

`sklearn.datasets.fetch_openml(name='credit-g', version=1)`.

Realize as seguintes tarefas utilizando o *dataset* fornecido:

1. Preparação dos dados: carregue o *dataset*, identifique quais atributos são numéricos e quais são categóricos. Verifique se existe necessidade de codificação adequada às variáveis categóricas (*one-hot encoding* ou *ordinal*

encoding). Avalie o balanceamento entre as classes e comente o impacto de um conjunto desbalanceado (70%/30%) sobre a interpretação da acurácia.

2. Justifique por que a normalização dos atributos não é necessária para uma árvore de decisão.
3. Divisão treino/teste: divida os dados em 80% para treino e 20% para teste, utilizando divisão estratificada para garantir que a proporção das duas classes seja mantida em ambos os conjuntos.
4. Treinamento e controle de complexidade: treine árvores com diferentes valores de profundidade máxima (ex: 2, 3, 5, 7, 10 e sem limite), utilizando validação cruzada de 5 *folds* sobre o conjunto de treino. Plote, em um mesmo gráfico, a acurácia média de treino e a de validação em função da profundidade, e escolha o valor com melhor desempenho. O que acontece com o modelo para profundidades muito baixas e muito altas? Relacione sua resposta aos conceitos de *underfitting* e *overfitting*. Repita o experimento trocando o critério de divisão dos nós de Gini para entropia e comente se houve diferença relevante.
5. Interpretação do modelo: usando a árvore com a profundidade escolhida, gere a visualização gráfica da árvore e a lista de importância dos atributos. Responda: quais são os três atributos mais determinantes para a classificação? Escreva, em linguagem natural, o conjunto de regras correspondente ao caminho que leva da raiz até a folha com maior número de amostras de mau risco.
6. Avaliação do modelo: utilizando o conjunto de teste, calcule a matriz de confusão e as métricas de acurácia, precisão, *recall* e F1-score para cada classe. Responda: qual tipo de erro o modelo comete com mais frequência e por que ele é o mais grave nesta aplicação? Que ajuste você faria no treinamento para reduzi-lo?

Problema 5 – Segmentação de Clientes Utilizando k-*Means*

Um distribuidor atacadista atende, ao mesmo tempo, clientes muito diferentes entre si: o restaurante que compra hortifrúti e congelados em alto giro, o pequeno mercado de bairro que se abastece de mercearia, laticínios e produtos de limpeza, entre outros. Tratar todos eles com a mesma política comercial é, na prática, desperdiçar margem e capacidade logística.

A segmentação de clientes tem aplicações diretas no planejamento de rotas e estoques, na definição de campanhas promocionais dirigidas, na concessão de limites de crédito e na identificação de clientes atípicos, que merecem atendimento dedicado. No Brasil, o crescimento do modelo de atacarejo e a importância dos distribuidores regionais no abastecimento do interior do Nordest, tornam o problema especialmente concreto para a nossa realidade.

Este projeto tem uma característica que o distingue dos anteriores: não existe um rótulo a ser previsto. Ninguém classificou previamente os clientes em "perfil restaurante" ou "perfil varejo', se esses grupos existem, eles precisam emergir da própria estrutura dos gastos. É o domínio do aprendizado não supervisionado.

Neste projeto, você é convidado a identificar perfis de consumo de clientes de um distribuidor atacadista por meio do algoritmo de agrupamento *k-Means*.

O projeto utiliza o arquivo `Wholesale customers data.csv` do *dataset* Wholesale Customers (`https://archive.ics.uci.edu/dataset/292/wholesale+customers`). O *dataset* foi doado por Margarida G. M. S. Cardoso (ISCTE-IUL, Lisboa, Portugal) em 2014 e reúne 440 clientes de um distribuidor atacadista português. Para cada cliente são registrados os gastos anuais, em unidades monetárias, em seis categorias de produto — `Fresh` (frescos), `Milk` (laticínios), `Grocery` (mercearia), `Frozen` (congelados), `Detergents_Paper` (detergentes e papel) e `Delicassen` (delicatessen) — além de dois atributos categóricos: `Channel`, indicando se o cliente pertence ao canal *Horeca* (hotéis, restaurantes e cafés, 298 clientes) ou *Retail* (varejo, 142 clientes), e `Region`, indicando sua localização (Lisboa, Porto ou outras regiões).

Observação: os atributos `Channel` e `Region` **não** devem ser utilizados no agrupamento. Eles serão reservados para a validação externa da tarefa 5. O agrupamento deve basear-se exclusivamente nas seis categorias de gasto.

Realize as seguintes tarefas utilizando o *dataset* fornecido:

1. Preparação dos dados: carregue o *dataset* e separe `Channel` e `Region` do restante. Para cada uma das seis categorias de gasto, calcule média, mediana, desvio padrão e valores extremos, e construa um *boxplot* ou histograma. Você observará distribuições fortemente assimétricas à direita, com poucos clientes de gasto muito elevado — em `Fresh`, por exemplo, os valores vão de dezenas a mais de cem mil unidades monetárias. Aplique então a transformação logarítmica $x' = \log(1 + x)$ e, em seguida, padronize os atributos por *Z-score*.

Justifique as duas etapas separadamente: (a) por que a transformação logarítmica é recomendável diante da assimetria e da presença de *outliers*, e (b) por que a padronização é determinante para o *k-Means*, relacionando sua resposta ao uso da distância euclidiana na atribuição dos pontos aos centróides. Calcule também a matriz de correlação entre as seis categorias e comente o par `Grocery`–`Detergents_Paper`.

2. Ausência de divisão treino/teste: diferentemente dos projetos anteriores, aqui **não** se separa um conjunto de teste. Explique por quê, contrastando o objetivo do aprendizado supervisionado (estimar o erro de generalização sobre rótulos conhecidos) com o do não supervisionado. Discuta, então, qual é a dificuldade central da validação em agrupamento: como afirmar que uma partição é "boa" sem dispor de um gabarito?

3. Escolha do número de grupos: execute o *k-Means* para k variando de 2 a 10. Plote a inércia (soma dos quadrados intra-cluster) em função de k e aplique o método do cotovelo; em seguida, plote o coeficiente de silhueta médio em função de k. Escolha o valor de k justificando sua decisão à luz dos dois critérios e da interpretabilidade comercial dos grupos resultantes — um segmento só é útil se a área comercial souber o que fazer com ele. Responda: por que a inércia decresce monotonicamente com k e por que, portanto, ela não pode ser usada isoladamente como critério de escolha? O que ocorre no caso limite em que k é igual ao número de amostras?

4. Inicialização e convergência: o *k-Means* converge para um mínimo local, e não necessariamente global. Execute o algoritmo dez vezes com `init='random'` e `n_init=1`, usando sementes distintas, e registre a inércia final de cada execução. Repita o procedimento com `init='k-means++'`. Compare a dispersão dos resultados nos dois casos e explique qual problema a inicialização *k-means*++ busca mitigar e de que forma.

5. Interpretação e validação dos grupos: com o k escolhido, recupere os centróides, reverta-os para a escala original de gasto (desfazendo a padronização e a transformação logarítmica) e apresente-os em uma tabela e em um gráfico de barras agrupadas por categoria. Atribua a cada agrupamento um nome descritivo de natureza comercial, baseado nas categorias em que ele se destaca. Em seguida, realize uma validação externa: construa tabelas de contingência cruzando o agrupamento de cada cliente com `Channel` e com `Region`, e calcule o índice Rand ajustado (*Adjusted Rand Index*) entre a partição obtida e a variável `Channel`. Responda: o algoritmo, sem jamais ter visto o canal de venda, foi capaz de reconstruí-lo? Qual conjunto de categorias de produto mais separa *Horeca* de *Retail*? E a região geográfica — ela se reflete nos agrupamentos? Por fim, projete os dados em duas dimensões por PCA, colorindo os pontos por agrupamento, e discuta duas limitações do *k-Means* evidenciadas nesse gráfico: a tendência a formar grupos de geometria esférica e de tamanhos semelhantes e a sensibilidade a *outliers*.