

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR PAU DOS FERROS
CURSO DE ENGENHARIA DE COMPUTAÇÃO

PAM0466 – SISTEMAS INTELIGENTES

kNN (k-Nearest Neighbor)

Prof. Dr. Pedro Thiago Valério de Souza
pedro.souza@ufersa.edu.br

Semestre de 2026.1

Conceitos Fundamentais

- Algoritmo de classificação baseado no vizinho mais próximo (*Nearest Neighbor* – NN);
- Proposto por Fukunaga e Narendra em 1975;
- Expansão do algoritmo *Nearest Neighbor*, proposto por Cover e Hart em 1966;
- Técnica amplamente empregada na tarefa de reconhecer padrões, mas pode ser utilizada para regressão;
- Consiste em uma técnica de aprendizado supervisionado;
- Diferentemente de algoritmos como regressão logística, o k-NN *não constrói um modelo durante o treinamento*. Ele simplesmente *memoriza* os dados de treino;
- Todo o trabalho computacional acontece na hora da predição.

Conceitos Fundamentais

- Principais vantagens:
 - É um dos métodos de classificação mais simples de ser implementado;
 - Possui uma fácil compreensão;
 - Possui bons resultados em determinadas aplicações;
 - O k-NN pode ser usado tanto para classificação quanto para regressão.
 - Pode lidar com múltiplas classes de forma natural;
 - Não faz nenhuma suposição sobre os dados (como, por exemplo, a regressão linear).

Conceitos Fundamentais


- Principais desvantagens:
 - Pode não ser útil quando a relação entre as variáveis de entrada não é tão simples;
 - É sensível a sua parametrização;
 - A precisão da classificação pode ser severamente degradada pela presença de ruído;
 - Quando o conjunto de treinamento é composto por várias amostras, o algoritmo pode:
 - Exigir muita memória do dispositivo;
 - Ser lento;

Princípio de Funcionamento

- Classificar uma amostra nova baseado nas amostras vizinhas (advindas de um conjunto de treinamento);
- Utiliza-se k vizinhos mais próximos da amostra a ser classificada;
- O k-NN funciona atribuindo à amostra a ser classificada à classe representada mais frequentemente dentre as k amostras mais próximas;
 - A variável k representa a quantidade de vizinhos a serem averiguados.

Princípio de Funcionamento

- Exemplo de funcionamento ($k = 7$):
 - Como existem mais vizinhos da classe A, a nova amostra receberá a mesma classe deles, ou seja, A;



Princípio de Funcionamento

- Condições necessárias para utilização do k-NN:
 - Um conjunto de exemplos de treinamento (entrada/saída desejada);
 - Definir uma métrica para calcular a distância entre os exemplos de treinamento;
 - Definir o valor de k (o número de vizinhos mais próximos que serão considerados pelo algoritmo);
- Como todo processo de treinamento supervisionado, o k-NN consiste em duas fase: treinamento e classificação;

Princípio de Funcionamento

- **Fase de treinamento:**

- Armazenamento simples;
 - Consiste em armazenar toda a base de treinamento TR em uma memória do k-NN ($TR^n = \{X^{(1)}, \dots, X^{(n)}\}$);
- Um padrão X qualquer possui duas características: um vetor de valores e um vetor de classes.
 - Vetor de valores: Armazena as características;
 - Vetor de classe: Armazena a qual classe o padrão pertence;

Princípio de Funcionamento

- **Fase de treinamento:**

- Observação: Requisito de memória no k-NN;
- Embora simples, o k-NN geralmente exige mais memória do que uma regressão logística;
 - Treinamento da regressão logística: Conhecimento armazenado nos parâmetros do modelo;
 - Treinamento do k-NN: Conhecimento armazenado de forma pura;

Princípio de Funcionamento

- **Fase de classificação:**

- Consiste em três etapas fundamentais:

- Calcular a distância entre a amostra a ser classificada e o outros exemplos do conjunto de treinamento;
 - Identificar os k vizinhos mais próximos;
 - Utilizar o rotulo da classe dos vizinhos mais próximos para determinar a classe da amostra a ser classificada.

Princípio de Funcionamento

- **Fase de classificação:**

- Pseudo-código para a fase de classificação:

algoritmo kNN_classificação(base_de_treinamento, novo_ponto, k):

1. Para cada ponto x_i no conjunto de treino:
 - a. Calcular distância $d(x_i, \text{novo_ponto})$;
2. Ordenar as distâncias em ordem crescente;
3. Selecionar os k pontos com menores distâncias;
4. Contar os votos de cada classe entre os k vizinhos;
5. Retornar a classe com mais votos (maioria simples).

Princípio de Funcionamento

- **Fase de classificação:**

- As principais métricas de distância são:

- Distância de Minkowski;
 - Distância de Manhattan;
 - Distância Euclidiana;
 - Distância de Chebyshev;

Parametrização do kNN

- **Fase de classificação:**

- Distância de Minkowski:

- Valor de métrica expressa por uma norma:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt[p]{|x_1 - y_1|^p + |x_2 - y_2|^p + \dots + |x_n - y_n|^p}$$

em que $\mathbf{x} = (x_1, x_2, \dots, x_n)$ e $\mathbf{y} = (y_1, y_2, \dots, y_n)$ são dois objetos n -dimensional e p é um inteiro positivo;

Princípio de Funcionamento

- **Fase de classificação:**

- Distância de Manhattan (*City-Block*):

- Caso especial da distância de Minkowski para $p = 1$:

$$d(\mathbf{x}, \mathbf{y}) = |x_1 - y_1|^p + |x_2 - y_2|^p + \cdots + |x_n - y_n|^p$$

- Distância de Euclidiana:

- Caso especial da distância de Minkowski para $p = 2$:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \cdots + (x_n - y_n)^2}$$

- Distância de Chebyshev:

- Caso especial da distância de Minkowski para $q \rightarrow \infty$:

$$d(\mathbf{x}, \mathbf{y}) = \max_i |x_i - y_i|$$

Princípio de Funcionamento

- **Fase de classificação:**

- **Resumo - Similaridades baseadas na distância de Minkowski:**
 - A distância euclidiana é calculada através de uma linha reta entre os pontos;
 - A distância Manhattan é calculada um quarteirão de cada vez;
 - A distância de Chebyshev é dada pela maior das duas dimensões da distância.

Princípio de Funcionamento

- **Fase de classificação:**

- Observação: Normalização dos atributos;
 - Na maioria das vezes os atributos precisam ser normalizados para evitar que as medidas de distância sejam dominado por um único atributo.
- Exemplos:
 - Altura pode variar de 1,20m a 2,10m.
 - Peso pode variar de 40 kg a 150 kg.
 - O salário pode variar de R\$ 800 a R\$20.000.

Princípio de Funcionamento

- **Determinação do valor k :**


- Varia de acordo com a base de dados;
- Recomendável sempre utilizar valores ímpares/primos (para não haver empate na votação);
- Pode utilizar validação cruzada para obter o melhor valor de k .

Parametrização do kNN

- **Determinação do valor k :**

- Influência do parâmetro k :

- $k = 1$: Pertence a classe de quadrados.
 - $k = 3$: Pertence a classe de triângulos.
 - $k = 7$: Pertence a classe de quadrados.



Parametrização do kNN

- **Determinação do valor k :**

- Influência do parâmetro k :

- Se k for muito pequeno, a classificação fica sensível a pontos de ruído;
 - Se k é muito grande, a vizinhança pode incluir elementos de outras classes;