


UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS (CMPF)
DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA (DETEC)

SISTEMAS INTELIGENTES

# Introdução ao Aprendizado de Máquina

Prof. Dr. Pedro Thiago Valério de Souza

pedro.souza@ufersa.edu.br

Semestre de 2026.1

# O que é Aprendizado de Máquina?

- Definições possíveis:
  - É a ciência da programação de computadores de modo que eles possam aprender com dados;
  - Alega-se que um programa de computador aprende pela experiência *E* em relação a alguma tarefa *T* e alguma medida de performance *P* se sua performance em *T*, conforme medida por *P*, melhora com a experiência *E* (Tom Mitchell, 1997);

# O que é Aprendizado de Máquina?

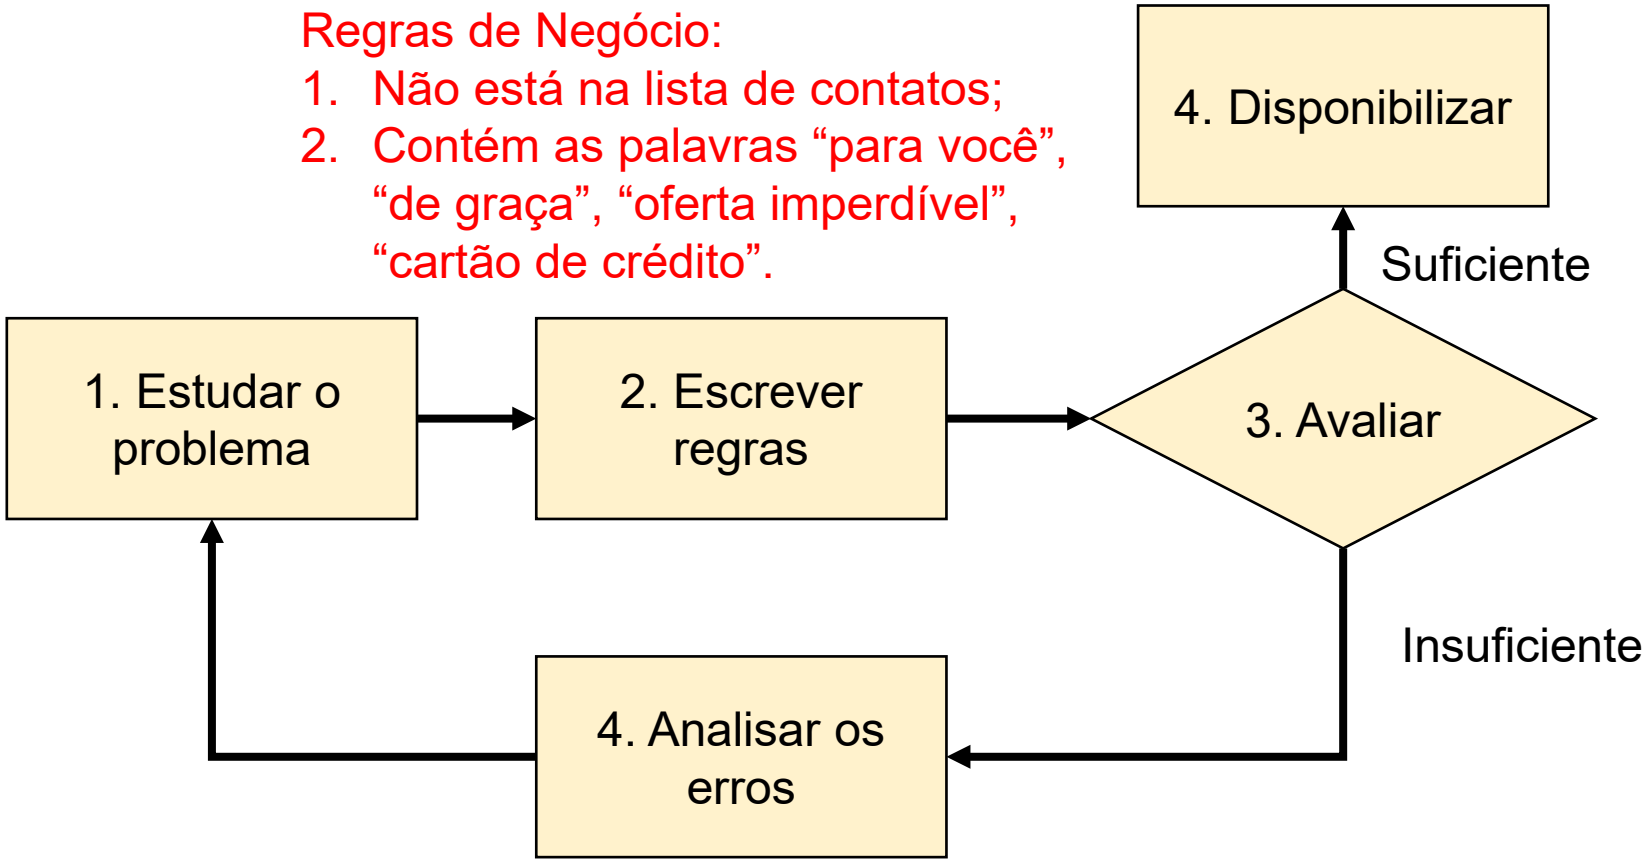
- Exemplo: Filtro de *spam* na caixa de *e-mail*;
  - Dados exemplos de *spam* e não-*spam* (marcados por usuários) pode aprender a identificar novos *spam*.
    - Experiência (*E*): exemplos de spam e não-spam;
    - Tarefa (*T*): marcar *spam*;
    - Performance (*P*): taxa de acerto na identificação de *spam* (acurácia);

# O que é Aprendizado de Máquina?

- Definições importantes:
  - Conjunto de treinamento: exemplos utilizados para o aprendizado;
  - Amostra de treinamento: cada exemplo de treinamento;
  - Modelo: algoritmo de aprendizado de máquina que faz as predições:
  - Treinamento: Processo de ajustar os parâmetros do modelo para realizar a aprendizagem;
- Os modelos devem ser capazes de fazerem generalizações, ou seja, fazer boas predições para exemplos que nunca viu antes;
- Os dados por si só não consiste em aprendizado de máquina!

# Por que usar Aprendizado de Máquina?

- Abordagem tradicional para identificação de *spam*:

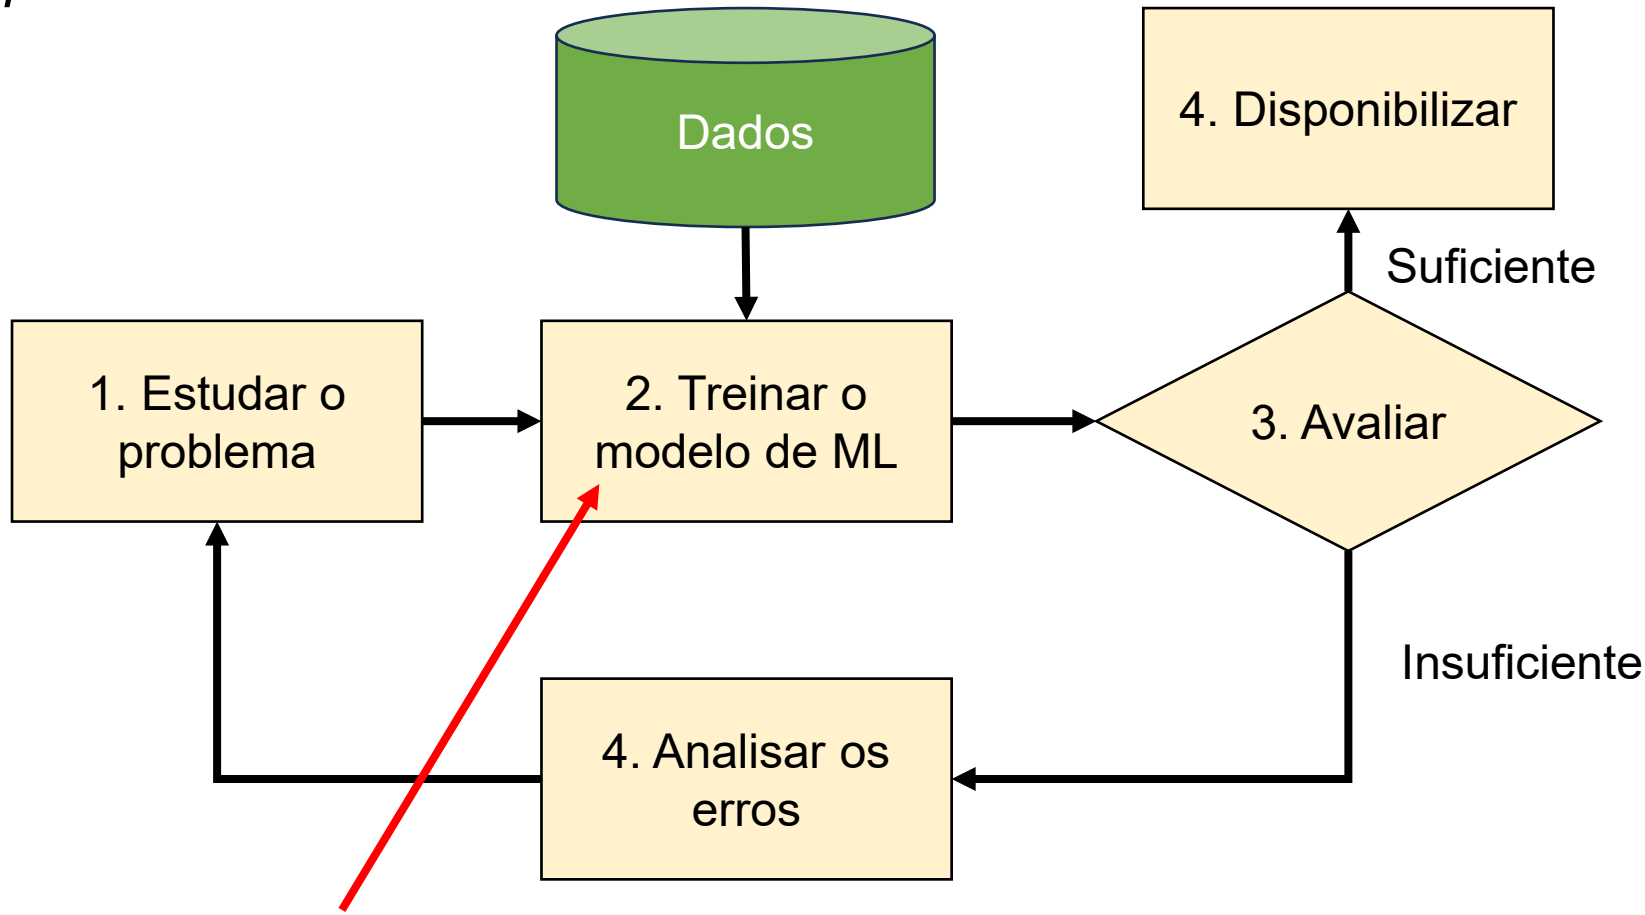


# Por que usar Aprendizado de Máquina?

- Problemas da abordagem tradicional:
  - Se o problema é difícil, existirá muitas regras de negócio;
    - Baixa manutenção;
  - É complicado de se adaptar às mudanças;
    - Baixa escalabilidade;
- Em contrapartida, utilizando aprendizado de máquina, o modelo é capaz de identificar as melhores regras de negócio;
  - Programa menor;
  - Melhor manutenção;

# Por que usar Aprendizado de Máquina?

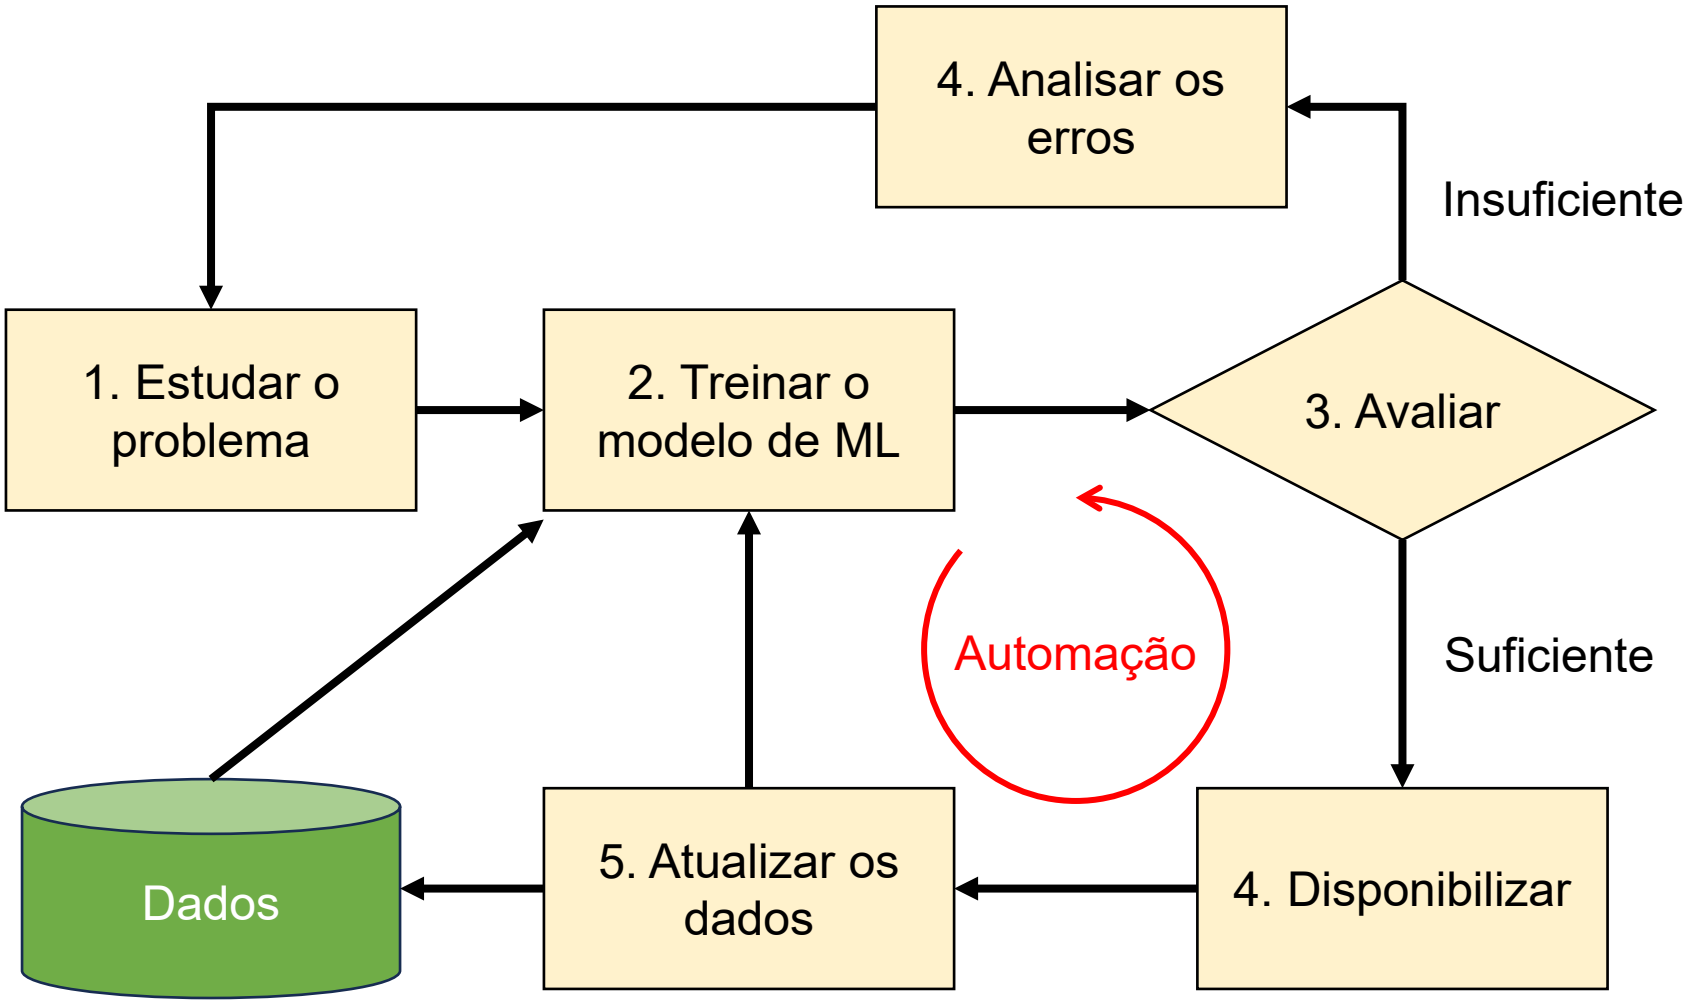
- Abordagem com aprendizado de máquina para identificação de *spam*:




*A IA é capaz de escrever as regras de negócio.*

# Por que usar Aprendizado de Máquina?

- Abordagem com aprendizado de máquina para identificação de *spam* + adaptação;



# Por que usar Aprendizado de Máquina?

- Outras aplicações de aprendizado de máquina:
  - Resolução de problemas complexos, no qual a criação de regras de negócio não é simples → identificação de voz;
  - Ajudar seres humanos a aprender a partir do modelo treinado;
    - Exemplo: analisar as regras de negócio geradas pelo identificador de *spams*;
    - Relacionado à área de mineração de dados;

# Exemplos de Aplicações

- Análise de imagens de produtos em uma linha de produção a fim de classificar-lós automaticamente;
- Detecção de tumores em exames de imagens cerebrais;
- Classificação automática de artigos de notícias;
- Sinalização automática de conteúdos ofensivos ou impróprios na *internet*;
- Resumo automático de documentos extensos;
- Criação de *chatbox* ou um assistente pessoal;

# Exemplos de Aplicações

- Previsão do faturamento de uma empresa no próximo ano fiscal baseado em métricas de desempenho;
- Detecção de fraudes em cartões de crédito;
- Segmentação de clientes com bases em suas compras, de forma que possa elaborar um plano estratégico de publicidade direcionada;
- Representação de um conjunto de dados complexo e de alta dimensão em um diagrama claro;
- *Bots* inteligentes em jogos eletrônicos.

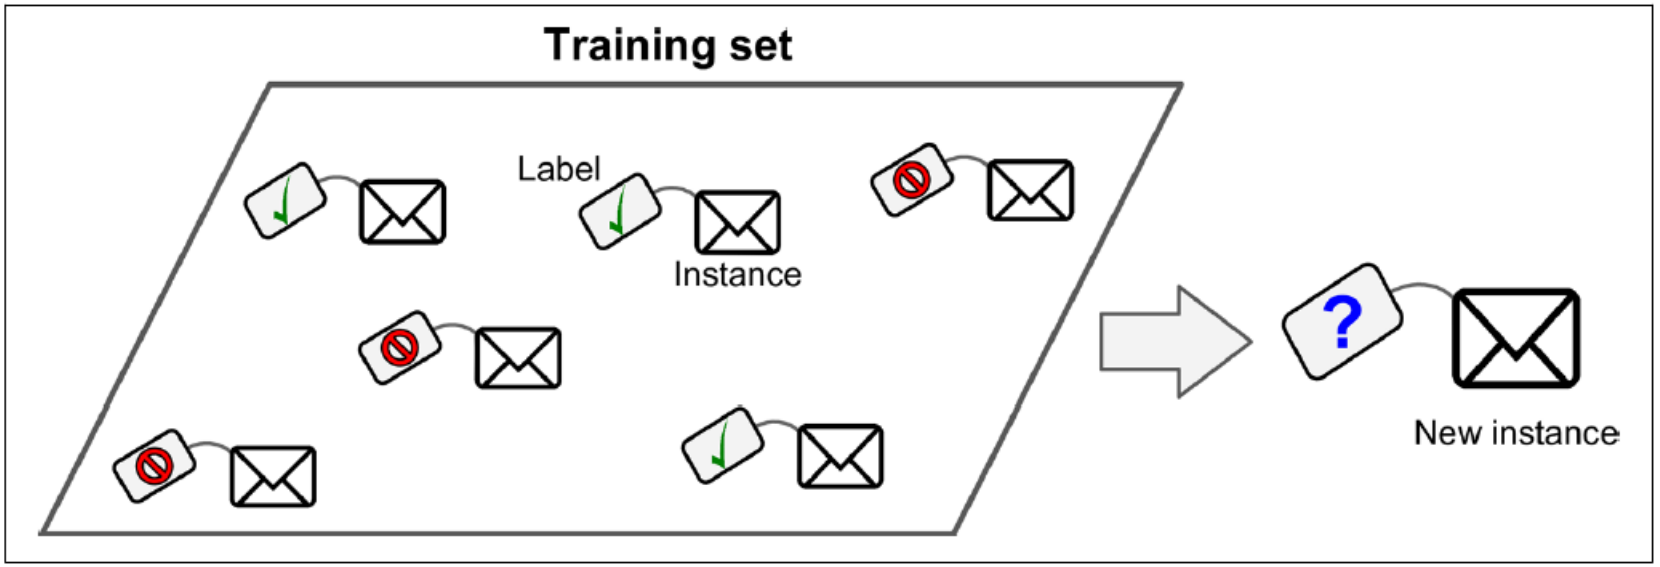
# Supervisão de Treinamento

- Aprendizado supervisionado;
- Aprendizado não supervisionado;
- Aprendizado semisupervisionado;
- Aprendizado por reforço.

# Supervisão de Treinamento

**Treinamento supervisionado:**

- O conjunto de treinamento é rotulado, ou seja, o conjunto de treinamento possui os exemplos e as respostas desejadas.
- Exemplo: conjunto de treinamento para identificação de *spam*;



# Supervisão de Treinamento

**Treinamento supervisionado:**

- Tarefas típicas:
  - Classificação;
  - Regressão: prevê um valor numérico (por exemplo, valor de um carro), a partir de características (motor, lugares, tamanho, etc.)



# Supervisão de Treinamento

**Treinamento supervisionado:**

- Exemplos de algoritmos:
  - *k-Nearest Neighbors* (kNN);
  - Regressão linear;
  - Regressão logística;
  - Máquinas de vetor de suporte (SVM);
  - Árvores de decisão;
  - Redes Neurais.

# Supervisão de Treinamento

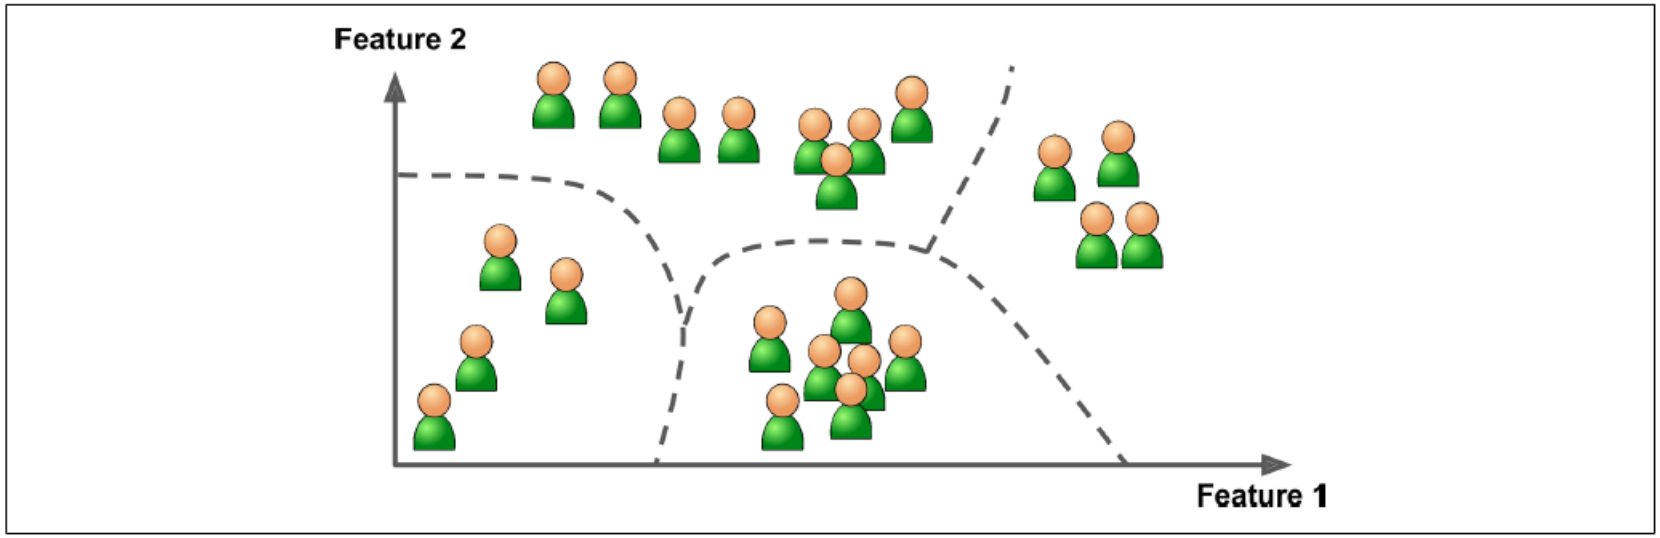
**Treinamento não supervisionado:**

- Os dados de treinamento não são rotulados;
- Tipos de treinamentos não supervisionados:
  - Algoritmos de agrupamento;
  - Algoritmos de visualização;
  - Redução de dimensionalidade;
  - Detecção de anomalias ou novidade.

# Supervisão de Treinamento

**Treinamento não supervisionado:**

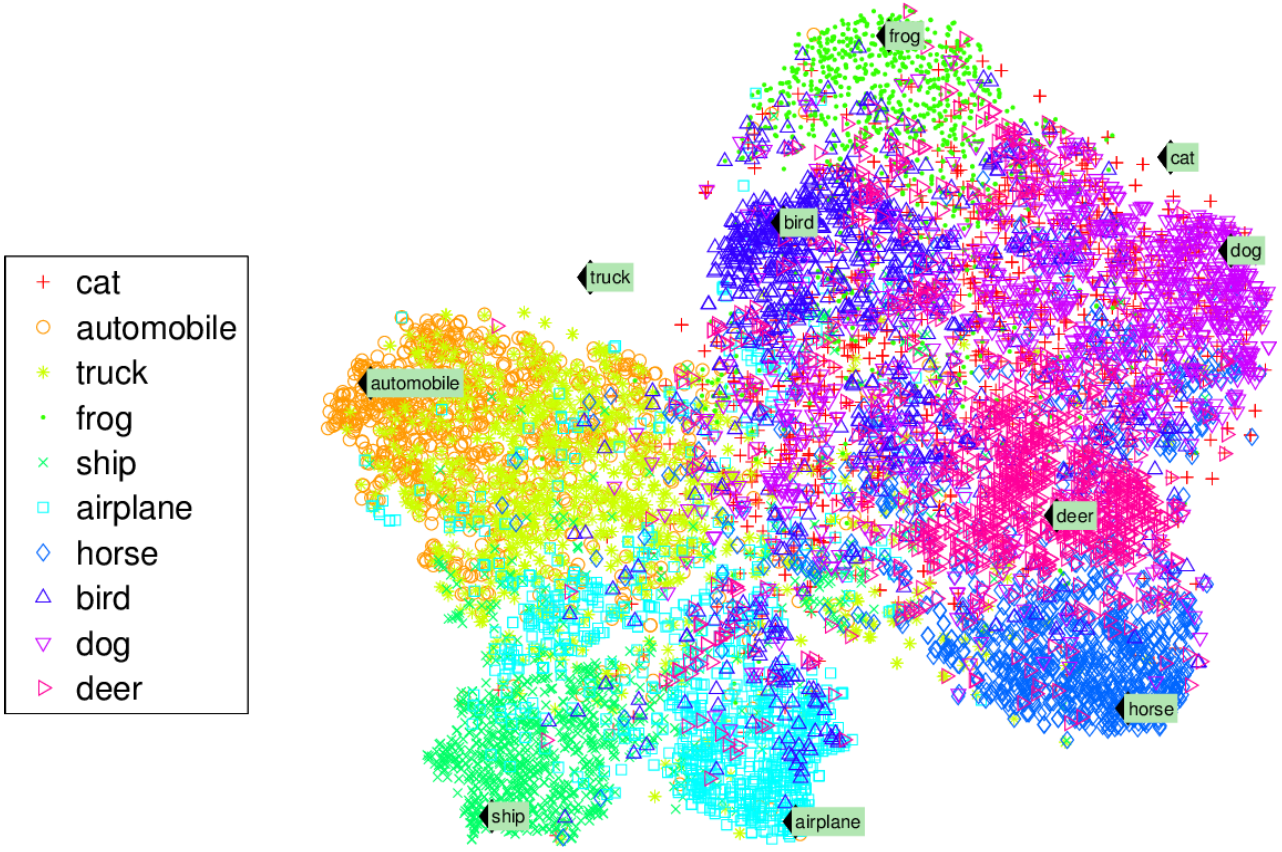
- Algoritmos de agrupamento: O algoritmo tende a organizar os dados de entrada em subconjuntos (*cluters*) a partir das particularidades existentes no conjunto de entrada;
  - Exemplo: agrupamento de clientes em uma rede social;



# Supervisão de Treinamento

## Treinamento não supervisionado:

- Algoritmos de visualização: permitem que dados que dependam de muitas variáveis sejam visualizados em uma representação 2D ou 3D em que os dados apareçam de forma separadas;



# Supervisão de Treinamento

**Treinamento não supervisionado:**

- Redução de dimensionalidade: simplificar os dados sem perder muita informação;
  - Mesclam diversas características em uma só, que está correlacionada;
    - Exemplo: quilometragem do carro e tempo de uso;
  - Podem ser utilizados como uma etapa de processamento antes de aplicar os dados em um algoritmo de aprendizado de máquina;

# Supervisão de Treinamento

**Treinamento não supervisionado:**

- Detecção de anomalia (ou novidade): identifica se um novo dado é diferente de um conjunto de dados ditos “normais”;
  - Exemplo: identificação de transação fraudulenta em cartões de crédito;
  - Pode ser utilizado para “limpar” o conjunto de treinamento antes de aplicar em outro algoritmo de aprendizado de máquina.

# Supervisão de Treinamento

**Treinamento não supervisionado:**

- Exemplos de algoritmos:
  - Algoritmos de agrupamento:
    - *k-means*;
    - DBSCAN;
  - Detecção de anomalias:
    - SVM de uma classe;
    - *Isolation Forest*;
  - Redução de dimensionalidade e visualização:
    - Análise de componentes principais (PCA);
    - *t-Distributed Stochastic Neighbor Embedding* (t-SNE).

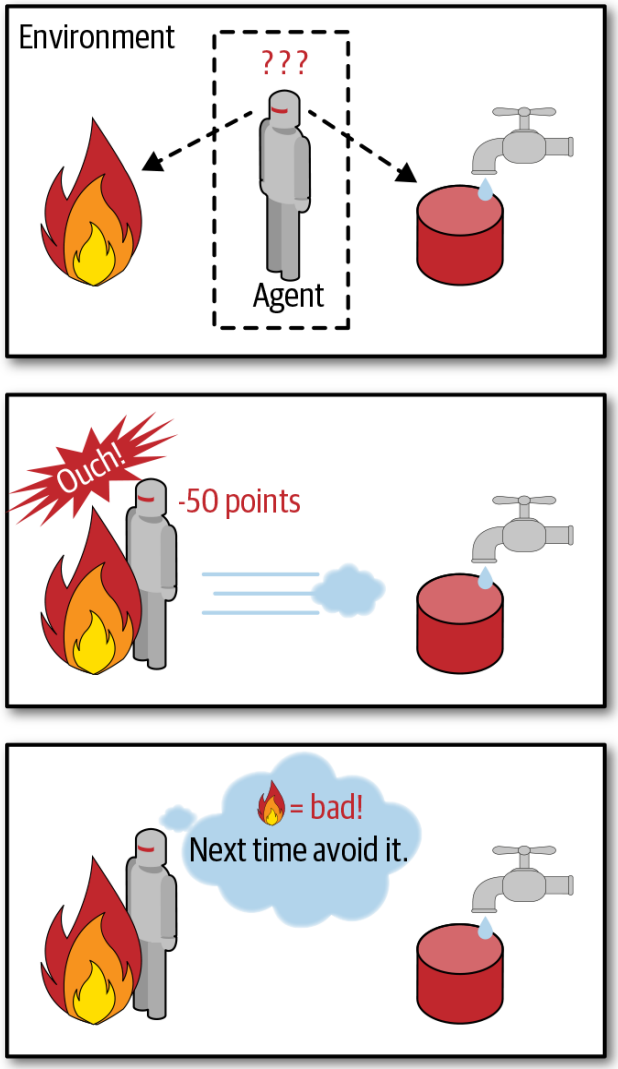
# Supervisão de Treinamento

**Aprendizado por reforço:**

- O sistema de aprendizado, chamado de agente, pode observar o ambiente e executar ações, obtendo recompensas (ou penalidades) em troca;
- Aprende a melhor política através dessas recompensas ao longo do tempo;
- Exemplos:
  - Movimentação de robôs;
  - Algoritmos de jogos → AlphaGo.

# Supervisão de Treinamento

## Aprendizado por reforço:




1. Observe
2. Select action using policy
3. Action!
4. Get reward or penalty
5. Update policy (learning step)
6. Iterate until an optimal policy is found

# Supervisão de Treinamento

**Aprendizado semisupervisionado:**

- São algoritmos que trabalham com dados parcialmente rotulados;
- Exemplo: Google Fotos;
  - Fazer upload de fotos de família;
  - O sistema irá fazer o agrupamento de fotos com pessoas semelhantes (e.x. a pessoa A aparece nas fotos 1, 5 e 11 e a pessoa B aparece nas fotos 4, 6 e 7);
    - Etapa não supervisionada;
  - Após isso, o usuário identificar as pessoas (dá rótulos) e o sistema é capaz de identificar a pessoa em novas fotos;

# Aprendizado em *Batch* vs *On-line*

**Aprendizado em *Batch*:**

- O algoritmo é treinado utilizando todos os dados do conjunto de treinamento;
- Após treinado, o sistema é posto em produção;
- Demanda muito tempo e recursos computacionais, de forma que a etapa de treinamento é realizada *off-line*;
- Após posto em produção, o sistema não aprende mais nada – utiliza apenas o conhecimento adquirido no treinamento;

# Aprendizado em *Batch* vs *On-line*

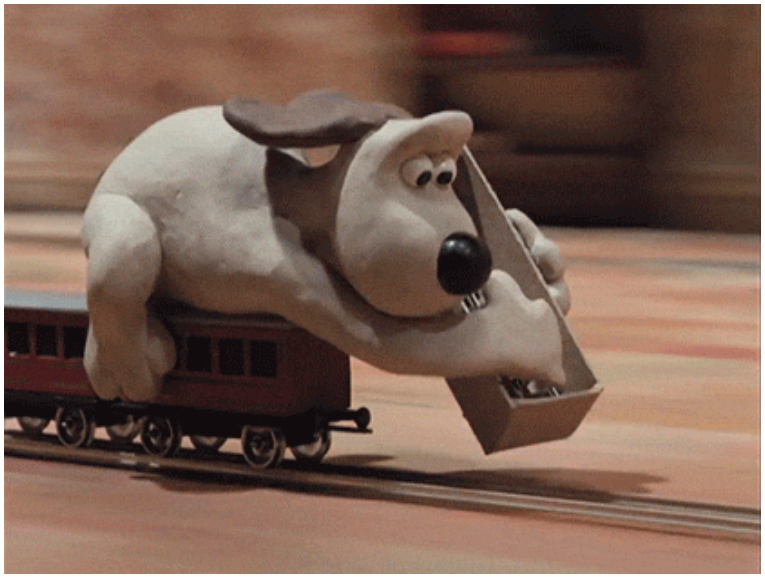
**Aprendizado em *Batch*:**

- Degradação do modelo: após algum tempo, existe a possibilidade do algoritmo perder performance;
  - Requer o retreinamento do algoritmo;
  - O retreinamento é feito com todos os dados, sejam os novos como os antigos;
  - Existem ferramentas para automação dessa tarefa;
  - O retreinamento pode demorar muito tempo!

# Aprendizado em *Batch* vs *On-line*

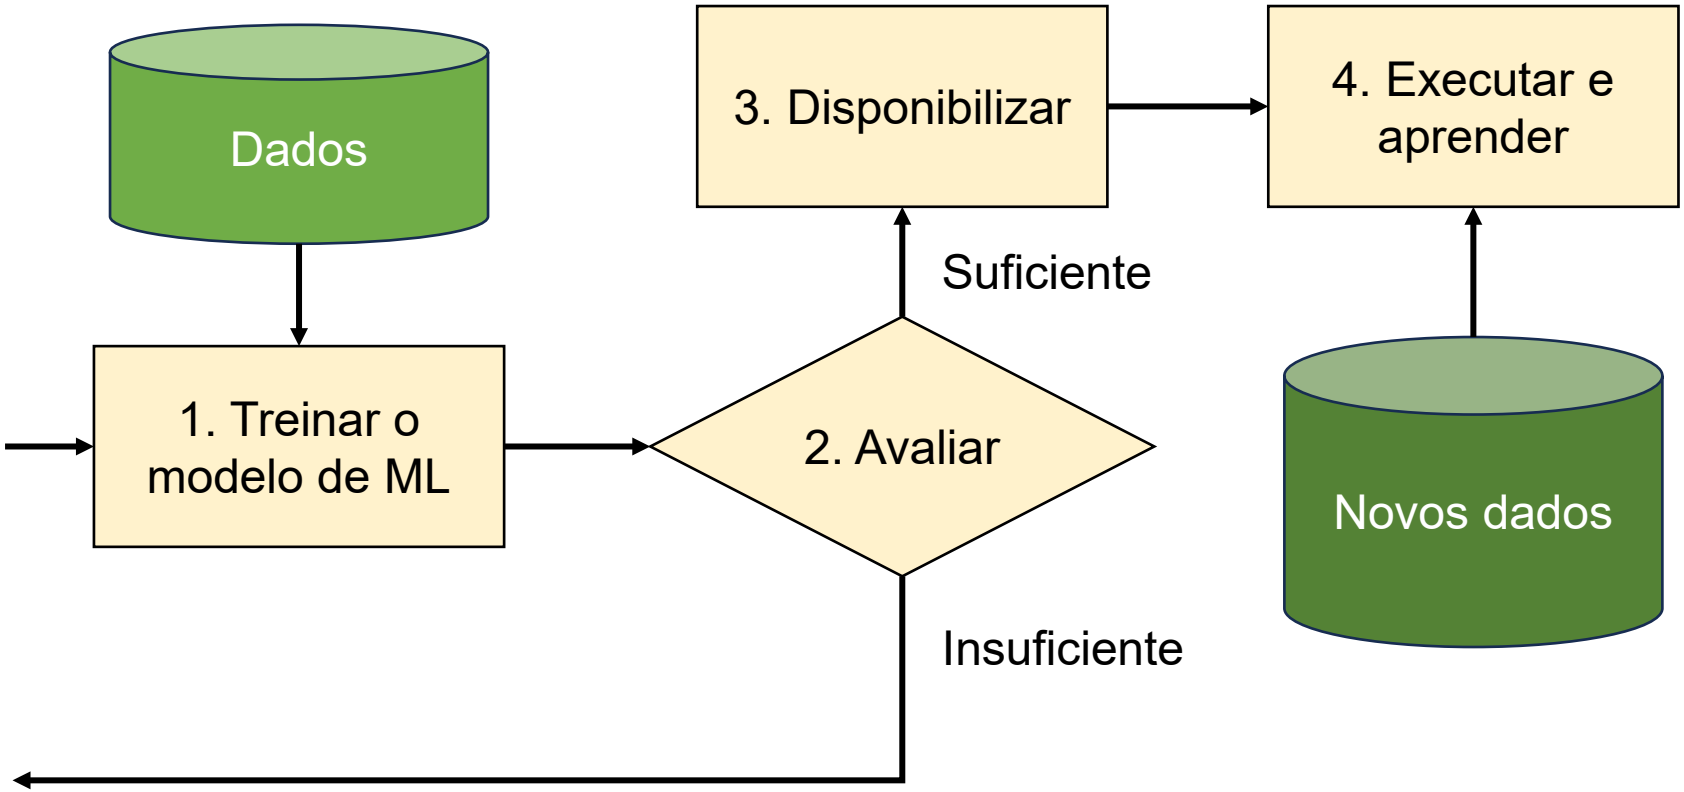
**Aprendizado *On-line*:**

- O algoritmo de IA aprende de forma incremental (passo-a-passo) – a medida que os dados “vão chegando” eles são utilizados para treinar o algoritmo;
  - Observação: o treinamento pode também utilizar pequenos grupos de dados, chamados de *mini-batches*;



# Aprendizado em *Batch* vs *On-line*

## Aprendizado *On-line*:



# Aprendizado em *Batch* vs *On-line*

**Aprendizado *On-line*:**

- Quando utilizar aprendizado *on-line*:
  - Dados que mudam rápido (*Concept Drift*);
  - Memória Limitada;
- Taxa de aprendizado: define o quão rápido um modelo é capaz de aprender com dados novos;
  - Valores altos: aprende rapidamente novos conhecimentos, esquece rapidamente os conhecimentos antigos;
    - Cuidado com dados novos que possam conter ruídos!
  - Valores baixos: aprende lentamente novos conhecimentos, esquece lentamente os conhecimentos antigos.

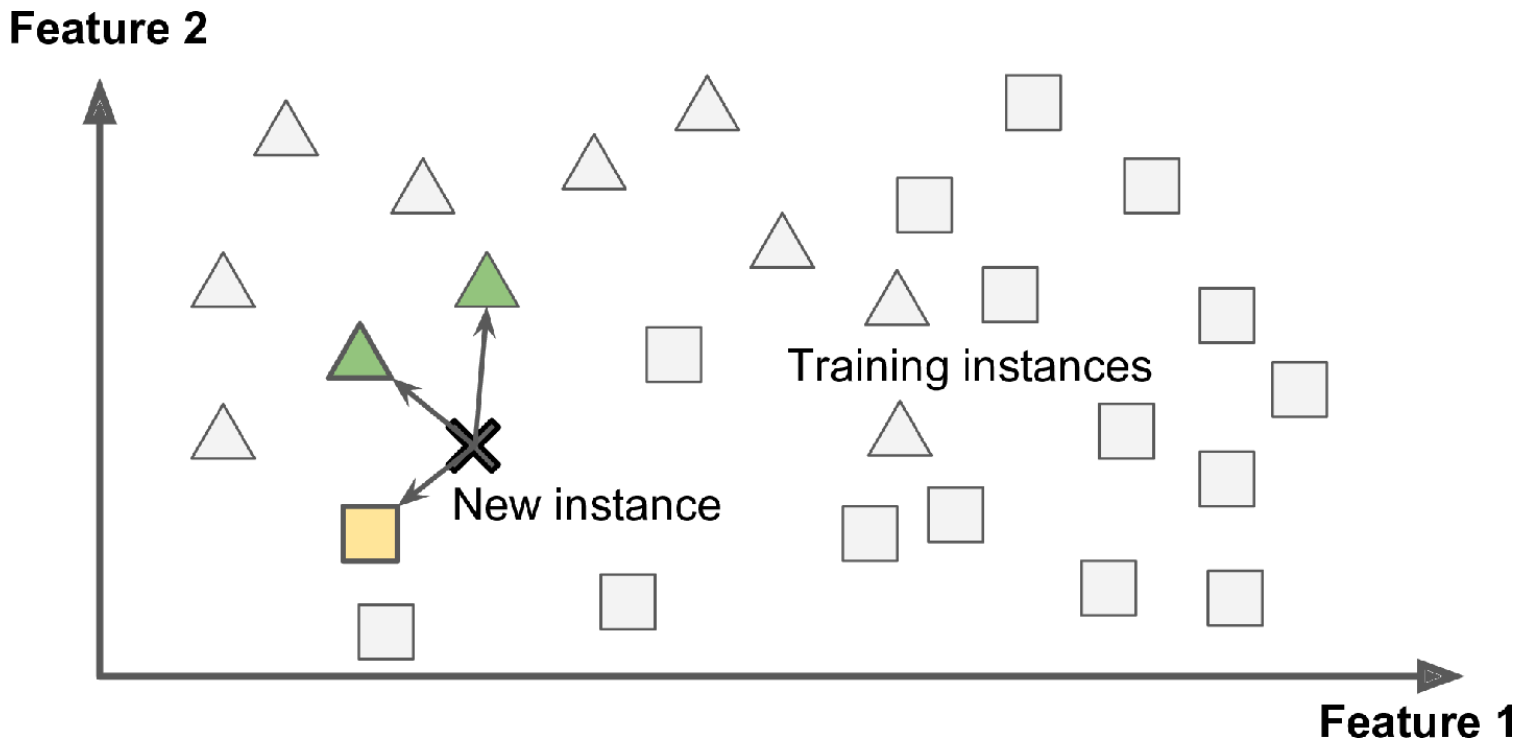
# Formas de Armazenamento do Conhecimento

- Aprendizado baseado em instância;
- Aprendizado baseado em modelo.

# Formas de Armazenamento do Conhecimento

**Aprendizado baseado em instância:**

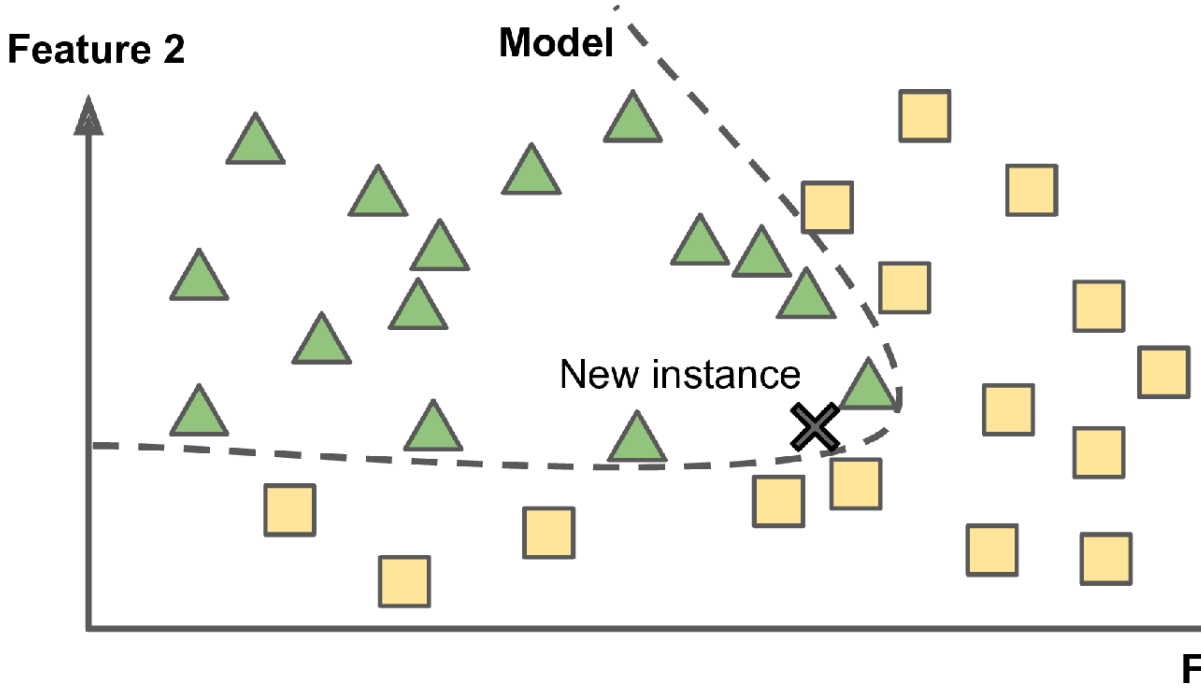
- Consiste em memorização;
- O sistema armazena a base de treinamento e utiliza uma medida de similaridade (distância) entre o dado novo e a base de treinamento;



# Formas de Armazenamento do Conhecimento

**Aprendizado baseado em modelo:**

- Ocorre a construção de um modelo matemático, gerado a partir dos exemplos;
- Após isso, o modelo é utilizado para prever novos resultados;
- O que é armazenado não são os exemplos, mas sim os parâmetros do modelo.

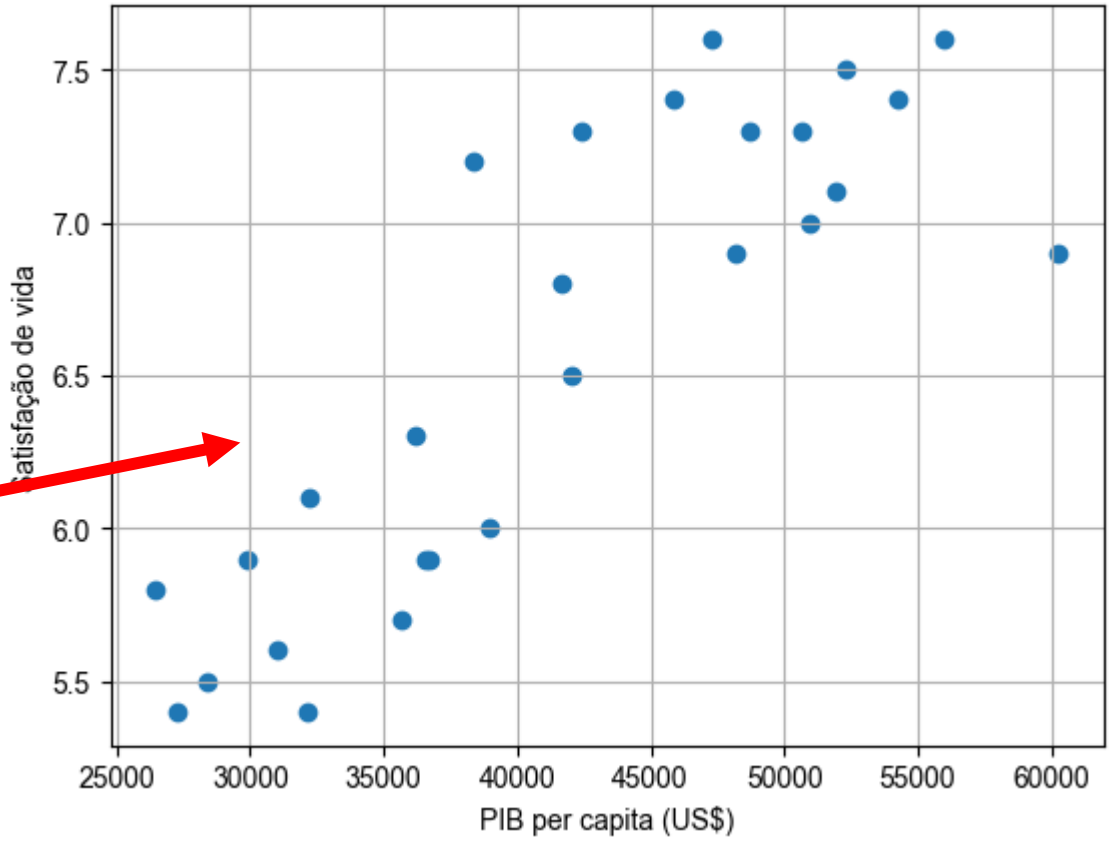


# Formas de Armazenamento do Conhecimento

## Aprendizado baseado em modelo:

- Exemplo: Nível de satisfação de vida × PIB

| Country | GDP per capita (USD) | Life satisfaction |
|---|---|---|
| Hungary | 12,240 | 4.9 |
| Korea | 27,195 | 5.8 |
| France | 37,675 | 6.5 |
| Australia | 50,962 | 7.3 |
| United States | 55,805 | 7.2 |




*Existe uma tendência de linearidade!*

# Formas de Armazenamento do Conhecimento

**Aprendizado baseado em modelo:**

- Exemplo: Nível de satisfação de vida × PIB
  - Seleção de um modelo: regressão linear.

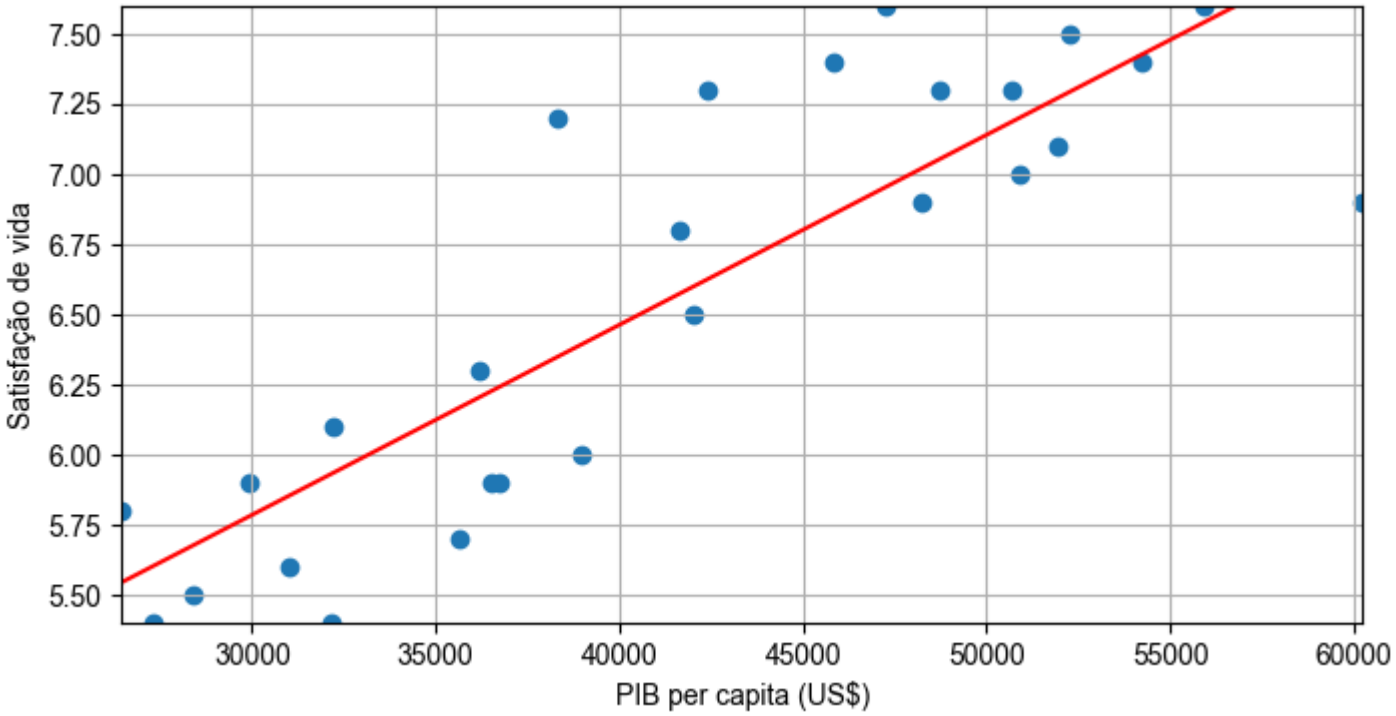
$$\text{satisfação de vida} = \theta_0 + \theta_1 \times \text{PIB}$$ ← *Parâmetros do modelo: $\theta_0$ e $\theta_1$*

  - O que é “salvo” são os parâmetros do modelo;
  - É necessário um método de ajuste dos parâmetros do modelo → treinamento;

# Formas de Armazenamento do Conhecimento

**Aprendizado baseado em modelo:**

- Exemplo: Nível de satisfação de vida × PIB.
  - No caso, o treinamento resulta em valores $\theta_0 = 3{,}75$ e $\theta_1 = 6{,}78 \times 10^{-5}$.




$$\text{satisfação de vida} = 3{,}75 + \left(6{,}78 \times 10^{-5}\right) \times \text{PIB}$$

# Formas de Armazenamento do Conhecimento

**Aprendizado baseado em modelo:**

- Exemplo: Nível de satisfação de vida × PIB.
  - Após isso, é possível prever o nível de satisfação de vida para novos valores.
  - Exemplo: Chipre → PIB US$ 32.655:

$$\begin{aligned}\text{satisfação de vida} &= 3,75 + \left(6,78 \times 10^{-5}\right) \times \text{PIB} \\ &= 3,75 + \left(6,78 \times 10^{-5}\right) \times 32655 \\ &= 6,30\end{aligned}$$

# Formas de Armazenamento do Conhecimento

**Aprendizado baseado em modelo:**

- Exemplo: Nível de satisfação de vida × PIB.
  - Etapas:
    - Estudo dos dados;
    - Seleção do modelo;
    - Treinamento do modelo;
    - Aplicação para novos dados.

# Principais Desafios do Aprendizado de Máquina

- Quantidade insuficiente de dados de treinamento;
- Dados de treinamento não representativos;
- Dados de baixa qualidade;
- Características irrelevantes;
- Sobreajuste dos dados de treinamento;
- Subajuste dos dados de treinamento;

# Principais Desafios do Aprendizado de Máquina

**Quantidade insuficiente de dados de treinamento:**

- É necessário uma quantidade boa de dados para que o algoritmo funcione perfeitamente;
- Em problemas complexos, a quantidade de dados é mais representativa do que o modelo (Peter Norvig et. al., 2009);

**Dados não representativos:**

- Os dados devem representar o problema perfeitamente;
- Exemplo: nível de satisfação vs. qualidade de vida.
  - Incluir países com PIB muito alto e muito baixo.

# Principais Desafios do Aprendizado de Máquina

**Dados com baixa qualidade:**

- Dados com erros, valores atípicos, ruídos ou informações faltantes → dificulta o processo de aprendizado;
- É necessário dedicar um tempo para trabalhar com os dados → engenharia de dados:
  - Eliminar valores atípicos (*outliers*);
  - Dados faltantes:
    - Ignorar as instâncias em que o dado está faltante;
    - Ignorar a característica faltante;
    - Preencher os valores ausentes;
    - Treinar um modelo com a característica faltante e outro sem.

# Principais Desafios do Aprendizado de Máquina

**Características irrelevantes:**

- Selecionar as melhores características para descrever o seu problema → engenharia de características:
  - Seleção de características;
  - Extração de características:
    - Combinar características existentes para criar uma nova (e.x. quilometragem + tempo de uso de um carro);
    - Utilizar transformações que mapeiam uma informação em outra (e.x. transformada de Fourier).

# Principais Desafios do Aprendizado de Máquina

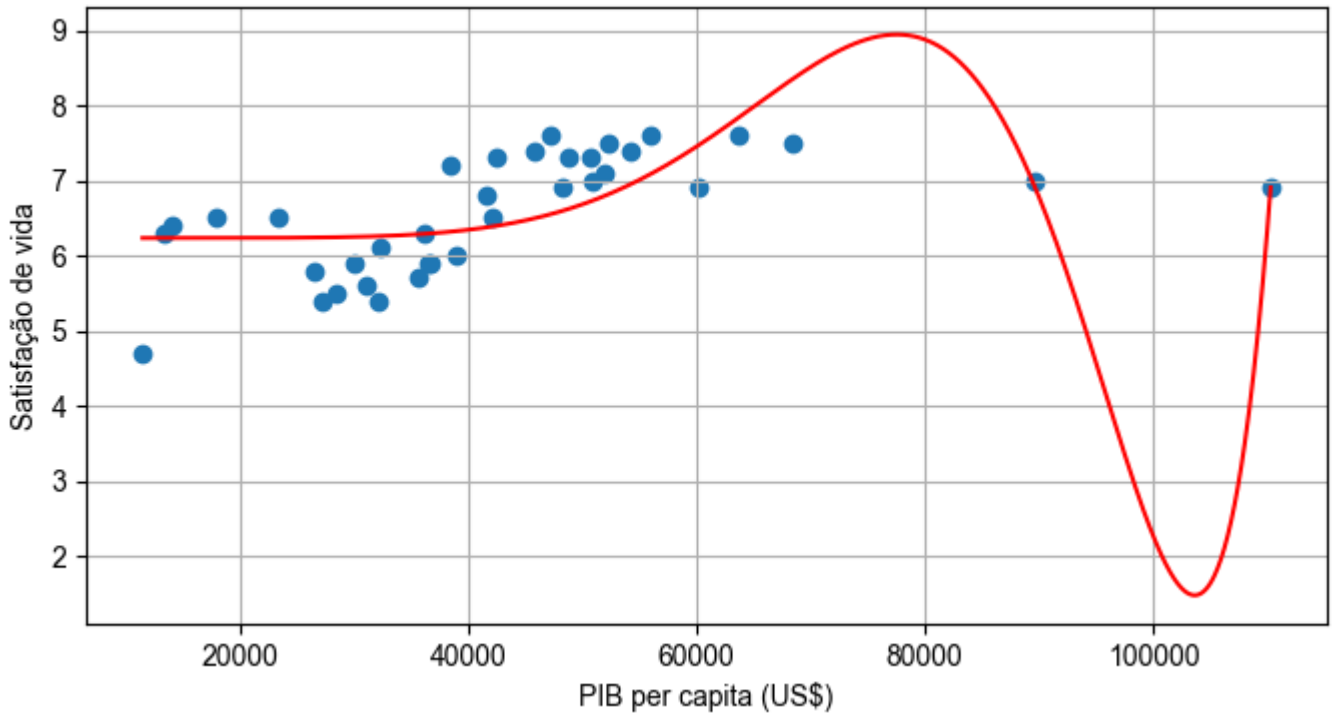
**Sobreajuste (*overfitting*) dos dados de treinamento:**

- Situação em que o algoritmo não realmente aprende, mas sim "decora" os exemplos de treinamento;
  - O modelo apresenta bom resultados para o conjunto de treinamento, mas não consegue generalizar a solução;

# Principais Desafios do Aprendizado de Máquina

**Sobreajuste (*overfitting*) dos dados de treinamento:**

- Exemplo: utilização de um modelo polinomial no problema de nível de satisfação vs. qualidade de vida.



# Principais Desafios do Aprendizado de Máquina

**Sobreajuste (*overfitting*) dos dados de treinamento:**

- Em um aprendizado sobreajustado, se os dados de treinamento possuírem ruído, o modelo tende a "aprender" esse ruído.
- Possíveis soluções:
  - Simplificar o modelo;
  - Coletar mais dados de treinamento;
  - Reduzir o ruído dos dados de treinamento.
- Regularização → método utilizado para simplificar o modelo e reduzir o risco de sobreajuste.
  - A quantidade de regularização é ajustada por um hiperparâmetro.

# Principais Desafios do Aprendizado de Máquina

**Observação – Parâmetro × Hiperparâmetro.**

- Parâmetro: valores do modelo que são ajustados através de alguma técnica de treinamento;
  - Não precisam ser especificados antes do treinamento;
- Hiperparâmetro: valores pré-definidos antes do treinamento;
  - Não é afetado pelo algoritmo de treinamento;
  - Devem permanecer constante durante todo o treinamento.

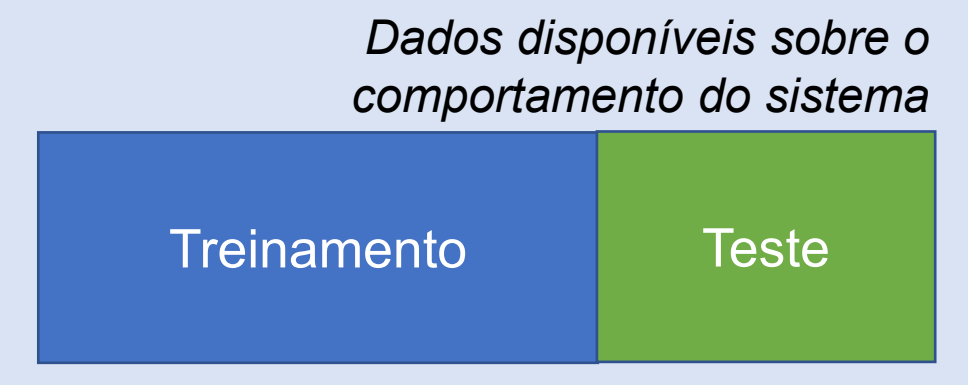
# Principais Desafios do Aprendizado de Máquina

**Subajuste (*underfitting*) dos dados de treinamento:**

- Oposto do sobreajuste: o modelo é simples demais para modelar o problema;
- Soluções:
  - Selecionar um modelo mais poderoso;
  - Utilizar dados com melhores características;
  - Minimizar as restrições do modelo (e.x. reduzindo o hiperparâmetro de regularização).

# Conjunto de Teste e Validação

- **Conjunto de teste:** dados utilizados para verificar a capacidade de generalização do modelo.



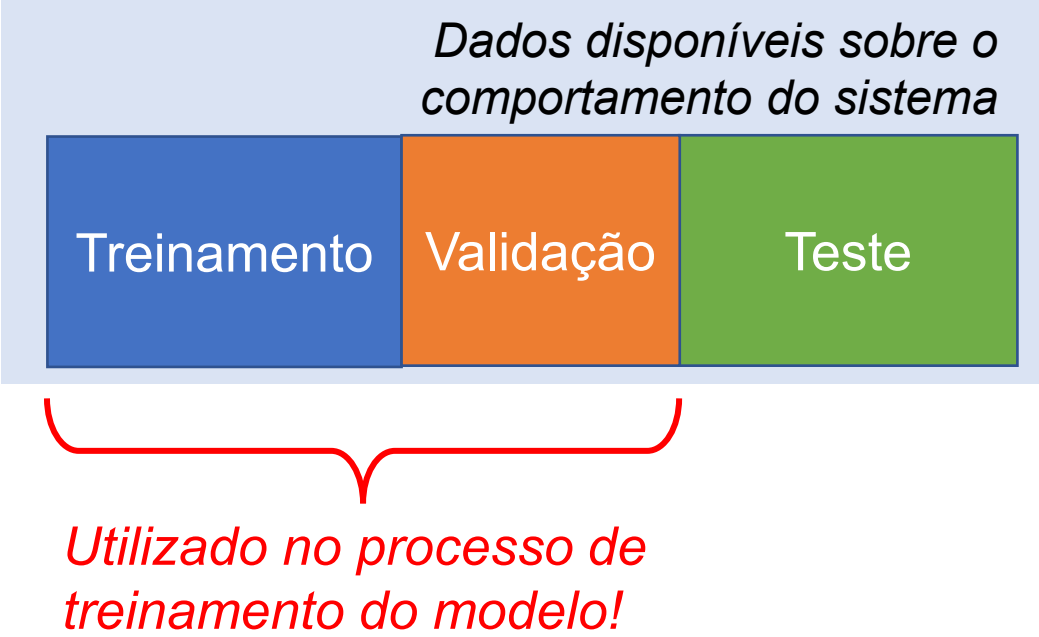

- Desempenho ruim no conjunto de teste → *overfitting*;
- Desempenho ruim no conjunto de treinamento → *underfitting*;
- Divisões usuais:
  - Conjunto de treinamento: ~80%;
  - Conjunto de teste: ~20%;

# Conjunto de Teste e Validação

- **Conjunto de validação:**
  - Problema: como escolher o melhor valor de um hiperparâmetro de treinamento?
  - Solução:
    - Dividir o conjunto de treinamento em dois subconjuntos: treinamento e validação;
    - Treinar diversos modelos com hiperparâmetros diferentes com o mesmo subconjunto de treinamento;
    - Verificar o desempenho do modelo no subconjunto de validação;
    - Selecionar o modelo com hiperparâmetro que otimize o desempenho no subconjunto de validação.

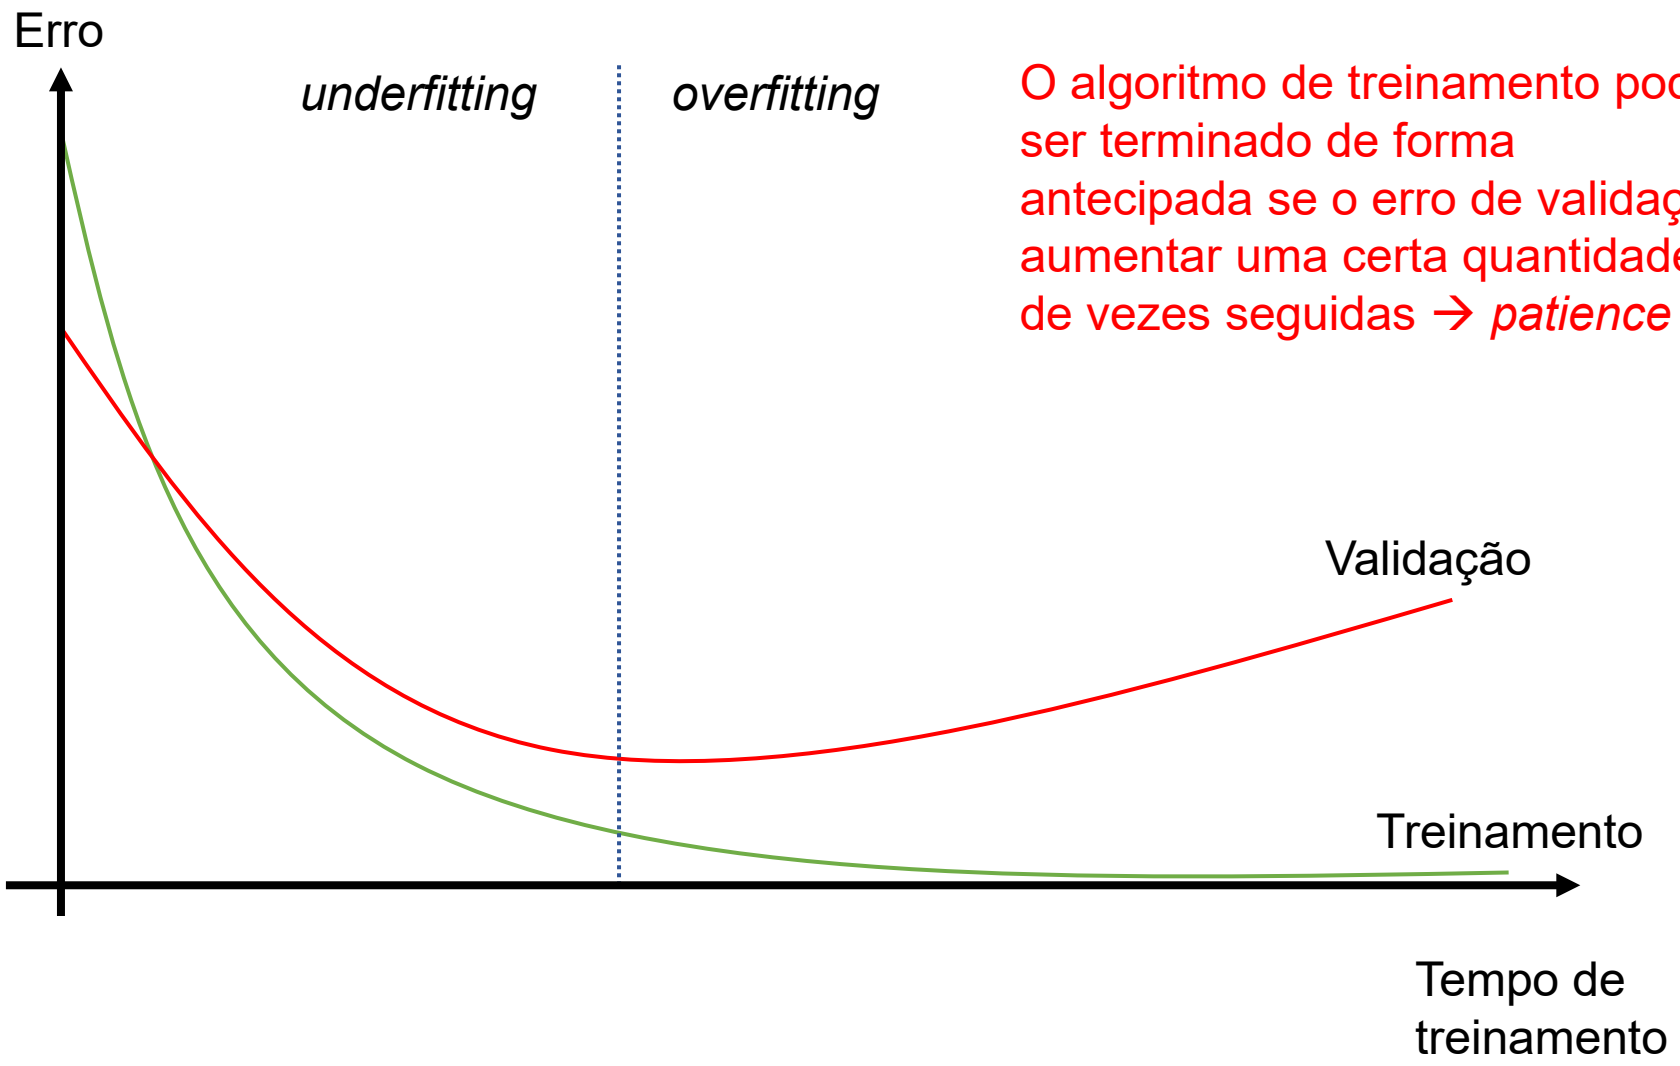
# Conjunto de Teste e Validação

- **Conjunto de validação:**




O conjunto de validação também pode ser utilizado como "*trigger*" para a parada antecipada.

# Conjunto de Teste e Validação




O algoritmo de treinamento pode ser terminado de forma antecipada se o erro de validação aumentar uma certa quantidade de vezes seguidas → *patience*