

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS (CMPF)
DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA (DETEC)

SISTEMAS INTELIGENTES

Análise Exploratória de Dados (AED)

Prof. Pedro Thiago Valério de Souza
UFERSA – Campus Pau dos Ferros
pedro.souza@ufersa.edu.br

Introdução

- Modelos de aprendizado de máquina necessitam de dados para aprender padrões e fazer previsões.
- Antes de treinar qualquer modelo de aprendizado de máquina, precisamos entender os dados.
- A análise exploratória de dados busca:
  - Resumir as principais características dos dados;
  - Revelar padrões, tendências e relações entre variáveis;
  - Identificar problemas: valores faltantes, erros e *outliers*.
- A qualidade do modelo depende da qualidade e do entendimento dos dados → se entra lixo, sai lixo (*garbage in, garbage out*).

Classificação de Dados

Dados podem ser classificados de várias maneiras, dependendo do critério:

- Estrutura: estruturados, não estruturados, semi-estruturados;
- Tempo/frequência: estático, dinâmico, tempo real;
- Dependência: independentes ou dependentes.

Classificação de Dados

Classificação Quanto à Estrutura:

- **Estruturados:** organizados em formato tabular bem definido (linhas e colunas).

  Ex.: planilhas, tabelas de banco de dados.
- **Não estruturados:** sem esquema fixo; exigem processamento para extrair informação.

  Ex.: texto livre, imagens, áudio, vídeo.
- **Semi-estruturados:** possuem alguma organização (marcadores, hierarquia), mas sem esquema rígido.

  Ex.: JSON, XML, e-mails.

Observação: Grande parte das técnicas clássicas de AED assume dados *estruturados*.

Classificação de Dados

Classificação Quanto ao Tempo/Frequência:

- **Estático:** coletado uma vez e não muda ao longo do tempo.
  Ex.: censo, cadastro histórico.
- **Dinâmico:** atualizado periodicamente (lotes/batches).
  Ex.: relatório de vendas mensal.
- **Tempo real:** gerado e consumido continuamente, em fluxo (*streaming*).
  Ex.: sensores IoT, transações financeiras.

Classificação de Dados

Classificação Quanto à Dependência:

- **Independentes:** cada amostra não guarda relação com as demais; a ordem não importa.

  Ex.: registros de pacientes distintos.

- **Dependentes:** existe relação entre as amostras, tipicamente temporal ou espacial; a ordem importa.

  Exemplos:

  - Séries temporais (valor de hoje depende de ontem);
  - Dados espaciais (pontos vizinhos são correlacionados).

Caracterização de Dados Estruturados

- Boa parte das técnicas de aprendizado de máquina assume dados estruturados (tabelas).
- Para dados estruturados, cada linha representa uma amostra (ou instância) e cada coluna representa um atributo (ou característica).
- A análise exploratória de dados estruturados envolve:
  - Estatísticas descritivas (média, mediana, desvio padrão, etc.);
  - Visualização de dados (histogramas, boxplots, scatterplots, etc.);
  - Identificação de padrões, tendências e relações entre atributos;

Caracterização de Dados Estruturados

Tipos de de Dados Estruturados:

- **Qualitativos (categóricos)**
  - **Nominais:** categorias sem ordem.
    Ex.: cor, sexo, espécie.
  - **Ordinais:** categorias com ordem natural.
    Ex.: escolaridade, $\{$ruim, médio, bom$\}$.
- **Quantitativos (numéricos)**
  - **Contínuos:** qualquer valor num intervalo.
    Ex.: altura, peso, tempo.
  - **Discretos:** valores enumeráveis (contagens).
    Ex.: nº de filhos, nº de acessos.

Observação:

- Dados qualitativos ordinais permitem apenas operações de comparação;
- Dados quantitativos permitem operações aritméticas e de comparação.

Caracterização de Dados Estruturados

Matriz de Dados: É a representação matemática de dados estruturados através de uma matriz $\mathbf{X}$ de dimensão $n \times d$:

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{bmatrix}$$

- $n \rightarrow$ quantidade de amostras/instâncias/observações;
- $d \rightarrow$ quantidade atributos/características/*features*;
- $x_{ij} \rightarrow$ valor do atributo j na amostra i;
- $\mathbf{x}_i \rightarrow$ vetor de atributos da amostra i (ou seja, contém os valores de todos os atributos para a amostra i).

Caracterização de Dados Estruturados

A **coluna alvo** (variável alvo ou *target*) é o que se deseja prever; as demais colunas são as *features*. O tipo da coluna alvo define o problema em aprendizado supervisionado:

- **Classificação:** alvo qualitativo (categorias).
  Ex.: espécie da flor, {spam, não-spam}.
  - Se existem apenas duas categorias, o problema é chamado de binário;
  - Se existem mais de duas categorias, o problema é chamado de multiclasse.
- **Regressão:** alvo quantitativo (valor numérico contínuo).
  Ex.: preço de um imóvel, temperatura.
- Sem coluna alvo, o problema é **não supervisionado** (ex.: agrupamento).

Caracterização de Dados Estruturados

Distribuição de Frequências: Descrevem quantas vezes cada valor (ou faixa de valores) ocorre.

- **Discreta:** conta a frequência de cada valor distinto.

Tabela - Estudo sobre o número de computadores por setor na UFERSA.

Valor	Freq. absoluta	Freq. relativa
8	15	30%
12	21	42%
15	9	18%
18	5	10%

- **Contínua:** os valores são agrupados em *classes* (faixas).

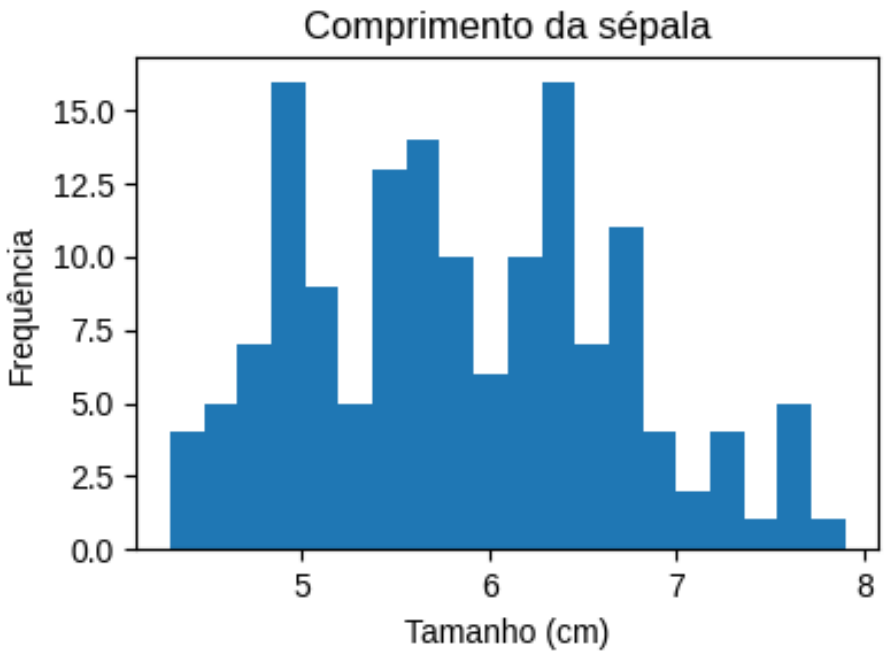
Tabela - Notas dos alunos de Sistemas Inteligentes.

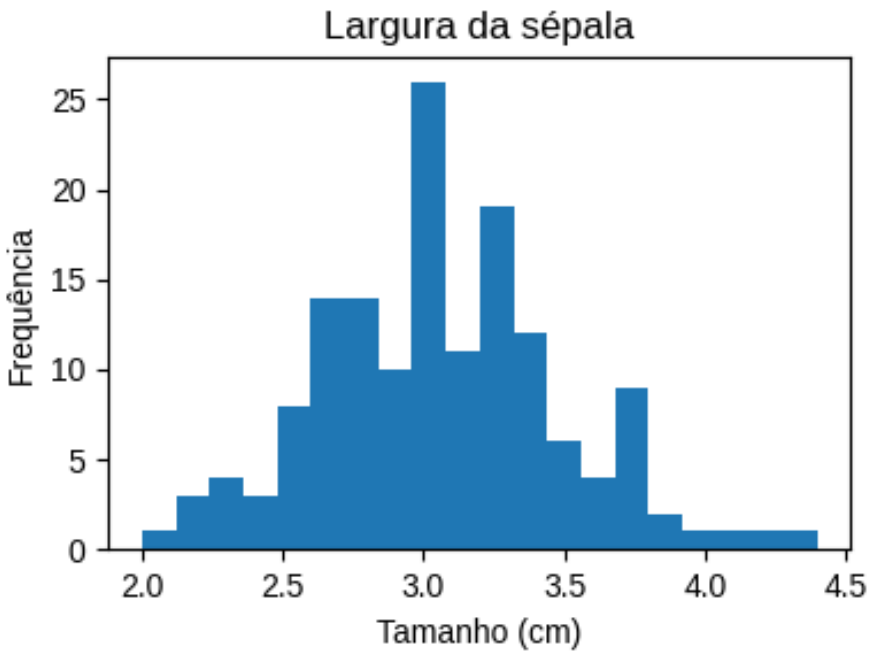
Notas	Freq. absoluta	Freq. relativa
7,4 ⊢ 7,7	6	30%
7,7 ⊢ 8,0	4	20%
8,0 ⊢ 8,3	4	20%
8,3 ⊢ 8,6	4	20%
8,6 ⊢ 8,9	2	10%

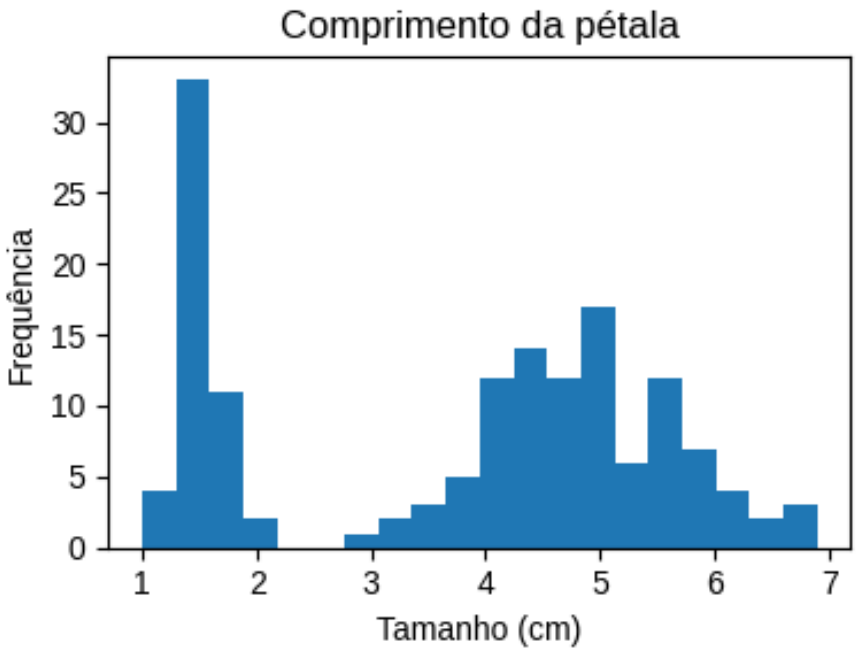
Caracterização de Dados Estruturados

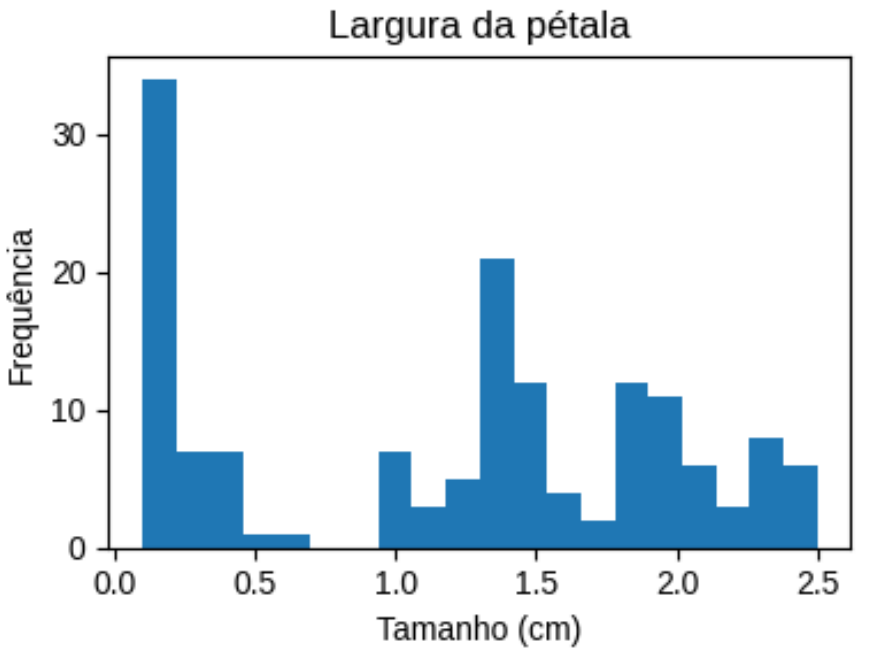
Histograma:

- Representação **gráfica** de uma distribuição de frequência de dados quantitativos.
- Eixo x: classes (faixas de valores);
- Eixo y: frequência de cada classe.
- Barras *coladas*, indicando continuidade dos dados.
- Permite visualizar rapidamente:
  - A forma da distribuição (simétrica, assimétrica, multimodal);
  - A concentração e a dispersão dos valores;
  - Possíveis *outliers*.


Comprimento da sépala
Frequência
Tamanho (cm)
0.0
2.5
5.0
7.5
10.0
12.5
15.0
5
6
7
8


Largura da sépala
Frequência
Tamanho (cm)
0
5
10
15
20
25
2.0
2.5
3.0
3.5
4.0
4.5


Comprimento da pétala
Frequência
Tamanho (cm)
0
5
10
15
20
25
30
1
2
3
4
5
6
7


Largura da pétala
Frequência
Tamanho (cm)
0
10
20
30
0.0
0.5
1.0
1.5
2.0
2.5

Caracterização de Dados Estruturados

Frequência Acumulada (ou ogivas):

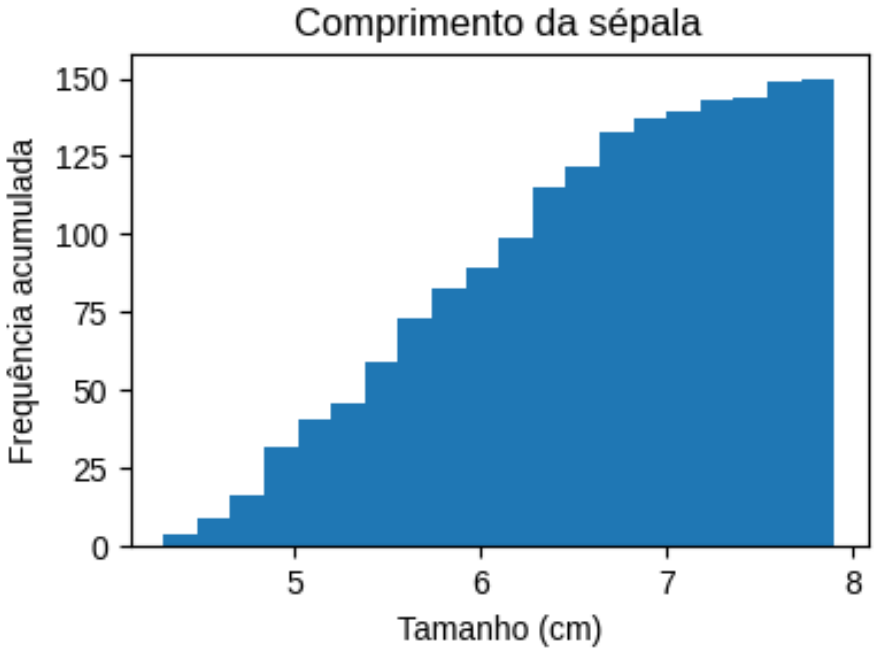
- Soma progressiva das frequências ao percorrer os valores/classes em ordem crescente.

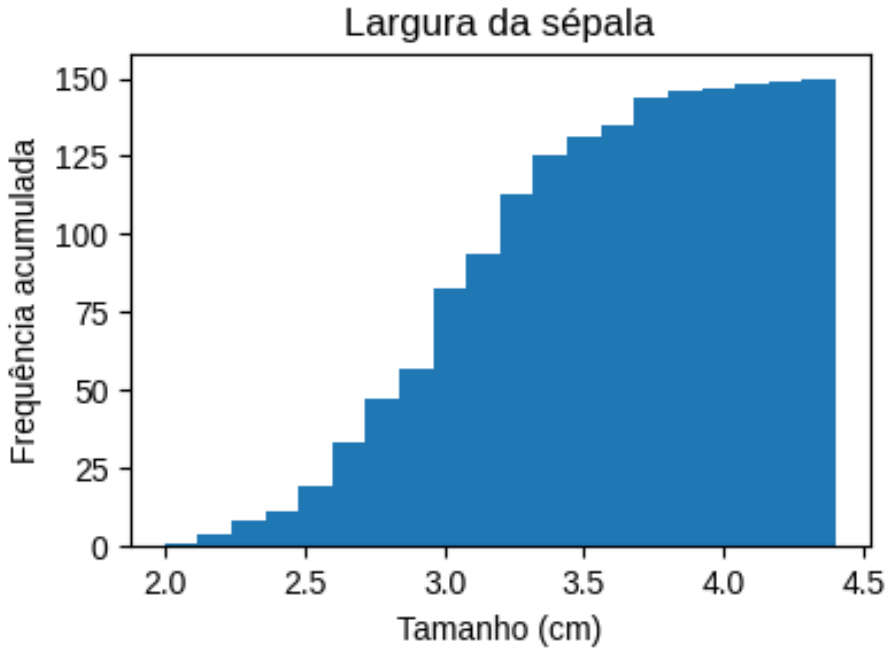
$$F_{ac}(k) = \sum_{j \leq k} f_j$$

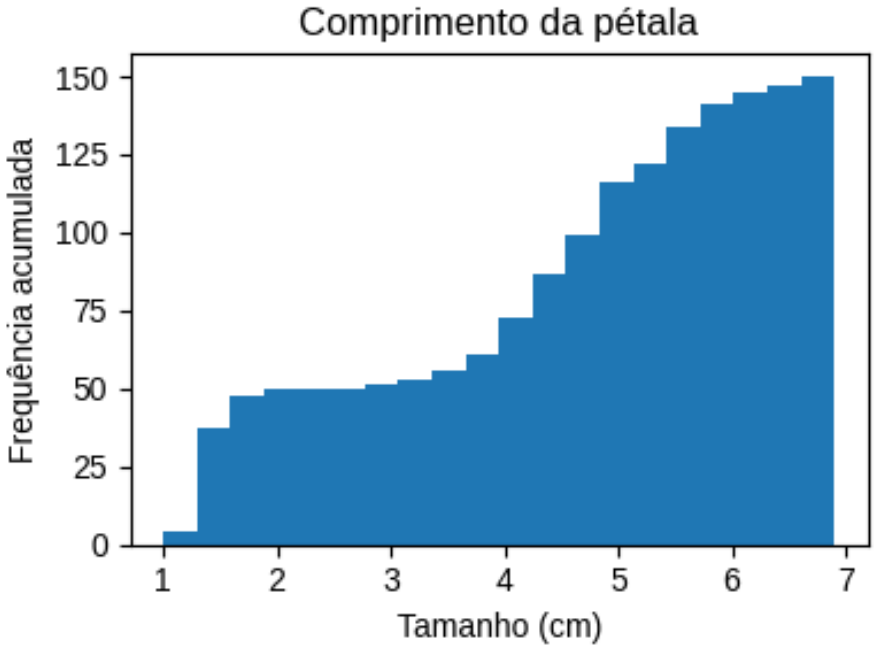
em que:

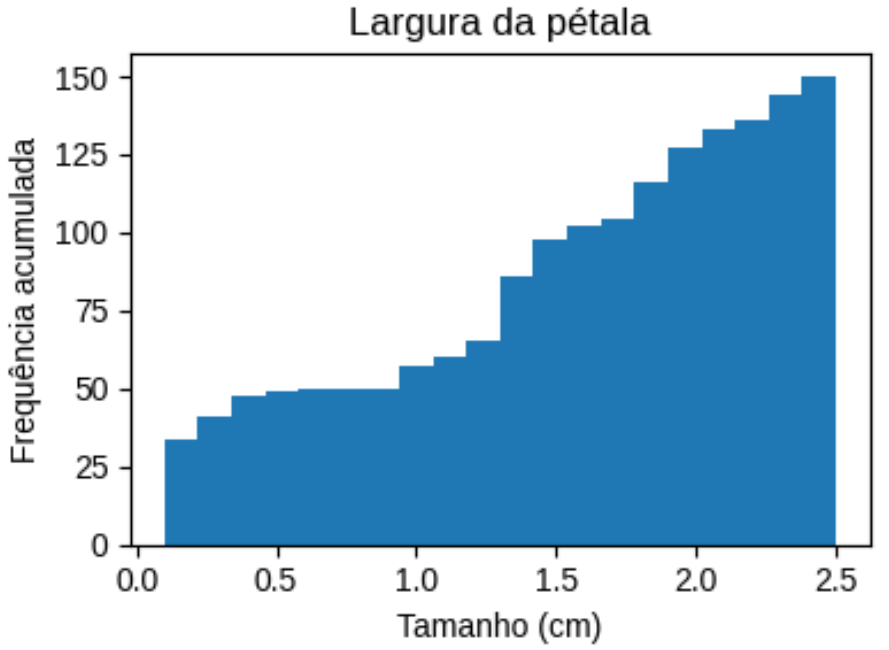
- $F_{ac}(k)$ = frequência acumulada do valor/classe k;
- f_j = frequência do valor/classe j.

- Responde perguntas do tipo “quantos (ou que proporção de) valores são $\leq$ a um limiar?”
- Graficamente é não decrescente (monotônico crescente).


Comprimento da sépala
Frequência acumulada
Tamanho (cm)
0
25
50
75
100
125
150
5
6
7
8


Largura da sépala
Frequência acumulada
Tamanho (cm)
0
25
50
75
100
125
150
2.0
2.5
3.0
3.5
4.0
4.5


Comprimento da pétala
Frequência acumulada
Tamanho (cm)
0
25
50
75
100
125
150
1
2
3
4
5
6
7


Largura da pétala
Frequência acumulada
Tamanho (cm)
0
25
50
75
100
125
150
0.0
0.5
1.0
1.5
2.0
2.5

Análise Exploratória de Dados

- A análise exploratória de dados (AED) é o processo de investigar e resumir os dados antes de aplicar modelos de aprendizado de máquina.
- Em muitos casos, é necessário que os dados estejam organizados em ordem crescente, o qual chamamos de *rol*.
- Após isso, pode-se determinar:
  - Medidas de tendência central (média, mediana, moda);
  - Medidas de posição ou separatrizes (quartis, percentis);
  - Medidas de dispersão (amplitude, variância, desvio padrão);
  - Medidas de forma (assimetria, curtose).

Análise Exploratória de Dados

Medidas de Tendência Central: Resumem os dados em um único valor, o mais representativo do conjunto.

- **Média:** A média aritmética de n valores $\{x_i\}$ é:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

  Problema: sensível a *outliers*.

- **Mediana ($\mathbf{Med}(x)$):** os dados dispostos em rol, a mediana é o valor no qual 50% dos dados estão abaixo e 50% acima. Se os n números $\{x_i\}$ estão em rol, então a mediana é:

$$\mathrm{Med}(x) = \begin{cases} x_{(n+1)/2}, & \text{se } n \text{ ímpar} \\ \dfrac{x_{(n/2)} + x_{(n/2+1)}}{2}, & \text{se } n \text{ par} \end{cases}$$

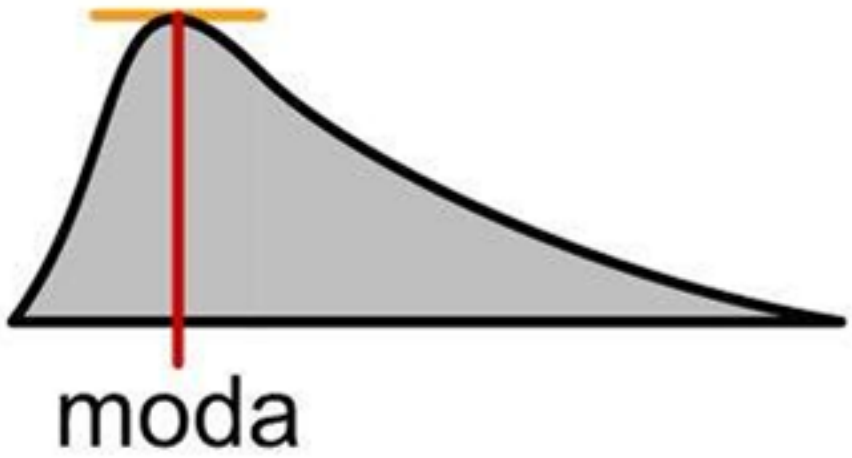
  É mais robusta a *outliers*.

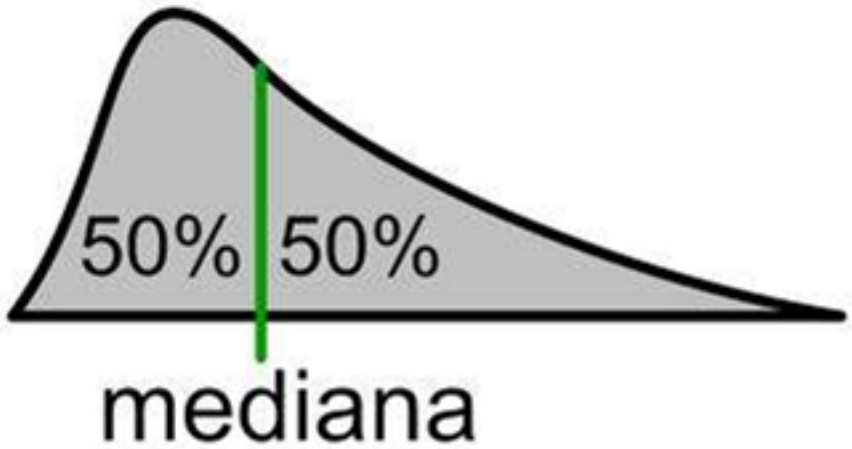
Análise Exploratória de Dados

Medidas de Tendência Central:

- **Moda ($\mathbf{Moda}(x)$):** valor (ou valores) mais frequente(s). Única medida aplicável também a dados *nominais*. Dependendo da quantidade de modas, a distribuição pode ser:
  - Unimodal: uma moda;
  - Bimodal: duas modas;
  - Multimodal: mais de duas modas.
- Em um histograma:
  - Mediana: É o valor que separa o histograma em duas metades de área igual;
  - Moda: É o valor mais “alto” do histograma.
- Assim,
  - Distribuições simétricas: Média = Moda = Mediana;
  - Distribuições à direita: Média > Mediana > Moda;
  - Distribuições à esquerda: Moda > Mediana > Média.
- Para distribuições moderadamente simétricas, pode-se estabelecer que:

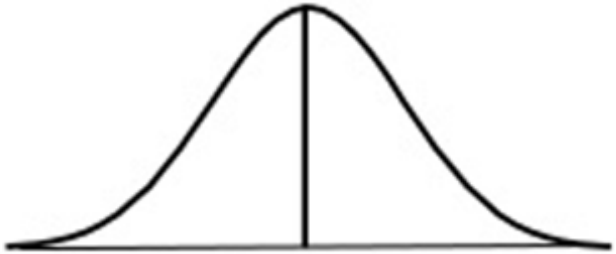
$$\mathrm{Moda}(x) = 3\mathrm{Med}(x) - 2\bar{x}$$


moda

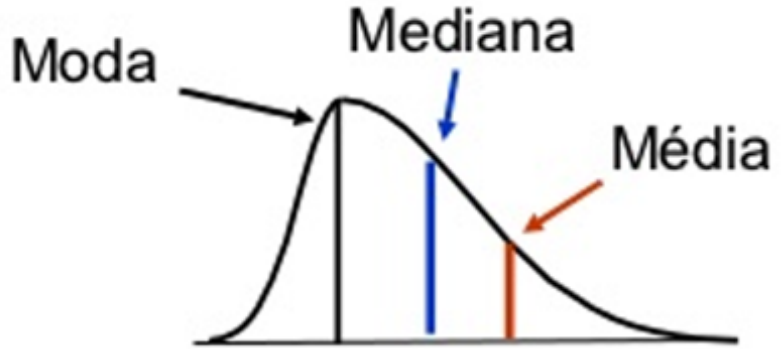

50%
50%
mediana

Distribuição Simétrica

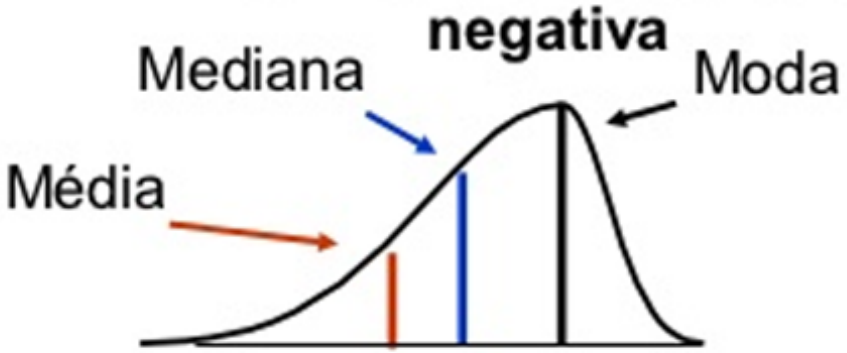
Média = Mediana = Moda



Assimetria à direita ou positiva



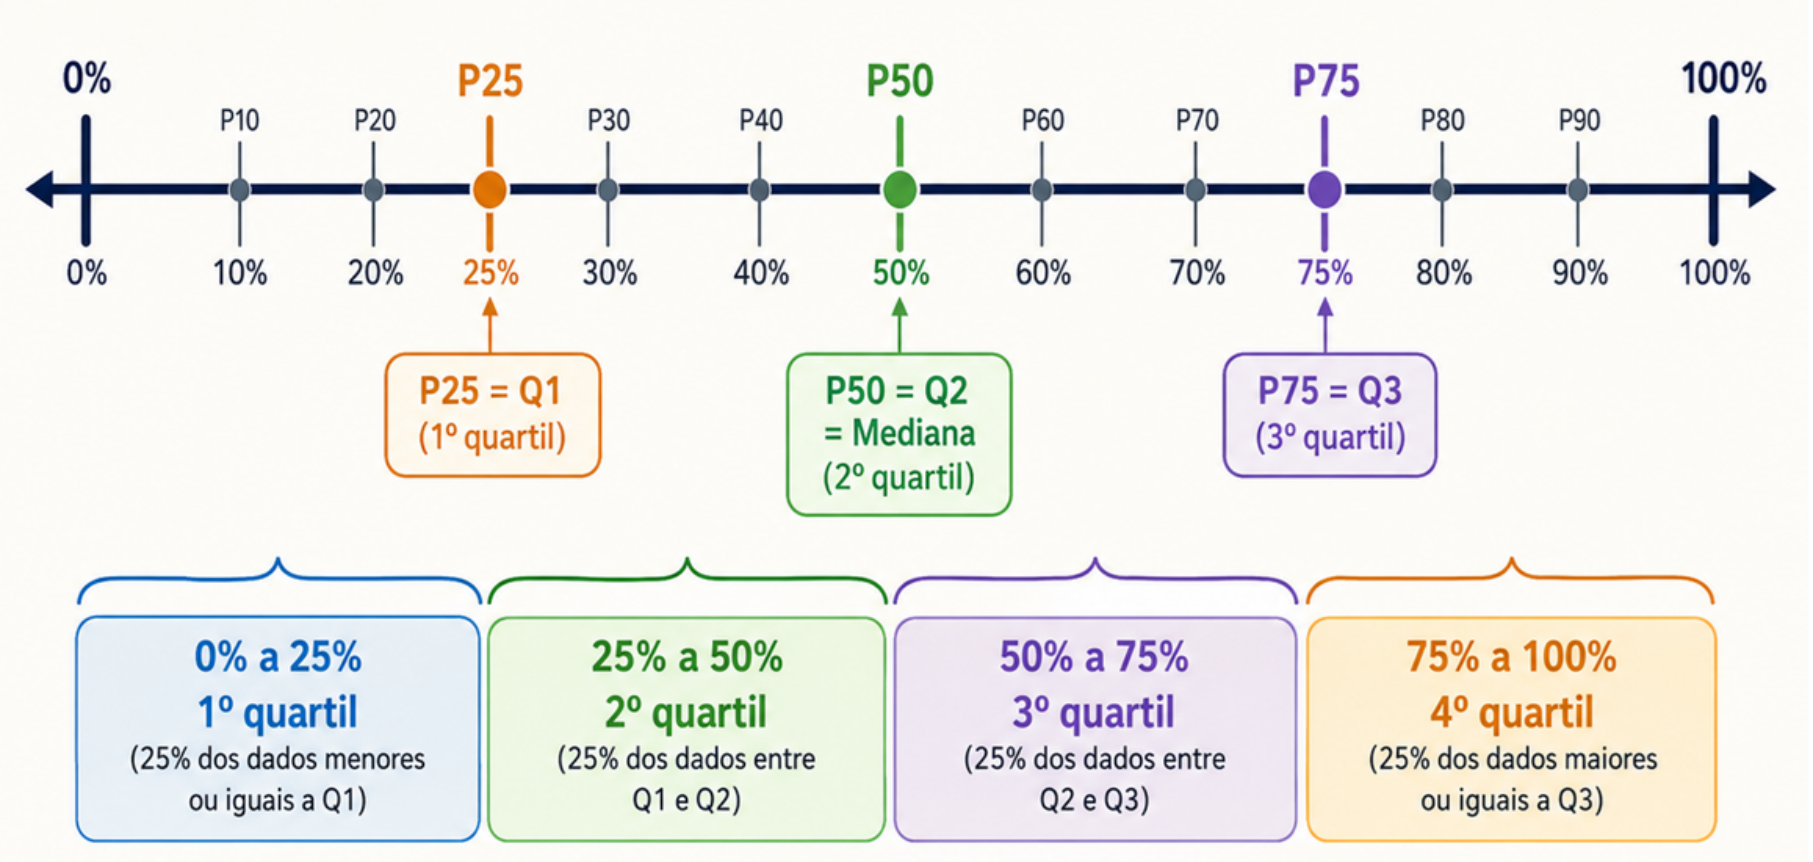
Assimetria à esquerda ou negativa



Análise Exploratória de Dados

Medidas de Posição: Indicam a posição relativa de um valor em relação ao conjunto de dados.

- **Percentil** P_p: valor abaixo do qual estão $p\%$ das observações (dados ordenados). O percentil p é calculado assim:
  - Se $\frac{np}{100}$ for um número inteiro, então $P_p = \frac{x_{(np/100)} + x_{(np/100+1)}}{2}$, sendo que $x_{(k)}$ é o k-ésimo valor do rol;
  - Caso contrário, $P_p = x_{(\lceil np/100 \rceil)}$, sendo $\lceil \cdot \rceil$ a função teto.
- **Quartis** dividem os dados em quatro partes iguais:
  - $Q_1 = P_{25}$ (primeiro quartil);
  - $Q_2 = P_{50}$ = mediana;
  - $Q_3 = P_{75}$ (terceiro quartil).
- São a base de vários resumos e da detecção de *outliers*.


0%
P10
P20
P25
P30
P40
P50
P60
P70
P75
P80
P90
100%
0%
10%
20%
25%
30%
40%
50%
60%
70%
75%
80%
90%
100%
P25 = Q1
(1º quartil)
P50 = Q2
= Mediana
(2º quartil)
P75 = Q3
(3º quartil)
0% a 25%
1º quartil
(25% dos dados menores ou iguais a Q1)
25% a 50%
2º quartil
(25% dos dados entre Q1 e Q2)
50% a 75%
3º quartil
(25% dos dados entre Q2 e Q3)
75% a 100%
4º quartil
(25% dos dados maiores ou iguais a Q3)

Análise Exploratória de Dados

Medidas de Dispersão: Quantificam o quanto os dados se "espalham" em torno de uma medida de tendência central.

- **Amplitude total** (R):

$$R = x_{\max} - x_{\min}$$

  Simples, mas muito sensível a extremos.

- **Amplitude interquartílica** (IQR):

$$IQR = Q_3 - Q_1$$

  Robusta a *outliers*, mas requer os cálculos dos quartis.

- **Variância** (s^2):

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2$$

  Medida de dispersão mais usada, mas em unidades ao quadrado.

- **Desvio padrão** (s):

$$s = \sqrt{s^2}$$

  Apresenta a mesma informação da variância, mas em unidades originais.

Análise Exploratória de Dados

Medidas de Dispersão:

- **Desvio médio absoluto** (DMA):

$$DMA = \frac{1}{n} \sum_{i=1}^{n} |x_i - \bar{x}|$$

- **Desvio mediano absoluto** (MAD):

$$MAD = \text{mediana} \left(|x_i - \tilde{x}| \right)$$

Análise Exploratória de Dados

Medidas de Dispersão – Propriedades importantes:

- O desvio padrão pode ser calculado como:

$$s^2 = \overline{x^2} - \bar{x}^2$$

sendo $\overline{x^2} = \frac{1}{n}\sum_{i=1}^{n} x_i^2$ o valor quadrático médio. Para dados com média nula, então:

$$s^2 = \overline{x^2} = \frac{1}{n}\sum_{i=1}^{n} x_i^2$$

- Para distribuições normais,
  - 68,27% dos dados estão entre $\bar{x} \pm s$;
  - 95,45% dos dados estão entre $\bar{x} \pm 2s$;
  - 99,73% dos dados estão entre $\bar{x} \pm 3s$.

Análise Exploratória de Dados

Medidas de Dispersão:

- Utilizando-se as medidas de posição e dispersão, podemos definir uma regra empírica para detectar *outliers*:
- *Outlier*: observação muito distante das demais;
- Regras comuns para detectar *outliers*:
  - **Regra do IQR**: é *outlier* todo x_i com,

$$x_i < Q_1 - 1{,}5\,IQR \quad \text{ou} \quad x_i > Q_3 + 1{,}5\,IQR$$

  - **Regra do desvio padrão** (z-score): supondo dados aproximadamente simétricos,

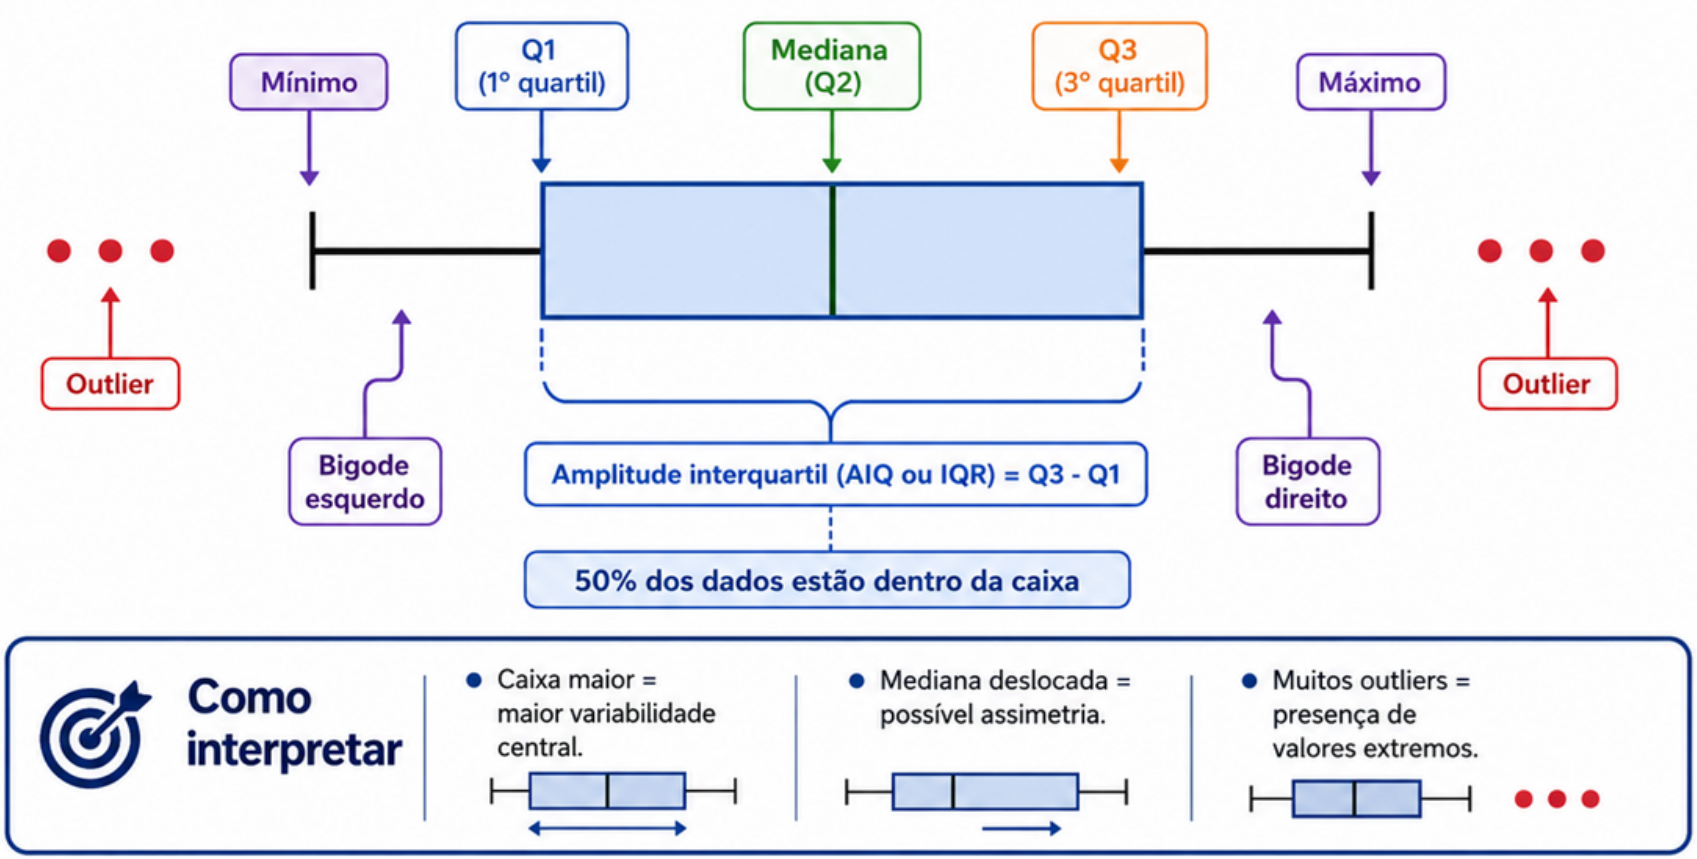
$$z_i = \frac{x_i - \bar{x}}{s}, \qquad |z_i| > 3 \Rightarrow \text{possível outlier}$$

- A regra do IQR são preferíveis quando há assimetria ou extremos, pois são mais robustas.

Análise Exploratória de Dados

Boxplot (diagrama de caixa): Representação gráfica da distribuição de dados univariados.

- Resume a distribuição usando o resumo dos cinco números: mínimo, Q_1, mediana, Q_3 e máximo.
- A caixa vai de Q_1 a Q_3 (contém 50% centrais); a linha interna é a mediana.
- Os bigodes (*whiskers*) estendem-se, tipicamente, até $1{,}5 \times IQR$ além dos quartis.
  - Valor máximo = $Q_3 + 1{,}5 \times IQR$;
  - Valor mínimo = $Q_1 - 1{,}5 \times IQR$.
- Pontos além dos bigodes são marcados como **outliers**.
- Excelente para comparar a distribuição entre grupos/classes.


Mínimo
Q1
(1º quartil)
Mediana
(Q2)
Q3
(3º quartil)
Máximo
Outlier
Bigode
esquerdo
Amplitude interquartil (AIQ ou IQR) = Q3 - Q1
50% dos dados estão dentro da caixa
Bigode
direito
Outlier
Como
interpretar
Caixa maior =
maior variabilidade
central.
Mediana deslocada =
possível assimetria.
Muitos outliers =
presença de
valores extremos.

Análise Exploratória de Dados

Medidas de Distribuição (forma): Caracterizam a forma da distribuição de dados.

- A principal métrica de distribuição é o momento central de ordem k:

$$m_k = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})^k$$

- Casos particulares:
  - m_2 = variância (populacional);
  - m_3 relaciona-se à *assimetria*;
  - m_4 relaciona-se ao *achatamento*.
- A partir dos momentos definimos as medidas de forma: *skewness* e curtose.

Análise Exploratória de Dados

Medidas de Distribuição (forma):

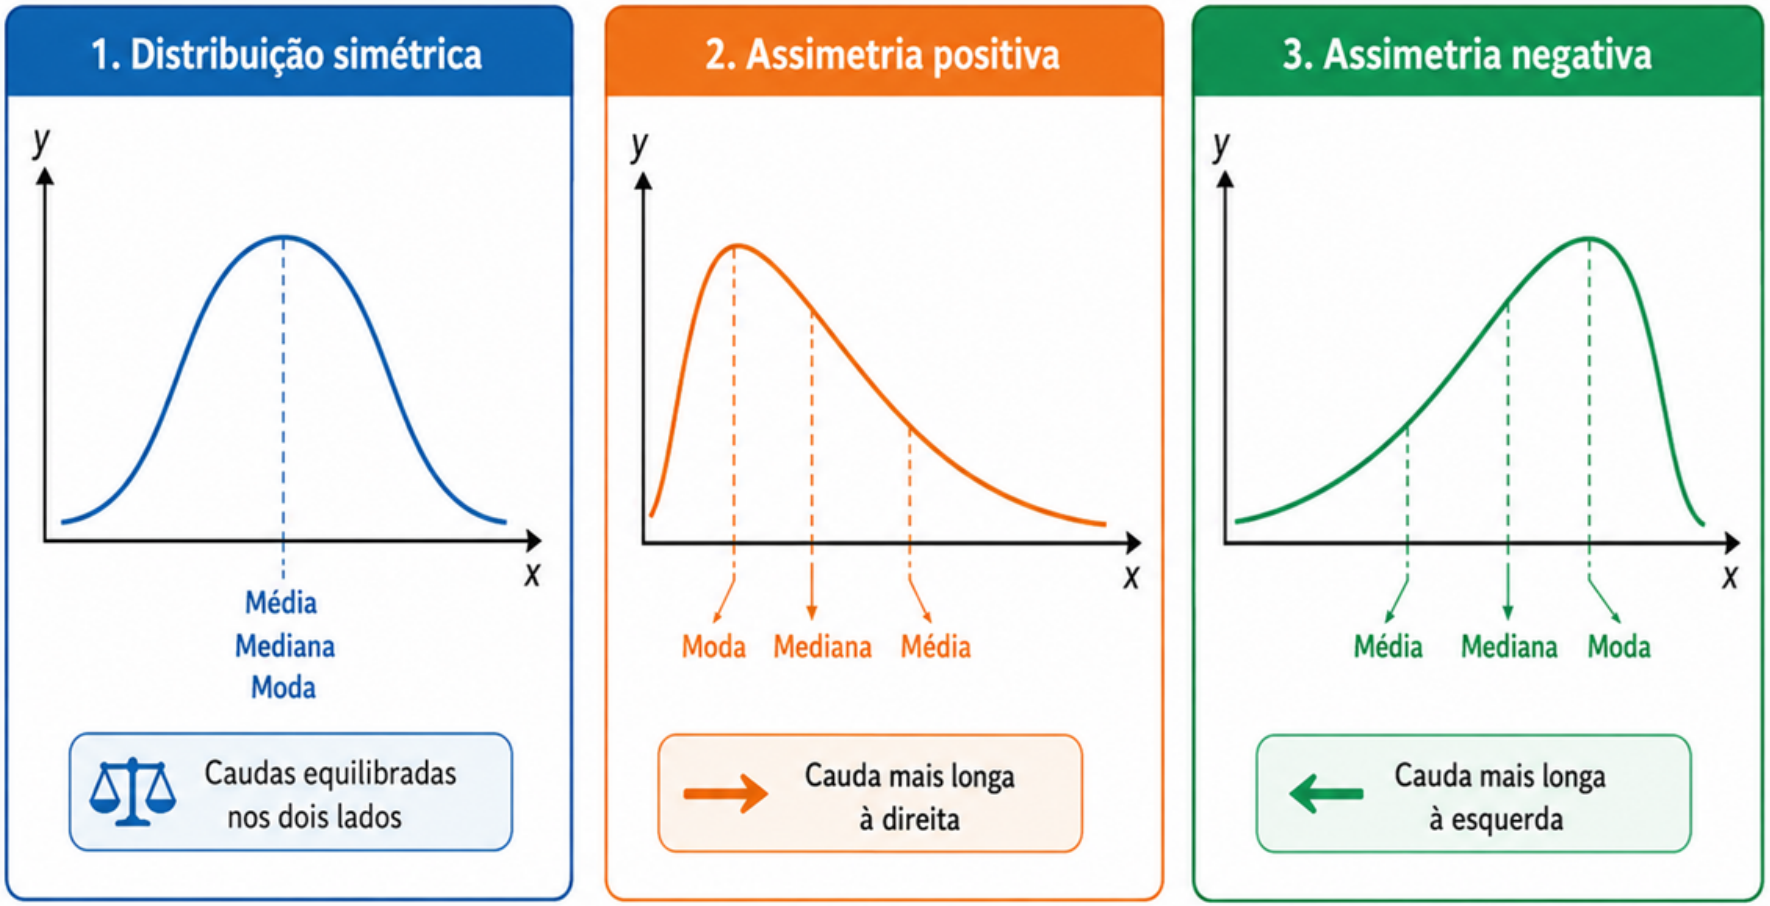
- **Skewness (assimetria):** Mede a assimetria da distribuição:

$$g_1 = \frac{m_3}{m_2^{3/2}}$$

Interpretação:

- $g_1 = 0$: simétrica;
- $g_1 > 0$: cauda mais longa à *direita* (assimetria positiva);
- $g_1 < 0$: cauda mais longa à *esquerda* (assimetria negativa).

Em distribuições assimétricas: relação típica entre média, mediana e moda muda de posição.


1. Distribuição simétrica
y
x
Média
Mediana
Moda
Caudas equilibradas nos dois lados
2. Assimetria positiva
y
x
Moda
Mediana
Média
Cauda mais longa à direita
3. Assimetria negativa
y
x
Média
Mediana
Moda
Cauda mais longa à esquerda

Análise Exploratória de Dados

Medidas de Distribuição (forma):

- **Curtose:** Mede o achatamento (ou peso) das caudas:

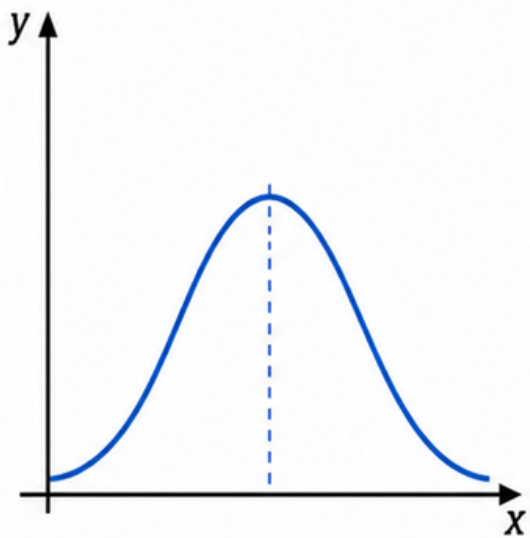
$$g_2 = \frac{m_4}{m_2^2}$$

  - Para a distribuição Gaussiana, $g_2 = 3$.
  - **Excesso de curtose** (correção para a Gaussiana):

$$g_2^* = \frac{m_4}{m_2^2} - 3$$

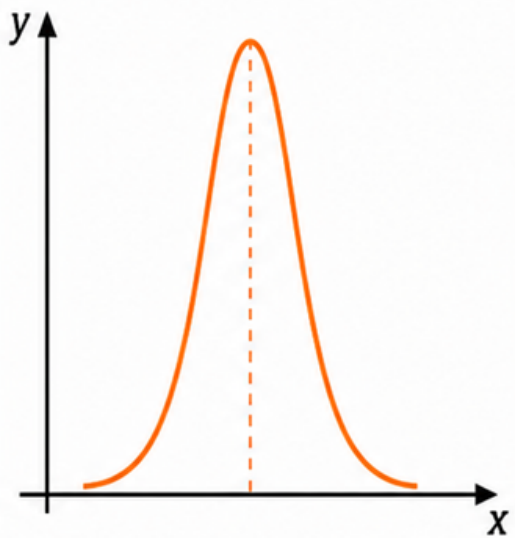
    - $g_2^* = 0$: caudas como a normal (mesocúrtica);
    - $g_2^* > 0$: pico agudo (leptocúrtica);
    - $g_2^* < 0$: achatada (platicúrtica).

1. Mesocúrtica



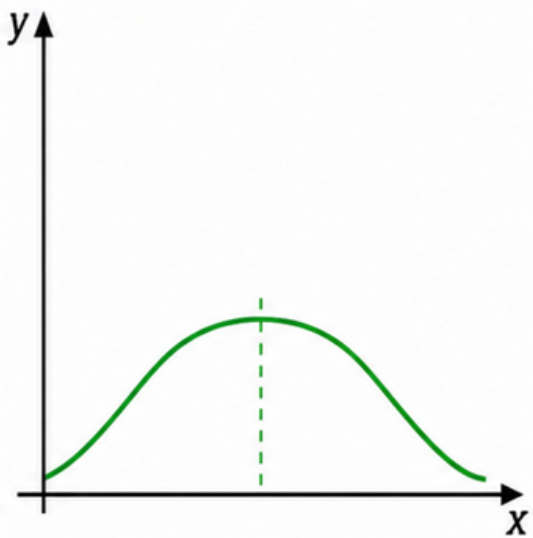
Pico intermediário
Ex.: distribuição normal

2. Leptocúrtica



Pico mais alto e estreito
Maior concentração central

3. Platicúrtica



Pico mais baixo e largo
Menor concentração central

Análise para Dados Multivariados

Com d atributos, podemos:

- Calcular as medidas anteriores (tendência central, dispersão, forma) para cada atributo individualmente;
- Investigar relações entre pares de atributos, usando medidas de associação: covariância e correlação.
  - **Covariância**:

$$\text{cov}(X,Y) = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$$

    - O sinal indica o sentido da relação linear;
    - A magnitude depende das unidades (por isso usamos a correlação).
  - **Correlação de Pearson:**

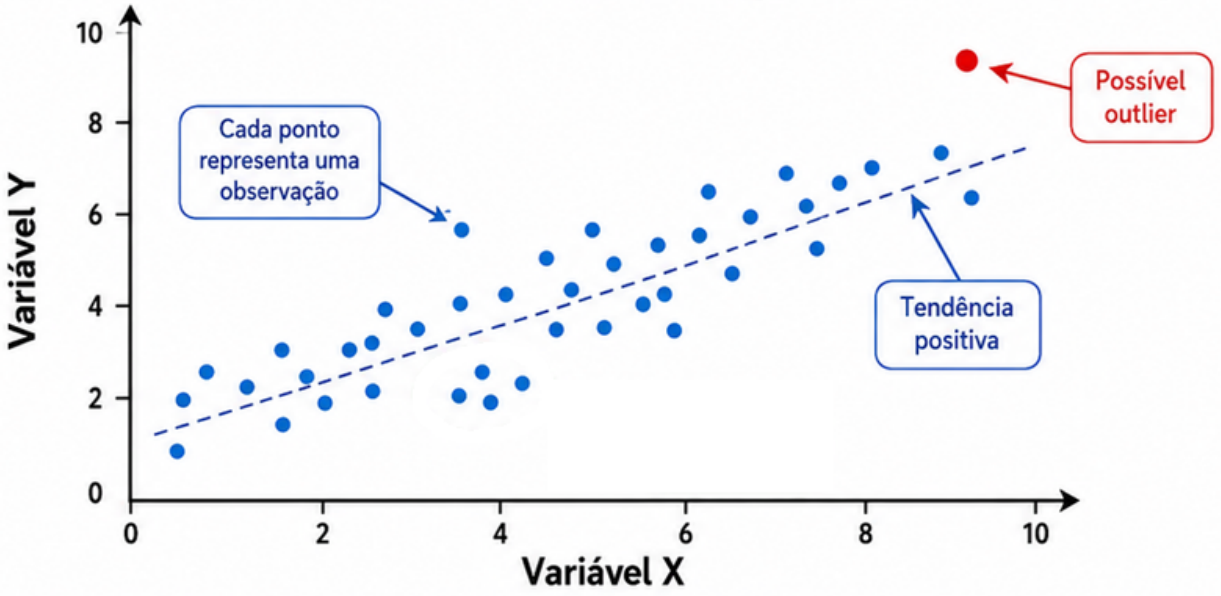
$$\rho_{XY} = \frac{\text{cov}(X,Y)}{s_X\, s_Y} \in [-1,1]$$

    Neste caso, quanto mais próximo de 1 ou -1, mais forte a relação linear entre os atributos.

Análise para Dados Multivariados

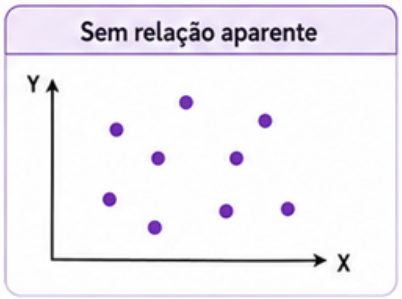
Ferramentas gráficas:

- **Scatterplot** (gráfico de dispersão): pontos de um atributo contra outro; revela relações lineares/não lineares, agrupamentos e *outliers*.
- **Heatmap** (mapa de calor): visualiza a matriz de correlação ρ com cores, permitindo identificar rapidamente pares de atributos fortemente relacionados.





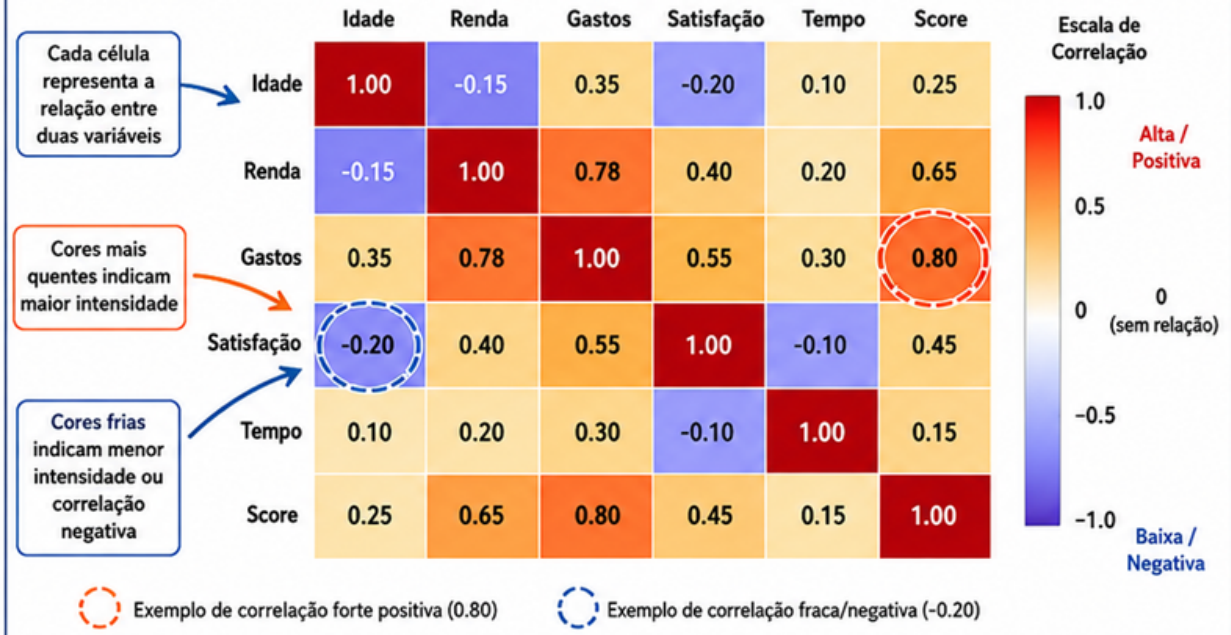




Para que serve o scatterplot na AED?

1. Visualizar a relação entre duas variáveis quantitativas.
2. Identificar tendências, padrões e correlação.
3. Detectar outliers e agrupamentos.
4. Sugerir relações lineares ou não lineares.

Exemplo: Heatmap de Correlação (6x6)



Para que serve o heatmap na AED?

1. Visualizar padrões em grande volume de dados.
2. Identificar correlações entre variáveis.
3. Detectar agrupamentos, blocos e estruturas.
4. Facilitar a comparação rápida por intensidade de cor.

Interpretação / Observações

- Quanto mais intensa a cor, maior tende a ser a magnitude da relação.
- Heatmaps ajudam a encontrar padrões visuais rapidamente.
- Eles não provam causalidade; ajudam na exploração inicial dos dados.

Outro exemplo: intensidade por período

