

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR PAU DOS FERROS
CURSO DE ENGENHARIA DE COMPUTAÇÃO

PAM0466 - SISTEMAS INTELIGENTES

Fundamentos do Aprendizado de Máquina (pt. 2)

Prof. Dr. Pedro Thiago Valério de Souza
pedro.souza@ufersa.edu.br

Semestre de 2026.1


Formas de Armazenamento do Conhecimento

- Aprendizado baseado em instância;
- Aprendizado baseado em modelo.

Formas de Armazenamento do Conhecimento

Aprendizado baseado em instância:


- Consiste em memorização;
- O sistema armazena a base de treinamento e utiliza uma medida de similaridade (distância) entre o dado novo e a base de treinamento;



Formas de Armazenamento do Conhecimento

Aprendizado baseado em modelo:

- Ocorre a construção de um modelo matemático, gerado a partir dos exemplos;
- Após isso, o modelo é utilizado para prever novos resultados;
- O que é armazenado não são os exemplos, mas sim os parâmetros do modelo.




Formas de Armazenamento do Conhecimento

Aprendizado baseado em modelo:

- Exemplo: Nível de satisfação de vida × PIB

Country	GDP per capita (USD)	Life satisfaction
Hungary	12,240	4.9
Korea	27,195	5.8
France	37,675	6.5
Australia	50,962	7.3
United States	55,805	7.2



Existe uma tendência de linearidade!

Formas de Armazenamento do Conhecimento

Aprendizado baseado em modelo:

- Exemplo: Nível de satisfação de vida $\times$ PIB
 - Seleção de um modelo: regressão linear.


satisfação de vida = $\theta_0 + \theta_1 \times \text{PIB}$  *Parâmetros do modelo: θ_0 e θ_1*

- O que é “salvo” são os parâmetros do modelo;
- É necessário um método de ajuste dos parâmetros do modelo $\rightarrow$ treinamento;
- Necessário definir uma função de adequação (custo);
 - Exemplo: erro quadrático médio;

Formas de Armazenamento do Conhecimento

Aprendizado baseado em modelo:

- Exemplo: Nível de satisfação de vida × PIB.



$$\text{MSE} = \frac{1}{N} \sum_{k=0}^{N-1} (y_k - h(x_k))^2$$

- $\{x_k, y_k\} \ k = 0, 1, \dots, N-1$ é o conjunto de treinamento
- $h(x_k)$ é a saída do modelo quando a entrada x_k é aplicada (saída prevista)


Formas de Armazenamento do Conhecimento

Aprendizado baseado em modelo:

- Exemplo: Nível de satisfação de vida × PIB.
- O processo de treinamento consiste em escolher os melhores parâmetros do modelo h que torna o MSE mínimo;

$$\text{MSE}(\theta_0, \theta_1) = \frac{1}{N} \sum_{k=0}^{N-1} (y_k - h(x_k))^2$$


$$\min_{\theta_0, \theta_1} \frac{1}{N} \sum_{k=0}^{N-1} (y_k - h(x_k))^2$$



Formas de Armazenamento do Conhecimento

Aprendizado baseado em modelo:

- Exemplo: Nível de satisfação de vida × PIB.
- No caso, o treinamento resulta em valores $\theta_0 = 3,75$ e $\theta_1 = 6,78 \times 10^{-5}$.



$$\text{satisfação de vida} = 3,75 + \left(6,78 \times 10^{-5}\right) \times \text{PIB}$$

Formas de Armazenamento do Conhecimento

Aprendizado baseado em modelo:

- Exemplo: Nível de satisfação de vida $\times$ PIB.
 - Após isso, é possível prever o nível de satisfação de vida para novos valores.
 - Exemplo: Chipre $\rightarrow$ PIB US\$ 32.655:

$$\begin{aligned}\text{satisfação de vida} &= 3,75 + \left(6,78 \times 10^{-5}\right) \times \text{PIB} \\ &= 3,75 + \left(6,78 \times 10^{-5}\right) \times 32655 \\ &= 6,30\end{aligned}$$

Formas de Armazenamento do Conhecimento

Aprendizado baseado em modelo:

- Exemplo: Nível de satisfação de vida $\times$ PIB.
- Etapas:
 - Estudo dos dados;
 - Seleção do modelo;
 - Treinamento do modelo;
 - Aplicação para novos dados.

Principais Desafios do Aprendizado de Máquina

- Quantidade insuficiente de dados de treinamento;
- Dados de treinamento não representativos;
- Dados de baixa qualidade;
- Características irrelevantes;
- Sobreajuste dos dados de treinamento;
- Subajuste dos dados de treinamento;

Principais Desafios do Aprendizado de Máquina

Quantidade insuficiente de dados de treinamento:

- É necessário uma quantidade boa de dados para que o algoritmo funcione perfeitamente;
- Em problemas complexos, a quantidade de dados é mais representativa do que o modelo (Peter Norvig et. al., 2009);


Dados não representativos:

- Os dados devem representar o problema perfeitamente;
- Exemplo: nível de satisfação vs. qualidade de vida.
 - Incluir países com PIB muito alto e muito baixo.

Principais Desafios do Aprendizado de Máquina

Dados não representativos:

- Exemplo: nível de satisfação vs. qualidade de vida.




Requer um retreinamento do modelo com os dados novos!

Principais Desafios do Aprendizado de Máquina

Dados não representativos:

- Exemplo: nível de satisfação vs. qualidade de vida.
- Modelo retreinado.



Principais Desafios do Aprendizado de Máquina

Dados com baixa qualidade:

- Dados com erros, valores atípicos, ruídos ou informações faltantes → dificulta o processo de aprendizado;
- É necessário dedicar um tempo para trabalhar com os dados → engenharia de dados:
 - Eliminar valores atípicos (*outliers*);
 - Dados faltantes:
 - Ignorar as instâncias em que o dado está faltante;
 - Ignorar a característica faltante;
 - Preencher os valores ausentes;
 - Treinar um modelo com a característica faltante e outro sem.

Principais Desafios do Aprendizado de Máquina

Características irrelevantes:

- Selecionar as melhores características para descrever o seu problema → engenharia de características:
 - Seleção de características;
 - Extração de características:
 - Combinar características existentes para criar uma nova (e.x. quilometragem + tempo de uso de um carro);
 - Utilizar transformações que mapeiam uma informação em outra (e.x. transformada de Fourier).

Principais Desafios do Aprendizado de Máquina


Sobreajuste (*overfitting*) dos dados de treinamento:

- Situação em que o algoritmo não realmente aprende, mas sim “decora” os exemplos de treinamento;
 - O modelo apresenta bom resultados para o conjunto de treinamento, mas não consegue generalizar a solução;

Principais Desafios do Aprendizado de Máquina

Sobreajuste (*overfitting*) dos dados de treinamento:

- Exemplo: utilização de um modelo polinomial no problema de nível de satisfação vs. qualidade de vida.



Principais Desafios do Aprendizado de Máquina


Sobreajuste (*overfitting*) dos dados de treinamento:

- Em um aprendizado sobreajustado, se os dados de treinamento possuírem ruído, o modelo tende a “aprender” esse ruído.
- Possíveis soluções:
 - Simplificar o modelo;
 - Coletar mais dados de treinamento;
 - Reduzir o ruído dos dados de treinamento.
- Regularização → método utilizado para simplificar o modelo e reduzir o risco de sobreajuste.
 - A quantidade de regularização é ajustada por um hiperparâmetro.

Principais Desafios do Aprendizado de Máquina

Sobreajuste (*overfitting*) dos dados de treinamento:

- Exemplo: nível de satisfação vs. qualidade de vida.
- Utilizando regularização, é possível utilizar apenas uma parte do conjunto de dados e obter resultados tão bons quanto utilizando um conjunto completo sem regularização.



Principais Desafios do Aprendizado de Máquina

Observação – Parâmetro × Hiperparâmetro.

- Parâmetro: valores do modelo que são ajustados através de alguma técnica de treinamento;
 - Não precisam ser especificados antes do treinamento;
- Hiperparâmetro: valores pré-definidos antes do treinamento;
 - Não é afetado pelo algoritmo de treinamento;
 - Devem permanecer constante durante todo o treinamento.


Principais Desafios do Aprendizado de Máquina

Subajuste (*underfitting*) dos dados de treinamento:

- Oposto do sobreajuste: o modelo é simples demais para modelar o problema;
- Soluções:
 - Selecionar um modelo mais poderoso;
 - Utilizar dados com melhores características;
 - Minimizar as restrições do modelo (e.x. reduzindo o hiperparâmetro de regularização).

Conjunto de Teste e Validação

- **Conjunto de teste:** dados utilizados para verificar a capacidade de generalização do modelo.



- Desempenho ruim no conjunto de teste → *overfitting*;
- Desempenho ruim no conjunto de treinamento → *underfitting*;
- Divisões usuais:
 - Conjunto de treinamento: ~80%;
 - Conjunto de teste: ~20%;

Conjunto de Teste e Validação

- **Conjunto de validação:**


- Problema: como escolher o melhor valor de um hiperparâmetro de treinamento?

- Solução:

- Dividir o conjunto de treinamento em dois subconjuntos: treinamento e validação;
 - Treinar diversos modelos com hiperparâmetros diferentes com o mesmo subconjunto de treinamento;
 - Verificar o desempenho do modelo no subconjunto de validação;
 - Selecionar o modelo com hiperparâmetro que otimize o desempenho no subconjunto de validação.

Conjunto de Teste e Validação

- **Conjunto de validação:**



- O conjunto de validação também pode ser utilizado como “trigger” para a parada antecipada.

Conjunto de Teste e Validação

