

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS (CMPF)
DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA (DETEC)

SISTEMAS INTELIGENTES

Métricas de Avaliação em Aprendizado de Máquina

Prof. Pedro Thiago Valério de Souza
UFERSA – Campus Pau dos Ferros
pedro.souza@ufersa.edu.br

Métricas de Avaliação em Aprendizado de Máquina

- Após o treinamento de um modelo de aprendizado de máquina, é necessário avaliar seu desempenho.
- A avaliação é feita com base em métricas específicas, que variam de acordo com o tipo de problema (classificação, regressão, etc.).
- A avaliação sempre ocorre em dados **não vistos no treino** (conjunto de teste).
- As principais métricas (e ferramentas de avaliação) incluem:
  - Matriz de Confusão;
  - Acurácia, Precisão, Revocação e F-score;
  - Curva ROC e AUC;
  - Métricas para Regressão - MAE, MSE, RMSE, MAPE, R^2;

Matriz de Confusão

Definição: Tabela que relaciona os rótulos reais com os rótulos previstos pelo modelo.

		Previsto	
		Positivo	Negativo
Real	Positivo	**VP**	**FN**
	Negativo	**FP**	**VN**

- **VP** (verdadeiro positivo): era positivo, previu positivo ✓
- **VN** (verdadeiro negativo): era negativo, previu negativo ✓
- **FP** (falso positivo): era negativo, previu positivo – *erro tipo I* (alarme falso)
- **FN** (falso negativo): era positivo, previu negativo – *erro tipo II*

Matriz de Confusão

Exemplo: O conjunto de teste tem 1000 pacientes; a classe *positiva* é doente.

		Previsto		
		Doente	Saudável	Total
Real	Doente	VP = 80	FN = 20	100
	Saudável	FP = 50	VN = 850	900
	Total	130	870	1000

- 80 pacientes doentes foram corretamente detectados como doentes (VP).
- 850 pacientes saudáveis foram corretamente identificados como saudáveis (VN).
- 20 pacientes doentes **não** foram detectados (FN) – erro muito grave.
- 50 pacientes saudáveis receberam alarme falso (FP) – erro pouco grave.

Dependendo do problema, FP e FN têm custos diferentes; a matriz de confusão permite analisar isso.

Acurácia, Precisão, Revocação e F-score

Acurácia: Fração de acertos sobre o total, ou seja,

$$\text{Acurácia} = \frac{\text{VP} + \text{VN}}{\text{VP} + \text{VN} + \text{FP} + \text{FN}}$$

		Previsto		
		Doente	Saudável	Total
Real	Doente	$\text{VP} = 80$	$\text{FN} = 20$	100
	Saudável	$\text{FP} = 50$	$\text{VN} = 850$	900
	Total	130	870	1000

No exemplo: Acurácia $= (80 + 850)/1000 = 0{,}93$.

Acurácia, Precisão, Revocação e F-score

Problema – O paradoxo da acurácia:

- Se apenas 1% dos pacientes tem a doença, um modelo que diz *"ninguém tem"* uma doença acerta 99%, e é inútil (pois nunca vai dizer que alguém está doente, mesmo que ele esteja).
- Assim sendo, a acurácia **não é confiável** em problemas com classes desbalanceadas.
- É uma boa métrica com classes **razoavelmente balanceadas**.
- Trata FP e FN como igualmente ruins, o que quase nunca é verdade.

Acurácia, Precisão, Revocação e F-score

Precisão e Revocação:

$$\text{Precisão} = \frac{\text{VP}}{\text{VP} + \text{FP}} \qquad \text{Revocação} = \frac{\text{VP}}{\text{VP} + \text{FN}}$$

Precisão (*precision*)

- "Dos que eu *marquei* como positivos, quantos realmente eram?"
- Penaliza **FP**.

Revocação (*recall*)

- "Dos que *realmente* eram positivos, quantos eu encontrei?"
- Penaliza **FN**.

Acurácia, Precisão, Revocação e F-score

Precisão e Revocação: Para o exemplo,

		Previsto		
		Doente	Saudável	Total
Real	Doente	VP = 80	FN = 20	100
	Saudável	FP = 50	VN = 850	900
	Total	130	870	1000

$$\text{Precisão} = \frac{\text{VP}}{\text{VP} + \text{FP}} = \frac{80}{80 + 50} = 0{,}62$$

$$\text{Revocação} = \frac{\text{VP}}{\text{VP} + \text{FN}} = \frac{80}{80 + 20} = 0{,}80$$

Acurácia, Precisão, Revocação e F-score

Precisão e Revocação:

- As duas **competem**: aumentar uma normalmente reduz a outra.
- Modelo “cauteloso” (marca poucos como positivos): precisão alta, revocação baixa.
- Modelo “alarmista” (marca muitos): revocação alta, precisão baixa.

Priorize revocação quando...	**Priorize precisão quando...**
o FN é caro	o FP é caro
triagem de doença grave	filtro de spam
detecção de fraude	recomendação ao usuário
falha em equipamento crítico	sugestão de conteúdo

Exemplos:

- Na triagem de câncer, um FN (doente não detectado) pode ser fatal. Logo, priorize revocação.
- No filtro de spam, um FP joga um e-mail legítimo no lixo. Priorize precisão.

Acurácia, Precisão, Revocação e F-score

F1-Score: É a **média harmônica** de precisão (P) e revocação (R):

$$F_1 = 2 \cdot \frac{P \cdot R}{P + R}$$

- A média harmônica **pune desequilíbrios**: se uma das duas for baixa, o F_1 é baixo.
- Ex.: $P = 1{,}0$ e $R = 0{,}1 \rightarrow$ média aritmética $= 0{,}55$, mas $F_1 = 0{,}18$.
- No exemplo da doença: $F_1 = 2 \cdot (0{,}62 \cdot 0{,}80)/(0{,}62 + 0{,}80) = 0{,}70$.

Versão geral (F_β): β define o peso da revocação.

$$F_\beta = (1 + \beta^2)\,\frac{P \cdot R}{\beta^2 P + R}$$

$\beta = 2$ valoriza mais a revocação; $\beta = 0{,}5$, mais a precisão.

Acurácia, Precisão, Revocação e F-score

Resumo do Exemplo Numérico:

		Previsto		
		Doente	Saudável	Total
	Doente	$\mathrm{VP} = 80$	$\mathrm{FN} = 20$	100
Real	Saudável	$\mathrm{FP} = 50$	$\mathrm{VN} = 850$	900
	Total	130	870	1000

Métrica	**Valor**	**Leitura**
Acurácia	0,93	acerta 93% do total
Precisão	0,62	38% dos alarmes são falsos
Revocação	0,80	encontra 80% dos doentes
F_1	0,70	equilíbrio entre as duas

- A acurácia (0,93) é **otimista demais**: esconde que 1 em cada 5 doentes passa despercebido.
- Em dados desbalanceados, prefira **precisão, revocação e F1** – nunca só a acurácia.

Curva ROC

- A maioria dos classificadores devolve uma **probabilidade** da entrada pertecer à classe positivo, ou seja, retorna $\hat{p} \in [0,1]$, não um rótulo.
- O rótulo vem de um teste binário de hipótese:

$$\hat{y} = \begin{cases} 1 & \text{se } \hat{p} \geq t \\ 0 & \text{se } \hat{p} < t \end{cases}$$

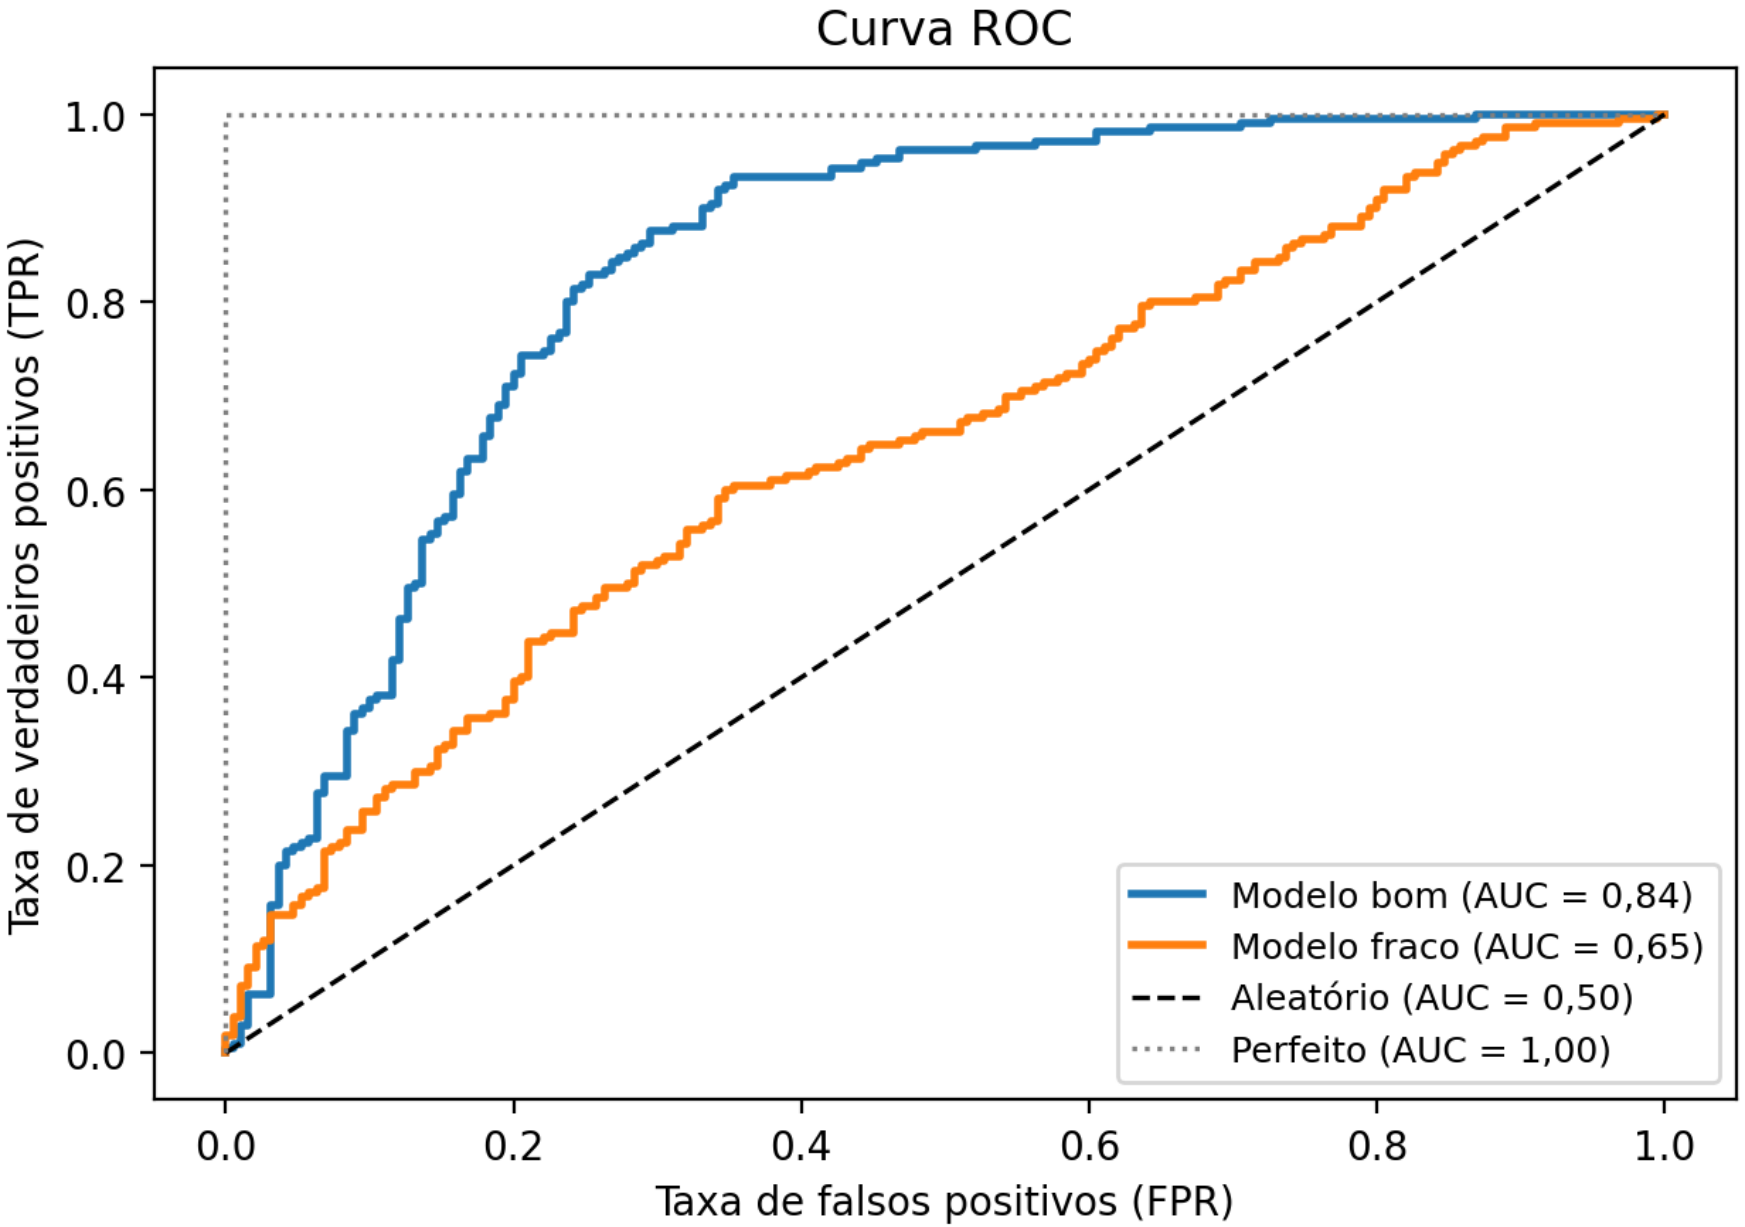
  em que t é o **limiar de decisão** (*threshold*).
- O padrão $t = 0{,}5$ é apenas uma **convenção**, não uma escolha ótima.
- Mudar t muda toda a matriz de confusão:
  - t **baixo** $\rightarrow$ mais positivos $\rightarrow$ revocação $\uparrow$, precisão $\downarrow$;
  - t **alto** $\rightarrow$ menos positivos $\rightarrow$ precisão $\uparrow$, revocação $\downarrow$.
- **Ideia da ROC (*Receiver Operating Characteristic*):** avaliar o modelo para *todos* os limiares de uma vez.

Curva ROC

Definição: Gráfico da taxa de verdadeiros positivos (**TPR**) versus a taxa de falsos positivos (**FPR**), variando o limiar t:

$$\text{TPR} = \frac{\text{VP}}{\text{VP} + \text{FN}} \ (= \text{revocação}) \qquad \text{FPR} = \frac{\text{FP}}{\text{FP} + \text{VN}}$$

- Cada **ponto** da curva corresponde a um limiar.
- Canto superior esquerdo $(0,1)$ = classificador **perfeito**.
- Diagonal = classificador **aleatório**.
- Quanto mais a curva se aproxima do canto superior esquerdo, melhor o modelo.


Curva ROC
Taxa de verdadeiros positivos (TPR)
Taxa de falsos positivos (FPR)
0.0
0.2
0.4
0.6
0.8
1.0
Modelo bom (AUC = 0,84)
Modelo fraco (AUC = 0,65)
Aleatório (AUC = 0,50)
Perfeito (AUC = 1,00)

AUC-ROC

AUC-ROC: Área sob a curva ROC (por definição, $0 \leq \text{AUC} \leq 1$).

AUC	Interpretação
1,0	classificador perfeito
0,9 – 1,0	excelente
0,8 – 0,9	bom
0,7 – 0,8	razoável
0,5	equivalente a jogar uma moeda
$< 0{,}5$	pior que o acaso (rótulos invertidos?)

- **Vantagens:**
  - Independe do limiar escolhido;
  - Permite comparar modelos diretamente.
- **Limitações:**
  - Com forte desbalanceamento, pode ser **otimista**;
  - Nesse caso, prefira a curva **Precisão-Revocação** e a **AUC-PR**.
- Regra prática: dados equilibrados $\rightarrow$ ROC; minoritária rara e de interesse $\rightarrow$ PR.

Métricas de Performance para Classificação Multiclasse

Matriz de confusão multiclasse: Com c classes, a matriz é $c \times c$ (exemplo com o Iris):

		Previsto		
		setosa	versicolor	virginica
Real	setosa	**15**	0	0
	versicolor	0	**13**	2
	virginica	0	1	**14**

- A **diagonal** traz os acertos; fora dela, os erros.
- Mostra *quais* classes o modelo confunde entre si (aqui: versicolor ↔ virginica).
- Precisão/revocação são calculadas **por classe**, no esquema *um-contra-todos* (*one-vs-rest*).
  - Exemplo: para a classe versicolor, VP = 13, FN = 2, FP = 1.
  - Após isso, calcula-se a precisão/revocação, no caso:

$$P_{\text{versicolor}} = \frac{\text{VP}}{\text{VP} + \text{FP}} = \frac{13}{13 + 1} = 0{,}93 \qquad R_{\text{versicolor}} = \frac{\text{VP}}{\text{VP} + \text{FN}} = \frac{13}{13 + 2} = 0{,}87$$

Métricas de Performance para Classificação Multiclasse

Agregação de Métricas: Cada classe i tem seu P_i, R_i e F_i. Existem três formas de resumir:

- **Macro:** média simples entre as classes.

$$P_{\text{macro}} = \frac{1}{c} \sum_{i=1}^{c} P_i$$

  Todas as classes pesam **igual** – boa quando as minoritárias importam.
- ***Weighted:*** média ponderada pelo nº de amostras de cada classe. Reflete o desempenho global, mas as classes raras quase somem.
- **Micro:** soma VP, FP e FN de *todas* as classes e calcula uma vez só.

$$P_{\text{micro}} = \frac{\sum_i \text{VP}_i}{\sum_i \text{VP}_i + \sum_i \text{FP}_i}$$

Atenção: Não é necessário fazer a agregação para acurácia, pois ela já é global.

Métricas de Performance para Classificação Multiclasse

Macro vs. *Weighted*: um exemplo: Problema com 3 classes: A (900 amostras), B (50), C (50).

Classe	n	$F1_i$
A	900	0,98
B	50	0,40
C	50	0,30

$$F1_{\text{macro}} = \frac{0{,}98 + 0{,}40 + 0{,}30}{3} = 0{,}56 \qquad F1_{\text{weighted}} \approx 0{,}91$$

- A ponderada (0,91) **esconde** o fracasso nas classes B e C.
- A macro (0,56) revela o problema – por isso é a preferida quando há desbalanceamento e as classes raras importam.

Métricas de Performance para Regressão

Neste caso, y_i é o valor real e $\hat{y}_i$ é a predição do modelo. As métricas mais comuns são:

- **MAE** (erro absoluto médio):

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

  Mesma unidade do alvo, fácil de explicar, **robusto** a *outliers*.

- **MSE** (erro quadrático médio):

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

  Pune **muito** erros grandes; unidade ao quadrado.

- **RMSE**: $\sqrt{\text{MSE}}$ – volta à unidade original, mantendo a sensibilidade a erros grandes.

Métricas de Performance para Regressão

- **MAPE** (erro percentual absoluto médio):

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^{n} \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

  Erro relativo, comparável entre problemas. **Não use** se y_i puder ser zero ou muito pequeno.

- R^2 – fração da variância explicada pelo modelo:

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

  - $R^2 = 1$: predição perfeita;
  - $R^2 = 0$: equivale a sempre prever a média $\bar{y}$;
  - $R^2 < 0$: pior que prever a média (é possível no teste!).

Dilema Viés-Variância

O erro esperado em dados **novos** se decompõe em três partes:

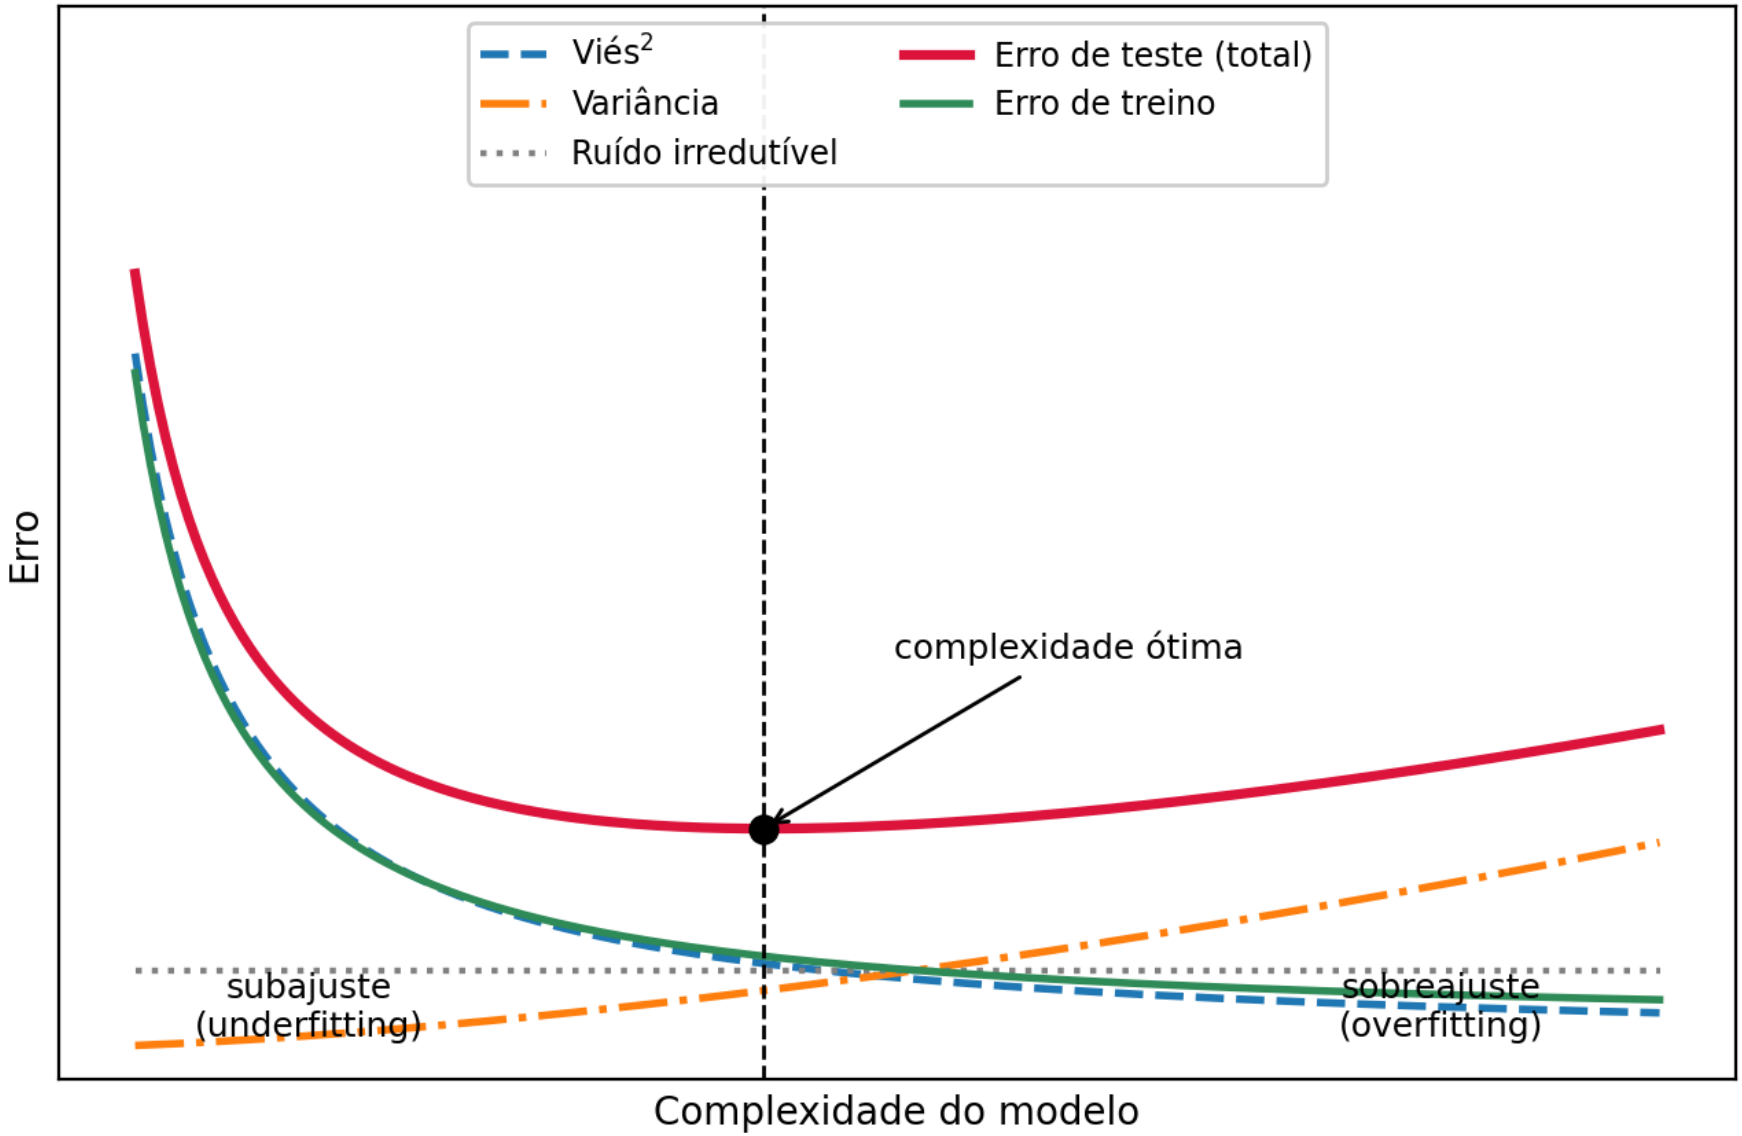
$$\mathbb{E}[\text{Erro}] = \underbrace{\text{Viés}^2}_{\text{suposições}} + \underbrace{\text{Variância}}_{\text{sensibilidade}} + \underbrace{\sigma^2}_{\text{ruído irredutível}}$$

- **Viés:** erro por suposições *simplistas demais*. O modelo é rígido e não captura o padrão real.
- **Variância:** erro devido a memorização do treino. O modelo não generaliza bem.
- **Ruído irredutível:** aleatoriedade do próprio problema – nenhum modelo elimina. É o piso do erro.

Dilema Viés-Variância

	Subajuste (*underfitting*)	**Sobreajuste** (*overfitting*)
Viés	alto	baixo
Variância	baixa	alta
Erro de treino	alto	**muito baixo**
Erro de teste	alto	alto
Sintoma	“não aprende”	“decora”

- **Diagnóstico rápido:** compare os dois erros.
  - treino alto *e* teste alto → subajuste;
  - treino baixo *e* teste alto → sobreajuste;
  - ambos baixos e próximos → bom equilíbrio.


Viés^2
Variância
Ruído irredutível
Erro de teste (total)
Erro de treino
Erro
complexidade ótima
subajuste
(underfitting)
sobreajuste
(overfitting)
Complexidade do modelo

Dilema Viés-Variância

Exemplos de situações em que o modelo tende a viés alto ou variância alta:

Tendem a viés alto

(subajuste)

- regressão linear / logística
- Naive Bayes
- árvores muito rasas
- k-NN com k grande
- modelos muito regularizados

Tendem a variância alta

(sobreajuste)

- árvores de decisão profundas
- k-NN com $k = 1$
- redes neurais grandes
- SVM com kernel muito flexível

Dilema Viés-Variância

Formas para controlar o viés e a variância do modelo:

- **Reduzir variância** (combater sobreajuste):
  - regularização (ℓ_1 / Lasso, ℓ_2 / Ridge, *dropout*);
  - poda de árvores, limitar profundidade;
  - *bagging* / Random Forest (média de modelos instáveis);
  - **mais dados de treino**.
- **Reduzir viés** (combater subajuste):
  - modelo mais complexo, mais atributos;
  - *boosting* (combina modelos fracos);
  - treinar por mais tempo / menos regularização.
- **Sempre:** usar **validação** para estimar honestamente o erro de generalização e localizar o mínimo do “U”.