

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR PAU DOS FERROS
CURSO DE ENGENHARIA DE COMPUTAÇÃO

PAM0466 – SISTEMAS INTELIGENTES

Introdução às Redes Neurais Artificiais

Prof. Dr. Pedro Thiago Valério de Souza
pedro.souza@ufersa.edu.br

Semestre de 2026.1

Introdução

- Redes Neurais Artificiais são modelos computacionais inspirados no sistema nervoso de seres vivos;
- Possuem a capacidade de aquisição e manutenção do conhecimento;
- Podem ser definidas como um conjunto de unidades de processamento, denominadas de neurônios;
- Os neurônios são interligados entre si de forma a gerar uma estrutura de rede;

Introdução

■ Características Principais:

- Adaptação por experiência: A rede é capaz de armazenar o conhecimento através da apresentação sucessiva de exemplos relacionados ao problema;
- Capacidade de aprendizado: Através de um método de treinamento, a rede consegue extrair as informações entre as diversas variáveis que compõem o problema;
- Habilidade de generalização: Após treinada, a rede é capaz de generalizar o conhecimento adquirido, estimando respostas para casos desconhecidos;

Introdução

■ Características Principais:

- Organização de dados: A rede é capaz de se organizar internamente visando possibilitar o agrupamento de padrões que possuem particularidades entre si;
- Armazenamento distribuído: O conhecimento a respeito de um problema é realizado de forma distribuída entre as ligações da rede;
- Facilidade de prototipagem: implementação fácil via *software* ou via *hardware*;

Introdução

■ **Potenciais Áreas de Aplicação:**

- Aproximador universal de funções;
- Reconhecimento/classificação de padrões;
- Agrupamento de dados (clusterização);
- Sistemas de previsão;
- Otimização de sistemas.


Neurônio Biológico

- A definição do neurônio biológico é importante para a definição do neurônio artificial;
- São as unidades elementares de processamento do cérebro humano;
- São unidades de processamento paralelo;
- São capazes de conduzir impulsos nervosos;

Neurônio Biológico

■ Composição de um neurônio biológico:


- Dendritos;
- Corpo Celular (soma);
- Axônio;



Neurônio Biológico

■ Composição de um neurônio biológico:


- Os dentritos tem como função captar os estímulos vindo de outros neurônios;



Neurônio Biológico

■ Composição de um neurônio biológico:


- O soma é responsável por realizar a função de processamento do neurônio.
- Ele é responsável por gerar um potencial de ativação e determinar se um neurônio poderá disparar um sinal elétrico ao longo do axônio;



Neurônio Biológico



■ Composição de um neurônio biológico:

- O axônio é responsável por conduzir o sinal elétrico do neurônio para outros neurônios;




Neurônio Biológico

- A ligação entre dois neurônios é denominado de sinapse;
- A sinapse é responsável por armazenar o conhecimento;



Neurônio Biológico

- O disparo de um neurônio depende dos potencial de ativação obtido no soma;
- Caso o potencial de ativação for maior que um determinado limiar (limiar de disparo), ocorre um disparo de um sinal elétrico que será transmitido ao longo do axônio do neurônio;




Neurônio Artificial

- São unidades básicas de processamento de uma rede neural;
- Constituem-se de modelos simplificados dos neurônios biológicos;
- Características:
 - Tipicamente não lineares;
 - Realizam funções simples, como coletar as entradas, realizar um processamento e gerar a saída.


Neurônio Artificial

- Modelo de neurônio mais usual: Modelo de McCulloch-Pitts (MCP);
 - Proposto em 1943;
 - Arquitetura simples – a saída é determinada por um produto escalar entre o vetor de entrada e um vetor de pesos;
 - Representação:



Neurônio Artificial

- Modelo MCP de neurônio artificial:



- Elementos básicos:


- Sinais de entrada $\{x_1, x_2, \dots, x_n\}$:

- Sinais provindos do meio externo;

- Equivalente aos dendritos em um neurônio biológico;

Neurônio Artificial

- Modelo MCP de neurônio artificial:




- Elementos básicos:

- Pesos sinápticos $\{w_1, w_2, \dots, w_n\}$:

- Ponderam cada entrada, permitindo quantificar a relevância de cada entrada na solução do problema;
 - Armazenam o conhecimento adquirido no processo de aprendizagem.

Neurônio Artificial

- Modelo MCP de neurônio artificial:




- Elementos básicos:

- Combinador linear $\{\Sigma\}$:

- Agrega todas os sinais de entrada ponderados;
 - Produz um potencial de ativação (u);
 - Equivale ao soma do neurônio biológico.

Neurônio Artificial

- Modelo MCP de neurônio artificial:




- Elementos básicos:

- Limiar de ativação $\{\theta\}$:

- Variável que especifica quando o potencial de ativação será suficiente para ativar o neurônio;
 - Também denominado de *bias*.

Neurônio Artificial

- Modelo MCP de neurônio artificial:




- Elementos básicos:

- Potencial de ativação $\{u\}$: Resultado obtido na saída do combinador linear;

$$u = \sum_{i=1}^n w_i x_i - \theta$$

Neurônio Artificial

- Modelo MCP de neurônio artificial:




- Elementos básicos:

- Função de ativação $\{g(\cdot)\}$;

- Limita a saída do neurônio a valores razoáveis;
 - A sua escolha depende da aplicação.

Neurônio Artificial

- Modelo MCP de neurônio artificial:



- Elementos básicos:


- Saída $\{y\}$: Consiste no valor final do neurônio, podendo ser utilizado como entrada em outros neurônios.

$$y = g(u) = g\left(\sum_{i=1}^n w_i x_i - \theta\right)$$

Neurônio Artificial

- **Modelo MCP de neurônio artificial:**

- Expressões vetoriais:



$$u = \sum_{i=1}^n w_i x_i - \theta = \mathbf{w}^T \mathbf{x}$$

$$y = g(u) = g(\mathbf{w}^T \mathbf{x})$$

$$\mathbf{w} = \begin{bmatrix} 1 & w_1 & w_2 & \cdots & w_n \end{bmatrix}^T$$


$$\mathbf{x} = \begin{bmatrix} 1 & x_1 & x_2 & \cdots & x_n \end{bmatrix}^T$$

Funções de Ativação

- Funções de ativação parcialmente diferenciáveis:

- Função Degrau:

$$g(u) = \mathbf{1}(u) = \begin{cases} 1 & u \geq 0 \\ 0 & u < 0 \end{cases}$$




Funções de Ativação

- Funções de ativação parcialmente diferenciáveis:

- Função Sinal:

$$g(u) = \text{sign}(u) = \begin{cases} +1 & u > 0 \\ 0 & u = 0 \\ -1 & u < 0 \end{cases}$$




Funções de Ativação

- Funções de ativação parcialmente diferenciáveis:

- Função rampa simétrica:

$$g(u) = \text{sign}(u) = \begin{cases} a & u > a \\ u & -a \leq u \leq a \\ -a & u < -a \end{cases}$$




Funções de Ativação

- Funções de ativação completamente diferenciáveis:

- Função logística:

$$g(u) = \frac{1}{1 + e^{-\beta u}}$$




Funções de Ativação

- Funções de ativação completamente diferenciáveis:

- Função tangente hiperbólica:

$$g(u) = \frac{1 - e^{-\beta u}}{1 + e^{-\beta u}}$$




Funções de Ativação

- Funções de ativação completamente diferenciáveis:

- Função gaussiana:

$$g(u) = \exp\left[-\frac{(u-c)^2}{2\sigma^2}\right]$$




- c : é o ponto médio (central);
 - σ^2 : é a variância (dispersão).

Funções de Ativação

- Funções de ativação completamente diferenciáveis:
 - Função linear:

$$g(u) = u$$




Arquiteturas de Redes Neurais Artificiais

- Redes *feedforward* de camada simples;
- Redes *feedforward* de múltiplas camadas;
- Redes recorrentes;
- Redes reticuladas.

Arquiteturas de Redes Neurais Artificiais

- Redes *feedforward* de camada simples:


- Possui apenas a camada de entrada e a camada de saída;



- Fluxo em apenas uma direção (*entradas* $\rightarrow$ *saídas*);

Arquiteturas de Redes Neurais Artificiais

- Redes *feedforward* de camada simples:




- A quantidade de saídas igual ao número de neurônios na camada de saída;
- Aplicações: classificação de padrões e filtragem linear;
- Principais redes: *Perceptron* e *Adaline*.

Arquiteturas de Redes Neurais Artificiais

- Redes *feedforward* de múltiplas camadas:


- Caracterizada pela presença das camadas de entrada, saídas e das camadas ocultas;



Arquiteturas de Redes Neurais Artificiais

■ Redes *feedforward* de múltiplas camadas:

- Fluxo em apenas uma direção (*entradas* → *saídas*);
- Aplicações: aproximação de funções, classificação de padrões, identificação de sistemas, otimização, robótica, controle de processos, etc.



Arquiteturas de Redes Neurais Artificiais


- **Redes *feedforward* de múltiplas camadas:**

- Principais redes: *Perceptron* de múltiplas camadas (MLP), redes de função de base radial (RBF) e redes convolucionais (CNN);
- Determinação do número de camadas ocultas e do número de neurônios por camadas:
 - Complexidade do problema a ser mapeado;
 - Qualidade e quantidade dos dados no treinamento.
- Observação: A quantidade de saídas igual ao número de neurônios na camada de saída;

Arquiteturas de Redes Neurais Artificiais

- **Rede recorrente (ou realimentada):**

- As saídas da rede são realimentadas como entrada para outros neurônios;



Arquiteturas de Redes Neurais Artificiais

- **Rede recorrente (ou realimentada):**

- A saída atual da rede depende da entrada atual e das saídas passadas;
- Aplicações: processamento dinâmico (previsão de séries temporais, identificação de sistemas, controle de processos);
- Principais redes: Hopfield e RNN.

Arquiteturas de Redes Neurais Artificiais

- **Rede em estrutura reticulada:**

- Possui uma disposição espacial dos neurônios;
- Aplicações: problemas de agrupamento, reconhecimento de padrões, otimização, grafos, etc.
- Principal rede: Rede de Kohonen.

