

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR PAU DOS FERROS
CURSO DE ENGENHARIA DE COMPUTAÇÃO

PAM0466 – SISTEMAS INTELIGENTES


Redes *Perceptron*

Prof. Dr. Pedro Thiago Valério de Souza
pedro.souza@ufersa.edu.br

Semestre de 2026.1


Conceitos Fundamentais da Rede *Perceptron*

- Rede neural proposta por Rosembat (1958);
- Configuração mais simples de uma rede neural artificial;
- Modelo computacional inspirado na retina humana;
 - Proposta inicial para identificar padrões geométricos;
- Concepção inicial:



Conceitos Fundamentais da Rede *Perceptron*

- Características gerais da rede *Perceptron*:
 - Arquitetura *feedforward* de camada única;
 - Quantidade de entradas: n entradas;
 - Apenas uma saída;



Conceitos Fundamentais da Rede *Perceptron*


- Características gerais da rede *Perceptron*:

- Vetor de pesos sinápticos: valores reais;

$$\mathbf{w} = [\theta \quad w_1 \quad w_2 \quad \cdots \quad w_n]^T$$

- Vetor de entradas: valores reais ou binários;


$$\mathbf{x} = [-1 \quad x_1 \quad x_2 \quad \cdots \quad x_n]^T$$



Conceitos Fundamentais da Rede *Perceptron*

- Características gerais da rede *Perceptron*:
 - Expressões de saída da rede *Perceptron*:

$$u = \sum_{i=0}^n w_i x_i = \mathbf{w}^T \mathbf{x} \qquad y = g(u)$$



Conceitos Fundamentais da Rede *Perceptron*

- Características gerais da rede *Perceptron*:

- Funções de ativação usuais:

- Função degrau unitário:

$$g(u) = \mathbf{1}(u) = \begin{cases} 1 & u \geq 0 \\ 0 & u < 0 \end{cases}$$

- Função sinal:

$$g(u) = \text{sign}(u) = \begin{cases} +1 & u > 0 \\ 0 & u = 0 \\ -1 & u < 0 \end{cases}$$

Conceitos Fundamentais da Rede *Perceptron*


- Características gerais da rede *Perceptron*:
 - Saída: apenas valores binários;
 - Processo de treinamento: supervisionado;
 - Necessita dos pares entrada e saída desejada;
 - Conjunto de treinamento: p amostras de treinamento;
 - Regra de aprendizado: algoritmo de Hebb.

Conceitos Fundamentais da Rede *Perceptron*

- Características gerais da rede *Perceptron*:
 - Utilização principal: classificação de padrões;
 - Saídas possíveis para a rede *Perceptron* (assumindo função de ativação sinal): $\{-1, 1\}$;
 - Dado duas classes, denominadas de **A** e **B** a serem classificadas, poderíamos fazer o seguinte mapeamento:
 - Classe **A**: saída 1;
 - Classe **B**: saída -1;

Análise Matemática da Rede *Perceptron*

- A rede *Perceptron* atua como um discriminador linear entre duas classes;
- Analise para uma rede com apenas duas entradas:



- Análise da saída:

$$y = g(u) = \begin{cases} +1 & u \geq 0 \\ -1 & u < 0 \end{cases}$$

$$u = \mathbf{w}^T \mathbf{x}$$

$$\mathbf{w} = [\theta \quad w_1 \quad w_2]^T$$

$$\mathbf{x} = [-1 \quad x_1 \quad x_2]^T$$

Análise Matemática da Rede *Perceptron*

- De forma sucinta:

$$u = w_1x_1 + w_2x_2 - \theta$$

$$y = \begin{cases} +1 & u \geq 0 \\ -1 & u < 0 \end{cases}$$

$$= \begin{cases} +1 & w_1x_1 + w_2x_2 - \theta \geq 0 \\ -1 & w_1x_1 + w_2x_2 - \theta < 0 \end{cases}$$

ou seja,

$$w_1x_1 + w_2x_2 - \theta < 0 \quad \Leftrightarrow \quad (x_1, x_2) \in B$$

$$w_1x_1 + w_2x_2 - \theta \geq 0 \quad \Leftrightarrow \quad (x_1, x_2) \in A$$

Análise Matemática da Rede *Perceptron*


- Essas desigualdades formam uma fronteira de decisão composta pela equação da reta:

$$w_1x_1 + w_2x_2 - \theta = 0$$

- Valores acima da reta (i.e. ≥ 0) correspondem à classe A;
- Valores abaixo da reta (i.e. < 0) correspondem à classe B;

Análise Matemática da Rede *Perceptron*


- Superfície de separação gerada pela rede *Perceptron*;



- O objetivo da rede *Perceptron* é gerar uma hiperplano de separação entre duas classes que sejam linearmente separáveis;

Análise Matemática da Rede *Perceptron*

- **Teorema da convergência do *Perceptron*:** padrões que não são linearmente separáveis não podem ser classificados utilizando a rede *Perceptron*;
- Limita a utilização deste tipo de rede a um conjunto pequeno de aplicações;



Treinamento da Rede *Perceptron*

- Aplicação de passos de forma a ajustar os pesos sinápticos da rede neural;
- Utiliza a regra de aprendizado de Hebb:
 - Treinamento supervisionado;
 - Princípio do treinamento:
 - Se a saída da rede *Perceptron* não está coincidente com a saída desejada, os pesos sinápticos são ajustados proporcionalmente aos sinais de entrada (*ação excitatória*);
 - Caso contrário (a saída da rede é igual a saída desejada), os pesos sinápticos permaneceram inalterados (*ação inibitória*);

Treinamento da Rede *Perceptron*

- A regra de Hebb pode ser resumida na seguinte expressão:

$$w_i^{\text{atual}} = w_i^{\text{anterior}} + \eta \left(y_d^{(k)} - y \right) x_i^{(k)} \quad \begin{array}{l} i = 0, 1, \dots, n \\ k = 1, 2, \dots, p \end{array}$$

em que:

- w_i^{atual} é o novo valor do peso sináptico associado a i -ésima entrada (contém n pesos);
- w_i^{anterior} é o valor antigo do peso associado a i -ésima entrada;
- $x_i^{(k)}$ é a i -ésima entrada da k -ésima posição do conjunto de treinamento (contém p amostras);

Treinamento da Rede *Perceptron*

- A regra de Hebb pode ser resumida na seguinte expressão:

$$w_i^{\text{atual}} = w_i^{\text{anterior}} + \eta \left(y_d^{(k)} - y \right) x_i^{(k)} \quad \begin{array}{l} i = 0, 1, \dots, n \\ k = 1, 2, \dots, p \end{array}$$

em que:

- $y_d^{(k)}$ é a k -ésima resposta desejada associada a entrada $x^{(k)}$ do conjunto de treinamento;
- y : saída do *Perceptron* após a aplicação da entrada $x^{(k)}$.
- η : é a constante de aprendizado;

Treinamento da Rede *Perceptron*

- Representação vetorial:

$$\mathbf{w} = \mathbf{w} + \eta \left(y_d^{(k)} - y \right) \mathbf{x}^{(k)}$$

em que:

$$\mathbf{w} = [\theta \quad w_1 \quad w_2 \quad \cdots \quad w_n]^T$$

$$\mathbf{x}^{(k)} = [-1 \quad x_1^{(k)} \quad x_2^{(k)} \quad \cdots \quad x_n^{(k)}]^T$$

Treinamento da Rede *Perceptron*

- O processo de ajuste dos pesos sinápticos segue até que a saída da rede *Perceptron* seja igual a saída desejada para todas as amostras do conjunto de treinamento;
- Influência da constante de aprendizado (η):
 - Exprime o quão rápido será o processo de treinamento da rede neural;
 - Para valores baixos, o processo de treinamento é lento, porém será bem estável;
 - Para valores altos, o processo de treinamento é rápido, porém está sujeito a instabilidades;
- Valores típicos: $0 < \eta < 1$;

Treinamento da Rede *Perceptron*


Início {Algoritmo Perceptron – Fase de Treinamento}

- <1> Obter o conjunto de amostras de treinamento $\{\mathbf{x}^{(k)}\}$
- <2> Associar a saída desejada $\{y_d^{(k)}\}$ para cada amostra obtida;
- <3> Iniciar o vetor $\mathbf{w}$ com valores aleatórios pequenos;
- <4> Especificar a taxa de aprendizagem $\{\eta\}$;
- <5> Iniciar o contador de número de épocas $\{\text{época} \leftarrow 0\}$;
- <6> Repetir as instruções:
 - <6.1> erro $\leftarrow$ “inexiste”;
 - <6.2> Para todas as amostras de treinamento $\{\mathbf{x}^{(k)}, y_d^{(k)}\}$ fazer:
 - <6.2.1> $u \leftarrow \mathbf{w}^T \mathbf{x}^{(k)}$
 - <6.2.2> $y \leftarrow \text{sinal}(u)$
 - <6.2.3> $y \neq y_d^{(k)}$, então:
 - <6.2.3.1> $\mathbf{w} \leftarrow \mathbf{w} + \eta(y_d^{(k)} - y)\mathbf{x}^{(k)}$
 - <6.2.3.2> erro $\leftarrow$ “existe”
 - <6.3> $\text{época} \leftarrow \text{época} + 1$
- Até que: erro = “inexiste”

Fim {Algoritmo Perceptron – Fase de Treinamento}


Treinamento da Rede *Perceptron*

- A variável *epoca* é responsável por contabilizar quantas épocas são necessárias para o treinamento da rede;
- O processo de treinamento da rede *Perceptron* consiste em mover um hiperplano de separação que permite dividir duas classes;



Treinamento da Rede *Perceptron*

- Existe uma infinidade de hiperplanos que separam duas classes linearmente separáveis;
- Os pesos sinápticos obtidos após o treinamento não são únicos;



Operação da Rede *Perceptron*

- Após treinada (obtido o valor dos pesos), a rede *Perceptron* está apta para proceder com a tarefa de classificação dos padrões:

Início {Algoritmo Perceptron – Fase de Classificação}

- <1> Obter uma nova amostra a ser classificada $\{\mathbf{x}\}$
- <2> Utilizar o vetor $\mathbf{w}$ ajustado durante o treinamento
- <3> Executar as seguintes ações:
 - <3.1> $u \leftarrow \mathbf{w}^T \mathbf{x}$
 - <3.2> $y \leftarrow \text{sinal}(u)$
 - <3.3> Se $y = +1$, então amostra $\mathbf{x} \in \{\text{Classe A}\}$
 - <3.4> Se $y = -1$, então amostra $\mathbf{x} \in \{\text{Classe B}\}$

Fim {Algoritmo Perceptron – Fase de Classificação}

Aspectos Práticos das Redes *Perceptron*

- A rede divergirá se o problema for não linearmente separável.
 - Deve-se limitar o processo de aprendizagem por um número máximo de épocas de treinamento;
- Quando a faixa de separabilidade entre as duas classes for estreita, deve-se utilizar uma taxa de aprendizado pequena, de forma que a busca do hiperplano ocorra de forma suave;

Aspectos Práticos das Redes *Perceptron*

- A quantidade de épocas necessárias para a convergência da rede depende:
 - Dos valores iniciais do vetor de pesos da rede;
 - Da disposição das amostras de treinamento;
 - Da constante de aprendizagem;
- A normalização das entradas contribui para incrementar o desempenho do treinamento;
- Recomenda-se embaralhar a ordem de apresentação dos exemplos no processo de treinamento.