

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS (CMPF)
DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA (DETEC)

SISTEMAS INTELIGENTES

Regressão Linear

Prof. Pedro Thiago Valério de Souza
UFERSA – Campus Pau dos Ferros
pedro.souza@ufersa.edu.br

Introdução

- A regressão linear é um modelo estatístico utilizado para entender a relação entre variáveis.
- Utiliza um modelo linear (reta ou hiperplano) para aproximar a relação entre as variáveis.
- Resolve problema de **aprendizado supervisionado** de **regressão**: a saída desejada é uma variável contínua.
- É amplamente utilizada para **prever valores numéricos** a partir de uma ou mais características.
  - Exemplo: prever o nível de satisfação de vida de uma população em função do PIB de um país.
- Tipos de Regressão Linear:
  - **Regressão linear simples**: o modelo utiliza apenas *uma* variável independente.
  - **Regressão linear múltipla**: o modelo utiliza *duas ou mais* variáveis independentes.

Modelo	Forma
Simples	$y = \theta_0 + \theta_1 x + \epsilon$
Múltipla	$y = \theta_0 + \theta_1 x_1 + \cdots + \theta_p x_p + \epsilon$

Regressão Linear Simples

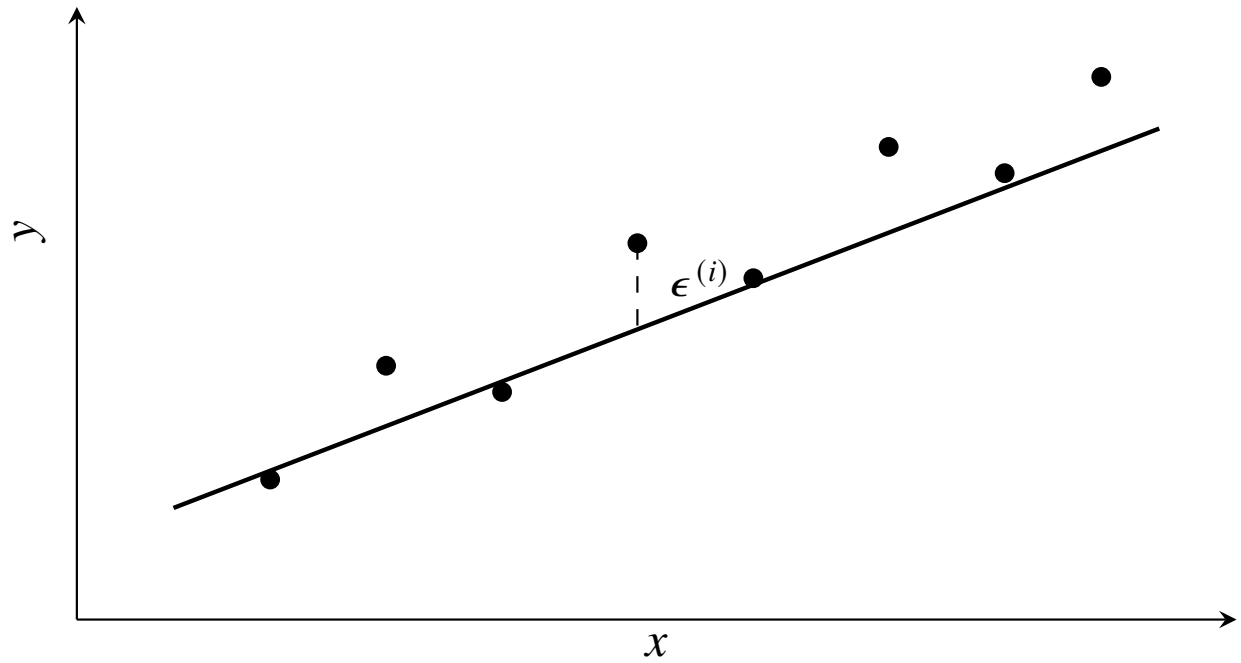
A regressão linear simples busca modelar a relação entre duas variáveis, x e y, em que $y = f(x)$:

$$y = \theta_0 + \theta_1 x + \epsilon$$

- x: variável independente (características ou *features*);
- y: variável dependente (valor que desejamos aproximar ou prever);
- θ_0: coeficiente linear da reta (intercepto);
- θ_1: coeficiente angular da reta;
- ϵ: erro (ou resíduo) da aproximação.
  - O erro representa tudo aquilo que o modelo não consegue explicar: fatores não incluídos, imprecisões de medição e aleatoriedade.
  - Exemplo: Ao prever o gasto com alimentação de várias famílias com base na renda delas, o erro é a diferença entre o valor previsto pelo modelo e o valor que a família realmente gastou.

Regressão Linear Simples

Interpretação Geométrica:



A reta ajustada $\hat{y} = \hat{\theta}_0 + \hat{\theta}_1 x$ é aquela que torna os resíduos, no conjunto, os menores possíveis.

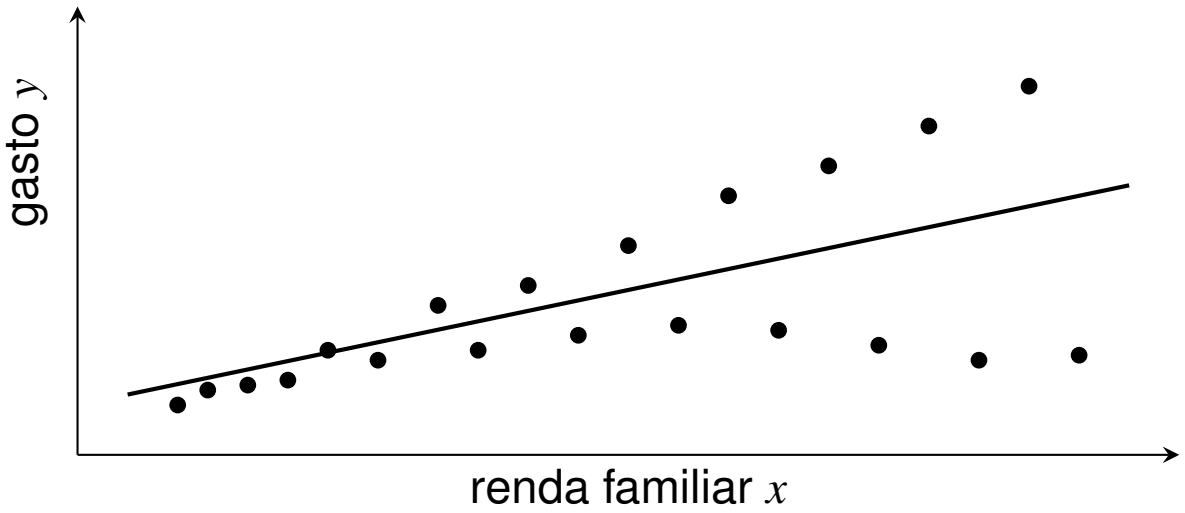
Regressão Linear Simples

Suposições do Modelo:

- **Linearidade**: A relação entre a variável dependente y e a variável independente x é linear ou aproximadamente linear.
- **Independência dos erros**: Os erros (ϵ) são independentes entre si (o erro de uma observação não deve depender do erro de outra observação).
- **Homocedasticidade**: A variância dos erros é constante para todos os valores de x.
  - No exemplo do gasto com alimentação em função da renda, um modelo homocedástico apresenta erros com a mesma dispersão, independentemente de a família ser rica ou pobre.
- **Normalidade dos erros**: Os erros seguem uma distribuição normal.

Regressão Linear Simples

Suponha que desejamos prever o **gasto mensal com alimentação** (y) em função da **renda familiar** (x).



- Famílias de baixa renda têm pouca margem de escolha: gastam quase tudo com o essencial e os pontos ficam próximos da reta.
- Famílias de alta renda podem cozinhar em casa ou comer fora todos os dias: a dispersão em torno da reta cresce.

Regressão Linear Simples

Quando a variância do erro depende de x, dizemos que o modelo é **heterocedástico**:

$$\text{Var}(\epsilon \mid x) = \sigma^2(x) \neq \text{constante}$$

- As estimativas de $\hat{\theta}_0$ e $\hat{\theta}_1$ continuam não enviesadas, mas deixam de ser as de menor variância.
- Como identificar: observando o gráfico dos resíduos em função de x (ou de $\hat{y}$): um formato de “funil” ou “cone” indica heterocedasticidade.

Regressão Linear Simples

Estimativa dos Parâmetros:

- Método mais comum: **Mínimos Quadrados Ordinários** (MMQ).
- Ideia: minimizar a soma dos quadrados das diferenças entre os valores observados y e os valores ajustados $\hat{y}$.

$$J(\theta_0,\theta_1) = \sum_{i=1}^{N} \left(y^{(i)} - \hat{y}^{(i)} \right)^2$$

em que N é o número de amostras do conjunto de treinamento $\left\{x^{(i)},y^{(i)}\right\}_{i=1,\ldots,N}$ e $\hat{y}^{(i)}$ é o valor previsto pelo modelo quando a entrada $x^{(i)}$ é aplicada:

$$\hat{y}^{(i)} = \hat{\theta}_0 + \hat{\theta}_1 x^{(i)}$$

Regressão Linear Simples

Estimativa dos Parâmetros: Substituindo a expressão de $\hat{y}^{(i)}$, a função a ser minimizada torna-se:

$$J(\hat{\theta}_0,\hat{\theta}_1) = \sum_{i=1}^{N} \left(y^{(i)} - \left(\hat{\theta}_0 + \hat{\theta}_1 x^{(i)} \right) \right)^2$$

- $\hat{\theta}_0$ e $\hat{\theta}_1$ são os valores estimados para θ_0 e θ_1.
- J é uma função quadrática dos parâmetros, portanto convexa: possui um único ponto de mínimo.
- Os desvios são elevados ao quadrado para que erros positivos e negativos não se cancelem e para penalizar mais fortemente os desvios grandes.

Regressão Linear Simples

Estimativa dos Parâmetros: Para encontrar o ponto de mínimo, calculamos a derivada parcial de J em relação a cada parâmetro e igualamos a zero.

Em relação a $\hat{\theta}_0$:

$$\frac{\partial J(\hat{\theta}_0,\hat{\theta}_1)}{\partial \hat{\theta}_0} = -2 \sum_{i=1}^{N} \left(y^{(i)} - \hat{\theta}_0 - \hat{\theta}_1 x^{(i)} \right) = 0$$

Em relação a $\hat{\theta}_1$:

$$\frac{\partial J(\hat{\theta}_0,\hat{\theta}_1)}{\partial \hat{\theta}_1} = -2 \sum_{i=1}^{N} x^{(i)} \left(y^{(i)} - \hat{\theta}_0 - \hat{\theta}_1 x^{(i)} \right) = 0$$

Regressão Linear Simples

Estimativa dos Parâmetros: A estimativa para o coeficiente angular é:

$$\hat{\theta}_1 = \frac{\sum_{i=1}^{N} \left(x^{(i)} - \bar{x}\right)\left(y^{(i)} - \bar{y}\right)}{\sum_{i=1}^{N} \left(x^{(i)} - \bar{x}\right)^2}$$

em que $\bar{x}$ e $\bar{y}$ são as médias dos conjuntos de dados x e y. Após calcular $\hat{\theta}_1$, o intercepto é determinado como:

$$\hat{\theta}_0 = \bar{y} - \hat{\theta}_1 \bar{x}$$

Regressão Linear Simples

Estimativa dos Parâmetros:

- A solução é **fechada**: não há necessidade de processo iterativo.
- A expressão de $\hat{\theta}_0$ mostra que a reta ajustada sempre passa pelo ponto $(\bar{x},\bar{y})$.
- Se x for constante, o denominador se anula e o modelo não é definido.

Regressão Linear Múltipla

Extensão do modelo simples, em que a variável dependente é explicada por mais de uma variável independente:

$$y = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_p x_p + \epsilon$$

- $x_1, x_2, \ldots, x_p$: variáveis independentes (características ou *features*);
- y: variável dependente;
- θ_0: coeficiente linear (intercepto);
- $\theta_1, \theta_2, \ldots, \theta_p$: coeficientes que representam o impacto de cada variável independente em y;
- ϵ: erro (ou resíduo) da aproximação.

Regressão Linear Múltipla

Interpretação dos Coeficientes:

- Cada θ_j indica a variação esperada em y quando x_j aumenta em uma unidade, **mantidas as demais variáveis constantes**.
- Geometricamente, o modelo deixa de ser uma reta e passa a ser um *hiperplano* no espaço de $p + 1$ dimensões.
- A magnitude dos coeficientes só é diretamente comparável se as variáveis estiverem em escalas equivalentes.

Regressão Linear Múltipla

Pressupostos do Modelo:

- **Pressupostos herdados do modelo simples:** linearidade, independência dos erros, homocedasticidade e normalidade dos erros.
- **Exogeneidade das variáveis independentes**: As variáveis independentes não devem ter nenhuma relação com o erro do modelo,

$$E(\epsilon \mid X) = 0$$

  em que $E(\cdot \mid X)$ é a média condicional dado um valor X. Não importa o valor que X assuma, a média dos erros deve ser sempre zero. Se houver correlação entre X e o erro, dizemos que a variável é **endógena**.
- **Ausência de multicolinearidade:** A multicolinearidade ocorre quando há alta correlação entre duas ou mais variáveis independentes do modelo.
  - Variáveis muito relacionadas entre si carregam informação redundante.
  - Nesse caso, a atribuição do efeito de cada variável sobre y torna-se ambígua e os coeficientes ficam instáveis.

Regressão Linear Múltipla

Estimativa dos Parâmetros: Assim como na regressão linear simples, minimizamos a soma dos quadrados das diferenças entre os valores observados e os valores ajustados. Em forma matricial:

$$J(\mathbf{\Phi}) = (\mathbf{Y} - \mathbf{X}\mathbf{\Phi})^T (\mathbf{Y} - \mathbf{X}\mathbf{\Phi})$$

- $\mathbf{Y}$: vetor coluna de observações da variável dependente, de tamanho $(N \times 1)$;
- $\mathbf{X}$: matriz de delineamento, de tamanho $(N \times (p+1))$, cuja primeira coluna é preenchida por 1s (para o intercepto θ_0) e as demais colunas são as observações de $x_1, \ldots, x_p$;
- $\mathbf{\Phi}$: vetor de parâmetros $[\theta_0, \theta_1, \ldots, \theta_p]^T$, de tamanho $((p+1) \times 1)$.

Regressão Linear Múltipla

Estimativa dos Parâmetros:

$$\mathbf{Y} = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(N)} \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_p^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_p^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(N)} & \cdots & x_p^{(N)} \end{bmatrix}, \quad \mathbf{\Phi} = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_p \end{bmatrix}$$

A coluna de 1s permite tratar o intercepto como mais um coeficiente do vetor $\mathbf{\Phi}$.

Para minimizar a função de custo $J(\mathbf{\Phi})$, derivamos a expressão em relação a $\mathbf{\Phi}$ e igualamos a zero. O resultado desse processo de otimização é a chamada **Equação Normal**:

$$\mathbf{\Phi} = \left(\mathbf{X}^T\mathbf{X}\right)^{-1}\mathbf{X}^T\mathbf{Y}$$

- Fornece a solução exata em uma única operação.
- Exige que $\mathbf{X}^T\mathbf{X}$ seja inversível, o que falha na presença de multicolinearidade perfeita.
- O custo computacional da inversão cresce rapidamente com o número de variáveis p.

Método do Gradiente Descendente

A Equação Normal fornece a solução exata, mas apresenta limitações:

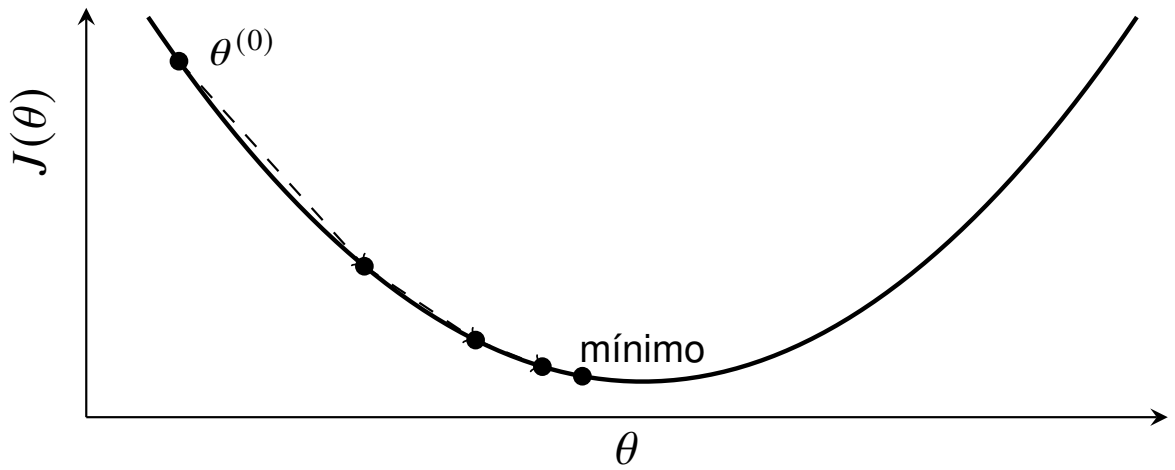
- Exige a inversão de $\mathbf{X}^T\mathbf{X}$, torna-se proibitiva quando o número de variáveis é grande.
- A matriz $\mathbf{X}^T\mathbf{X}$ pode ser singular (não inversível) na presença de multicolinearidade.
- Exige que todo o conjunto de dados esteja em memória de uma só vez.
- Nem toda função de custo possui solução fechada (é o caso da regularização Lasso).

Alternativa: a partir de uma estimativa inicial qualquer e *refiná-la iterativamente* até atingir o mínimo da função de custo.

Método do Gradiente Descendente

Ideia Geral:

- O gradiente ∇J aponta na direção de **maior crescimento** da função de custo.
- Portanto, para *minimizar* J, devemos caminhar no **sentido oposto** ao do gradiente.
- Repetindo esse passo várias vezes, os parâmetros convergem para o ponto de mínimo.



Método do Gradiente Descendente

A cada iteração k, todos os parâmetros são atualizados simultaneamente:

$$\theta_j^{(k+1)} = \theta_j^{(k)} - \eta \frac{\partial J}{\partial \theta_j}, \qquad j = 0,1,\ldots,p$$

- η é a **taxa de aprendizagem** (*learning rate*): controla o tamanho do passo dado a cada iteração.
- O sinal negativo garante que o passo seja dado no sentido de descida.
- Quanto mais próximo do mínimo, menor o valor do gradiente e, portanto, menores os passos.

Atenção

A atualização deve usar os valores de θ da iteração k para calcular *todas* as derivadas antes de substituí-los.

Método do Gradiente Descendente

Método do Gradiente em Regressão Linear Simples: Usando a função de custo na forma média (o que não altera o ponto de mínimo, apenas a escala),

$$J(\theta_0,\theta_1) = \frac{1}{N}\sum_{i=1}^{N}\left(y^{(i)} - \hat{y}^{(i)}\right)^2, \qquad \hat{y}^{(i)} = \theta_0 + \theta_1 x^{(i)}$$

As derivadas parciais são:

$$\frac{\partial J(\theta_0,\theta_1)}{\partial \theta_0} = -\frac{2}{N}\sum_{i=1}^{N}\left(y^{(i)} - \hat{y}^{(i)}\right)$$

$$\frac{\partial J(\theta_0,\theta_1)}{\partial \theta_1} = -\frac{2}{N}\sum_{i=1}^{N} x^{(i)}\left(y^{(i)} - \hat{y}^{(i)}\right)$$

Método do Gradiente Descendente

Método do Gradiente em Regressão Linear Simples: Substituindo os gradientes na regra de atualização,

$$\theta_0^{(k+1)} = \theta_0^{(k)} + \frac{2\eta}{N} \sum_{i=1}^{N} \left(y^{(i)} - \hat{y}^{(i)} \right)$$

$$\theta_1^{(k+1)} = \theta_1^{(k)} + \frac{2\eta}{N} \sum_{i=1}^{N} x^{(i)} \left(y^{(i)} - \hat{y}^{(i)} \right)$$

Método do Gradiente Descendente

Método do Gradiente em Regressão Linear Multipla: Para a regressão linear múltipla, todos os parâmetros são atualizados de uma só vez,

$$\nabla J(\mathbf{\Phi}) = -\frac{2}{N}\,\mathbf{X}^T\,(\mathbf{Y} - \mathbf{X}\mathbf{\Phi})$$

$$\mathbf{\Phi}^{(k+1)} = \mathbf{\Phi}^{(k)} + \frac{2\eta}{N}\,\mathbf{X}^T\left(\mathbf{Y} - \mathbf{X}\mathbf{\Phi}^{(k)}\right)$$

- $\mathbf{Y} - \mathbf{X}\mathbf{\Phi}$ é o vetor de resíduos, de tamanho $(N \times 1)$.
- $\mathbf{X}^T$ projeta esses resíduos sobre cada variável, gerando um vetor de correções de tamanho $((p+1) \times 1)$.
- Cada iteração custa apenas produtos matriz–vetor: não há inversão de matriz.

Método do Gradiente Descendente

- Número máximo de iterações (ou *épocas*) atingido.
- Norma do gradiente menor que uma tolerância: $\|\nabla J(\mathbf{\Phi})\| < \varepsilon$.
- Variação da função de custo entre iterações consecutivas menor que uma tolerância:

$$\left| J(\mathbf{\Phi}^{(k+1)}) - J(\mathbf{\Phi}^{(k)}) \right| < \varepsilon$$

- Variação dos próprios parâmetros abaixo de uma tolerância.

Na prática, é comum registrar o valor de J a cada iteração e verificar a chamada **curva de aprendizagem**: ela deve ser monotonicamente decrescente.

Método do Gradiente Descendente

Algoritmo 1 Gradiente descendente em lote (*batch*)

Entrada: matriz $\mathbf{X}$, vetor $\mathbf{Y}$, taxa de aprendizagem η, número máximo de iterações K, tolerância ε

Saída: vetor de parâmetros $\mathbf{\Phi}$

$\mathbf{\Phi} \leftarrow \mathbf{0}$ $k \leftarrow 0$

repita

- $\hat{\mathbf{Y}} \leftarrow \mathbf{X}\mathbf{\Phi}$ // predições
- $\mathbf{R} \leftarrow \mathbf{Y} - \hat{\mathbf{Y}}$ // resíduos
- $\nabla J(\mathbf{\Phi}) \leftarrow -\frac{2}{N}\mathbf{X}^T\mathbf{R}$ // gradiente
- $\mathbf{\Phi} \leftarrow \mathbf{\Phi} - \eta\,\nabla J(\mathbf{\Phi})$ // atualização
- $k \leftarrow k + 1$

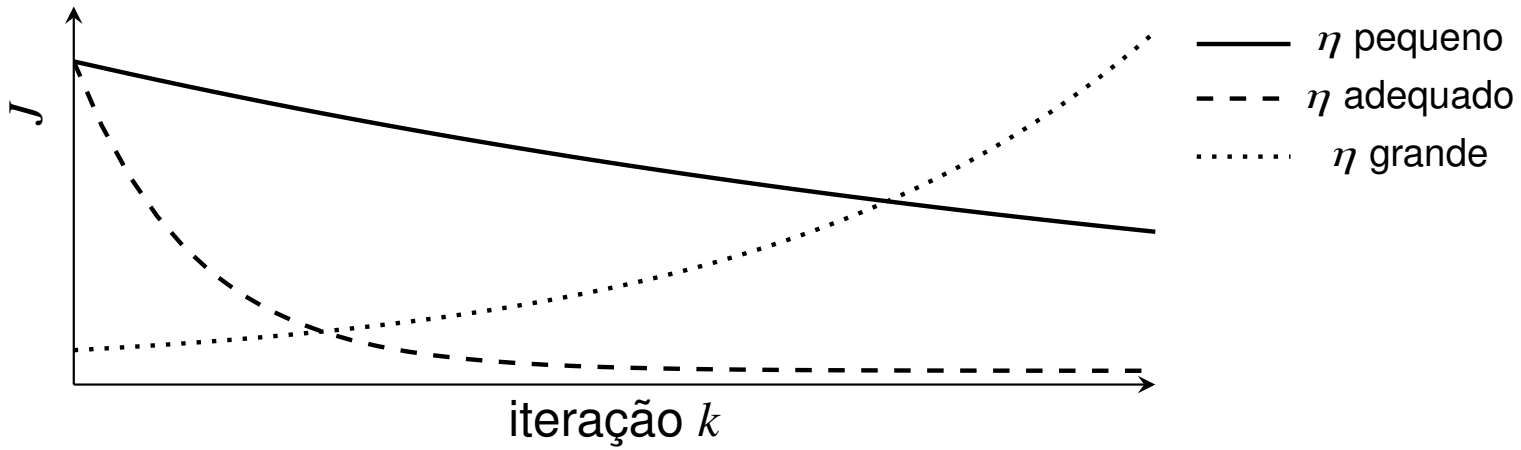
até $k = K$ *ou* $\|\nabla J(\mathbf{\Phi})\| < \varepsilon$

retorna $\mathbf{\Phi}$

Método do Gradiente Descendente

Influência da Taxa de Aprendizagem:

- η **muito pequeno**: os passos são minúsculos e a convergência exige um número enorme de iterações.
- η **muito grande**: o algoritmo ultrapassa o mínimo a cada passo, oscilando ou até divergindo (a função de custo cresce indefinidamente).
- η **adequado**: a função de custo decresce de forma suave e rápida.



Método do Gradiente Descendente

Variantes do Método do Gradiente Descendente:

- **Em lote** (*batch*): usa todas as N amostras para calcular cada gradiente. Passos estáveis, porém caros quando N é grande.
- **Estocástico** (SGD): usa uma única amostra por atualização. Muito rápido e capaz de escapar de mínimos locais, mas a trajetória é ruidosa.
- **Mini-lote** (*mini-batch*): usa subconjuntos de amostras. Compromisso entre estabilidade e custo computacional; é a opção mais usada na prática.

Observação: Como a função de custo da regressão linear é convexa, existe um único mínimo global: qualquer uma das variantes converge para a mesma solução, desde que η seja adequado.

Método do Gradiente Descendente

Equação Normal $\times$ Gradiente Descendente:

	Equação Normal	**Gradiente Descendente**
Natureza	Solução fechada	Solução iterativa
Hiper-parâmetros	Nenhum	η, número de iterações
Custo	Alto com muitas variáveis (inversão)	Escala bem com p e N
Requisitos	$\mathbf{X}^T\mathbf{X}$ inversível	Função de custo diferenciável
Resultado	Exato	Aproximado

Regularização

- Em modelos de regressão linear, o objetivo é minimizar a soma dos quadrados dos resíduos.
- No entanto, se o modelo for muito complexo (muitas variáveis ou coeficientes muito altos), ele pode “decorar” o ruído dos dados de treino: ***overfitting***.
- Nesse caso, o desempenho no conjunto de treinamento é excelente, mas a capacidade de generalização é baixa.
- **Ideia da Regularização:** adicionar uma penalidade ao tamanho dos coeficientes. Assim, o modelo é forçado a manter os pesos baixos, priorizando apenas as variáveis mais importantes.

Regularização

A função de custo regularizada tem a forma:

$$J_{\text{reg}}(\mathbf{\Phi}) = \underbrace{J(\mathbf{\Phi})}_{\text{ajuste aos dados}} + \underbrace{\alpha \cdot \text{penalidade}(\mathbf{\Phi})}_{\text{complexidade do modelo}}$$

- Existe um compromisso entre ajustar bem os dados e manter o modelo simples.
- O hiperparâmetro α controla o peso relativo entre esses dois termos.

Regularização

Regularização Ridge (L_2): Na regularização Ridge, um termo $\frac{\alpha}{2}\sum_{i=1}^{p}\theta_i^2$ é adicionado à função de custo,

$$J_{\text{reg}}(\mathbf{\Phi}) = J(\mathbf{\Phi}) + \frac{\alpha}{2}\sum_{i=1}^{p}\theta_i^2$$

- Como os coeficientes são elevados ao quadrado, a penalidade cresce rapidamente para valores grandes dos coeficientes.
- α é um hiperparâmetro que ajusta a quantidade de regularização.
- Se $\alpha = 0$, a regularização é nula e temos uma regressão linear convencional.

Regularização

Regularização Ridge (L_2): A equação normal para a regularização Ridge é:

$$\mathbf{\Phi} = \left(\mathbf{X}^T\mathbf{X} + \alpha\mathbf{I}\right)^{-1}\mathbf{X}^T\mathbf{Y}$$

em que $\mathbf{I}$ é uma matriz identidade de dimensão $(p+1) \times (p+1)$.

- A Ridge preserva a solução em **forma fechada**.
- O termo $\alpha\mathbf{I}$ também torna a matriz inversível mesmo em situações de multicolinearidade.
- Os coeficientes são reduzidos em direção a zero, mas em geral não se anulam exatamente.

Regularização

Regularização Lasso (L_1): Na regularização Lasso, um termo $\alpha \sum_{i=1}^{p} |\theta_i|$ é adicionado à função de custo:

$$J_{\text{reg}}(\mathbf{\Phi}) = J(\mathbf{\Phi}) + \alpha \sum_{i=1}^{p} |\theta_i|$$

- A geometria da regularização L_1 possui "quinas" nos eixos. Isso faz com que, durante a otimização, muitos coeficientes sejam forçados a ser exatamente zero.
- É, portanto, uma forma de **seleção de variáveis**.
- Diferentemente da L_2, a Lasso não possui fórmula fechada (analítica) para estimativa dos coeficientes, sendo necessário um algoritmo recursivo para minimização da função de custo.

Regularização

Regularização Ridge vs Lasso:

	Ridge (L_2)	**Lasso (L_1)**
Penalidade	$\frac{\alpha}{2} \sum \theta_i^2$	$\alpha \sum \lvert\theta_i\rvert$
Solução	Fórmula fechada	Algoritmo iterativo
Coeficientes	Reduzidos, mas não nulos	Muitos exatamente nulos
Uso típico	Variáveis correlacionadas	Seleção de variáveis

Regularização

O Papel do Hiperparâmetro α:

- $\alpha = 0$: nenhuma penalidade; recupera-se a regressão linear convencional, com risco de *overfitting*.
- α pequeno: leve redução dos coeficientes; o ajuste aos dados ainda predomina.
- α grande: forte penalização; os coeficientes tendem a zero e o modelo perde capacidade de representação (*underfitting*).
- $\alpha \to \infty$: todos os coeficientes tendem a zero e a predição se aproxima de uma constante.

A escolha de α é feita experimentalmente, com apoio de um conjunto de validação.