

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR PAU DOS FERROS
CURSO DE ENGENHARIA DE COMPUTAÇÃO

PAM0466 – SISTEMAS INTELIGENTES

Redes *Adaline*

Prof. Dr. Pedro Thiago Valério de Souza
pedro.souza@ufersa.edu.br


Semestre de 2026.1

Conceitos Fundamentais da Rede *Adaline*

- Rede neural proposta por Widrow-Hoff em 1960;
- Aplicação inicial: chaveamento de circuitos telefônicos;
 - Primeira aplicação industrial de uma RNA;
- Principais contribuições da rede *Adaline*:
 - Desenvolvimento do algoritmo de aprendizado regra Delta;
 - Utilizado em outras redes neurais mais avançadas, como a rede *Perceptron* de múltiplas camadas;
 - Aplicações em diversos problemas práticos envolvendo processamento de sinais analógicos;

Conceitos Fundamentais da Rede *Adaline*

- Características gerais da rede *Adaline*:
 - Arquitetura *feedforward* de camada única;
 - Quantidade de entradas: n entradas;
 - Apenas uma saída;
 - Redes com mais de uma saída: Madaline;



Conceitos Fundamentais da Rede *Adaline*


- Características gerais da rede *Adaline*:

- Pesos sinápticos: valores reais;

$$\mathbf{w} = [\theta \quad w_1 \quad w_2 \quad \cdots \quad w_n]^T$$

- Vetor de entradas: valores binários ou reais;


$$\mathbf{x} = [-1 \quad x_1 \quad x_2 \quad \cdots \quad x_n]^T$$



Conceitos Fundamentais da Rede *Adaline*

- Características gerais da rede *Adaline*:
 - Expressões de saída da rede *Adaline*:

$$u = \sum_{i=0}^n w_i x_i = \mathbf{w}^T \mathbf{x} \qquad y = g(u)$$



Conceitos Fundamentais da Rede *Adaline*

- Características gerais da rede *Adaline*:
 - Funções de ativação usuais: degrau unitário ou função sinal;
 - Saída: valores binários;
 - Processo de treinamento: supervisionado;


Conceitos Fundamentais da Rede *Adaline*

- Características gerais da rede *Adaline*:
 - Regra de aprendizado: regra delta (LMS ou algoritmo de Widrow-Hoff);
 - Principal diferença entre a rede *Perceptron* e a rede *Adaline*;
 - Utilização principal: classificação de padrões;

Conceitos Fundamentais da Rede *Adaline*

- Características gerais da rede *Adaline*:
 - Função do bloco associador: gerar um sinal de erro necessário para o processo de treinamento;
 - Diferença entre a resposta desejada e o *potencial de ativação*;

$$e = y_d - y$$



Processo de Treinamento do *Adaline*

- Ideia básica do processo de treinamento do *Adaline*:
 - Ajustar os pesos do neurônio de forma a minimizar o erro entre a saída desejada $\{y_d\}$ e as respostas do combinador linear $\{u\}$, considerando-se para tanto todas as p amostras do conjunto de treinamento;
 - Consiste em um processo de minimização de uma função;
 - Soma dos erro quadráticos;

$$E(\mathbf{w}) = \frac{1}{2} \sum_{k=1}^p \left(y_d^{(k)} - u \right)^2$$

Processo de Treinamento do *Adaline*

- Ideia básica do processo de treinamento do *Adaline*:
 - Matematicamente temos:

$$\min_{\mathbf{w}} E(\mathbf{w}) = \frac{1}{2} \sum_{k=1}^p \left(y_d^{(k)} - u \right)^2$$

- Principal método: algoritmo do gradiente descendente:

$$\mathbf{w}^{\text{atual}} = \mathbf{w}^{\text{anterior}} - \eta \frac{\partial E(\mathbf{w})}{\partial \mathbf{w}}$$

Processo de Treinamento do *Adaline*

- A aplicação do método do gradiente leva as seguintes equações de atualização dos pesos sinápticos:

- Modo *Batch (off-line)*:

$$\mathbf{w}^{\text{atual}} = \mathbf{w}^{\text{anterior}} + \eta \sum_{k=1}^p \left(y_d^{(k)} - u \right) \mathbf{x}^{(k)}$$

- Modo *on-line*:

$$\mathbf{w}^{\text{atual}} = \mathbf{w}^{\text{anterior}} + \eta \left(y_d^{(k)} - u \right) \mathbf{x}^{(k)} \quad k = 1, 2, \dots, p$$

Processo de Treinamento do *Adaline*

- Influência da constante de aprendizado (η): determina a rapidez do treinamento da rede neural;
 - Valores baixos: lento e estável;
 - Valores altos: rápidos e instável;
 - Valores típicos: $0 < \eta < 1$;
- Critério de parada: em função do erro quadrático médio;

$$\text{MSE}(\mathbf{w}) = \frac{1}{p} \sum_{k=1}^p \left(y_d^{(k)} - u \right)^2$$

- O Algoritmo converge se a diferença entre o EQM entre duas épocas for suficientemente pequeno, i.e:

$$\left| \text{MSE}(\mathbf{w}^{\text{atual}}) - \text{MSE}(\mathbf{w}^{\text{anterior}}) \right| \leq \varepsilon$$

Processo de Treinamento do *Adaline*


Início {Algoritmo *Adaline* – Fase de Treinamento}

- <1> Obter o conjunto de amostras de treinamento $\{\mathbf{x}^{(k)}\}$
 - <2> Associar a saída desejada $\{y_d^{(k)}\}$ para cada amostra obtida;
 - <3> Iniciar o vetor $\mathbf{w}$ com valores aleatórios pequenos;
 - <4> Especificar a taxa de aprendizagem $\{\eta\}$ e a precisão requerida $\{\varepsilon\}$;
 - <5> Iniciar o contador de número de épocas $\{\text{época} \leftarrow 0\}$;
 - <6> Repetir as instruções:
 - <6.1> $E^{\text{anterior}} = \text{MSE}(\mathbf{w})$
 - <6.2> Para todas as amostras de treinamento $\{\mathbf{x}^{(k)}, y_d^{(k)}\}$ fazer:
 - <6.2.1> $u \leftarrow \mathbf{w}^T \mathbf{x}^{(k)}$
 - <6.2.2> $\mathbf{w} \leftarrow \mathbf{w} + \eta(y_d^{(k)} - u)\mathbf{x}^{(k)}$
 - <6.3> $\text{época} \leftarrow \text{época} + 1$
 - <6.4> $E^{\text{atual}} \leftarrow \text{MSE}(\mathbf{w})$
- Até que: $|E^{\text{atual}} - E^{\text{anterior}}| \leq \varepsilon$

Fim {Algoritmo *Adaline* – Fase de Treinamento}

Processo de Treinamento do *Adaline*

- Curva do erro quadrático médio em função das épocas do treinamento: função monotonamente decrescente;



Fase de Operação da Rede *Adaline*

- Após treinada (obtido o valor dos pesos), a rede *Adaline* está apta para proceder com a tarefa de classificação dos padrões



Início {Algoritmo Adaline – Fase de Classificação}

- <1> Obter uma nova amostra a ser classificada $\{\mathbf{x}\}$
- <2> Utilizar o vetor $\mathbf{w}$ ajustado durante o treinamento
- <3> Executar as seguintes ações:
 - <3.1> $u \leftarrow \mathbf{w}^T \mathbf{x}^{(k)}$
 - <3.2> $y \leftarrow \text{sinal}(u)$
 - <3.3> Se $y = -1$, então amostra $\mathbf{x} \in \{\text{Classe A}\}$
 - <3.4> Se $y = 1$, então amostra $\mathbf{x} \in \{\text{Classe B}\}$

Fim {Algoritmo Adaline – Fase de Classificação}



Comparação das Redes *Adaline* e *Perceptron*

- O processo de treinamento do *Adaline* visa mover um hiperplano de separação de forma a minimizar o erro quadrático em relação a todas as amostras do conjunto de treinamento;
- O hiperplano obtido sempre será o mesmo, dado que o ponto de mínimo $\mathbf{w}^*$ tende a ser único.





Comparação das Redes *Adaline* e *Perceptron*

- Posição do hiperplano de separação:
 - Rede *Perceptron*: admite qualquer hiperplano de separação, desde que factível;
 - Rede *Adaline*: admite apenas um hiperplano de separação, aquele que minimiza o EQM nas amostras de treinamento;



Comparação das Redes *Adaline* e *Perceptron*

- Imunidade ao ruído:
 - A rede *Adaline* possui uma maior robustez do que a rede *Perceptron* a amostras que podem ser acometidas por um ruído aditivo;



Aspectos Práticos das Redes *Adaline*

- A rede *Adaline* é própria para separação de classes que são linearmente separáveis;
- Diferentemente do *Perceptron*, mesmo se as classes não forem linearmente separáveis, a regra Delta é passível de convergência em função do patamar de precisão atribuído ao processo de parada;
 - Porém o resultado no desempenho da rede não será satisfatório;

Aspectos Práticos das Redes *Adaline*

- O valor da constante de aprendizado deve ser bem especificado (seguir mesmas regras da rede *Perceptron*);
- A quantidade de épocas necessárias para a convergência varia de acordo com:
 - Valores iniciais do pesos;
 - Disposição das amostras de treinamento;
 - Valor da constante de aprendizado;

Aspectos Práticos das Redes *Adaline*

- A disposição final do hiperplano confere a rede *Adaline* uma maior robustez a eventuais ruídos que podem afetar as amostras a serem classificadas;
- A normalização das entradas contribui para incrementar o desempenho do treinamento.