

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS (CMPF)
DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA (DETEC)

SISTEMAS INTELIGENTES

Regressão Logística

Prof. Pedro Thiago Valério de Souza
UFERSA – Campus Pau dos Ferros
pedro.souza@ufersa.edu.br

Fundamentos da Regressão Logística

- A regressão logística é um modelo estatístico utilizado para resolver problemas de classificação binária;
- A classificação binária é o processo de separar um conjunto de dados em duas categorias distintas e exclusivas.
- O objetivo é construir um modelo que, ao receber uma nova informação, consiga prever a qual dos dois grupos ela pertence.
- Matematicamente, representamos as classes como 0 (negativo, ausência) e 1 (positivo, presença).
- A saída não é diretamente a classe, e sim uma **probabilidade** de a amostra pertencer a uma determinada classe. Essa probabilidade varia no intervalo $[0,1]$ e indica o nível de confiança do modelo na sua previsão.

Fundamentos da Regressão Logística

Para que o sistema tome uma decisão final, aplica-se um **limiar de decisão** (*threshold*), cujo valor padrão costuma ser $0{,}5$.

Exemplo: Classificação de *spam*:

- Seja $y = 1$ uma mensagem com *spam* e $y = 0$ uma mensagem desejada.
- O modelo retorna a probabilidade condicional $P(y = 1 \mid x)$, dado um conjunto de características x (palavras-chave, remetente, etc.).
- A decisão é então:
  - se $P(y = 1 \mid x) \geq 0{,}5$, a mensagem é classificada como Classe 1 (*spam*);
  - se $P(y = 1 \mid x) < 0{,}5$, a mensagem é classificada como Classe 0 (desejada).

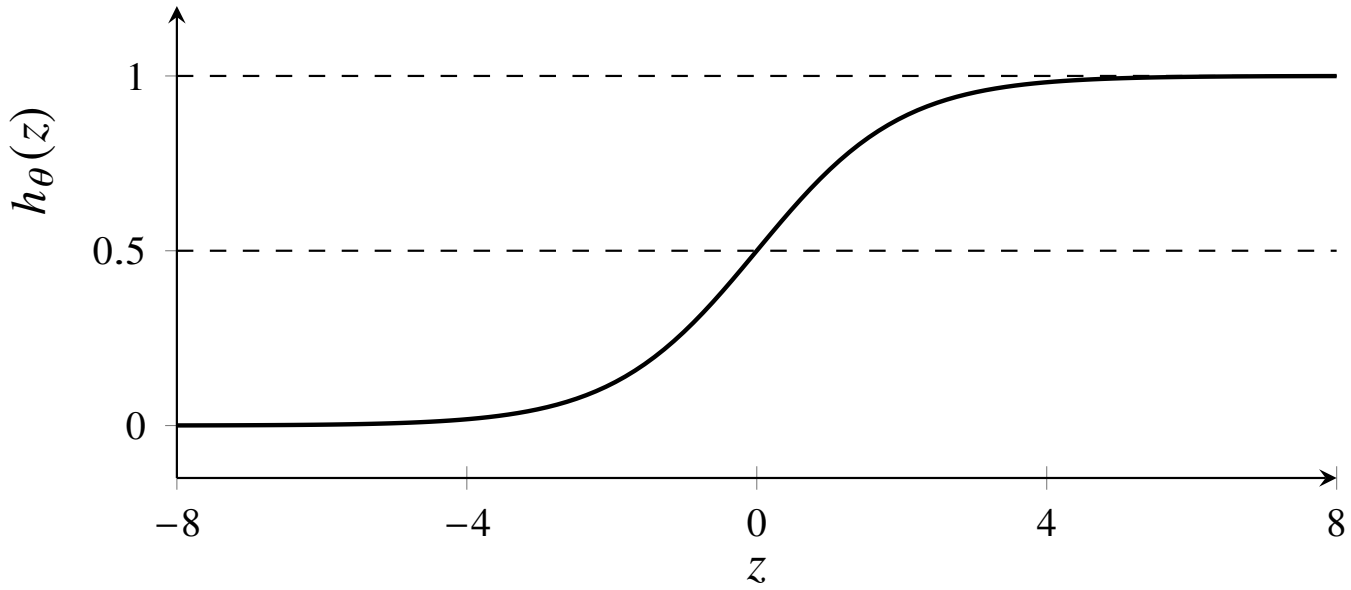
Fundamentos da Regressão Logística

- A primeira ideia para resolver a classificação binária seria ajustar uma reta aos dados, como na regressão linear.
- O problema é que a regressão linear pode prever valores como $-1{,}5$ ou $2{,}0$.
- Em classificação, buscamos uma probabilidade $P(y = 1 \mid x)$, que deve estar estritamente entre 0 e 1.
- A solução é "esmagar" a saída da equação linear com a **função logística** (ou sigmoide), garantindo que o resultado fique sempre limitado ao intervalo $[0{,}1]$.

Fundamentos da Regressão Logística

Função Logística:

$$h_\theta(z) = \frac{1}{1 + e^{-z}}$$



Mesmo para valores muito altos ou muito baixos de z, a saída permanece limitada ao intervalo $[0,1]$ e, portanto, pode ser interpretada como uma probabilidade.

Fundamentos da Regressão Logística

Propriedades da Função Logística:

- É contínua e diferenciável em todo o domínio: permite o uso de métodos baseados em gradiente.
- É monotonicamente crescente: quanto maior z, maior a probabilidade estimada.
- $h_\theta(0) = 0{,}5$; $h_\theta(z) \to 1$ quando $z \to +\infty$ e $h_\theta(z) \to 0$ quando $z \to -\infty$.
- Possui derivada de forma simples:

$$\frac{d\, h_\theta(z)}{dz} = h_\theta(z)\,[1 - h_\theta(z)]$$

Fundamentos da Regressão Logística

O Modelo da Regressão Logística: Na entrada da função logística aplicamos um modelo descrito por uma relação linear das variáveis,

$$z = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_p x_p$$

Logo, a saída do modelo de regressão logística é:

$$\hat{p} = h_\theta\left(\theta_0 + \theta_1 x_1 + \cdots + \theta_p x_p\right) = \frac{1}{1 + e^{-\left(\theta_0 + \theta_1 x_1 + \cdots + \theta_p x_p\right)}}$$

- A parte linear é idêntica à da regressão linear múltipla.
- A diferença está na transformação não linear aplicada sobre essa combinação linear.

Fundamentos da Regressão Logística

O Modelo da Regressão Logística: De forma equivalente, o modelo pode ser representado vetorialmente,

$$\hat{p} = h_\theta\left(\mathbf{\Phi}^T\mathbf{x}\right) = \frac{1}{1 + e^{-\mathbf{\Phi}^T\mathbf{x}}}$$

em que:

- $\mathbf{x} = \begin{bmatrix} 1 & x_1 & x_2 & \cdots & x_p \end{bmatrix}^T$ é o vetor de entrada (ou vetor de características), em que o valor 1 é adicionado para permitir o produto escalar com o termo de intercepto (*bias*);
- $\mathbf{\Phi} = \begin{bmatrix} \theta_0 & \theta_1 & \theta_2 & \cdots & \theta_p \end{bmatrix}^T$ é o vetor de parâmetros (ou pesos) do modelo.

O produto escalar $\mathbf{\Phi}^T\mathbf{x}$ resulta exatamente na combinação linear z, que é então processada pela sigmoide para gerar a probabilidade $\hat{p}$.

Fundamentos da Regressão Logística

Fronteira de Decisão: Com o limiar de $0{,}5$, a classe prevista é 1 quando $\hat{p} \geq 0{,}5$. Como $h_\theta(z) \geq 0{,}5$ exatamente quando $z \geq 0$, a decisão equivale a:

$$\mathbf{\Phi}^T \mathbf{x} \geq 0 \implies \hat{y} = 1, \qquad \mathbf{\Phi}^T \mathbf{x} < 0 \implies \hat{y} = 0$$

- A fronteira de decisão é o conjunto de pontos em que $\mathbf{\Phi}^T \mathbf{x} = 0$.
- Trata-se de uma **fronteira linear**: uma reta para $p = 2$ variáveis, um plano para $p = 3$ e um hiperplano no caso geral.
- Embora o modelo produza uma saída não linear em $\hat{p}$, a superfície que separa as classes continua sendo linear nas variáveis de entrada.

Ajuste dos Parâmetros do Modelo

Função de Custo:

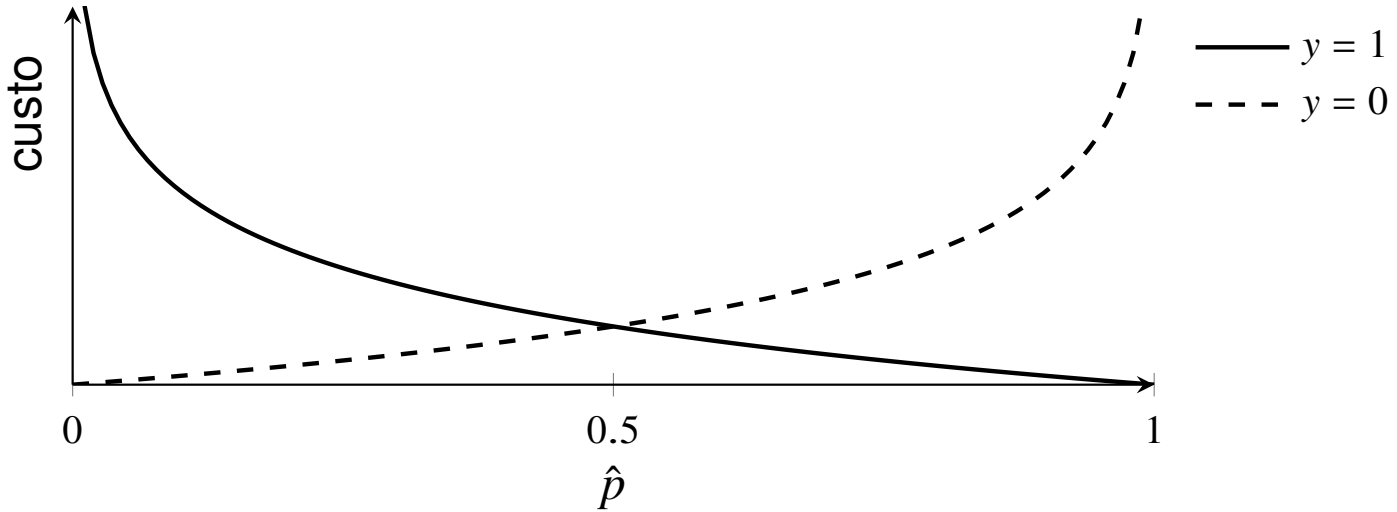
- Diferentemente da regressão linear, que utiliza o erro quadrático médio, a regressão logística utiliza uma função de custo chamada **Log Loss** (ou entropia cruzada binária).
- A ideia fundamental é punir o modelo com base na distância entre a probabilidade prevista $\hat{p}$ e o rótulo real y.
- Custo de um único exemplo:

$$\text{custo}\,(\hat{p}, y) = \begin{cases} -\log\left(\hat{p}\right), & \text{se } y = 1 \\ -\log\left(1 - \hat{p}\right), & \text{se } y = 0 \end{cases}$$

Ajuste dos Parâmetros do Modelo

Função de Custo:

- Se o valor real é $y = 1$, o custo é $-\log(\hat{p})$: vale 0 quando o modelo prevê $\hat{p} = 1$ e cresce infinitamente à medida que $\hat{p}$ se aproxima de 0.
- Se o valor real é $y = 0$, o custo é $-\log(1 - \hat{p})$: vale 0 quando o modelo prevê $\hat{p} = 0$ e cresce infinitamente à medida que $\hat{p}$ se aproxima de 1.



Ajuste dos Parâmetros do Modelo

Função de Custo: Somando o custo de todos os N exemplos em uma única fórmula compacta:

$$J(\mathbf{\Phi}) = -\frac{1}{N}\sum_{i=0}^{N-1} y^{(i)} \log\left(\hat{p}^{(i)}\right) + \left(1 - y^{(i)}\right) \log\left(1 - \hat{p}^{(i)}\right)$$

em que:

- N: número total de amostras;
- $y^{(i)}$: rótulo real do exemplo i (0 ou 1);
- $\hat{p}^{(i)}$: probabilidade prevista pelo modelo para o exemplo i.

SVeja que se $y^{(i)} = 1$, então $1 - y^{(i)} = 0$ e o termo $\log\left(1 - \hat{p}^{(i)}\right)$ desaparece da expressão. Se $y^{(i)} = 0$, o primeiro termo é que se anula. A fórmula seleciona automaticamente a punição correta para cada caso.

Ajuste dos Parâmetros do Modelo

Função de Custo: Como $\hat{p}^{(i)} = h_\theta\left(\mathbf{\Phi}^T \mathbf{x}^{(i)}\right)$, então:

$$J(\mathbf{\Phi}) = -\frac{1}{N} \sum_{i=0}^{N-1} \left\{ y^{(i)} \log\left[h_\theta\left(\mathbf{\Phi}^T \mathbf{x}^{(i)}\right)\right] + \left(1 - y^{(i)}\right) \log\left[1 - h_\theta\left(\mathbf{\Phi}^T \mathbf{x}^{(i)}\right)\right] \right\}$$

O objetivo do treinamento é encontrar os parâmetros que minimizam $J(\mathbf{\Phi})$. Para isso, calculamos a derivada da função de custo em relação a cada peso:

$$\frac{\partial J(\mathbf{\Phi})}{\partial \theta_j} = \frac{1}{N} \sum_{i=0}^{N-1} \left[h_\theta\left(\mathbf{\Phi}^T \mathbf{x}^{(i)}\right) - y^{(i)}\right] x_j^{(i)}$$

- O termo entre colchetes é o erro cometido na amostra i.
- A expressão tem a *mesma forma* da derivada obtida na regressão linear; a diferença está apenas na função h_θ aplicada.
- Diferentemente da regressão linear, não existe solução em forma fechada: os parâmetros devem ser obtidos por um método iterativo.

Ajuste dos Parâmetros do Modelo

Regra de Atualização: Para cada parâmetro θ_j do modelo, a regra de atualização do gradiente descendente é:

$$\theta_j := \theta_j - \eta \frac{\partial}{\partial \theta_j} J(\mathbf{\Phi})$$

em que η é a taxa de aprendizagem (*learning rate*), que controla o tamanho do passo em direção ao mínimo. Substituindo a derivada da função Log Loss, a fórmula expandida para a atualização de todos os pesos simultaneamente é:

$$\theta_j := \theta_j - \eta \frac{1}{N} \sum_{i=0}^{N-1} \left[h_\theta \left(\mathbf{\Phi}^T \mathbf{x}^{(i)} \right) - y^{(i)} \right] x_j^{(i)}$$

Ajuste dos Parâmetros do Modelo

Regra de Atualização: Reunindo todas as amostras, a atualização pode ser escrita de uma só vez:

$$\hat{\mathbf{P}} = h_\theta(\mathbf{X}\boldsymbol{\Phi})\,, \qquad \nabla J(\boldsymbol{\Phi}) = \frac{1}{N}\,\mathbf{X}^T\left(\hat{\mathbf{P}} - \mathbf{Y}\right)$$

$$\boldsymbol{\Phi} := \boldsymbol{\Phi} - \eta\,\nabla J(\boldsymbol{\Phi})$$

- $\mathbf{X}$ é a matriz de delineamento $(N \times (p+1))$, cuja primeira coluna é preenchida por 1s;
- $\hat{\mathbf{P}}$ é o vetor de probabilidades previstas, obtido aplicando a sigmoide elemento a elemento;
- $\hat{\mathbf{P}} - \mathbf{Y}$ é o vetor de erros, de tamanho $(N \times 1)$.

Ajuste dos Parâmetros do Modelo

Regra de Atualização:

Algoritmo 1 Gradiente descendente para a regressão logística

Entrada: matriz $\mathbf{X}$, vetor de rótulos $\mathbf{Y}$, taxa de aprendizagem η, número máximo de iterações K, tolerância ε

Saída: vetor de parâmetros $\mathbf{\Phi}$

$\mathbf{\Phi} \leftarrow \mathbf{0}$ // inicialização

$k \leftarrow 0$

repita

- $\hat{\mathbf{P}} \leftarrow h_\theta(\mathbf{X}\mathbf{\Phi})$ // probabilidades
- $\mathbf{R} \leftarrow \hat{\mathbf{P}} - \mathbf{Y}$ // erros
- $\nabla J(\mathbf{\Phi}) \leftarrow \frac{1}{N}\mathbf{X}^T\mathbf{R}$ // gradiente
- $\mathbf{\Phi} \leftarrow \mathbf{\Phi} - \eta\,\nabla J(\mathbf{\Phi})$ // atualização
- $k \leftarrow k + 1$

até $k = K$ *ou* $\|\nabla J(\mathbf{\Phi})\| < \varepsilon$

retorna $\mathbf{\Phi}$

Regularização

O *overfitting* ocorre quando o modelo "decora" os dados de treino e não generaliza para novos dados. A regularização adiciona uma penalização à função de custo baseada na magnitude dos pesos.

- Lasso (L_1):

$$J_{\text{reg}}(\mathbf{\Phi}) = J(\mathbf{\Phi}) + \alpha \sum_{i=1}^{p} |\theta_i|$$

- Ridge (L_2):

$$J_{\text{reg}}(\mathbf{\Phi}) = J(\mathbf{\Phi}) + \frac{\alpha}{2} \sum_{i=1}^{p} \theta_i^2$$

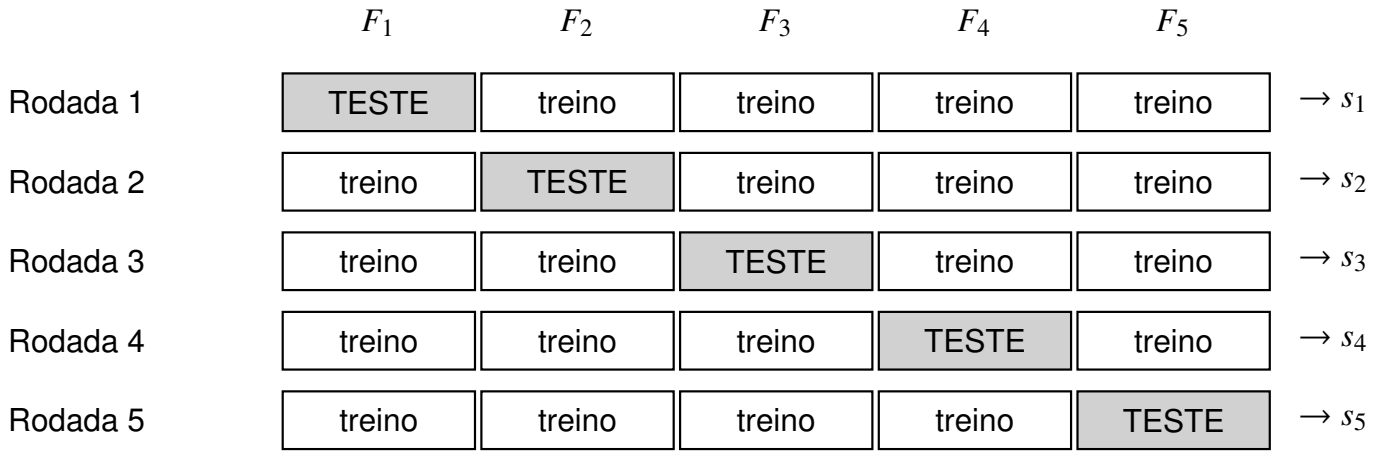
- O parâmetro α controla a **força** da regularização.
- Um α muito alto pode causar *underfitting*: o modelo fica simples demais e perde capacidade de representação.
- Um α muito baixo não resolve o *overfitting*: a penalização torna-se irrelevante diante do termo de ajuste.
- Assim como na regressão linear, a L_1 tende a zerar coeficientes (seleção de variáveis), enquanto a L_2 apenas os reduz.

Validação Cruzada

- Como estimar o valor adequado de α? Ele não pode ser aprendido a partir dos dados de treinamento, pois o menor custo de treino corresponde sempre a $\alpha = 0$. A resposta é a **validação cruzada**.
- Validação Cruzada: Técnica para avaliar a capacidade de generalização de um modelo a partir de um conjunto de dados.
- O conceito central é o **particionamento** do conjunto de dados em subconjuntos mutuamente exclusivos.
- Alguns desses subconjuntos são usados para a estimação dos parâmetros (dados de treinamento) e os restantes são empregados na validação do modelo.
- Os dados de validação permitem estimar os melhores hiperparâmetros do modelo, como o próprio α.

Validação Cruzada

***K-Fold Cross-Validation*:** A variante mais comum. O *dataset* é dividido em k partes iguais (*folds*) e o processo se repete k vezes: a cada rodada, um *fold* diferente é usado como teste e os demais como treino.



O resultado final é a média dos k escores. O desvio padrão indica a **estabilidade**: um desvio alto significa que o modelo é sensível à forma como os dados são divididos.

Validação Cruzada

***K-Fold Cross-Validation*:** A escolha de k envolve um *trade-off*:

- k **pequeno** (por exemplo, 3): cada modelo treina com menos dados, produzindo uma estimativa menos precisa, porém o processo é mais rápido.
- k **grande** (por exemplo, 10): estimativa mais precisa, mas computacionalmente mais custoso, pois são treinados k modelos.
- $k = 5$ ou $k = 10$ são os valores mais usados na prática.

Validação Cruzada $\times$ Conjunto de Teste

Um erro comum é usar a validação cruzada como substituta do conjunto de teste final. Os papéis são distintos:

Validação cruzada	**Conjunto de teste**
Usada *durante* o desenvolvimento	Usado *apenas* no final
Comparar modelos e ajustar hiperparâmetros	Estimar a performance real do modelo escolhido
Os dados influenciam as escolhas de projeto	Os dados nunca influenciam o projeto

Como o escore da validação cruzada foi usado para escolher os hiperparâmetros, ele é otimista: não serve como estimativa da performance final.