

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS (CMPF)
DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA (DETEC)

SISTEMAS INTELIGENTES

k-Vizinhos mais Próximos

Prof. Pedro Thiago Valério de Souza
UFERSA – Campus Pau dos Ferros
pedro.souza@ufersa.edu.br

Conceitos Fundamentais

- Algoritmo de classificação baseado no vizinho mais próximo (*Nearest Neighbor* – NN);
- Proposto por Fukunaga e Narendra em 1975;
- Expansão do algoritmo *Nearest Neighbor*, proposto por Cover e Hart em 1966;
- Técnica amplamente empregada na tarefa de reconhecer padrões, mas pode ser utilizada para regressão;
- Consiste em uma técnica de aprendizado supervisionado;
- Diferentemente de algoritmos como regressão logística, o k-NN não constrói um modelo durante o treinamento. Ele simplesmente memoriza os dados de treino;
- Todo o trabalho computacional acontece na hora da predição.

Conceitos Fundamentais

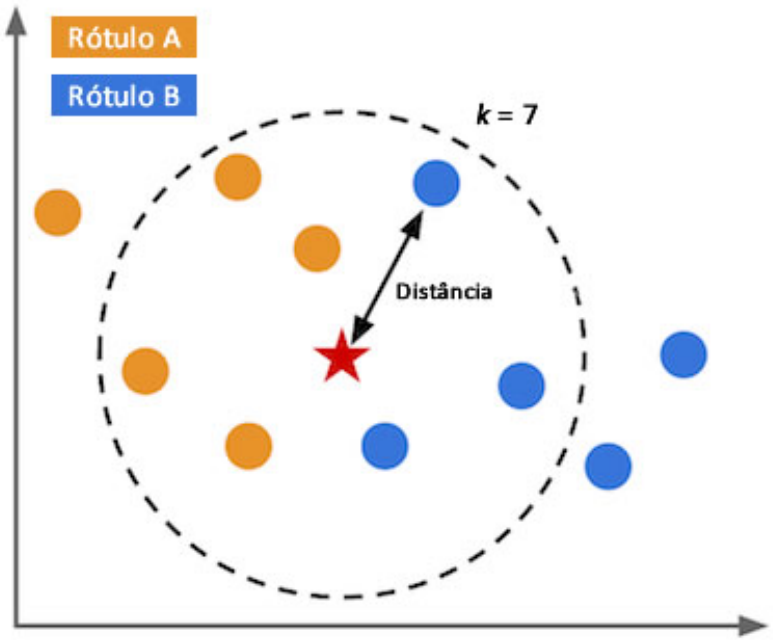
- Principais vantagens:
  - É um dos métodos de classificação mais simples de ser implementado;
  - Possui uma fácil compreensão;
  - Possui bons resultados em determinadas aplicações;
  - O k-NN pode ser usado tanto para classificação quanto para regressão;
  - Pode lidar com múltiplas classes de forma natural;
  - Não faz nenhuma suposição sobre os dados (como, por exemplo, a regressão linear).
- Principais desvantagens:
  - Pode não ser útil quando a relação entre as variáveis de entrada não é tão simples;
  - É sensível a sua parametrização;
  - A precisão da classificação pode ser severamente degradada pela presença de ruído;
  - Quando o conjunto de treinamento é composto por várias amostras, o algoritmo pode:
    - Exigir muita memória do dispositivo;
    - Ser lento.

Princípio de Funcionamento

- Classificar uma amostra nova baseado nas amostras vizinhas (advindas de um conjunto de treinamento);
- Utiliza-se k vizinhos mais próximos da amostra a ser classificada;
- O k-NN funciona atribuindo à amostra a ser classificada a classe representada mais frequentemente dentre as k amostras mais próximas;
  - A variável k representa a quantidade de vizinhos a serem averiguados.

Princípio de Funcionamento

- Exemplo de funcionamento ($k = 7$):
  - Como existem mais vizinhos da classe A, a nova amostra receberá a mesma classe deles, ou seja, A.



Princípio de Funcionamento

- Condições necessárias para utilização do k-NN:
  - Um conjunto de exemplos de treinamento (entrada/saída desejada);
  - Definir uma métrica para calcular a distância entre os exemplos de treinamento;
  - Definir o valor de k (o número de vizinhos mais próximos que serão considerados pelo algoritmo);
- Como todo processo de treinamento supervisionado, o k-NN consiste em duas fases: treinamento e classificação.

Princípio de Funcionamento

Fase de Treinamento:

- Armazenamento simples;
  - Consiste em armazenar toda a base de treinamento TR em uma memória do k-NN ($\mathrm{TR}_n = \{X^{(1)}, \ldots, X^{(n)}\}$);
- Um padrão X qualquer possui duas características: um vetor de valores e um vetor de classes.
  - Vetor de valores: armazena as características;
  - Vetor de classe: armazena a qual classe o padrão pertence.
- Embora simples, o k-NN geralmente exige mais memória do que uma regressão logística;
  - Treinamento da regressão logística: conhecimento armazenado nos parâmetros do modelo;
  - Treinamento do k-NN: conhecimento armazenado de forma pura.

Princípio de Funcionamento

Fase de Classificação:

- Consiste em três etapas fundamentais:
  - Calcular a distância entre a amostra a ser classificada e os outros exemplos do conjunto de treinamento;
  - Identificar os k vizinhos mais próximos;
  - Utilizar o rótulo da classe dos vizinhos mais próximos para determinar a classe da amostra a ser classificada.

Princípio de Funcionamento

Fase de Classificação – Pseudocódigo:

Algoritmo 1 k-NN — classificação

Entrada: conjunto de treinamento $\left\{\mathbf{x}^{(i)}, y^{(i)}\right\}_{i=0,\ldots,N-1}$, novo ponto $\mathbf{x}^*$, número de vizinhos k

Saída: classe $\hat{y}$ atribuída ao novo ponto

para cada *ponto* $\mathbf{x}^{(i)}$ *do conjunto de treinamento* **faça**

  $d_i \leftarrow d\left(\mathbf{x}^{(i)}, \mathbf{x}^*\right)$ `// distância`

ordenar as distâncias d_i em ordem crescente

$\mathcal{V} \leftarrow$ os k pontos de menor distância `// vizinhança`

contar os votos de cada classe entre os vizinhos de $\mathcal{V}$

$\hat{y} \leftarrow$ classe mais votada `// maioria simples`

retorna $\hat{y}$

Princípio de Funcionamento

Fase de Classificação:

- As principais métricas de distância são:
  - Distância de Minkowski;
  - Distância de Manhattan;
  - Distância Euclidiana;
  - Distância de Chebyshev.

Parametrização do k-NN

Métricas de Distância:

- Distância de Minkowski:
  - Valor de métrica expressa por uma norma:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt[p]{|x_1 - y_1|^p + |x_2 - y_2|^p + \cdots + |x_n - y_n|^p}$$

  - em que $\mathbf{x} = (x_1, x_2, \ldots, x_n)$ e $\mathbf{y} = (y_1, y_2, \ldots, y_n)$ são dois objetos n-dimensionais e p é um inteiro positivo.

Princípio de Funcionamento

Métricas de Distância:

- Distância de Manhattan (*City-Block*): caso especial da distância de Minkowski para $p = 1$:

$$d(\mathbf{x}, \mathbf{y}) = |x_1 - y_1| + |x_2 - y_2| + \cdots + |x_n - y_n|$$

- Distância Euclidiana: caso especial da distância de Minkowski para $p = 2$:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \cdots + (x_n - y_n)^2}$$

- Distância de Chebyshev: caso especial da distância de Minkowski para $p \to \infty$:

$$d(\mathbf{x}, \mathbf{y}) = \max_i |x_i - y_i|$$

Princípio de Funcionamento

Métricas de Distância:

- Resumo – similaridades baseadas na distância de Minkowski:
  - A distância Euclidiana é calculada através de uma linha reta entre os pontos;
  - A distância de Manhattan é calculada um quarteirão de cada vez;
  - A distância de Chebyshev é dada pela maior das duas dimensões da distância.

Princípio de Funcionamento

- Observação: normalização dos atributos:
  - Na maioria das vezes os atributos precisam ser normalizados para evitar que as medidas de distância sejam dominadas por um único atributo;
  - Exemplos:
    - Altura pode variar de 1,20 m a 2,10 m;
    - Peso pode variar de 40 kg a 150 kg;
    - O salário pode variar de R$ 800 a R$ 20.000.

Princípio de Funcionamento

Determinação do valor k:

- Varia de acordo com a base de dados;
- Recomendável sempre utilizar valores ímpares/primos (para não haver empate na votação);
- Pode utilizar validação cruzada para obter o melhor valor de k.

Parametrização do k-NN

Determinação do valor k:

- Influência do parâmetro k:
  - $k = 1$: pertence à classe dos quadrados;
  - $k = 3$: pertence à classe dos triângulos;
  - $k = 7$: pertence à classe dos quadrados.
- Logo:
  - Se k for muito pequeno, a classificação fica sensível a pontos de ruído;
  - Se k é muito grande, a vizinhança pode incluir elementos de outras classes.
- Pode-se utilizar validação cruzada para escolher o melhor valor de k.

