

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR PAU DOS FERROS
CURSO DE ENGENHARIA DE COMPUTAÇÃO

PAM0466 - SISTEMAS INTELIGENTES

Rede *Perceptron* de Múltiplas Camadas (MLP - *multilayer perceptron*)

Prof. Dr. Pedro Thiago Valério de Souza
pedro.souza@ufersa.edu.br

Semestre de 2026.1

Introdução

- Caracterizadas pela presença de pelo menos uma camada intermediária;
 - Possuem no mínimo duas camadas de neurônios *Perceptron*;
 - Permitem solucionar problemas não linearmente separáveis;
- A ideia que as redes neurais com múltiplas camadas solucionariam problemas não linearmente separáveis é antiga;
 - Antes da década de 1980, não existia um algoritmo de treinamento consistente para esse tipo de rede;
 - Desta forma, as redes com múltiplas camadas não poderiam ser aplicados a problemas práticos de engenharia;

Introdução


- A primeira proposição de um algoritmo de treinamento consistente para redes com múltiplas camadas foi proposto por Rumelhart em 1986;
 - Algoritmo da retropropagação (*Backpropagation* ou regra Delta generalizada);
 - Promoveu grande popularidade das redes MLP;

Introdução

- Podem ser utilizadas em diversas áreas do conhecimento;
 - Aproximação de função (contínua ou não contínua);
 - Reconhecimento de padrões;
 - Identificação e controle de processos;
 - Previsão de séries temporais;
 - Otimização de sistemas.

Introdução

- Características gerais da rede MLP:
 - Arquitetura *feedforward* de múltiplas camadas;
 - Quantidade de entradas: n entradas;
 - Quantidade de saídas: m saídas;



Introdução


- Características gerais da rede MLP:
 - Princípio de funcionamento:
 - As entradas externas (camada de entrada) são entradas para a 1º camada neural;
 - As saídas da 1º camada neural são entradas para a 2º camada neural;
 - As saídas da 2º camada neural são entradas para a 3º camada neural (camada de saída);
 - As saídas da 3º camada neural são as saídas da rede MLP;
 - Propagação em um único sentido;

Introdução

- Características gerais da rede MLP:
 - Pesos sinápticos: valores reais;
 - Vetor de entradas: valores binários ou reais;
 - Funções de ativação usuais: função logística, tangente hiperbólica, linear;
 - Saída: valores binários ou valores reais;
 - Classificação de padrões (valores binários);
 - Aproximação de funções (valores reais);
 - Processo de treinamento: supervisionado;
 - Regra de aprendizado: Algoritmo *Backpropagation* ou suas variações;

Introdução

- Características gerais da rede MLP:
 - O mapeamento do problema é realizado por todos os neurônios (de todas as camadas) da rede MLP;
 - Agrega uma maior robustez a essa rede em comparação à *Perceptron* e *Adaline*;



Introdução


- Características gerais da rede MLP:
 - Funções das camadas:
 - A primeira camada tem como função capturar os sinais externos;
 - As camadas intermediárias tem como função extrair a maioria das informação acerca do problema a ser mapeado;
 - A camada de saída tem como função gerar a resposta da rede em função das informações extraídas nas camadas intermediárias;

Introdução

- Características gerais da rede MLP:
 - Especificação topológica:
 - Depende de alguns fatores, tais como:
 - Classe do problema a ser resolvido (complexidade do problema);
 - Disposição espacial das amostras de treinamento;
 - Valores iniciais atribuídos ao processo de treinamento;
 - Algoritmo de treinamento utilizado;

Formalização matemática de uma rede MLP


- Cada camada de uma rede MLP pode ser entendida com uma matriz de pesos;
- O processo de obtenção de saída é entendido como um produto matricial;



Formalização matemática de uma rede MLP

■ Parâmetros do modelo:


- n_1 : número de neurônio na primeira camada da rede;
- n_2 : número de neurônio na segunda camada da rede;
- n_3 : número de neurônio na camada de saída da rede;



Formalização matemática de uma rede MLP

■ Parâmetros do modelo:


- $\mathbf{W}^{(1)}$: matriz de pesos da camada #1, em que o elemento $W_{ji}^{(1)}$ é o peso sináptico associado a ligação da entrada i para o neurônio j ;



Formalização matemática de uma rede MLP

■ Parâmetros do modelo:


- $\mathbf{W}^{(2)}$: matriz de pesos da camada #2, em que o elemento $W_{ji}^{(2)}$ é o peso sináptico associado a ligação do neurônio i para o neurônio j ;



Formalização matemática de uma rede MLP

- Parâmetros do modelo:

- $\mathbf{W}^{(3)}$: matriz de pesos da camada #3, em que o elemento $W_{ji}^{(3)}$ é o peso sináptico associado a ligação do neurônio i para o neurônio j ;




Formalização matemática de uma rede MLP

- Parâmetros do modelo:

- $I^{(1)}$: vetor de potencial de ativação da camada #1. O elemento $I_j^{(1)}$ é dado por:

$$I_j^{(1)} = \sum_{i=0}^n W_{ji}^{(1)} x_i = W_{j0}^{(1)} x_0 + W_{j1}^{(1)} x_1 + \dots + W_{jn}^{(1)} x_n \quad j = 1, \dots, n_1 \quad x_0 = -1$$




Formalização matemática de uma rede MLP

■ Parâmetros do modelo:

- $\mathbf{Y}^{(1)}$: vetor de saída da camada #1. O elemento $Y_j^{(1)}$ é dado por:

$$Y_j^{(1)} = g_1(I_j^{(1)}) \quad j = 1, \dots, n_1$$

$g_1(\)$ é a função de ativação da camada #1.




Formalização matemática de uma rede MLP

- Parâmetros do modelo:

- $I^{(2)}$: vetor de potencial de ativação da camada #2:

$$I_j^{(2)} = \sum_{i=0}^{n_1} W_{ji}^{(2)} Y_i^{(1)} = W_{j0}^{(2)} Y_0^{(1)} + \dots + W_{jn_1}^{(2)} Y_{n_1}^{(1)} \quad j = 1, \dots, n_2 \quad Y_0^{(1)} = -1$$




Formalização matemática de uma rede MLP

- Parâmetros do modelo:

- $Y^{(2)}$: vetor de saída da camada #2:

$$Y_j^{(2)} = g_2(I_j^{(2)}) \quad j = 1, \dots, n_2$$

$g_2(\)$ é a função de ativação da camada #2.




Formalização matemática de uma rede MLP

- Parâmetros do modelo:

- $I^{(3)}$: vetor de potencial de ativação da camada de saída:

$$I_j^{(3)} = \sum_{i=0}^{n_2} W_{ji}^{(3)} Y_i^{(2)} = W_{j0}^{(3)} Y_0^{(2)} + \dots + W_{jn_2}^{(3)} Y_{n_2}^{(2)} \quad j = 1, \dots, n_3 \quad Y_0^{(2)} = -1$$




Formalização matemática de uma rede MLP

- Parâmetros do modelo:

- $Y^{(3)}$: vetor de saída da camada #3 (saída da rede neural):

$$Y_j^{(3)} = g_3(I_j^{(3)}) \quad j = 1, \dots, n_3$$

$g_3(\)$ é a função de ativação da camada de saída.



Formalização matemática de uma rede MLP

- De uma forma geral, temos que:

$$I_j^{(L)} = \sum_{i=0}^{n_{L-1}} W_{ji}^{(L)} Y_i^{(L-1)} \quad j = 1, \dots, n_L \quad Y_0^{(L-1)} = -1$$

$$Y_j^{(L)} = g_L \left(I_j^{(L)} \right) \quad j = 1, \dots, n_L$$


ou, de forma equivalente:

$$\mathbf{I}^{(L)} = \mathbf{W}^{(L)} \mathbf{Y}^{(L-1)}$$

$$\mathbf{Y}^{(L)} = g \left(\mathbf{I}^{(L)} \right)$$


Formalização matemática de uma rede MLP

Exercício: Considere a seguinte topologia para uma rede MLP apresentada abaixo. Determine: (a) a matriz de pesos de cada uma das camadas da rede (b) A saída da rede para aplicação do seguinte conjunto de entrada $x_1 = 0,3$ e $x_2 = 0,7$. Considere que em todas as camadas a função de ativação é tangente hiperbólica.




Processo de treinamento da rede MLP

- Em treinamento de redes MLP geralmente utiliza-se o algoritmo *Backpropagation*;
 - Generalização da regra Delta no algoritmo do *Adaline*;
- Constitui-se de duas fases: fase *forward* e fase *backward*;



Processo de treinamento da rede MLP

- Fase *forward*: propagação dos sinais de entrada $\{x_1, x_2, \dots, x_n\}$ até a camada de saída;
 - Produz a resposta da rede considerando os pesos sinápticos desta;
 - Os pesos sinápticos e os limiares permanecem inalterados nessa etapa;



Processo de treinamento da rede MLP

- Fase *backward*: A saída da rede é comparada com a resposta desejada, gerando sinais de erro, que serão propagados para trás (retropropagação) de forma a ajustar os pesos sinápticos;
 - Para a camada de saída o erro é facilmente encontrado (resposta desejada – resposta da rede);
 - Para as camadas ocultas isso não ocorre, pois não temos a resposta desejada para cada neurônio das camadas intermediárias;
 - Estimação do erro via retropropagação;

Processo de treinamento da rede MLP

- Ajustes dos pesos sinápticos das camadas de saída e das camadas ocultas;
- *Ajuste da camada de saída:*
 - O erro de aproximação entre a resposta desejada e a resposta da rede está disponível;

$$E(k) = \frac{1}{2} \sum_{j=1}^{n_3} [d_j(k) - Y_j^{(3)}(k)]^2$$

Processo de treinamento da rede MLP

- Ajuste da camada de saída:
 - Desempenho global: erro quadrático médio;
 - Assumindo p amostras de treinamento, o erro quadrático médio será:

$$MSE = \frac{1}{p} \sum_{k=1}^p E(k) = \frac{1}{2p} \sum_{k=1}^p \sum_{j=1}^{n_3} [d_j(k) - Y_j^{(3)}(k)]^2$$

- Objetivo: ajustar $\mathbf{W}^{(3)}$ de forma a minimizar o erro entre a saída da rede e a resposta desejada;
 - Semelhante ao processo do *Adaline*;

Processo de treinamento da rede MLP

- Ajuste da camada de saída:
 - Pode-se demonstrar que:

$$\delta_j^{(3)} = \left[d_j - Y_j^{(3)} \right] g' \left(I_j^{(3)} \right) \quad j = 1, \dots, n_3$$
$$W_{ji}^{(3)} = W_{ji}^{(3)} + \eta \delta_j^{(3)} Y_i^{(2)}$$

em que:

- $\delta_j^{(3)}$ é denominado de gradiente local;
- η é a constante de aprendizado do *backpropagation*;
- De forma matricial:

$$\boldsymbol{\delta}^{(3)} = \left(\mathbf{d} - \mathbf{Y}^{(3)} \right) \odot g' \left(\mathbf{I}^{(3)} \right)$$
$$\mathbf{W}^{(3)} = \mathbf{W}^{(3)} + \eta \boldsymbol{\delta}^{(3)} \left(\mathbf{Y}^{(2)} \right)^T$$

Observação: $\odot$ é o produto de Hadamard

Processo de treinamento da rede MLP

- Ajuste da segunda camada oculta:
 - Nos neurônios da camada oculta não se tem acesso, de forma direta, os valores desejados para a saída desta camada;
 - Não temos acesso direto ao sinal de erro;
 - Solução: estimação do sinal de erro a partir das informações dos neurônios da camada imediatamente posterior;
 - Essência do algoritmo do *backpropagation*;

Processo de treinamento da rede MLP

- Ajuste da segunda camada oculta:

- Pode-se demonstrar que:

$$\delta_j^{(2)} = \left[\sum_{k=1}^{n_3} \delta_k^{(3)} W_{kj}^{(3)} \right] g'(I_J^{(2)}) \quad j = 1, \dots, n_2$$

$$W_{ji}^{(2)} = W_{ji}^{(2)} + \eta \delta_j^{(2)} Y_i^{(1)}$$

em que

- $\delta_j^{(2)}$ é denominado de gradiente local;
 - η é a constante de aprendizado do *backpropagation*;
- De forma matricial:

$$\begin{aligned} \boldsymbol{\delta}^{(2)} &= \left(\left(\mathbf{W}^{(3)} \right)^T \boldsymbol{\delta}^{(3)} \right) \odot g'(\mathbf{I}^{(2)}) \\ \mathbf{W}^{(2)} &= \mathbf{W}^{(2)} + \eta \boldsymbol{\delta}^{(2)} \left(\mathbf{Y}^{(2)} \right)^T \end{aligned}$$

Processo de treinamento da rede MLP

- Ajuste da primeira camada oculta:
 - Pode-se demonstrar que (de forma semelhante a primeira camada oculta):

$$\delta^{(1)} = \left(\left(\mathbf{W}^{(2)} \right)^T \delta^{(2)} \right) \odot g' \left(\mathbf{I}^{(1)} \right)$$
$$\mathbf{W}^{(1)} = \mathbf{W}^{(1)} + \eta \delta^{(1)} \left(\mathbf{Y}^{(1)} \right)^T$$

Processo de treinamento da rede MLP

- Comparando o gradiente local das camadas ocultas com o gradiente local da camada de saída:

$$\delta^{(3)} = (\mathbf{d} - \mathbf{Y}^{(3)}) \odot g'(\mathbf{I}^{(3)})$$

$$\delta^{(2)} = \left((\mathbf{W}^{(3)})^T \delta^{(3)} \right) \odot g'(\mathbf{I}^{(2)})$$



Estimação do erro da camada oculta, considerando o gradiente local e os pesos das camadas à frente.

Processo de treinamento da rede MLP

- De forma mais sucinta, o treinamento de uma rede MLP pode ser visto como:

$$\mathbf{W}^{(n)} = \mathbf{W}^{(n)} + \eta \boldsymbol{\delta}^{(n)} \left(\mathbf{Y}^{(n)} \right)^T$$

$$\boldsymbol{\delta}^{(n)} = \begin{cases} \left(\mathbf{d} - \mathbf{Y}^{(n)} \right) \odot g' \left(\mathbf{I}^{(n)} \right) & \text{caso } n \text{ seja camada de saída} \\ \left(\left(\mathbf{W}^{(n+1)} \right)^T \boldsymbol{\delta}^{(n+1)} \right) \odot g' \left(\mathbf{I}^{(n)} \right) & \text{caso } n \text{ seja camada oculta} \end{cases}$$


Aspectos práticos na utilização de redes MLP

- Problemas envolvendo classificação de padrões:

- A rede MLP é capaz de classificar padrões não-linearmente separáveis;

- *Exemplo de aplicação: Porta XOR:*

- Padrões não-linearmente separáveis;




x_1	x_2	X_{OR}
0	0	$0 \rightarrow \odot$
0	1	$1 \rightarrow \otimes$
1	0	$1 \rightarrow \otimes$
1	1	$0 \rightarrow \odot$

Aspectos práticos na utilização de redes MLP

- Problemas envolvendo classificação de padrões:

- *Exemplo de aplicação: Porta XOR:*

- Solução: Rede MLP com uma camada oculta (2 neurônios na camada oculta e 1 neurônio na camada de saída);




- Os neurônios **A** e **B** geram retas de separação que são unidas pelo neurônio **Y** por alguma função linearmente separável (e.g. AND, OR, ...);

Aspectos práticos na utilização de redes MLP

- Problemas envolvendo classificação de padrões:

- *Exemplo de aplicação: Porta XOR:*

- Posicionamento dos hiperplanos **A** e **B**;
 - Função executada pelo neurônio **Y**: função AND;




Aspectos práticos na utilização de redes MLP

- Problemas envolvendo classificação de padrões:

- *Exemplo de aplicação: Porta XOR:*


- Fronteiras de separação geradas pela rede MLP:



Aspectos práticos na utilização de redes MLP



■ Problemas envolvendo classificação de padrões:

- De forma geral, uma rede MLP com duas camadas (sendo uma a camada oculta) é capaz de mapear qualquer problema de classificação de padrões cujos elementos estejam dentro de uma região convexa;



Aspectos práticos na utilização de redes MLP


- Problemas envolvendo classificação de padrões:
 - Observação: Região convexa vs. Região não-convexa (côncava);



Aspectos práticos na utilização de redes MLP


■ Problemas envolvendo classificação de padrões:

- A quantidade de neurônios na camada oculta depende de quantas retas são necessárias para separar as classes;
- Exemplo: Rede (a) → 2 neurônios na camada oculta; Rede (b) → 6 neurônios na camada oculta; Rede (c) → 4 neurônios na camada oculta;



Aspectos práticos na utilização de redes MLP



- Problemas envolvendo classificação de padrões:
 - Caso as classes a serem separadas forem não-convexas ou forem formadas por regiões disjuntas, faz-se necessário duas camadas ocultas;



Aspectos práticos na utilização de redes MLP

- Problemas envolvendo classificação de padrões:

- Observações: Caso de regiões disjuntas;



Aspectos práticos na utilização de redes MLP


■ Classificação de mais de um padrão:

- As redes MLP permitem mais de uma saída e portanto podem classificar entre mais de uma classe;
- De forma geral, uma rede com m saídas pode classificar até 2^m classes distintas entre si;
- Formas de codificação das saídas da rede:
 - Codificação sequencial ou de largura mínima;
 - Codificação *one of c-classes*;

Aspectos práticos na utilização de redes MLP

- **Classificação de mais de um padrão:**


- *Codificação sequencial ou de largura mínima:*



Aspectos práticos na utilização de redes MLP

- Classificação de mais de um padrão:

- Codificação *one of c-classes*:



y_1	y_2	y_3	y_4	Classe
1	0	0	0	A
0	1	0	0	B
0	0	1	0	C
0	0	0	1	D

Aspectos práticos na utilização de redes MLP


■ Problemas envolvendo aproximação de funções:

- As redes MLP podem ser utilizadas em problemas de aproximação de função no qual o uso de técnicas convencionais;
- Teorema de Kolmogorov:
 - Função contínuas podem ser aproximadas com redes MLP de apenas duas camadas;
 - Funções que apresenta uma (ou mais) descontinuidades devem ser aproximadas por redes MLP com mais de duas camadas;

Aspectos práticos na utilização de redes MLP

■ Problemas envolvendo aproximação de funções:

- Neste caso, como a saída é formada pela ponderação de funções de ativação $g()$, a função de ativação na saída deverá ser linear;



Aspectos práticos na utilização de redes MLP

■ Aspectos de parada antecipada (*early-stopping*):

- O processo de treinamento é constantemente checado pelo conjunto de testes, sendo finalizado quando começar haver elevação do erro médio quadrático;

