



UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS (CMPF)
DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA (DETEC)

SISTEMAS INTELIGENTES

Redes Neurais Convolucionais

Prof. Pedro Thiago Valério de Souza
UFERSA – Campus Pau dos Ferros
pedro.souza@ufersa.edu.br

Introdução

- São redes neurais artificiais projetadas para processar dados com uma estrutura de grade, como imagens;

Introdução

- São redes neurais artificiais projetadas para processar dados com uma estrutura de grade, como imagens;
- Utilizam a operação de convolução para extrair características locais dos dados, permitindo o reconhecimento de padrões e a classificação de imagens;

Introdução

- São redes neurais artificiais projetadas para processar dados com uma estrutura de grade, como imagens;
- Utilizam a operação de convolução para extrair características locais dos dados, permitindo o reconhecimento de padrões e a classificação de imagens;
- São amplamente utilizadas em tarefas de visão computacional, como reconhecimento de objetos, detecção de objetos, segmentação de imagens e reconhecimento facial;

Convolução

- Operação utilizada para extrair alguma característica do sinal de entrada.

Convolução

- Operação utilizada para extrair alguma característica do sinal de entrada.
- Sinais unidimensionais:

Convolução

- Operação utilizada para extrair alguma característica do sinal de entrada.
- Sinais unidimensionais:

$$(x * w)[n] = \sum_{k=0}^{K-1} x[k]w[n - k]$$

Convolução

- Operação utilizada para extrair alguma característica do sinal de entrada.
- Sinais unidimensionais:

$$(x * w)[n] = \sum_{k=0}^{K-1} x[k]w[n-k]$$

em que:

Convolução

- Operação utilizada para extrair alguma característica do sinal de entrada.
- Sinais unidimensionais:

$$(x * w)[n] = \sum_{k=0}^{K-1} x[k]w[n-k]$$

em que:

- x é o sinal de entrada;

Convolução

- Operação utilizada para extrair alguma característica do sinal de entrada.
- Sinais unidimensionais:

$$(x * w)[n] = \sum_{k=0}^{K-1} x[k]w[n-k]$$

em que:

- x é o sinal de entrada;
- w é o filtro ou *kernel*;

Convolução

- Operação utilizada para extrair alguma característica do sinal de entrada.
- Sinais unidimensionais:

$$(x * w)[n] = \sum_{k=0}^{K-1} x[k]w[n-k]$$

em que:

- x é o sinal de entrada;
- w é o filtro ou *kernel*;
- K é o tamanho do filtro.

Convolução

- Operação utilizada para extrair alguma característica do sinal de entrada.
- Sinais unidimensionais:

$$(x * w)[n] = \sum_{k=0}^{K-1} x[k]w[n-k]$$

em que:

- x é o sinal de entrada;
 - w é o filtro ou *kernel*;
 - K é o tamanho do filtro.
- Sinais bidimensionais (imagens):

Convolução

- Operação utilizada para extrair alguma característica do sinal de entrada.
- Sinais unidimensionais:

$$(x * w)[n] = \sum_{k=0}^{K-1} x[k]w[n-k]$$

em que:

- x é o sinal de entrada;
 - w é o filtro ou *kernel*;
 - K é o tamanho do filtro.
- Sinais bidimensionais (imagens):

$$(X * W)[i,j] = \sum_{m=0}^{K-1} \sum_{n=0}^{K-1} X[m,n]W[i-m,j-n]$$

Convolução

- Operação utilizada para extrair alguma característica do sinal de entrada.
- Sinais unidimensionais:

$$(x * w)[n] = \sum_{k=0}^{K-1} x[k]w[n-k]$$

em que:

- x é o sinal de entrada;
 - w é o filtro ou *kernel*;
 - K é o tamanho do filtro.
- Sinais bidimensionais (imagens):

$$(X * W)[i,j] = \sum_{m=0}^{K-1} \sum_{n=0}^{K-1} X[m,n]W[i-m,j-n]$$

em que:

Convolução

- Operação utilizada para extrair alguma característica do sinal de entrada.
- Sinais unidimensionais:

$$(x * w)[n] = \sum_{k=0}^{K-1} x[k]w[n-k]$$

em que:

- x é o sinal de entrada;
 - w é o filtro ou *kernel*;
 - K é o tamanho do filtro.
- Sinais bidimensionais (imagens):

$$(X * W)[i,j] = \sum_{m=0}^{K-1} \sum_{n=0}^{K-1} X[m,n]W[i-m,j-n]$$

em que:

- X é a imagem de entrada;

Convolução

- Operação utilizada para extrair alguma característica do sinal de entrada.
- Sinais unidimensionais:

$$(x * w)[n] = \sum_{k=0}^{K-1} x[k]w[n-k]$$

em que:

- x é o sinal de entrada;
 - w é o filtro ou *kernel*;
 - K é o tamanho do filtro.
- Sinais bidimensionais (imagens):

$$(X * W)[i,j] = \sum_{m=0}^{K-1} \sum_{n=0}^{K-1} X[m,n]W[i-m,j-n]$$

em que:

- X é a imagem de entrada;
- W é o filtro ou *kernel* (apenas quadrado para simplificar);

Convolução

- Operação utilizada para extrair alguma característica do sinal de entrada.
- Sinais unidimensionais:

$$(x * w)[n] = \sum_{k=0}^{K-1} x[k]w[n-k]$$

em que:

- x é o sinal de entrada;
 - w é o filtro ou *kernel*;
 - K é o tamanho do filtro.
- Sinais bidimensionais (imagens):

$$(X * W)[i,j] = \sum_{m=0}^{K-1} \sum_{n=0}^{K-1} X[m,n]W[i-m,j-n]$$

em que:

- X é a imagem de entrada;
- W é o filtro ou *kernel* (apenas quadrado para simplificar);
- K é o tamanho do filtro.




Figura 1: Exemplo de convolução em uma imagem.

Convolução

- Exemplos de *kernels* comuns:

Convolução

- Exemplos de *kernels* comuns:
 - Detecção de bordas:

Convolução

- Exemplos de *kernels* comuns:
 - Detecção de bordas:

$$W = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

Convolução

- Exemplos de *kernels* comuns:
 - Detecção de bordas:

$$W = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

- Realce de nitidez:

Convolução

- Exemplos de *kernels* comuns:
 - Detecção de bordas:

$$W = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

- Realce de nitidez:

$$W = \begin{bmatrix} 0 & -2 & 0 \\ -2 & 5 & -2 \\ 0 & -2 & 0 \end{bmatrix}$$

Convolução

Parâmetros da Convolução:

Convolução

Parâmetros da Convolução:

- *Stride*: deslocamento do filtro (em pixels) sobre a matriz de entrada durante a convolução.




Figura 2: Exemplo de convolução em uma imagem com *stride*.

Convolução

Parâmetros da Convolução:

Convolução

Parâmetros da Convolução:

- *Padding*: inclusão de linhas e colunas externas de forma a aumentar a dimensão da matriz de entrada, permitindo que o filtro seja aplicado em todas as posições possíveis.

Convolução

Parâmetros da Convolução:

- *Padding*: inclusão de linhas e colunas externas de forma a aumentar a dimensão da matriz de entrada, permitindo que o filtro seja aplicado em todas as posições possíveis.
 - Válido: as convoluções são aplicadas apenas onde o filtro se encaixa completamente dentro da matriz de entrada, resultando em uma saída menor do que a entrada;

Convolução

Parâmetros da Convolução:

- *Padding*: inclusão de linhas e colunas externas de forma a aumentar a dimensão da matriz de entrada, permitindo que o filtro seja aplicado em todas as posições possíveis.
 - Válido: as convoluções são aplicadas apenas onde o filtro se encaixa completamente dentro da matriz de entrada, resultando em uma saída menor do que a entrada;
 - Igual (*same*): a matriz de entrada é preenchida com zeros ao redor das bordas, permitindo que o filtro seja aplicado em todas as posições possíveis, resultando em uma saída do mesmo tamanho da entrada;

Convolução

Parâmetros da Convolução:

- *Padding*: inclusão de linhas e colunas externas de forma a aumentar a dimensão da matriz de entrada, permitindo que o filtro seja aplicado em todas as posições possíveis.
 - Válido: as convoluções são aplicadas apenas onde o filtro se encaixa completamente dentro da matriz de entrada, resultando em uma saída menor do que a entrada;
 - Igual (*same*): a matriz de entrada é preenchida com zeros ao redor das bordas, permitindo que o filtro seja aplicado em todas as posições possíveis, resultando em uma saída do mesmo tamanho da entrada;
 - Completo (*full*): a matriz de entrada é preenchida com zeros ao redor das bordas, permitindo que o filtro seja aplicado em todas as posições possíveis, resultando em uma saída maior do que a entrada.

Convolução

Parâmetros da Convolução:

- *Padding*: inclusão de linhas e colunas externas de forma a aumentar a dimensão da matriz de entrada, permitindo que o filtro seja aplicado em todas as posições possíveis.
 - Válido: as convoluções são aplicadas apenas onde o filtro se encaixa completamente dentro da matriz de entrada, resultando em uma saída menor do que a entrada;
 - Igual (*same*): a matriz de entrada é preenchida com zeros ao redor das bordas, permitindo que o filtro seja aplicado em todas as posições possíveis, resultando em uma saída do mesmo tamanho da entrada;
 - Completo (*full*): a matriz de entrada é preenchida com zeros ao redor das bordas, permitindo que o filtro seja aplicado em todas as posições possíveis, resultando em uma saída maior do que a entrada.

A dimensão de saída de uma convolução é dada por:

Convolução

Parâmetros da Convolução:

- *Padding*: inclusão de linhas e colunas externas de forma a aumentar a dimensão da matriz de entrada, permitindo que o filtro seja aplicado em todas as posições possíveis.
 - Válido: as convoluções são aplicadas apenas onde o filtro se encaixa completamente dentro da matriz de entrada, resultando em uma saída menor do que a entrada;
 - Igual (*same*): a matriz de entrada é preenchida com zeros ao redor das bordas, permitindo que o filtro seja aplicado em todas as posições possíveis, resultando em uma saída do mesmo tamanho da entrada;
 - Completo (*full*): a matriz de entrada é preenchida com zeros ao redor das bordas, permitindo que o filtro seja aplicado em todas as posições possíveis, resultando em uma saída maior do que a entrada.

A dimensão de saída de uma convolução é dada por:

$$W_{out} = \frac{W_{in} - K + 2P}{S} + 1$$




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 3: Exemplo de convolução em uma imagem com *padding* do tipo “same”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.




Figura 4: Exemplo de convolução em uma imagem com *padding* do tipo “full”.

Convolução

Exemplo – Na rede LeNet-5, a primeira camada convolucional (C1) utiliza um filtro de tamanho 5×5 com *stride* de 1 e *padding* do tipo “valid”. Se a imagem de entrada tiver dimensão 32×32 , qual será a dimensão da saída da camada C1?

Convolução

Exemplo – Na rede LeNet-5, a primeira camada convolucional (C1) utiliza um filtro de tamanho 5×5 com *stride* de 1 e *padding* do tipo “valid”. Se a imagem de entrada tiver dimensão 32×32 , qual será a dimensão da saída da camada C1?

- $W_{in} = 32$

Convolução

Exemplo – Na rede LeNet-5, a primeira camada convolucional (C1) utiliza um filtro de tamanho 5×5 com *stride* de 1 e *padding* do tipo “valid”. Se a imagem de entrada tiver dimensão 32×32 , qual será a dimensão da saída da camada C1?

- $W_{in} = 32$
- $K = 5$

Convolução

Exemplo – Na rede LeNet-5, a primeira camada convolucional (C1) utiliza um filtro de tamanho 5×5 com *stride* de 1 e *padding* do tipo “valid”. Se a imagem de entrada tiver dimensão 32×32 , qual será a dimensão da saída da camada C1?

- $W_{in} = 32$
- $K = 5$
- $P = 0$ (pois o *padding* é do tipo “valid”).

Convolução

Exemplo – Na rede LeNet-5, a primeira camada convolucional (C1) utiliza um filtro de tamanho 5×5 com *stride* de 1 e *padding* do tipo “valid”. Se a imagem de entrada tiver dimensão 32×32 , qual será a dimensão da saída da camada C1?

- $W_{in} = 32$
- $K = 5$
- $P = 0$ (pois o *padding* é do tipo “valid”).
- $S = 1$

Convolução

Exemplo – Na rede LeNet-5, a primeira camada convolucional (C1) utiliza um filtro de tamanho 5×5 com *stride* de 1 e *padding* do tipo “valid”. Se a imagem de entrada tiver dimensão 32×32 , qual será a dimensão da saída da camada C1?

- $W_{in} = 32$
- $K = 5$
- $P = 0$ (pois o *padding* é do tipo “valid”).
- $S = 1$

Logo,

$$W_{out} = \frac{32 - 5 + 2 \times 0}{1} + 1 = 28$$

Redes Neurais Convolucionais

- São redes neurais especializadas na extração de características (*feature maps*) de objetos representados através de matrizes;

Redes Neurais Convolucionais

- São redes neurais especializadas na extração de características (*feature maps*) de objetos representados através de matrizes;
- A extração de características é realizada através de camadas convolucionais, que aplicam filtros para detectar padrões locais, como bordas, texturas e formas;

Redes Neurais Convolucionais

- São redes neurais especializadas na extração de características (*feature maps*) de objetos representados através de matrizes;
- A extração de características é realizada através de camadas convolucionais, que aplicam filtros para detectar padrões locais, como bordas, texturas e formas;
- Cada filtro é capaz de extrair uma característica específica e relevante para a tarefa de classificação ou reconhecimento de objetos;

Redes Neurais Convolucionais

- São redes neurais especializadas na extração de características (*feature maps*) de objetos representados através de matrizes;
- A extração de características é realizada através de camadas convolucionais, que aplicam filtros para detectar padrões locais, como bordas, texturas e formas;
- Cada filtro é capaz de extrair uma característica específica e relevante para a tarefa de classificação ou reconhecimento de objetos;
- A obtenção dos filtros é realizada durante o processo de treinamento da rede, onde os pesos dos filtros são ajustados para minimizar a função de perda, permitindo que a rede aprenda a identificar as características mais relevantes para a tarefa em questão.

Redes Neurais Convolucionais

Características das redes neurais convolucionais:

Redes Neurais Convolucionais

Características das redes neurais convolucionais:

- Arquitetura *feedforward* de múltiplas camadas;

Redes Neurais Convolucionais

Características das redes neurais convolucionais:

- Arquitetura *feedforward* de múltiplas camadas;
 - Diferente da MLP, que utiliza camadas baseadas em neurônios conectados, as CNNs utilizam camadas convolucionais que aplicam filtros para extrair características locais dos dados de entrada.

Redes Neurais Convolucionais

Características das redes neurais convolucionais:

- Arquitetura *feedforward* de múltiplas camadas;
 - Diferente da MLP, que utiliza camadas baseadas em neurônios conectados, as CNNs utilizam camadas convolucionais que aplicam filtros para extrair características locais dos dados de entrada.
- Entradas normalmente são imagens, mas podem ser outros tipos de dados estruturados em grade;

Redes Neurais Convolucionais

Características das redes neurais convolucionais:

- Arquitetura *feedforward* de múltiplas camadas;
 - Diferente da MLP, que utiliza camadas baseadas em neurônios conectados, as CNNs utilizam camadas convolucionais que aplicam filtros para extrair características locais dos dados de entrada.
- Entradas normalmente são imagens, mas podem ser outros tipos de dados estruturados em grade;
- Quantidade de saídas: m saídas;

Redes Neurais Convolucionais

Características das redes neurais convolucionais:

- Arquitetura *feedforward* de múltiplas camadas;
 - Diferente da MLP, que utiliza camadas baseadas em neurônios conectados, as CNNs utilizam camadas convolucionais que aplicam filtros para extrair características locais dos dados de entrada.
- Entradas normalmente são imagens, mas podem ser outros tipos de dados estruturados em grade;
- Quantidade de saídas: m saídas;
- Regra de atualização dos pesos: *backpropagation* com otimização por gradiente descendente.

Redes Neurais Convolucionais

Estrutura de uma rede neural convolucional típica:

Redes Neurais Convolucionais

Estrutura de uma rede neural convolucional típica:

- Camada de entrada;

Redes Neurais Convolucionais

Estrutura de uma rede neural convolucional típica:

- Camada de entrada;
- Camadas convolucionais;

Redes Neurais Convolucionais

Estrutura de uma rede neural convolucional típica:

- Camada de entrada;
- Camadas convolucionais;
- Camadas de *pooling*;

Redes Neurais Convolucionais

Estrutura de uma rede neural convolucional típica:

- Camada de entrada;
- Camadas convolucionais;
- Camadas de *pooling*;
- *Flattening*;

Redes Neurais Convolucionais

Estrutura de uma rede neural convolucional típica:

- Camada de entrada;
- Camadas convolucionais;
- Camadas de *pooling*;
- *Flattening*;
- Camadas totalmente conectadas;

Redes Neurais Convolucionais

Estrutura de uma rede neural convolucional típica:

- Camada de entrada;
- Camadas convolucionais;
- Camadas de *pooling*;
- *Flattening*;
- Camadas totalmente conectadas;
- Camada de saída.

Redes Neurais Convolucionais




Figura 5: Exemplo de arquitetura de uma rede neural convolucional (LeNET-5).

Redes Neurais Convolucionais

- Camadas de entrada: recebem os dados de entrada, como imagens, e os preparam para as camadas subsequentes;

Redes Neurais Convolucionais

- Camadas de entrada: recebem os dados de entrada, como imagens, e os preparam para as camadas subsequentes;
- Camadas convolucionais: aplicam filtros para extrair características locais dos dados de entrada, como bordas, texturas e formas;

Redes Neurais Convolucionais

- Camadas de entrada: recebem os dados de entrada, como imagens, e os preparam para as camadas subsequentes;
- Camadas convolucionais: aplicam filtros para extrair características locais dos dados de entrada, como bordas, texturas e formas;
- Camadas de *pooling*: reduzem a dimensionalidade dos mapas de características, mantendo as informações mais relevantes e reduzindo o risco de *overfitting*;

Redes Neurais Convolucionais

- Camadas de entrada: recebem os dados de entrada, como imagens, e os preparam para as camadas subsequentes;
- Camadas convolucionais: aplicam filtros para extrair características locais dos dados de entrada, como bordas, texturas e formas;
- Camadas de *pooling*: reduzem a dimensionalidade dos mapas de características, mantendo as informações mais relevantes e reduzindo o risco de *overfitting*;
 - *Max pooling*: seleciona o valor máximo em uma região específica do mapa de características;

Redes Neurais Convolucionais

- Camadas de entrada: recebem os dados de entrada, como imagens, e os preparam para as camadas subsequentes;
- Camadas convolucionais: aplicam filtros para extrair características locais dos dados de entrada, como bordas, texturas e formas;
- Camadas de *pooling*: reduzem a dimensionalidade dos mapas de características, mantendo as informações mais relevantes e reduzindo o risco de *overfitting*;
 - *Max pooling*: seleciona o valor máximo em uma região específica do mapa de características;
 - *Average pooling*: calcula a média dos valores em uma região específica do mapa de características;

Redes Neurais Convolucionais

- Camadas de entrada: recebem os dados de entrada, como imagens, e os preparam para as camadas subsequentes;
- Camadas convolucionais: aplicam filtros para extrair características locais dos dados de entrada, como bordas, texturas e formas;
- Camadas de *pooling*: reduzem a dimensionalidade dos mapas de características, mantendo as informações mais relevantes e reduzindo o risco de *overfitting*;
 - *Max pooling*: seleciona o valor máximo em uma região específica do mapa de características;
 - *Average pooling*: calcula a média dos valores em uma região específica do mapa de características;
 - *Sum pooling*: calcula a soma dos valores em uma região específica do mapa de características;

Redes Neurais Convolucionais

- *Flattening*: transforma os mapas de características em um vetor unidimensional, preparando os dados para as camadas totalmente conectadas;

Redes Neurais Convolucionais

- *Flattening*: transforma os mapas de características em um vetor unidimensional, preparando os dados para as camadas totalmente conectadas;
- Camadas totalmente conectadas: realizam a classificação ou regressão com base nas características extraídas pelas camadas convolucionais e de *pooling*;

Redes Neurais Convolucionais

- *Flattening*: transforma os mapas de características em um vetor unidimensional, preparando os dados para as camadas totalmente conectadas;
- Camadas totalmente conectadas: realizam a classificação ou regressão com base nas características extraídas pelas camadas convolucionais e de *pooling*;
 - Semelhante às camadas de uma MLP, onde cada neurônio está conectado a todos os neurônios da camada anterior, permitindo a combinação de características para realizar a tarefa de classificação ou regressão.

Redes Neurais Convolucionais

- *Flattening*: transforma os mapas de características em um vetor unidimensional, preparando os dados para as camadas totalmente conectadas;
- Camadas totalmente conectadas: realizam a classificação ou regressão com base nas características extraídas pelas camadas convolucionais e de *pooling*;
 - Semelhante às camadas de uma MLP, onde cada neurônio está conectado a todos os neurônios da camada anterior, permitindo a combinação de características para realizar a tarefa de classificação ou regressão.
- Camada de saída: produz a saída final da rede.

Redes Neurais Convolucionais

Redes neurais convolucionais conhecidas:

- LETNET-5: uma das primeiras arquiteturas de CNN, projetada para reconhecimento de dígitos manuscritos;

Redes Neurais Convolucionais

Redes neurais convolucionais conhecidas:

- LETNET-5: uma das primeiras arquiteturas de CNN, projetada para reconhecimento de dígitos manuscritos;
- AlexNet;

Redes Neurais Convolucionais

Redes neurais convolucionais conhecidas:

- LETNET-5: uma das primeiras arquiteturas de CNN, projetada para reconhecimento de dígitos manuscritos;
- AlexNet;
- VGGNet;

Redes Neurais Convolucionais

Redes neurais convolucionais conhecidas:

- LETNET-5: uma das primeiras arquiteturas de CNN, projetada para reconhecimento de dígitos manuscritos;
- AlexNet;
- VGGNet;
- ResNet;

Redes Neurais Convolucionais

Redes neurais convolucionais conhecidas:

- LETNET-5: uma das primeiras arquiteturas de CNN, projetada para reconhecimento de dígitos manuscritos;
- AlexNet;
- VGGNet;
- ResNet;
- GoogLeNet;




Figura 6: Exemplo de arquitetura de uma rede neural convolucional (AlexNet).