

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS (CMPF)
DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA (DETEC)

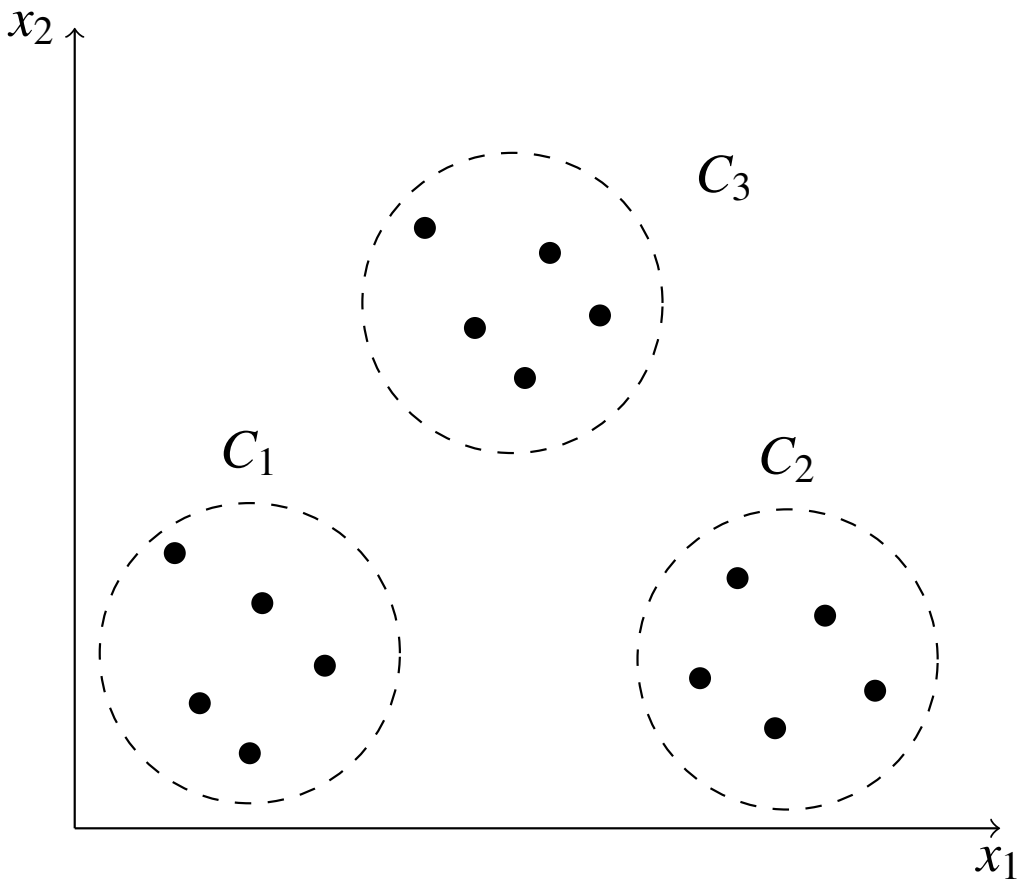
SISTEMAS INTELIGENTES

Algoritmos de Clusterização

Prof. Pedro Thiago Valério de Souza
UFERSA – Campus Pau dos Ferros
pedro.souza@ufersa.edu.br

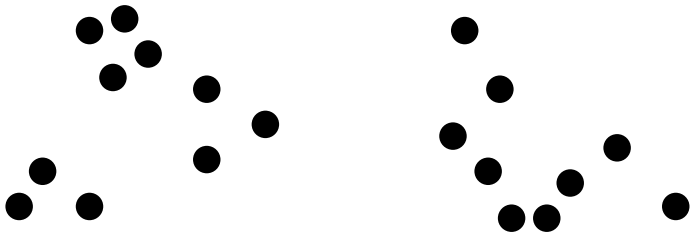
Conceitos Fundamentais

- *Cluster* (ou agrupamento): Coleção de objetos que compartilham características semelhantes.
- Objetos com características distintas fazem parte de *clusters* distintos.
- Clusterização: Agrupamento de conjuntos de dados em *clusters*;

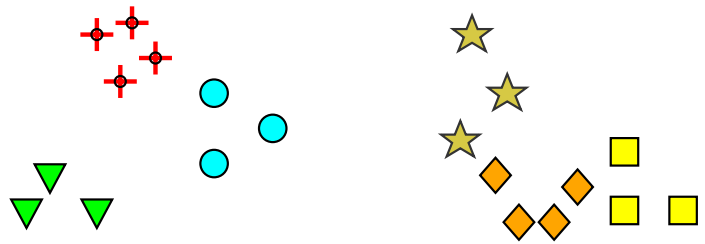


Conceitos Fundamentais

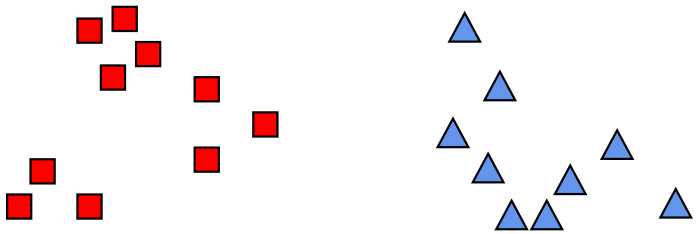
- A Clusterização é uma classificação não supervisionada;
  - Não é necessário conhecer as classes pré-definidas antes do algoritmo;
  - Sem resposta desejada para um determinado par de entrada;
  - Argumento necessário: quantidade de *clusters* no problema
- A definição da quantidade de *clusters* em um determinado problema pode ser ambígua.



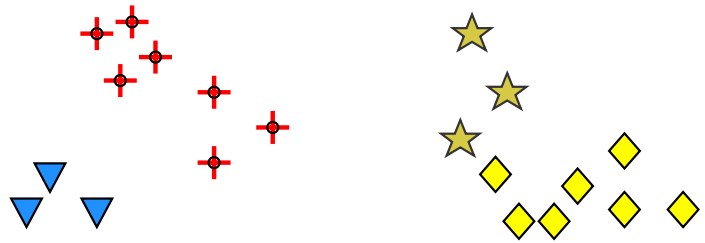
Quantos clusters?



Seis Clusters



Dois Clusters



Quatro Clusters

Conceitos Fundamentais

Clusterização versus Classificação:

- Classificação de padrões:
  - Aprendizado supervisionado;
  - Amostras de treinamento são classificadas
  - O número de classes e suas características são conhecidas;
  - Aprendizado por exemplos.
- Clusterização:
  - Aprendizado não supervisionado;
  - Aprendizado por observação;

Conceitos Fundamentais

Notação Formal: Considere n objetos com d atributos

$$X = \{\mathbf{x}_1, \ldots, \mathbf{x}_n\}, \qquad \mathbf{x}_i \in \mathbb{R}^d \qquad (\text{matriz } \mathbf{X} \in \mathbb{R}^{n \times d})$$

Agrupamento particional rígido em K grupos: partição $C = \{C_1, \ldots, C_K\}$ com

$$C_k \neq \emptyset, \qquad \bigcup_{k=1}^{K} C_k = X, \qquad C_j \cap C_k = \emptyset \ (j \neq k).$$

Agrupamento difuso: pertinência $u_{ik} \in [0,1]$, com $\sum_k u_{ik} = 1$.

Representantes (protótipos) dos grupos:

- *centroide*: vetor médio, $\boldsymbol{\mu}_k = \frac{1}{|C_k|} \sum_{\mathbf{x}_i \in C_k} \mathbf{x}_i$ (em geral, não é um objeto do conjunto);
- *medoide*: objeto do grupo que minimiza a soma das distâncias aos demais membros.

Conceitos Fundamentais

Por que precisamos de algoritmos heurísticos?

Número de partições de n objetos em K grupos não vazios (número de Stirling de 2.º tipo):

$$S(n,K) = \frac{1}{K!}\sum_{j=0}^{K}(-1)^j\binom{K}{j}(K-j)^n$$

n	K	$S(n,K)$
6	2	31
25	4	$\approx 4{,}68 \times 10^{13}$
100	5	$\approx 6{,}57 \times 10^{67}$

- Busca exaustiva é inviável mesmo para conjuntos pequenos.
- Algoritmos como o k-means encontram boas soluções (em geral, **ótimos locais**) em tempo razoável.

Conceitos Fundamentais

Tipos de agrupamento:

Quanto à estrutura produzida:

- **Particional**: uma única partição em K grupos (ex.: k-means).
- **Hierárquico**: sequência aninhada de partições, representada por um **dendrograma**.

Quanto à pertinência:

- **Exclusivo**: cada objeto em exatamente um grupo.
- **Sobreposto**: um objeto pode pertencer a mais de um grupo.
- **Difuso**: todos os objetos pertencem a todos os grupos, com graus diferentes.

Quanto à cobertura:

- **Completo**: todos os objetos são agrupados.
- **Parcial**: ruído e *outliers* podem ficar sem grupo (ex.: DBSCAN).

Conceitos Fundamentais

Família	Ideia central	Exemplos
Particionais (protótipos)	Otimizam uma função da distância dos objetos aos protótipos	k-means, k-medoids, fuzzy c-means
Hierárquicos	Fundem (ou dividem) grupos sucessivamente, formando uma árvore	Ligação simples, completa, média, Ward; DIANA
Densidade	Grupos são regiões densas separadas por regiões esparsas	DBSCAN, OPTICS, HDBSCAN
Probabilísticos	Dados gerados por uma mistura de distribuições	Mistura de gaussianas (EM)
Grafos	Componentes fracamente conectadas de um grafo de similaridade	Agrupamento espectral

Conceitos Fundamentais

Aplicações

- **Quantização vetorial e compressão**: os centroides formam um *codebook*; cada vetor é substituído pelo índice do centroide mais próximo (ex.: quantização de cores).
- **Segmentação de imagens**: agrupamento de pixels por cor, textura ou posição.
- **Redes de sensores e IoT**: formação de grupos de nós e escolha de *cluster heads*.
- **Detecção de anomalias**: objetos distantes de todos os protótipos (falhas, intrusões, fraudes).
- **Segmentação de usuários** e sistemas de recomendação.
- **Pré-processamento**: redução de dados, criação de atributos, rotulação inicial.

Conceitos Fundamentais

- Características de uma boa clusterização:
  - Alta similaridade entre os dados de uma mesma classe;
  - Baixa similaridade entre dados de classes diferentes;
- Características de um método ideal de clusterização:
  - Descobrir *clusters* com forma arbitrária;
  - Identificar *clusters* de tamanhos variados;
  - Aceitar os diversos tipos de variáveis possíveis;
  - Ser insensível a ordem de apresentação dos objetos;
  - Trabalhar com objetos com qualquer número de atributos;
  - Ser escalável para lidar com qualquer quantidade de objetos;
  - Ser robusto na presença de ruídos;
  - Exigir o mínimo de conhecimento do conjunto a ser clusterizado;
  - Aceitar restrições;
  - Encontrar o número adequado de *clusters*;

Conceitos Fundamentais

- A qualidade dos resultados depende:
  - Medida de similaridade usada;
  - Método e sua implementação;
- A qualidade do método de clusterização é medida pela sua habilidade de descobrir alguns ou todos as classes escondidas;
- Nenhuma técnica de Clusterização atende a todos os pontos adequadamente;
- Contudo, um trabalho considerável tenha sido feito para atender a cada ponto separadamente;

Medidas de Similaridade

- Medem o grau de similaridade entre os objetos;
- As medidas de similaridade dependem dos tipos de dados no problema de clusterização;
- As variáveis comuns são:
  - Variáveis numéricas;
  - Variáveis binárias;
  - Variáveis nominais;
  - Variáveis composta de vários tipos (mistura);

Medidas de Similaridade

Matriz de Dados:

- As linhas representam cada um dos objetos a serem clusterizados e as colunas, os atributos de cada objeto.
- Considerando n objetos cada qual com p atributos, tem-se uma matriz $n \times p$ como abaixo:

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

Medidas de Similaridade

Matriz de Dissimilariedade (ou distância):

- Cada elemento da matriz representa a distância entre pares de objetos;
- Considerando n objetos a serem clusterizados têm-se uma matriz $n \times n$;

$$X = \begin{bmatrix} 0 & d_{12} & \cdots & d_{1n} \\ d_{21} & 0 & \cdots & d_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ d_{n1} & d_{n2} & \cdots & 0 \end{bmatrix}$$

- Propriedades:
  - Positividade: $d_{ij} \geq 0$;
  - Simetria: $d_{ij} = d_{ji}$
    - A matriz de dissimilaridade é simetrica (i.e. $\mathbf{D}^T = \mathbf{D}$)
  - Reflexibilidade: $d_{ij} = 0 \iff i = j$
  - Desigualdade triangular: $d_{ij} \leq d_{ih} + d_{hj}$

Medidas de Similaridade

- Distância de Minkowski:

$$d_{ij} = \left(\sum_{k=1}^{p} |x_{ik} - x_{jk}|^m \right)^{1/m}$$

- Distância Euclidiana:

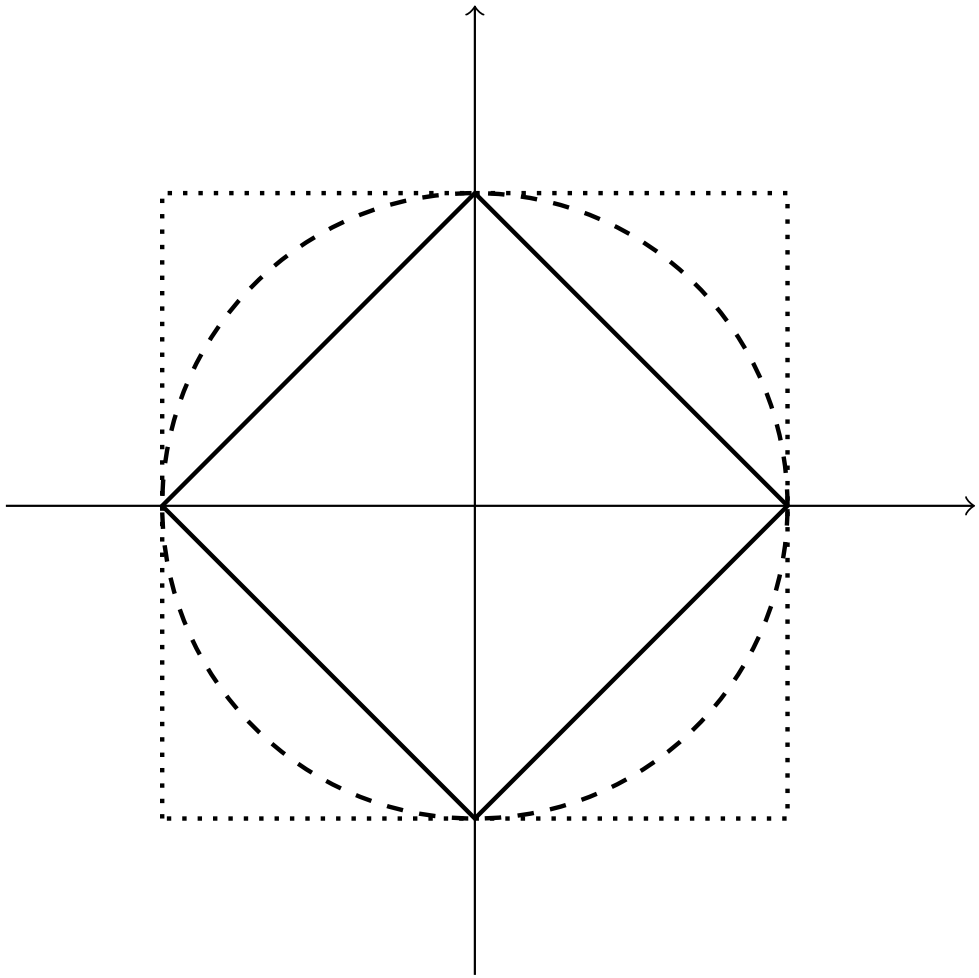
$$d_{ij} = \sqrt{\sum_{k=1}^{p} (x_{ik} - x_{jk})^2};$$

- Distância de Manhattan:

$$d_{ij} = \sum_{k=1}^{p} |x_{ik} - x_{jk}|;$$

- Distância de Chebyshev:

$$d_{ij} = \max_{k=1}^{p} |x_{ik} - x_{jk}|;$$



Pontos a distância 1 da origem:
contínua $p = 1$; tracejada $p = 2$; pontilhada $p = \infty$

Medidas de Similaridade

- Distância de Mahalanobis:

$$d_{ij} = \sqrt{(x_i - x_j)^T S^{-1} (x_i - x_j)}$$

sendo S a matriz de covariância dos dados, calculada como:

$$S = \frac{1}{n-1} \left(X - \bar{X}\right)^T \left(X - \bar{X}\right)$$

  - Leva em consideração a correlação entre as variáveis;
  - Formam estruturas elipsoides orientadas conforme a estrutura de covariância dos dados.

- Cosseno de Similaridade:

$$d_{ij} = \frac{\sum_{k=1}^{p} x_{ik} x_{jk}}{\sqrt{\sum_{k=1}^{p} x_{ik}^2} \sqrt{\sum_{k=1}^{p} x_{jk}^2}}$$

  - Equivalente a encontrar a componente do vetor x_i na direção de x_j;
  - Possui valores entre -1 e 1, onde 1 indica que os vetores estão na mesma direção, -1 indica que estão em direções opostas e 0 indica que são ortogonais (sem similaridade).

Medidas de Similaridade

- Coeficiente de Correlação de Pearson:

$$d_{ij} = \frac{\sum_{k=1}^{p}(x_{ik} - \bar{x}_i)(x_{jk} - \bar{x}_j)}{\sqrt{\sum_{k=1}^{p}(x_{ik} - \bar{x}_i)^2}\sqrt{\sum_{k=1}^{p}(x_{jk} - \bar{x}_j)^2}}$$

  - Mede a força e a direção da relação linear entre os vetores x_i e x_j;
  - Possui valores entre -1 e 1, onde 1 indica uma correlação positiva perfeita, -1 indica uma correlação negativa perfeita e 0 indica ausência de correlação.

- Distância de Hamming:

$$d_{ij} = \sum_{k=1}^{p} \delta(x_{ik}, x_{jk})$$

  onde $\delta(x_{ik}, x_{jk})$ é o delta de Kronecker:

$$\delta(x_{ik}, x_{jk}) = \begin{cases} 0, & \text{se } x_{ik} = x_{jk} \\ 1, & \text{se } x_{ik} \neq x_{jk} \end{cases}$$

  - Usada para dados binários ou categóricos;
  - Mede o número de posições em que os vetores x_i e x_j diferem.

Medidas de Similaridade

- Distância para Dados Nominais (mais de dois estados, sem ordem):

$$d(\mathbf{x}, \mathbf{y}) = \frac{p - m}{p}, \qquad m = \text{n.º de atributos coincidentes}$$

  - Alternativa: *one-hot encoding* (M estados $\rightarrow$ M atributos binários).
  - **Nunca** codificar categorias como $1, 2, 3, \ldots$ e usar a distância euclidiana: cria ordem e distâncias inexistentes.

- Distância para Dados Ordinais (M_j estados ordenados): substitui-se o estado pelo posto $r_{ij} \in \{1, \ldots, M_j\}$ e

$$z_{ij} = \frac{r_{ij} - 1}{M_j - 1} \in [0, 1],$$

  que passa a ser tratado como quantitativo.

  Ex.: prioridade $\in \{\text{baixa}, \text{média}, \text{alta}\} \rightarrow r \in \{1, 2, 3\} \rightarrow z \in \{0;\ 0{,}5;\ 1\}$

Medidas de Similaridade

- Distância para Atributos Mistos: Distância de Gower.

$$d(\mathbf{x}_i, \mathbf{x}_j) = \frac{\sum_f \delta_{ij}^{(f)}\, d_{ij}^{(f)}}{\sum_f \delta_{ij}^{(f)}},$$

$$\delta_{ij}^{(f)} = \begin{cases} 0, & \text{valor ausente (ou binário assimétrico } 0\text{–}0) \\ 1, & \text{caso contrário} \end{cases}$$

  - Quantitativo: $d_{ij}^{(f)} = |x_{if} - x_{jf}|/R_f$ (R_f: amplitude do atributo).
  - Nominal ou binário: 0 se iguais, 1 se diferentes.
  - Ordinal: converte-se para z e trata-se como quantitativo.

Medidas de Similaridade

Exemplo. Dispositivos IoT são descritos por consumo (W, amplitude de 20 W no conjunto), protocolo (Wi-Fi, Zigbee, LoRa) e prioridade (baixa, média, alta). Para $D_1 = (12\text{ W};\ \text{Wi-Fi};\ \text{alta})$ e $D_2 = (4\text{ W};\ \text{LoRa};\ \text{média})$:

$$d_{\text{consumo}} = \frac{|12-4|}{20} = 0{,}4, \qquad d_{\text{protocolo}} = 1, \qquad d_{\text{prioridade}} = |1-0{,}5| = 0{,}5,$$

$$d(D_1, D_2) = \frac{0{,}4 + 1 + 0{,}5}{3} \approx 0{,}633.$$

Medidas de Similaridade

Observação: Necessidade de normalização de variáveis numéricas.

- Quando utilizada variáveis numéricas, a unidade da medida usada pode afetar a análise (Ex.: distância em km para distância em m);
- Para evitar isso, sugere-se normalizar os dados antes da clusterização;
- Forma mais comum para normalização: *z-score*.

Algoritmos de Clusterização

Algoritmos de Clusterização:

- Métodos particionais;
- Métodos hierárquicos;
- Métodos baseados em densidade;
- Outros métodos de clusterização.

Algoritmos de Clusterização

Critérios para escolher o algoritmo:

- **Formato esperado dos grupos**: compactos e esféricos (k-*means*, Ward) ou alongados e arbitrários (ligação simples, DBSCAN).
- **Tipo dos atributos**: o k-*means* exige atributos numéricos (calcula médias); para qualitativos ou mistos: k-modes, k-prototypes, k-medoids ou hierárquicos com Gower.
- **Necessidade de informar** K: o k-*means* exige K; nos hierárquicos, K é escolhido depois.
- **Interpretabilidade**: centroides resumem os grupos; dendrogramas mostram suas relações.

Validação de Algoritmos de Clusterização

Sem rótulos, avaliar um agrupamento é mais difícil que avaliar um classificador.

- **Internos**: usam só os dados e a partição (coesão e separação).
- **Externos**: comparam com rótulos de referência, quando existem.
- **Relativos**: comparam partições de algoritmos ou parâmetros diferentes (ex.: vários K).

Validação de Algoritmos de Clusterização

Soma de Quadrados: Sejam $\bar{\mathbf{x}}$ a média global dos dados, $\boldsymbol{\mu}_k$ o centroide e $n_k = |C_k|$ o tamanho do grupo k. Definem-se:

$$\text{SST} = \sum_{i=1}^{n} \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 \qquad \text{(soma de quadrados total)},$$

$$\text{SSW (inércia)} = \sum_{k=1}^{K} \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 \qquad \text{(intragrupos: mede a coesão)},$$

$$\text{SSB} = \sum_{k=1}^{K} n_k \|\boldsymbol{\mu}_k - \bar{\mathbf{x}}\|^2 \qquad \text{(entre grupos: mede a separação)}.$$

$$\text{SST} = \text{SSW} + \text{SSB} \;\Rightarrow\; \text{minimizar SSW} \iff \text{maximizar SSB}.$$

Validação de Algoritmos de Clusterização

Coeficiente de Silhueta: Para o objeto $\mathbf{x}_i$ do grupo C_I:

$$a(i) = \frac{1}{|C_I| - 1} \sum_{\mathbf{x}_j \in C_I,\ j \neq i} d(\mathbf{x}_i, \mathbf{x}_j) \qquad \text{(distância média ao próprio grupo)}$$

$$b(i) = \min_{J \neq I} \frac{1}{|C_J|} \sum_{\mathbf{x}_j \in C_J} d(\mathbf{x}_i, \mathbf{x}_j) \qquad \text{(distância média ao grupo vizinho)}$$

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1]$$

- $s(i) \approx 1$: bem alocado; $s(i) \approx 0$: na fronteira; $s(i) < 0$: provavelmente no grupo errado.
- $s(i) = 0$ se $|C_I| = 1$ (convenção).
- Silhueta média: $\bar{s} = \frac{1}{n} \sum_i s(i)$ — quanto maior, melhor a partição.

Validação de Algoritmos de Clusterização

Outros Índices de Validação Internos:

- Davies–Bouldin (menor é melhor; σ_k: distância média ao centroide em C_k):

$$\text{DB} = \frac{1}{K} \sum_{k=1}^{K} \max_{j \neq k} \frac{\sigma_k + \sigma_j}{\|\boldsymbol{\mu}_k - \boldsymbol{\mu}_j\|}$$

- Calinski–Harabasz (maior é melhor): $\text{CH} = \dfrac{\text{SSB}/(K-1)}{\text{SSW}/(n-K)}$

Índices de Validação Externos (com rótulos de referência $L_1, \ldots, L_M$)

- Pureza: $\frac{1}{n} \sum_k \max_j |C_k \cap L_j|$ (enganosa para K grande).
- Índice de Rand ajustado (ARI): 1 para partições idênticas, ≈ 0 para partições aleatórias.

Métodos Particionais

- Os algoritmos particionais dividem a base de dados em k-grupos, em que o número k é dado pelo usuário;
- Objetivo: Encontrar uma partição de k *clusters* que otimiza o critério de particionamento escolhido.
- Principais algoritmos de clusterização particional:
  - k-médias (k-*means*): Cada *cluster* é representado pelo centro (centróide) do *cluster*;
  - k-medoids: Cada *cluster* é representado por um dos objetos no *cluster*.
- Principio de Funcionamento:
  - Inicialmente, o algoritmo escolhe k objetos como sendo os centros dos k *clusters*.
  - Os objetos então são divididos entre os k *clusters* de acordo com a medida de similaridade adotada;
  - Cada objeto fica no *cluster* que forneça o menor valor de distância entre o objeto e o centro do *cluster*.;
  - Atualizar a posição do centro do *cluster*, devido a inserção dos dados.

Algoritmo do k-means

- Algoritmo mais simples de clusterização particional;
- Proposto por James MacQueen em 1967;
- Objetivo: Particionar n objetos em k *clusters* de forma que a soma das distâncias quadráticas entre os objetos e o centro do *cluster* seja minimizada;
- O centro do *cluster* é a média dos objetos pertencentes ao *cluster*;
- O algoritmo é iterativo e converge para um mínimo local, mas não necessariamente para o mínimo global.

Algoritmo do k-means

Dado o número de grupos K, o *k-means* busca a partição $C = \{C_1, \ldots, C_K\}$ e os centroides $\boldsymbol{\mu}_1, \ldots, \boldsymbol{\mu}_K$ que minimizam a soma dos quadrados das distâncias euclidianas de cada objeto ao centroide do seu grupo:

$$J(C, \boldsymbol{\mu}_1, \ldots, \boldsymbol{\mu}_K) = \sum_{k=1}^{K} \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2.$$

- Minimizar J globalmente é **NP-difícil**.
- **Algoritmo de Lloyd**: otimização **alternada**
  - fixa os centroides $\rightarrow$ otimiza as atribuições;
  - fixa as atribuições $\rightarrow$ otimiza os centroides;
  - repete até convergir.
- Origem: quantização de sinais em sistemas PCM (*Pulse Code Modulation*) — próximo de processamento de sinais e comunicações digitais.

Algoritmo do k-means

1. **Inicialização**: escolha de K centroides — influencia fortemente o resultado.
2. **Atribuição**: cada objeto vai para o centroide mais próximo.
   - O espaço é dividido em K regiões convexas (**células de Voronoi**), separadas pelos hiperplanos mediadores entre pares de centroides.
3. **Atualização**: cada centroide passa a ser a média dos seus objetos.
4. **Parada**: nenhum objeto muda de grupo, deslocamento $< \varepsilon$ ou $t = T$.

Algoritmo 1: K-means (algoritmo de Lloyd).

Entrada: dados $X = \{\mathbf{x}_1, \ldots, \mathbf{x}_n\} \subset \mathbb{R}^d$; número de grupos K; tolerância ε; número máximo de iterações T

Saída: centroides $\boldsymbol{\mu}_1, \ldots, \boldsymbol{\mu}_K$ e rótulos $c_1, \ldots, c_n$

Escolha K centroides iniciais $\boldsymbol{\mu}_1, \ldots, \boldsymbol{\mu}_K$ (por exemplo, K objetos sorteados de X);

$t \leftarrow 0$;

repita

  $t \leftarrow t + 1$;

  `// Passo de atribuição`

  para $i \leftarrow 1$ **até** n **faça**

    $c_i \leftarrow \arg\min_{k \in \{1,\ldots,K\}} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$;

  fim

  `// Passo de atualização`

  para $k \leftarrow 1$ **até** K **faça**

    $C_k \leftarrow \{\mathbf{x}_i : c_i = k\}$;

    $\boldsymbol{\mu}_k^{\text{novo}} \leftarrow \dfrac{1}{|C_k|} \sum_{\mathbf{x}_i \in C_k} \mathbf{x}_i$;

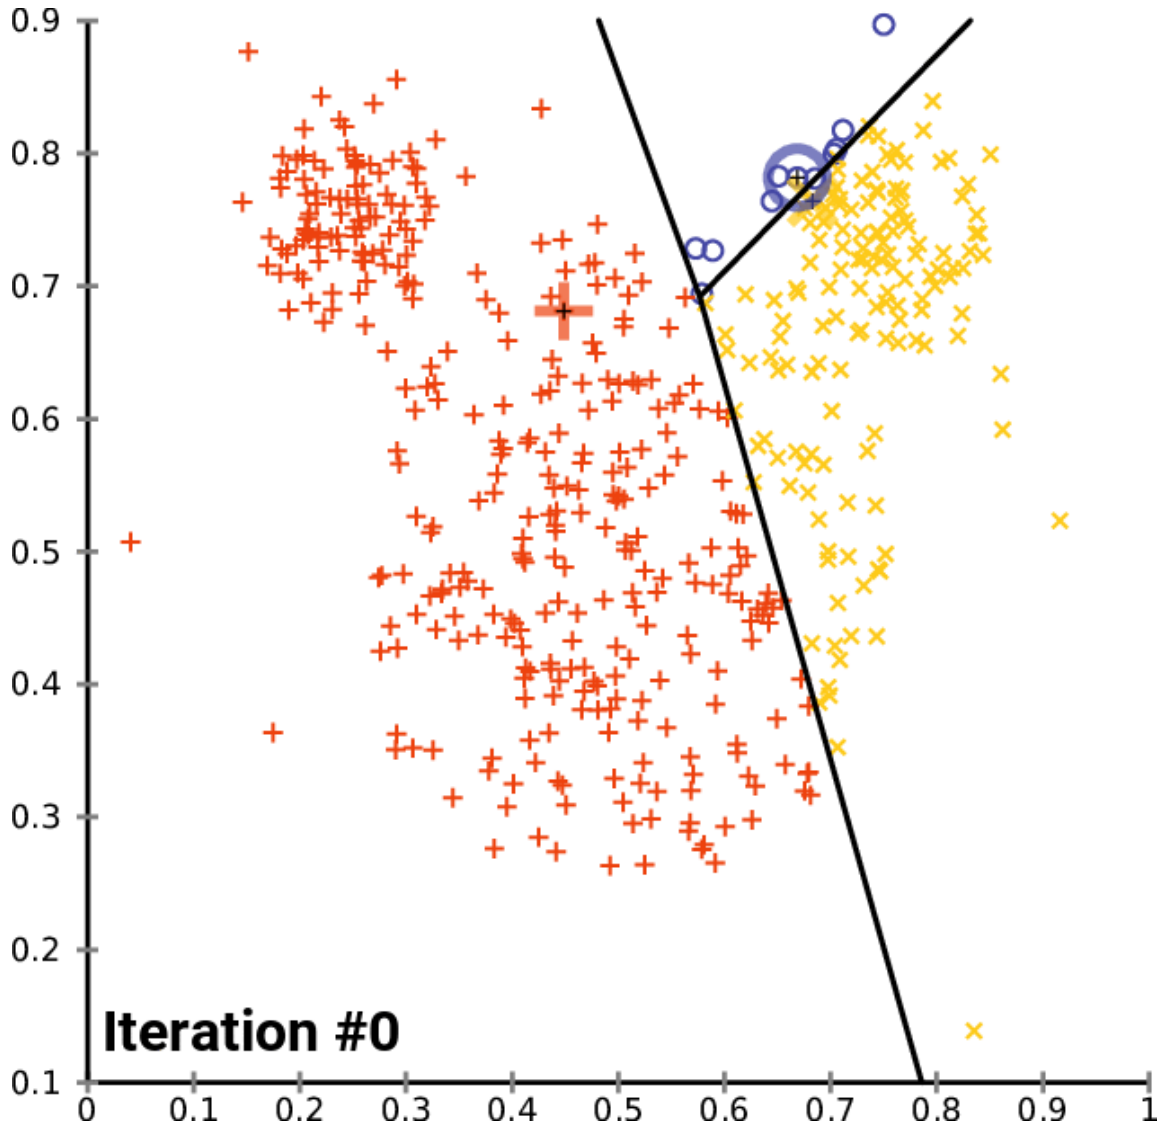
  fim

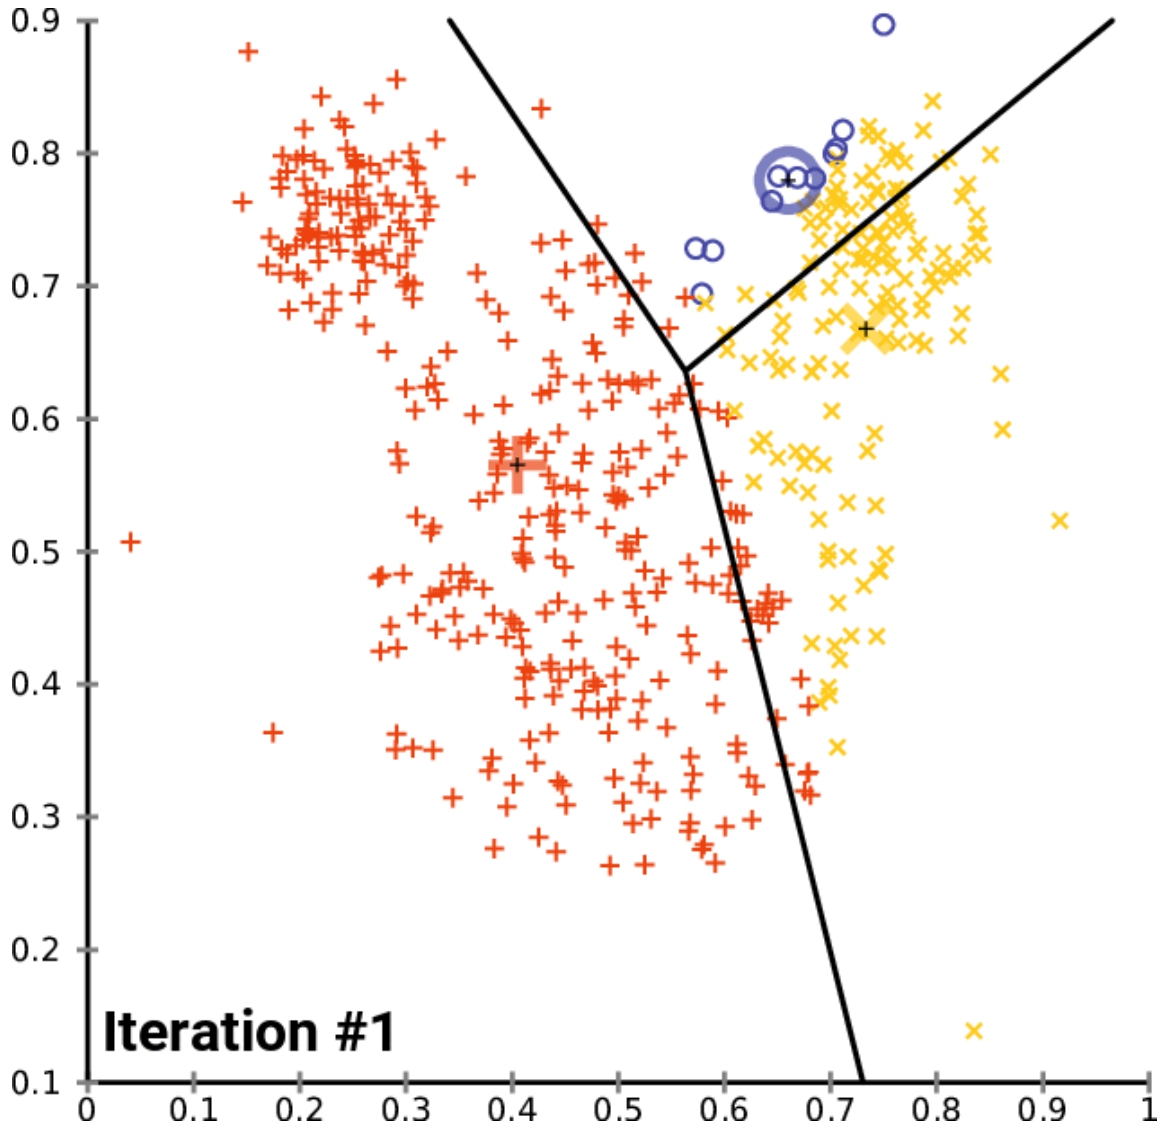
  $\Delta \leftarrow \max_k \|\boldsymbol{\mu}_k^{\text{novo}} - \boldsymbol{\mu}_k\|$;

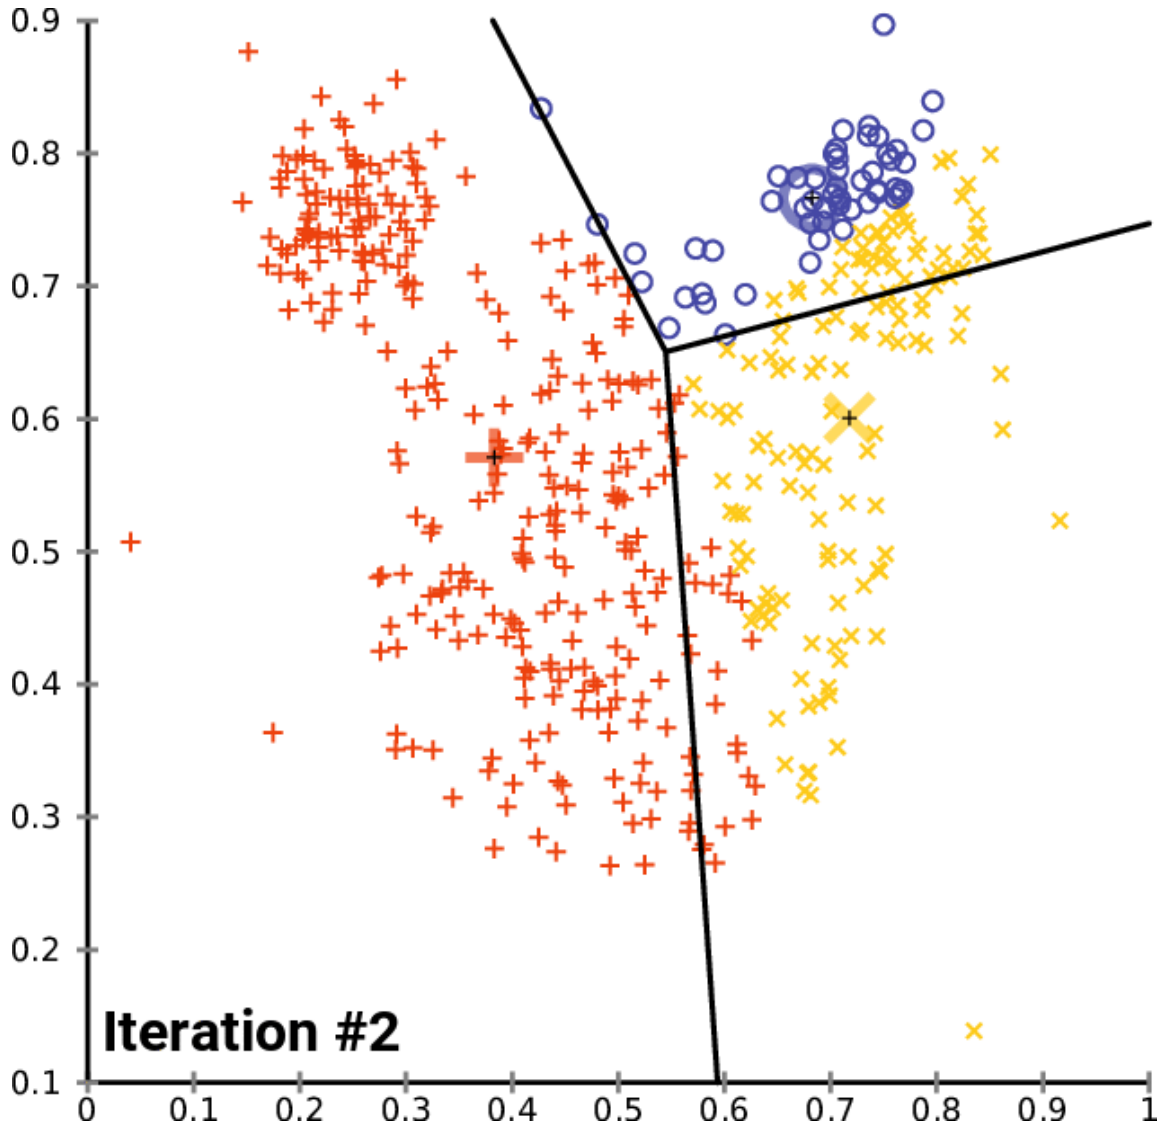
  $\boldsymbol{\mu}_k \leftarrow \boldsymbol{\mu}_k^{\text{novo}}$, para $k = 1, \ldots, K$;

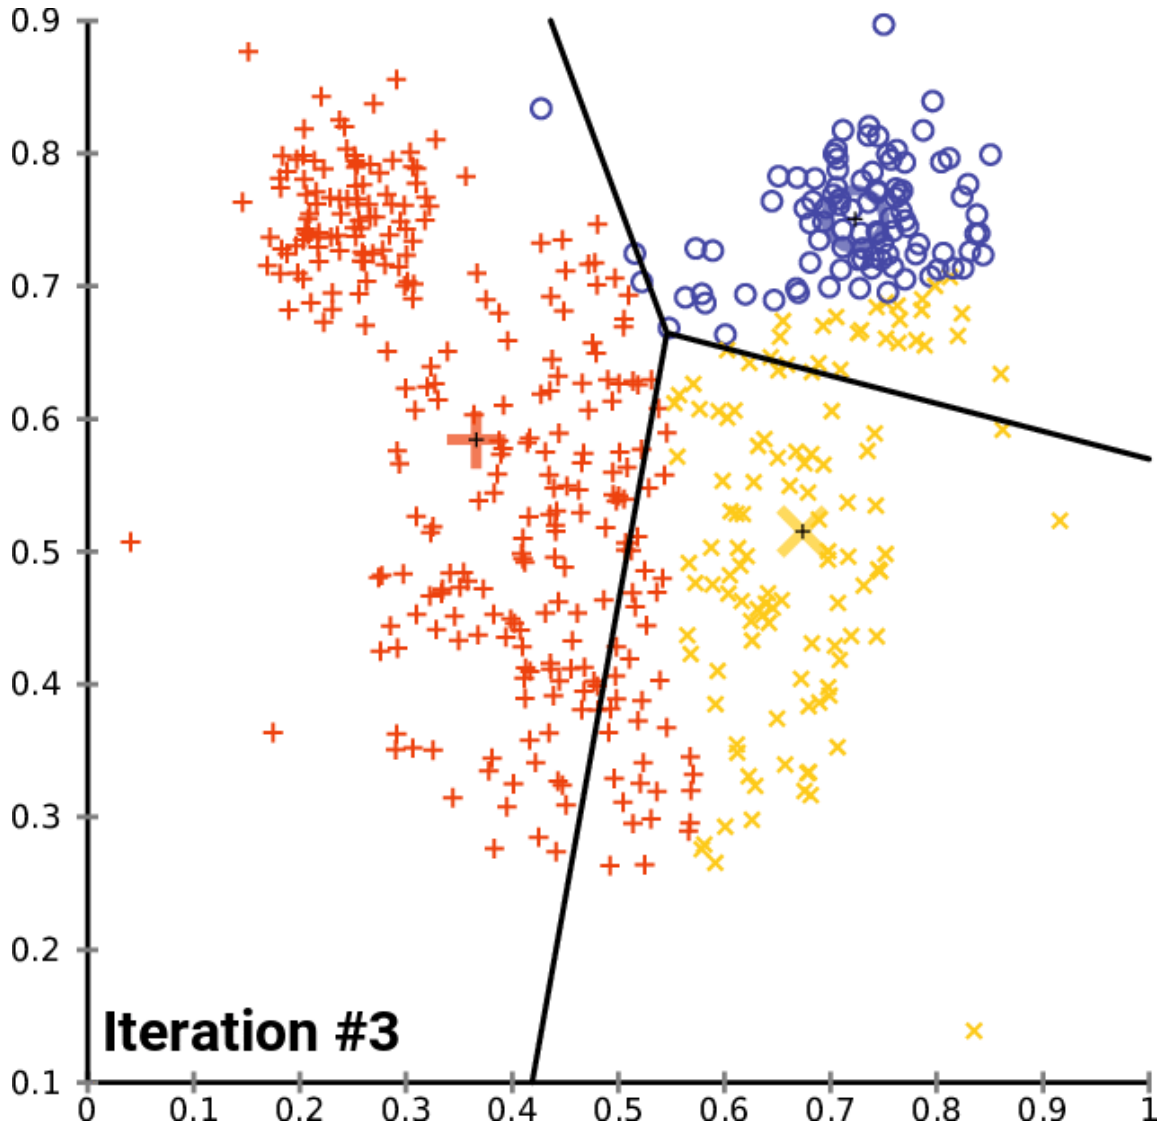
até $\Delta < \varepsilon$ ***ou*** $t = T$;

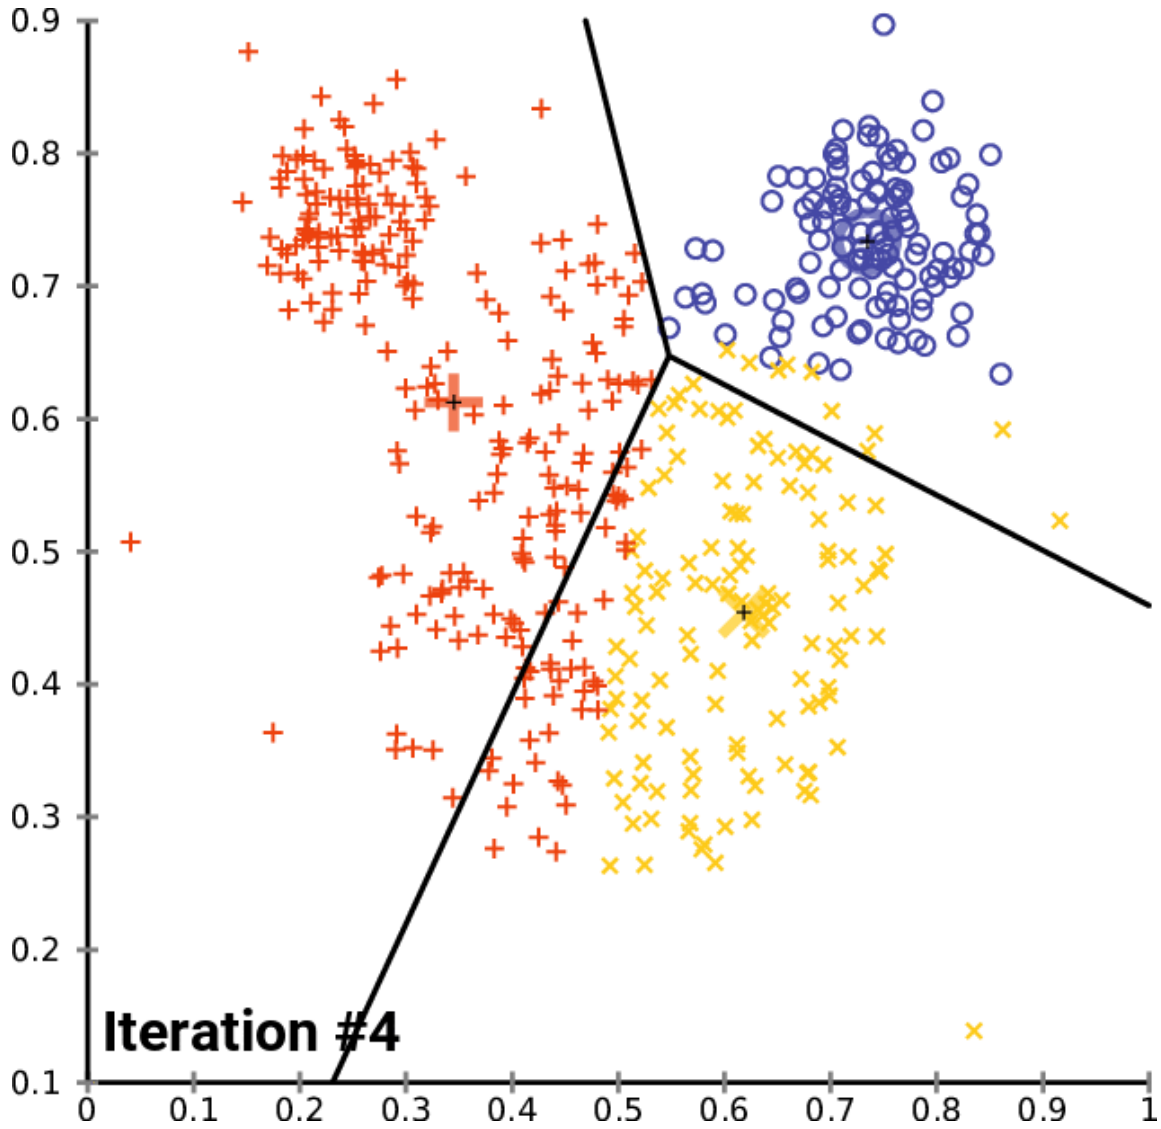
retorna $\{\boldsymbol{\mu}_k\}_{k=1}^K$ e $\{c_i\}_{i=1}^n$;

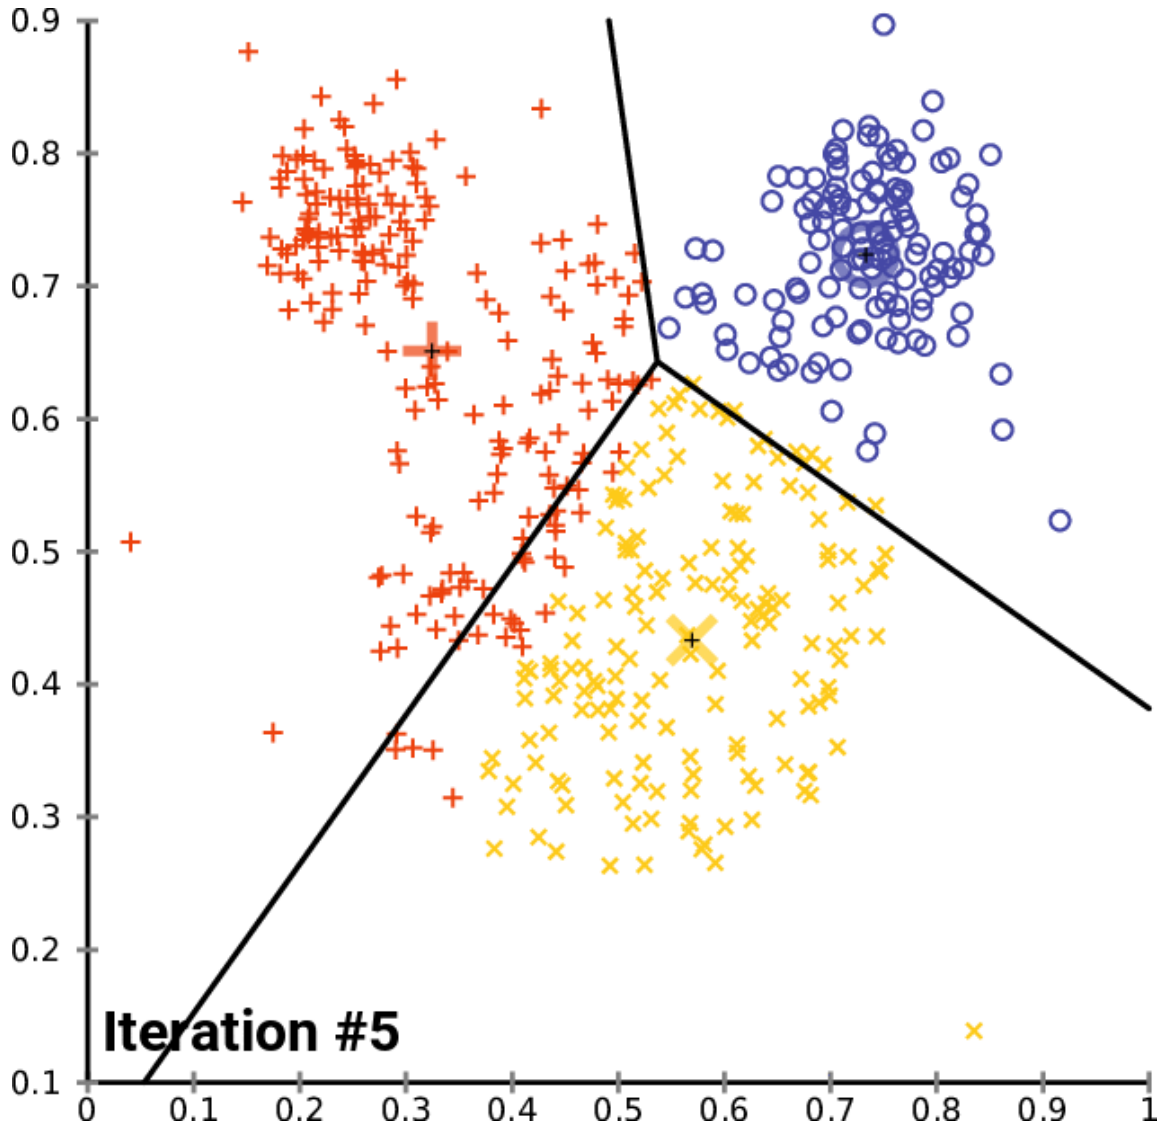

0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Iteration #0

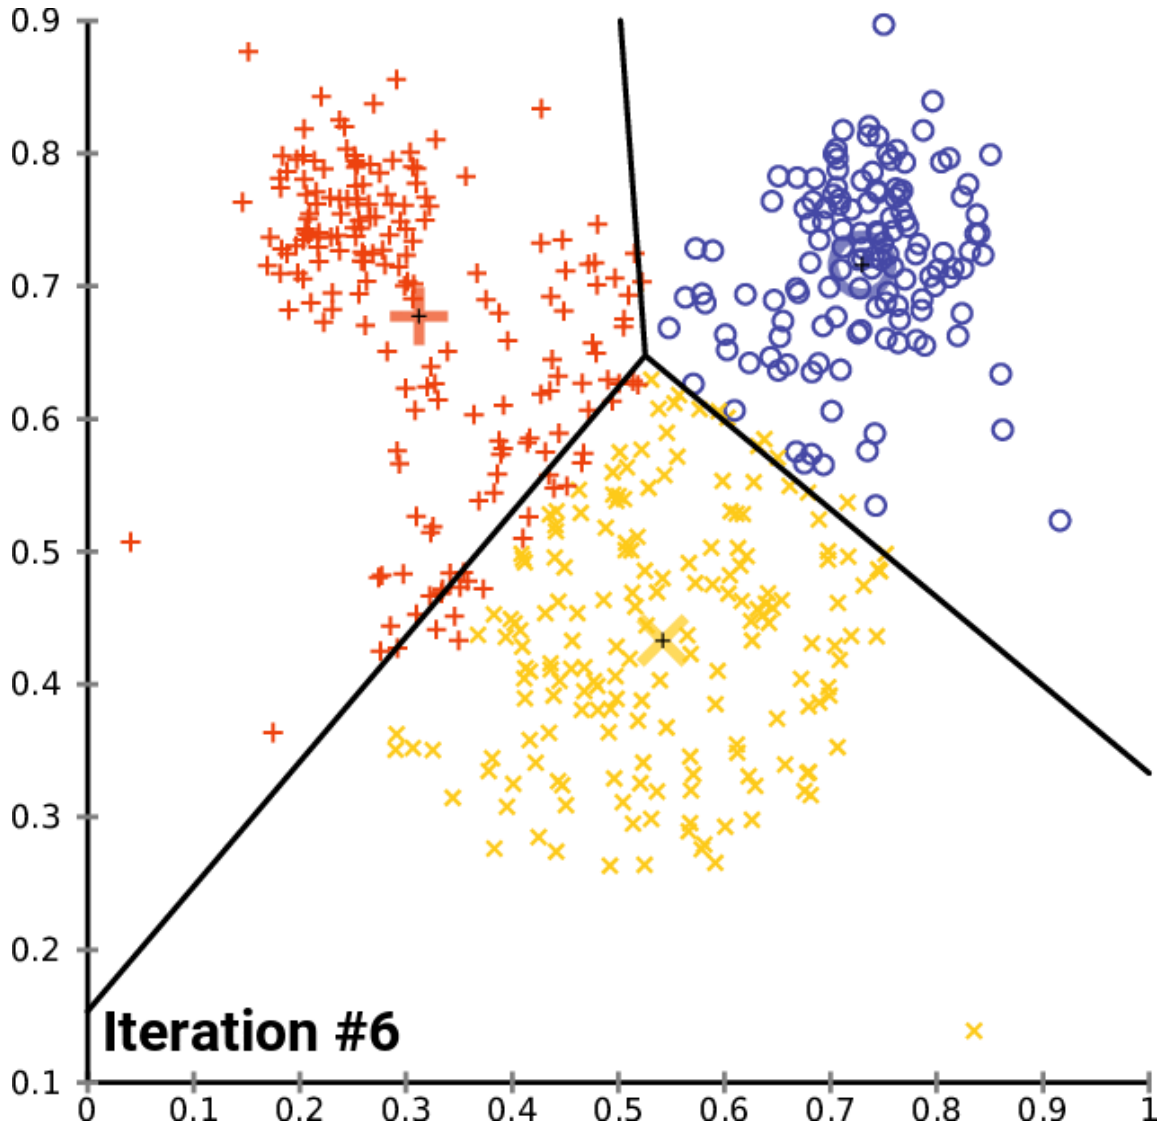

0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Iteration #1

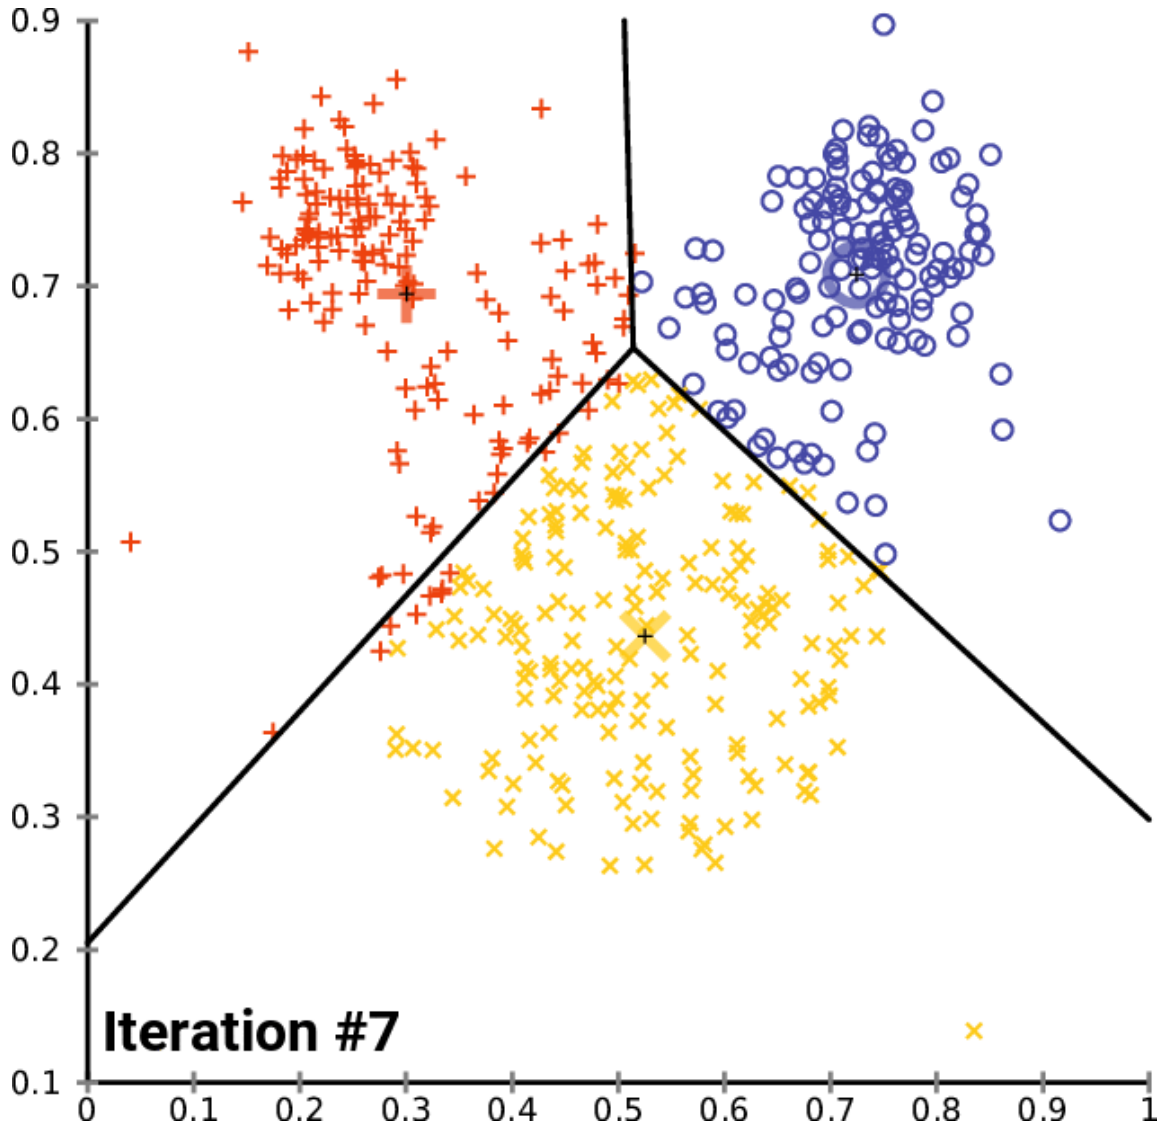

0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Iteration #2

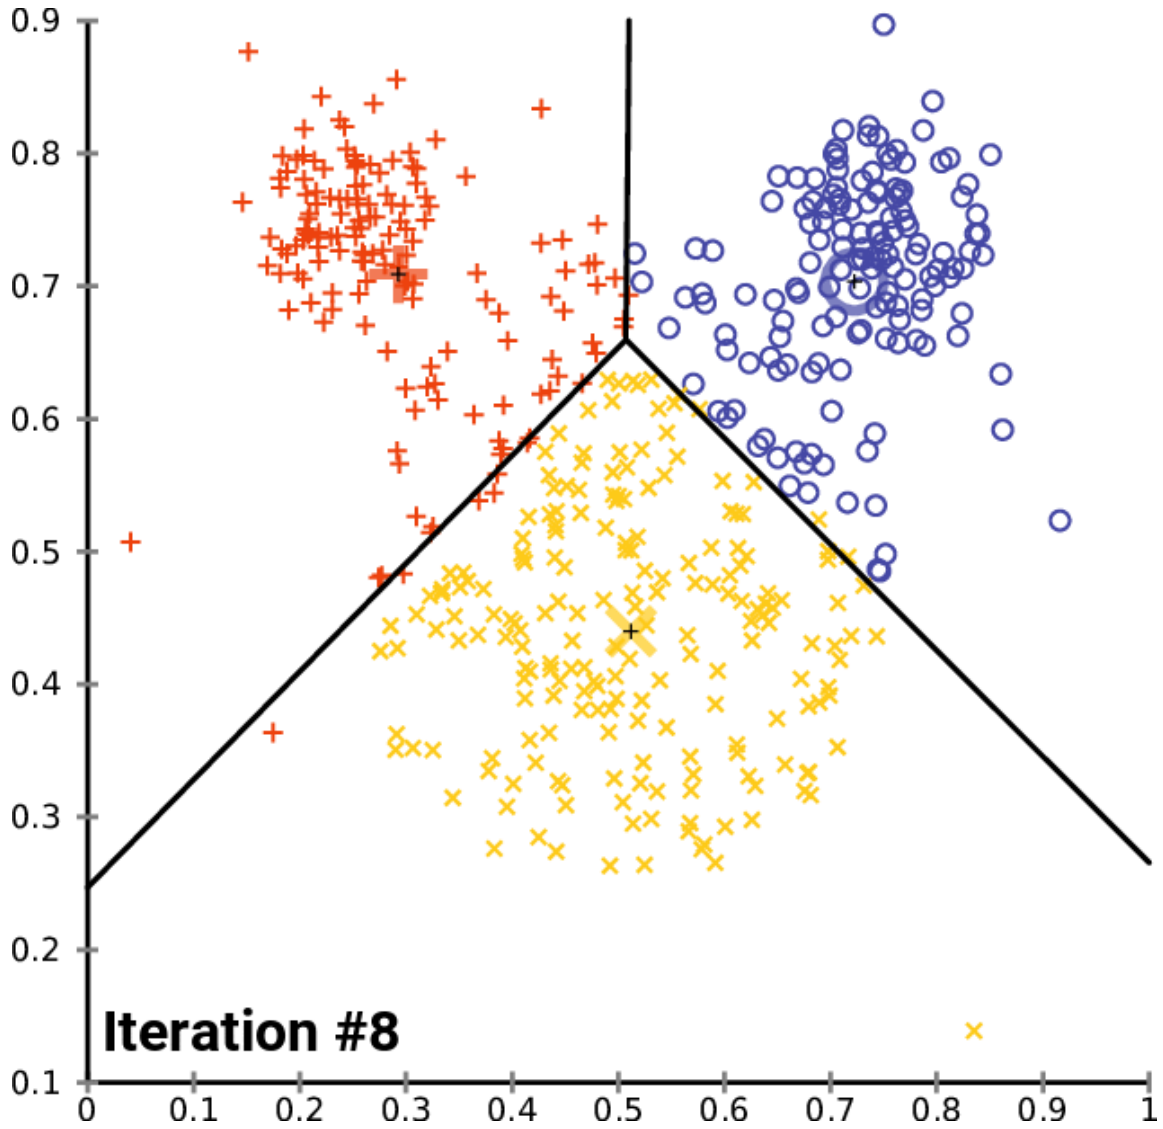

Iteration #3
0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1

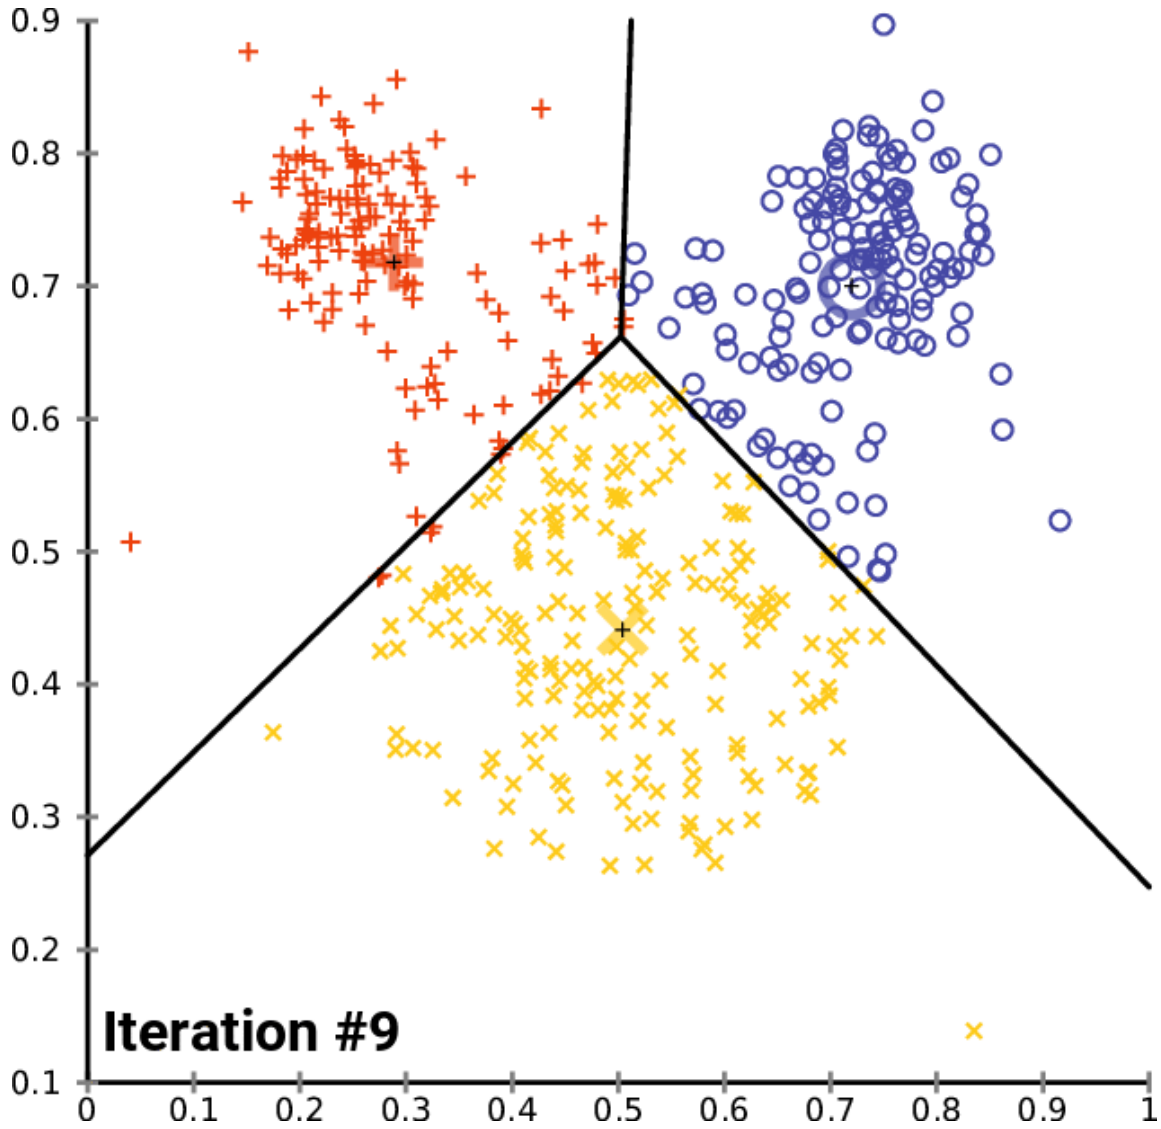

0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Iteration #4

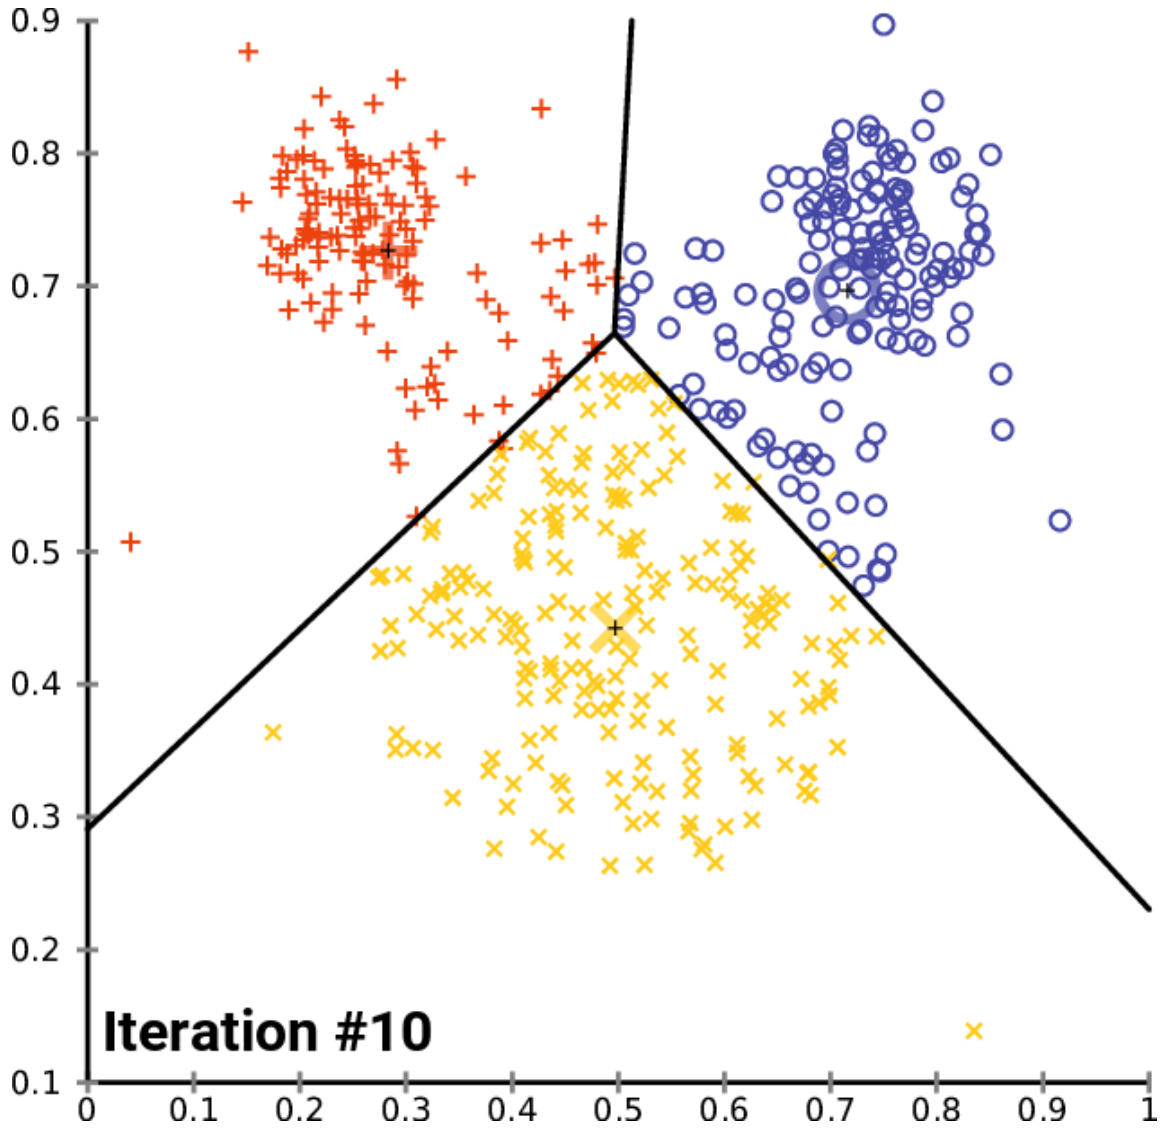

0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Iteration #5

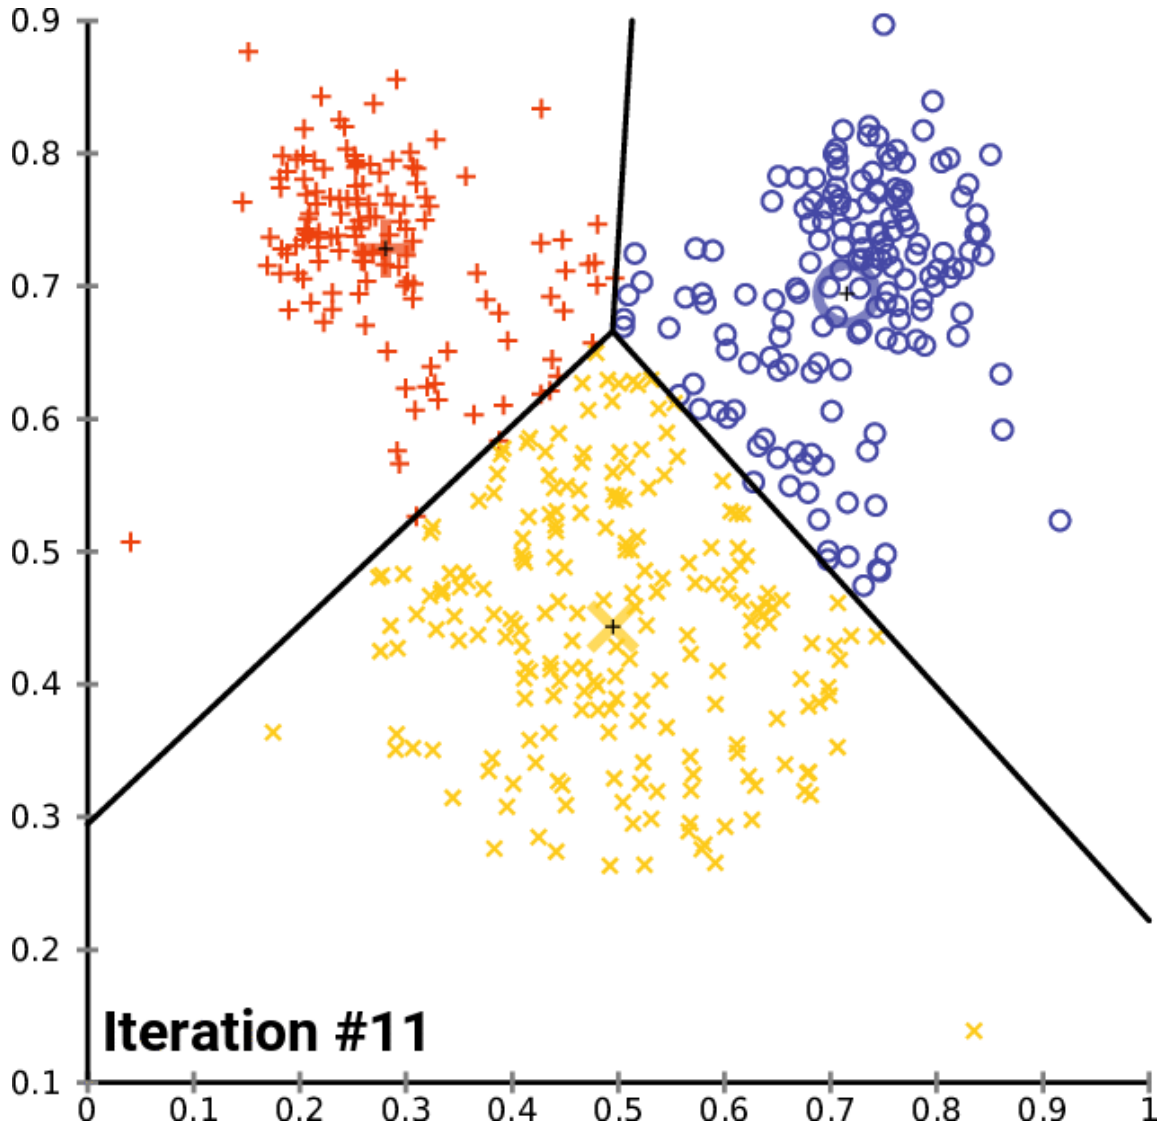

Iteration #6
0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1

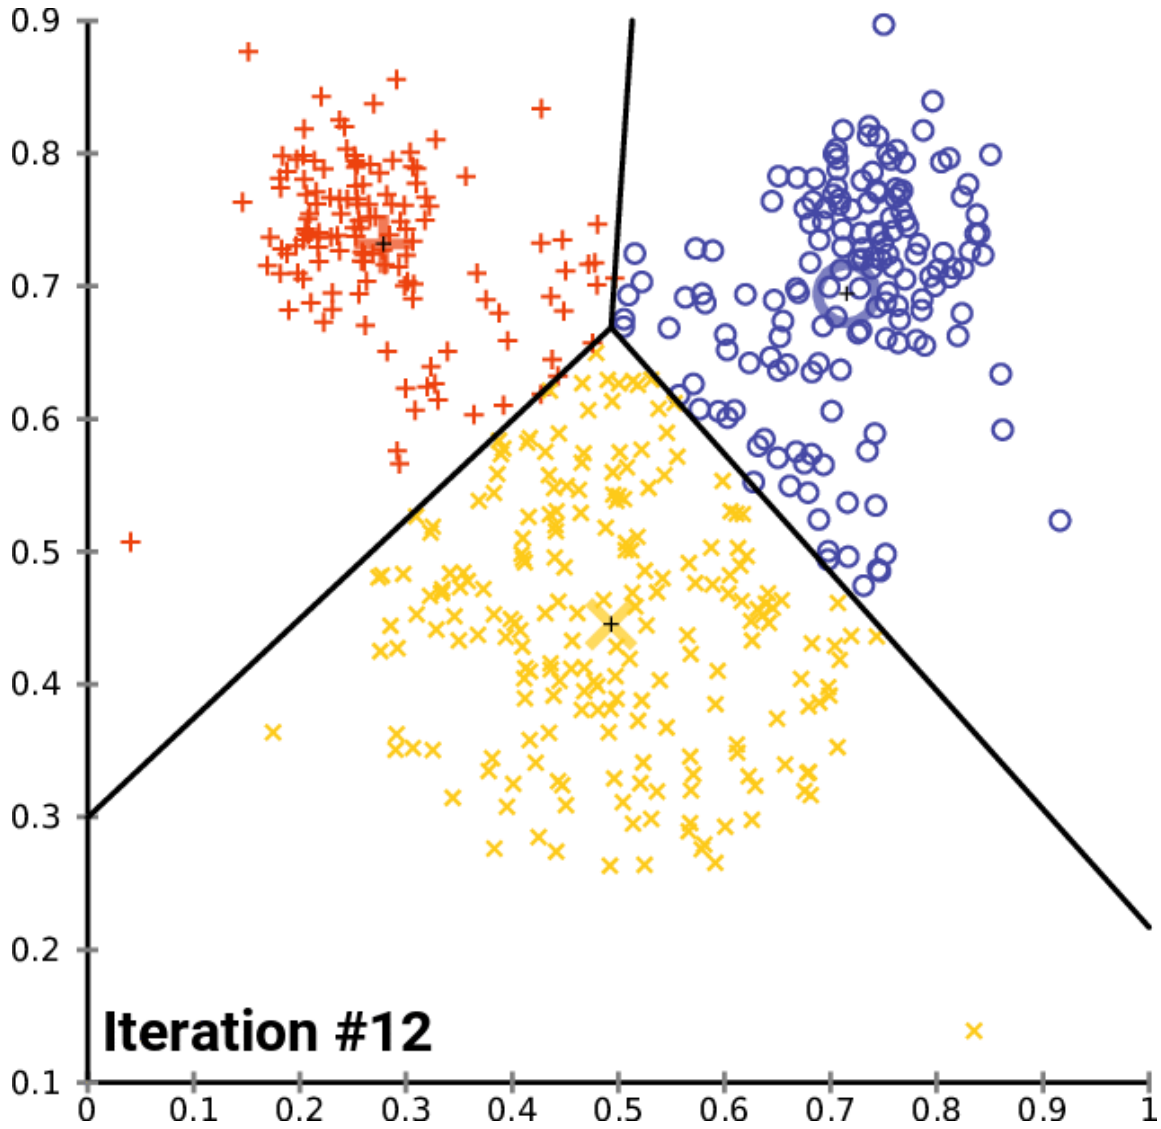

0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Iteration #7

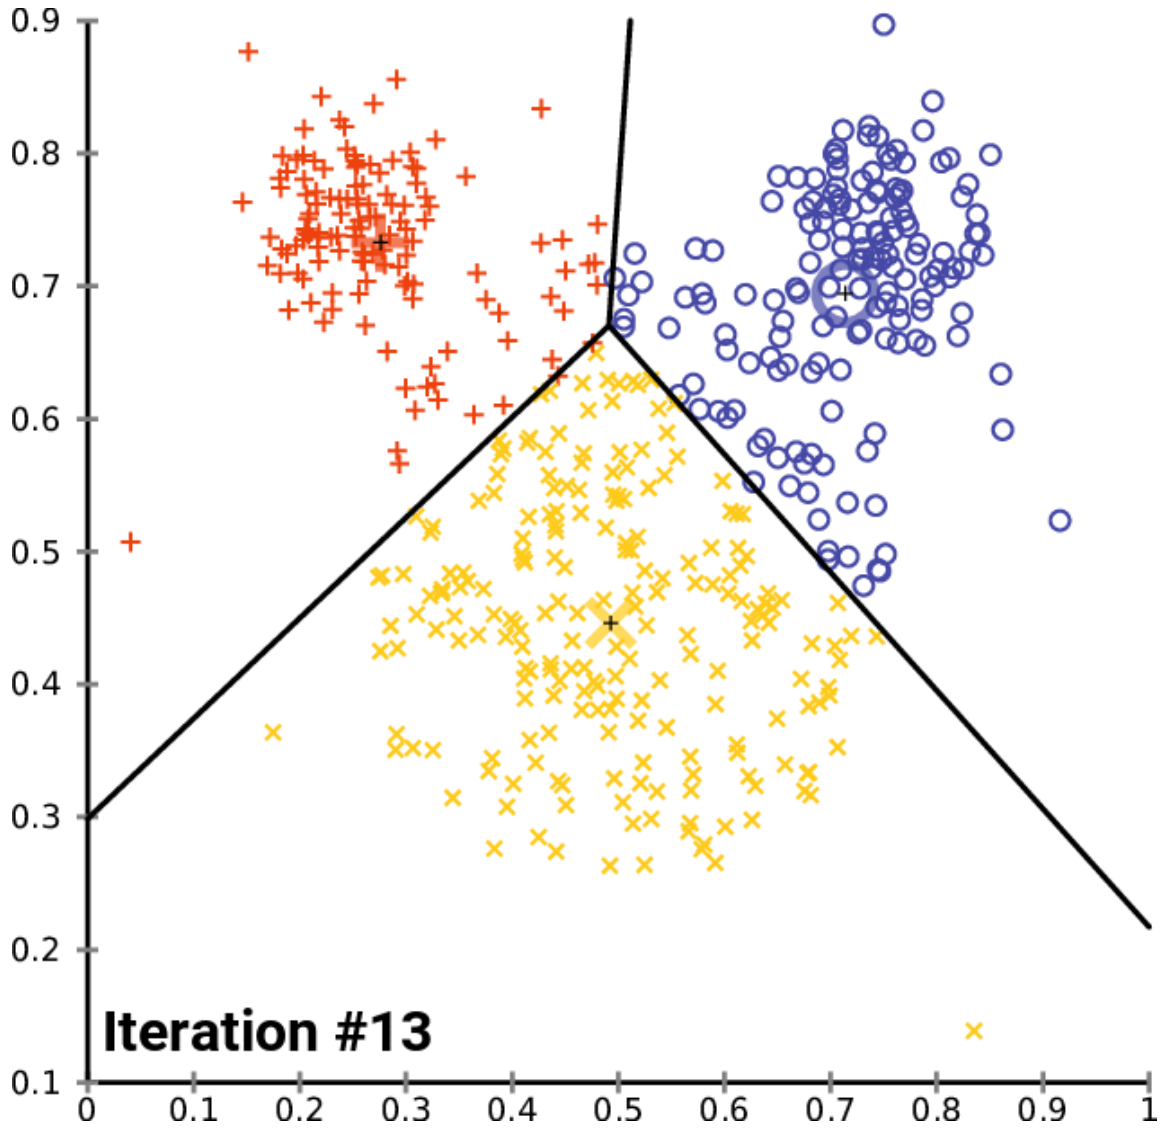

0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Iteration #8

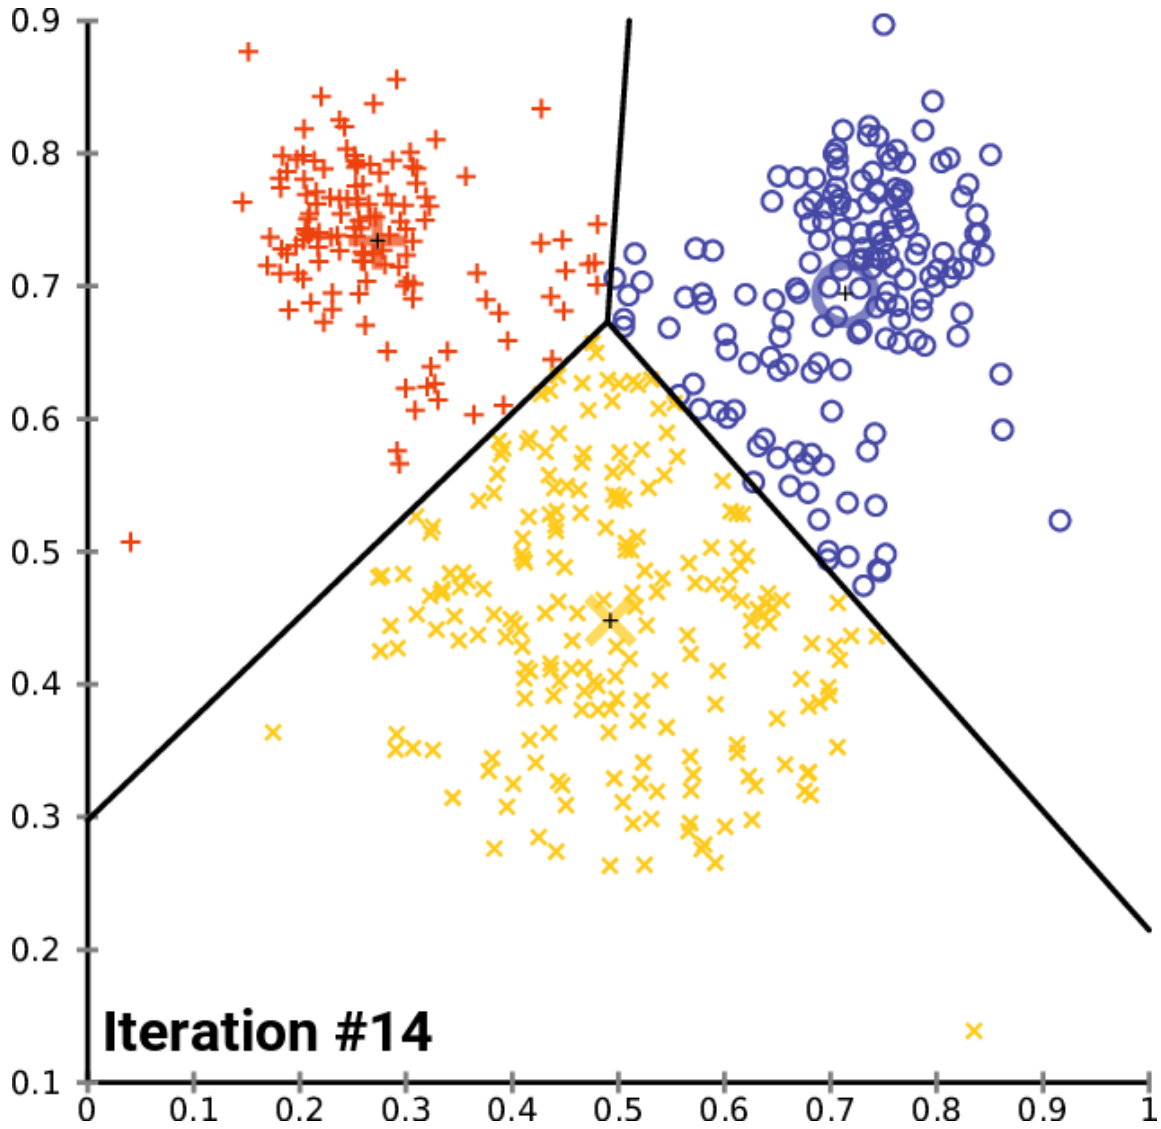

0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Iteration #9


0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Iteration #10


0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Iteration #11


0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Iteration #12


0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Iteration #13


0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Iteration #14

Algoritmo do k-means

Vantagens:

- É um dos métodos mais simples para realizar a clusterização de dados;
- Relativamente eficiente;
- Complexidade: $O(tkn)$, em que:
  - n é o número de objetos;
  - k é o número de *clusters*;
  - t é o número de iterações;

Desvantagens:

- A versão original é aplicável somente quando a média é definida $\rightarrow$ ineficiente para atributos nominais;
- Necessidade de especificar k, o número de *clusters*, a-priori;
- Ineficiente para lidar com ruídos e outliers;
- Inadequado para descobrir *clusters* com formato não convexo e/ou com densidade distinta;

Algoritmo do k-means

Inércia:

$$I = \sum_{i=1}^{n} \|\mathbf{x}_i - \boldsymbol{\mu}_{c_i}\|^2$$

Analogia mecânica: soma dos momentos de inércia de cada grupo em relação ao seu centro de massa.

Propriedades:

- mede apenas a **coesão**, não a separação;
- **diminui com** K: $J^*(K)$ é não crescente e $J^*(n) = 0$
  $\Rightarrow$ **não se escolhe** K **minimizando a inércia**;
- **depende da escala**: só se comparam inércias com os mesmos dados e pré-processamento;
- serve para **comparar execuções com o mesmo** K: a de menor inércia é a melhor;
- assume grupos **convexos e isotrópicos**.

Algoritmo do k-means

Método do Cotovelo:

Pergunta: a partir de qual K acrescentar um grupo deixa de trazer ganho significativo?

Procedimento:

1. execute o k-means para $K = 1, 2, \ldots, K_{\max}$;
2. registre a inércia $I(K)$;
3. trace $I(K)$ em função de K;
4. escolha o K do "cotovelo": onde a curva deixa de cair rapidamente.

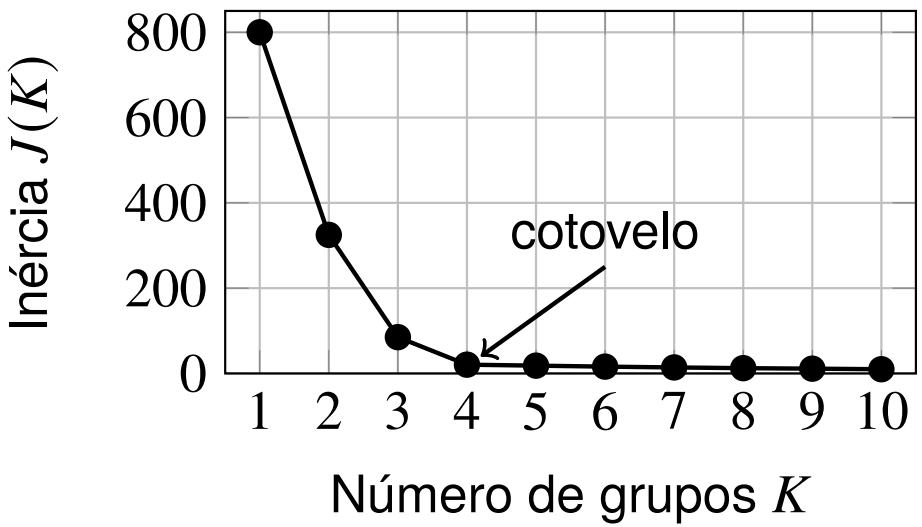
Intuição:

- K menor que o número "natural" de grupos: um novo centroide separa grupos reais misturados $\Rightarrow$ grande redução de I;
- K maior: novos centroides só subdividem grupos compactos $\Rightarrow$ pequena redução.

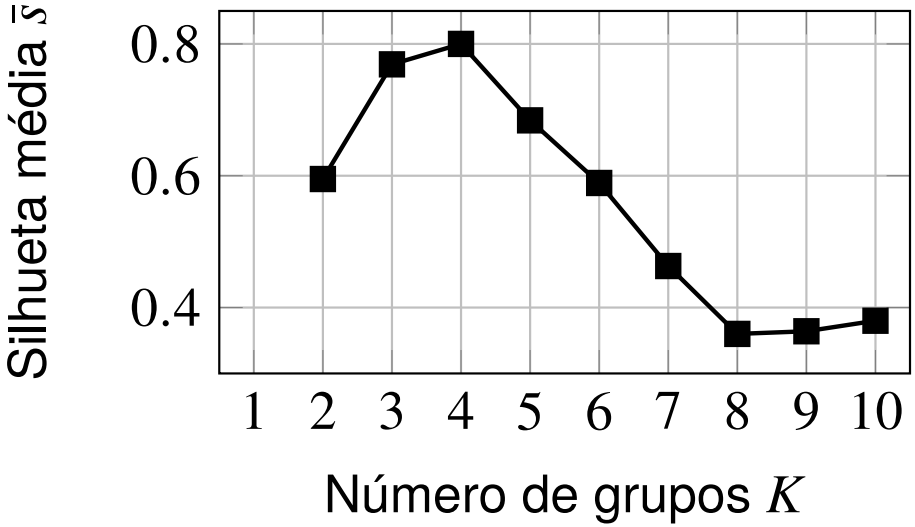
Redução relativa: $\Delta_{\%}(K) = 100 \cdot \dfrac{I(K-1) - I(K)}{I(K-1)}$

400 objetos em $\mathbb{R}^2$, gerados a partir de 4 gaussianas e padronizados (escore-z):

Curva de inércia



Silhueta média



K	$J(K)$	$\Delta_{\%}(K)$	$\bar{s}$
1	800,0	–	–
2	324,9	59,4	0,595
3	85,1	73,8	0,769
4	**20,6**	**75,8**	**0,800**
5	18,3	11,2	0,684
6	16,0	12,4	0,589
7	14,1	11,8	0,463
8	12,4	12,0	0,360
9	11,2	10,1	0,364
10	9,9	11,0	0,380

- Até $K = 4$: reduções acima de 59%.
- A partir de $K = 5$: reduções de 10 a 12%.
- Silhueta máxima em $K = 4$: confirma o cotovelo.
- $J(1) =$ SST; com dados padronizados, SST $= n \cdot d = 800$.

Limitações:

- em dados reais, o cotovelo pode ser ambíguo ou inexistente;
- combine com silhueta e conhecimento do domínio.

Algoritmo do k-means

Inicialização:

- **Aleatória (Forgy)**: K objetos sorteados. Simples, mas pode pôr dois centroides no mesmo grupo natural.
- **Partição aleatória**: grupos sorteados; centroides iniciais = médias (tendem ao centro dos dados).
- **K-means++** (padrão do scikit-learn): centroides iniciais espalhados
  1. primeiro centroide: objeto sorteado uniformemente;
  2. para cada $\mathbf{x}$: $D(\mathbf{x})$ = distância ao centroide já escolhido mais próximo;
  3. próximo centroide sorteado com probabilidade $P(\mathbf{x}) = \dfrac{D(\mathbf{x})^2}{\sum_{\mathbf{x}' \in \mathcal{X}} D(\mathbf{x}')^2}$;
  4. repete 2–3 até obter K centroides; depois, k-means normal.

  Uma forma simples de reduzir a dependência da inicialização é executar o k-means várias vezes com diferentes inicializações e escolher a solução com o menor valor de inércia.

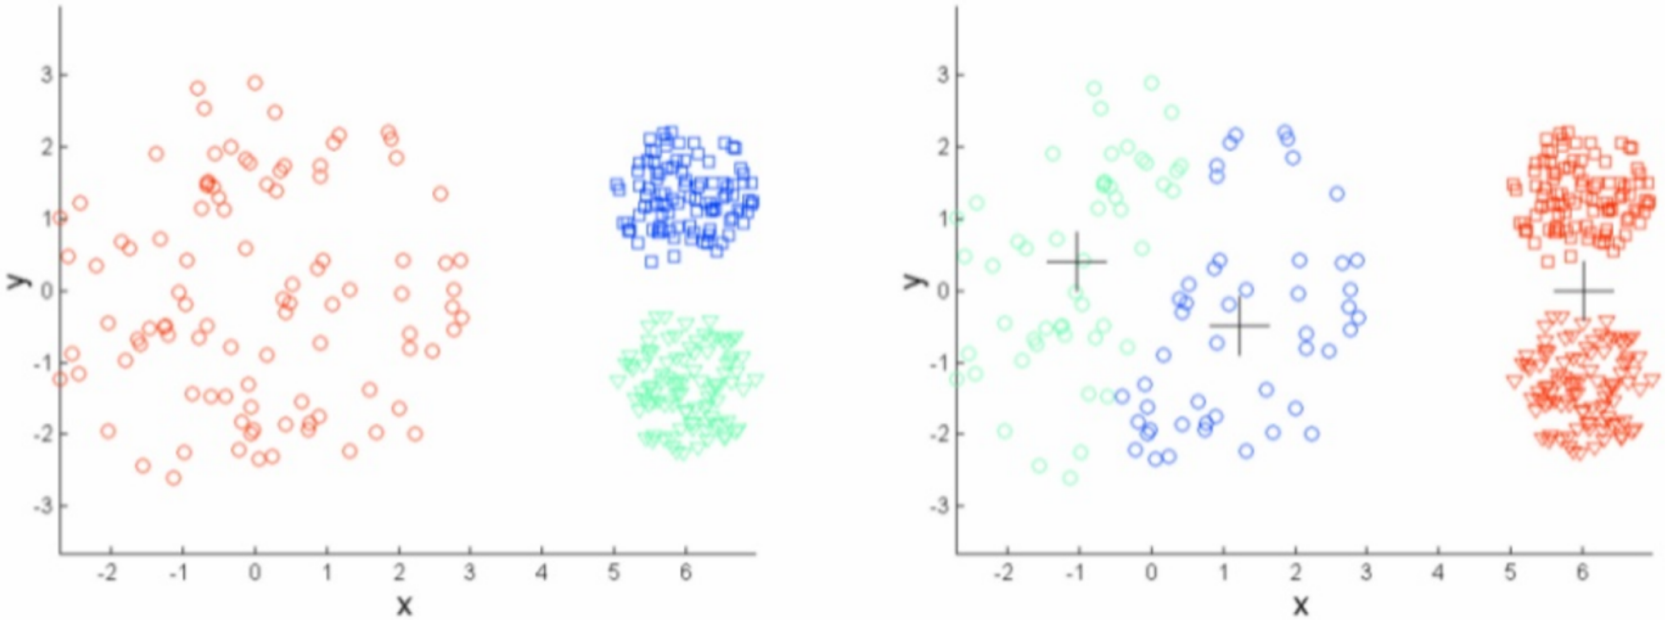
Algoritmo do k-means

Situações em que o k-means pode falhar:

- *Clusters* de formas não convexas: O k-means tende a formar *clusters* esféricos, o que pode não ser adequado para dados com *clusters* de formas irregulares;
- *Clusters* de densidades distintas: O k-means pode ter dificuldade em identificar *clusters* de densidades diferentes, pois ele atribui cada ponto ao *cluster* mais próximo, o que pode levar a atribuições incorretas em regiões de baixa densidade;
- Presença de ruídos e *outliers*: O k-means é sensível a ruídos e *outliers*, pois eles podem influenciar significativamente a posição dos centróides, levando a resultados de clusterização distorcidos.

Algoritmo do k-means

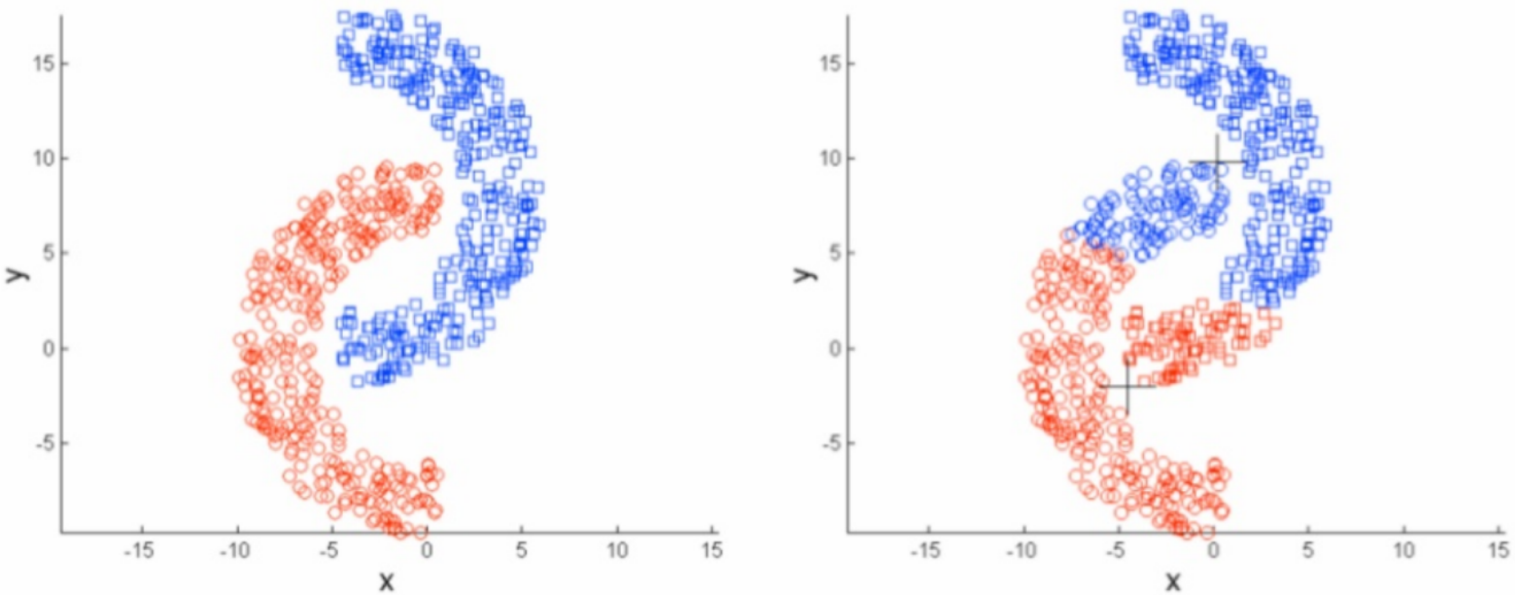
Situação em que o conjunto de dados possuem densidades diferentes:



Disposição dos dados com dados com densidades distintas e a clusterização resultante do k-means.

Algoritmo do k-means

Situação em que o conjunto de dados possuem formas não convexas:



Disposição dos dados com dados com formas não convexas e a clusterização resultante do k-means.

Agrupamento hierárquico

Produz uma **hierarquia de partições aninhadas**, representada por um **dendrograma**.

- **Aglomerativo** (*bottom-up*): começa com n grupos unitários e funde, a cada passo, os dois grupos mais próximos, até restar um.
- **Divisivo** (*top-down*): começa com um grupo com todos os objetos e divide, a cada passo, um grupo em dois.

Vantagens em relação ao k-*means*:

- **não é preciso definir K antes**: escolhe-se depois, "cortando" o dendrograma;
- trabalha com uma **matriz de dissimilaridades**: aceita qualquer medida (Gower, Jaccard etc.);
- determinístico (a menos de empates);
- mostra as relações entre os grupos.

Algoritmo Aglomerativo

Algoritmo 2: Agrupamento hierárquico aglomerativo.

Entrada: matriz de dissimilaridades $\mathbf{D}$ $(n \times n)$; critério de ligação
Saída: sequência de fusões e respectivas alturas (dendrograma)
$C \leftarrow \{\{\mathbf{x}_1\}, \{\mathbf{x}_2\}, \ldots, \{\mathbf{x}_n\}\}$; `// cada objeto é um grupo`
enquanto $|C| > 1$ **faça**
    Encontre o par (C_a, C_b), $a \neq b$, de menor dissimilaridade $D(C_a, C_b)$;
    $C_{ab} \leftarrow C_a \cup C_b$; registre a altura da fusão $h \leftarrow D(C_a, C_b)$;
    Remova C_a e C_b de C e insira C_{ab};
    Calcule a dissimilaridade de C_{ab} aos demais grupos (critério de ligação);
fim

O que diferencia os algoritmos é como se mede a dissimilaridade entre **grupos**: o **critério de ligação** (*linkage*).

Critérios de Ligação

Simples (vizinho mais próximo):

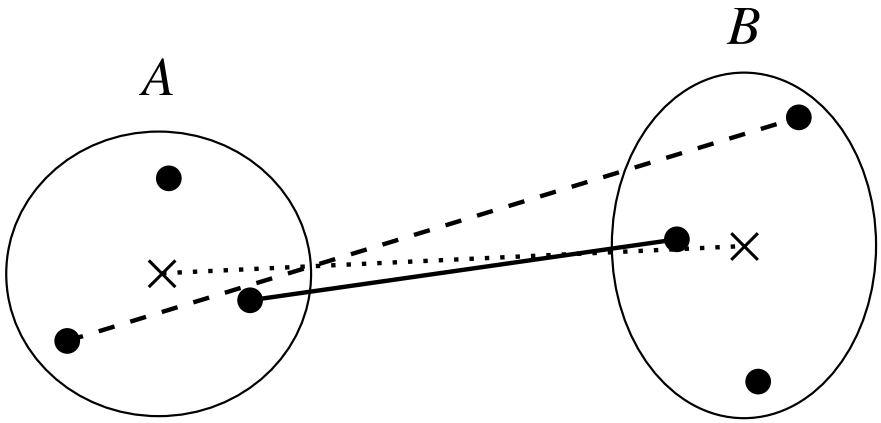
$$D_{\min}(A,B) = \min_{\mathbf{x}\in A,\ \mathbf{y}\in B} d(\mathbf{x},\mathbf{y})$$

Completa (vizinho mais distante):

$$D_{\max}(A,B) = \max_{\mathbf{x}\in A,\ \mathbf{y}\in B} d(\mathbf{x},\mathbf{y})$$

Média (UPGMA):

$$D_{\text{méd}}(A,B) = \frac{1}{|A|\,|B|}\sum_{\mathbf{x}\in A}\sum_{\mathbf{y}\in B} d(\mathbf{x},\mathbf{y})$$



contínua: simples; tracejada: completa; pontilhada: centroides (×)

Método de Ward

Mede o **aumento da inércia** (SSW) provocado pela fusão de A e B:

$$\Delta(A,B) = \sum_{\mathbf{x}\in A\cup B} \|\mathbf{x} - \boldsymbol{\mu}_{A\cup B}\|^2 - \sum_{\mathbf{x}\in A} \|\mathbf{x} - \boldsymbol{\mu}_A\|^2 - \sum_{\mathbf{x}\in B} \|\mathbf{x} - \boldsymbol{\mu}_B\|^2$$

$$= \frac{|A|\,|B|}{|A| + |B|} \|\boldsymbol{\mu}_A - \boldsymbol{\mu}_B\|^2$$

- A cada passo, funde o par que **menos aumenta a inércia**.
- Mesmo objetivo do k-*means* $\Longrightarrow$ grupos compactos e de tamanhos semelhantes.
- Requer a distância euclidiana.
- É o critério padrão do `AgglomerativeClustering` do scikit-learn.

Critério	Vantagens	Desvantagens
Simples	Grupos alongados e de forma arbitrária	**Encadeamento**: grupos ligados por uma “ponte” de objetos são fundidos; sensível a ruído
Completa	Grupos compactos, de diâmetros semelhantes	Sensível a *outliers*; tende a quebrar grupos grandes
Média	Meio-termo; mais robusta a ruído	Favorece grupos de variâncias semelhantes
Ward	Compactos, de tamanhos semelhantes; análogo ao k-*means*	Só euclidiana; dificuldade com grupos alongados ou de tamanhos muito diferentes

Exemplo Resolvido: Ligação Simples (1/2)

Matriz de dissimilaridades:

$$\mathbf{D}^{(0)} = \begin{array}{c|ccccc} & A & B & C & D & E \\ \hline A & 0 & & & & \\ B & 3 & 0 & & & \\ C & 7 & 6 & 0 & & \\ D & 10 & 9 & 5 & 0 & \\ E & 11 & 10 & 9 & \mathbf{2} & 0 \end{array}$$

Passo 1: menor valor $d(D, E) = 2$
$\Rightarrow$ funde $\{D, E\}$ na altura 2.

Atualização com o **mínimo**:

$$D(DE, A) = \min(10, 11) = 10$$
$$D(DE, B) = \min(9, 10) = 9$$
$$D(DE, C) = \min(5, 9) = 5$$

$$\mathbf{D}^{(1)} = \begin{array}{c|cccc} & A & B & C & DE \\ \hline A & 0 & & & \\ B & \mathbf{3} & 0 & & \\ C & 7 & 6 & 0 & \\ DE & 10 & 9 & 5 & 0 \end{array}$$

Exemplo Resolvido: Ligação Simples (2/2)

Passo 2: menor valor $d(A, B) = 3$
$\Rightarrow$ funde $\{A, B\}$ na altura 3.

$$D(AB, C) = \min(7, 6) = 6$$
$$D(AB, DE) = \min(10, 9) = 9$$

$$\mathbf{D}^{(2)} = \begin{array}{c|ccc} & AB & C & DE \\ \hline AB & 0 & & \\ C & 6 & 0 & \\ DE & 9 & \mathbf{5} & 0 \end{array}$$

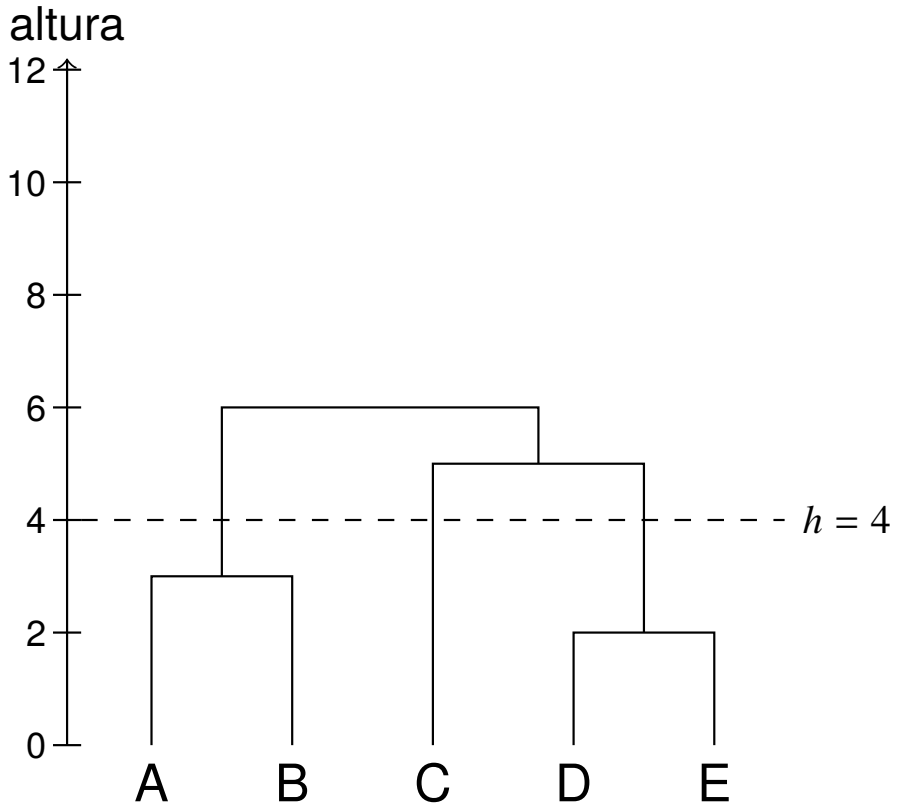
Passo 3: menor valor $D(C, DE) = 5$
$\Rightarrow$ funde $\{C, D, E\}$ na altura 5.

$$D(AB, CDE) = \min(6, 9) = 6$$

Passo 4: funde $\{A, B\}$ e $\{C, D, E\}$ na altura 6.

Sequência de fusões:

Fusão	Altura
$D + E$	2
$A + B$	3
$C + DE$	5
$AB + CDE$	6



Ligação simples

Corte em $h = 4$ (simples): $\{A, B\}$, $\{C\}$, $\{D, E\}$.

Exemplo Resolvido: Ligação Completa

Atualização com o **máximo**:

Passo 1: funde $\{D, E\}$ na altura 2.

$$D(DE, A) = \max(10, 11) = 11$$
$$D(DE, B) = \max(9, 10) = 10$$
$$D(DE, C) = \max(5, 9) = 9$$

Passo 2: funde $\{A, B\}$ na altura 3.

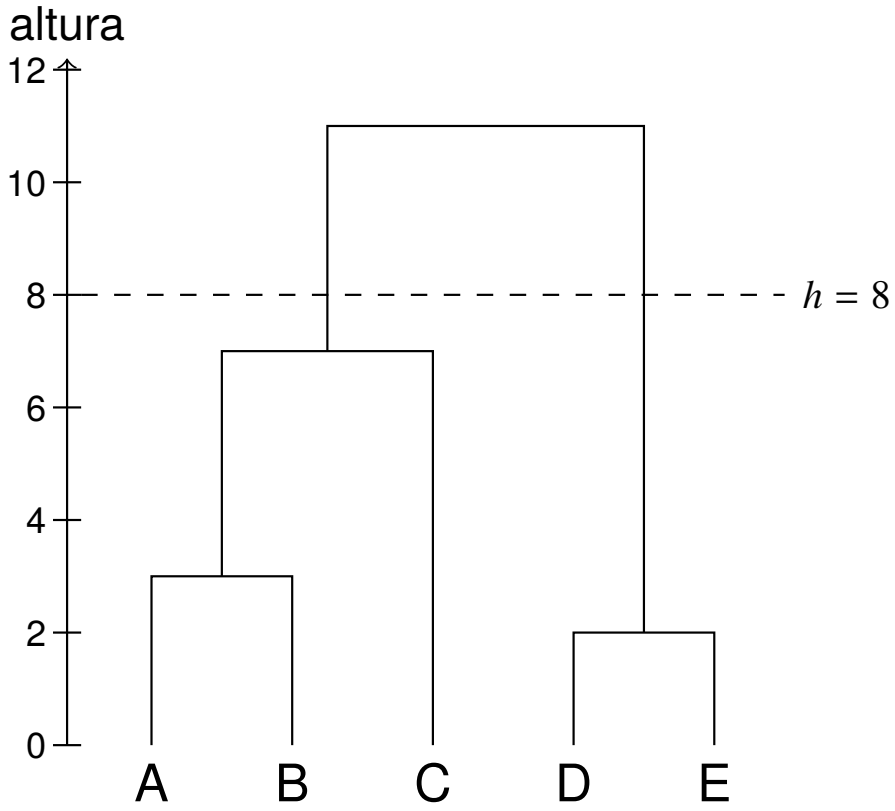
$$D(AB, C) = \max(7, 6) = 7$$
$$D(AB, DE) = \max(11, 10) = 11$$

$$\mathbf{D}^{(2)} = \begin{array}{c|ccc} & AB & C & DE \\ \hline AB & 0 & & \\ C & \mathbf{7} & 0 & \\ DE & 11 & 9 & 0 \end{array}$$

Passo 3: $D(AB, C) = 7 \Rightarrow$ funde $\{A, B, C\}$ na altura 7;
$D(ABC, DE) = \max(11, 9) = 11$.

Passo 4: funde $\{A, B, C\}$ e $\{D, E\}$ na altura 11.

Diferença: C vai para $\{D, E\}$ na simples (perto de D), mas para $\{A, B\}$ na completa (longe de E).



Ligação completa

Corte em $h = 8$ (completa): $\{A, B, C\}$, $\{D, E\}$.