



UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS (CMPF)
DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA (DETEC)

SISTEMAS INTELIGENTES

Árvores de Decisão

Prof. Pedro Thiago Valério de Souza
UFERSA – Campus Pau dos Ferros
pedro.souza@ufersa.edu.br

Conceitos Fundamentais

Definição:


- Algoritmo de aprendizado de máquina supervisionado;
- Modelo preditivo em forma de árvore que particiona o espaço de características (*features*) por meio de testes condicionais sucessivos;
- Pode ser utilizados para classificação ou regressão;

Características:

- Hierárquica: estrutura em níveis;
- Recursiva: cada nó, por sua vez, é uma árvore cada vez menor;
- Interpretável: cada predição é entendida como uma sequência de regras “se-então”.

Conceitos Fundamentais


Anatomia de uma Árvore de Decisão:



- Raiz: não tem ramificações de entrada. Contém o primeiro teste;
- Nó interno: avalia um teste e divide as amostras em duas ou mais derivações;
- Folha: nó terminal. Contém a classe (ou valor) predito.

Conceitos Fundamentais

Exemplo: Play Tennis (Quilan, 1986)



Conceitos Fundamentais

Etapa de Predição:

- 1 Iniciar pelo nó raiz;
- 2 Avaliar o teste no nó atual;
- 3 Desça pelo ramo correspondente ao ramo no qual o teste é verdadeiro;
- 4 Repetir os passos 3 e 4 até que o nó atual seja folha (nó terminal);
- 5 Retorne a classe (ou valor) do nó folha.

Complexidade Computacional (na predição): $O(n)$, em que n é a profundidade máxima da árvore.

Conceitos Fundamentais

Vantagens:

- Interpretabilidade;
- Não exige normalização dos dados de entrada;
- Trabalha facilmente com dados categóricos (sexo, escolaridade, estado civil, etc.), como dados numéricos (altura, idade, etc.);
- Capaz de trabalhar com problemas não linearmente separáveis;
- Pouco sensível à *outliers* e a dados faltantes;

Desvantagens:

- Tendência ao *overfitting* em árvores muito profundas;
- Uma pequena mudança no conjunto de treinamento pode resultar em árvores diferentes;
- Embora possa trabalhar com problemas não linearmente separáveis, as fronteiras de decisão são axiais em regras do tipo $x_i \leq t$ (forma retas paralelas ao eixo x_i);

Conceitos Fundamentais

Aplicações:


- Medicina: diagnóstico de doenças e estratificação de riscos;
- Mercado financeiro: análise de fraudes bancárias e aprovação de crédito;
- *Marketing*: segmentação de clientes;
- Indústria: programa de manutenção preditiva;
- Biologia e Química: classificação de proteínas ou moléculas

Tipos de Árvores de Decisão:

- ID3 (1986): trabalha apenas com dados categóricos. Utiliza entropia e ganho de informação como métricas de particionamento;
- C4.5 (1993): evolução da ID3 para trabalhar com dados numéricos. Permite trabalhar com dados faltantes, poda (*prunning*) e utiliza razão de ganho como métrica de particionamento, evitando o *overfitting*.
- CART (1984): utilizada tanto para classificação como regressão. Utiliza a impureza de Gini (em processos de classificação) ou MSE (em processos de regressão) como métricas de particionamento. Gera sempre uma árvore binária, ou seja, para cada nó existem apenas dois ramos.

Conceitos Fundamentais

Exemplo 10.1 Para a seguinte árvore de decisão, desenhe, no mapa de características $x_1 \times x_2$, as fronteiras de decisão e as regiões correspondentes às classes R_1, R_2, R_3, R_4, R_5 . Observação: o ramo da esquerda corresponde à quando o teste efetuado pelo nó é verdadeiro.



Construção de uma Árvore de Decisão

A construção de uma árvore de decisão sempre é realizado de forma **gulosa** e **top-down**.

- Gulosa: escolher a melhor divisão (*split*) para os dados;
- *Top-Down*: a escolha da divisão atual independe do que vem para frente.

Procedimento de elaboração de uma árvore:

- 1 Começar com todas as amostras de treinamento na raiz;
- 2 Avaliar todos os candidatos para um *split*;
- 3 Escolher o *split* que resulte um maior ganho (abordagem gulosa);
- 4 Particionar as amostras nos nós filhos;
- 5 Repetir os procedimentos 2, 3 e 4 até que um critério de parada seja atingido.

Construção de uma Árvore de Decisão

- Como escolher o melhor *split* em cada nó?
- Devemos, ao particionar os dados, obter subconjuntos de amostras o mais homogêneos possível (ou seja, com a mesma classe);
- Nos nós folhas, o ideal é que haja apenas amostras de uma única classe;
- Desta forma, é necessário definir uma métrica que meça o grau de impureza de um conjunto de dados.
 - Entropia;
 - Impureza de Gini;

Entropia

- Mede a quantidade de impureza (desordem ou informação) em um conjunto de dados;
- Dados homogêneos apresentam baixa entropia;
 - Se todos os dados pertencem à mesma classe, a entropia é zero;
- Dados heterogêneos apresentam alta entropia;
 - Se os dados estão igualmente distribuídos entre as classes, a entropia é máxima.
- Definição Matemática:

$$\mathcal{H}(S) = - \sum_i p_i \log_2 p_i$$

em que p_i é a proporção de amostras da classe i no conjunto S .

- Valor mínimo: $\mathcal{H}(S) = 0$ (dados homogêneos);
- Valor máximo: $\mathcal{H}(S) = \log_2 k$ (dados heterogêneos, com k classes).
 - Para o caso binário ($k = 2$), a entropia máxima é 1.

Impureza de Gini

- Assim como a entropia, a impureza de Gini mede o grau de impureza de um conjunto de dados;
- Definição Matemática:


$$\mathcal{G}(S) = 1 - \sum_i p_i^2$$

em que p_i é a proporção de amostras da classe i no conjunto S .

- Valor mínimo: $\mathcal{G}(S) = 0$ (dados homogêneos);
- Valor máximo: $\mathcal{G}(S) = 1 - \frac{1}{k}$ (dados heterogêneos, com k classes).
 - Para o caso binário ($k = 2$), a impureza de Gini máxima é 0.5.

Construção de uma Árvore de Decisão

Comparação entre Entropia e Impureza de Gini:



Construção de uma Árvore de Decisão

Exemplo 10.2 Em um conjunto de dados, existem 10 amostras da classe R_1 e 20 amostras da classe R_2 . Calcule a entropia e a impureza de Gini deste conjunto de dados.

Exemplo 10.3 Em um conjunto de dados, existem 10 amostras da classe R_1 e 10 amostras da classe R_2 . Calcule a entropia e a impureza de Gini deste conjunto de dados.

Ganho de Informação

- Quanto mais profundo o nó de uma árvore, mais homogêneo deve ser o conjunto de dados;
- Idealmente, nos nós terminais (folhas), deveremos ter apenas dados de uma única classe, e por consequência, entropia e impureza de Gini iguais a zero;
- A divisão dos dados em cada nó deve acontecer de forma a reduzir a impureza do conjunto de dados;
- O ganho de informação é a métrica que mede a redução da impureza após a divisão dos dados em um nó;

Ganho de Informação

- Definição Matemática:

$$\text{Ganho}(S, A) = \mathcal{I}(S) - \sum_{v \in \text{Valores}(A)} \frac{|S_v|}{|S|} \mathcal{I}(S_v)$$

em que:

- S é o conjunto de dados antes da divisão;
 - A é a característica utilizada para dividir os dados;
 - $\text{Valores}(A)$ é o conjunto de valores possíveis para a característica A ;
 - S_v é o subconjunto de dados em que a característica A assume o valor v ;
 - $\mathcal{I}$ é a métrica de impureza utilizada (entropia ou impureza de Gini).
- Em cada nó, o algoritmo de construção da árvore de decisão irá escolher a característica A que maximize o ganho de informação.

Construção de uma Árvore de Decisão

Exemplo 10.4 Considere o seguinte conjunto de dados, referente a um problema de classificação binária, em que o objetivo é prever se um jogo de tênis será jogado ou não, com base em quatro características.

Dia	Tempo	Temperatura	Umidade	Vento	Jogar Tênis
1	Ensolarado	Quente	Alta	Fraco	Não
2	Ensolarado	Quente	Alta	Forte	Não
3	Nublado	Quente	Alta	Fraco	Sim
4	Chuvoso	Ameno	Alta	Fraco	Sim
5	Chuvoso	Frio	Normal	Fraco	Sim
6	Chuvoso	Frio	Normal	Forte	Não
7	Nublado	Frio	Normal	Forte	Sim
8	Ensolarado	Ameno	Alta	Fraco	Não
9	Ensolarado	Frio	Normal	Fraco	Sim
10	Chuvoso	Ameno	Normal	Fraco	Sim
11	Ensolarado	Ameno	Normal	Forte	Sim
12	Nublado	Ameno	Alta	Forte	Sim
13	Nublado	Quente	Normal	Fraco	Sim
14	Chuvoso	Ameno	Alta	Forte	Não

Resumo: 14 exemplos, sendo 9 Sim e 5 Não.

Análise para o Nó Raiz

A entropia no nó raiz será,

Análise para o Nó Raiz

A entropia no nó raiz será,

$$\mathcal{H}(S) = -\frac{9}{14} \log_2 \left(\frac{9}{14} \right) - \frac{5}{14} \log_2 \left(\frac{5}{14} \right) = 0,940$$

Análise para o Nó Raiz

A entropia no nó raiz será,

$$\mathcal{H}(S) = -\frac{9}{14} \log_2 \left(\frac{9}{14} \right) - \frac{5}{14} \log_2 \left(\frac{5}{14} \right) = 0,940$$

Vamos agora testar cada um dos quatro atributos candidatos.

Análise para o Nó Raiz

A entropia no nó raiz será,

$$\mathcal{H}(S) = -\frac{9}{14} \log_2 \left(\frac{9}{14} \right) - \frac{5}{14} \log_2 \left(\frac{5}{14} \right) = 0,940$$

Vamos agora testar cada um dos quatro atributos candidatos.

Candidato 1: Tempo

Análise para o Nó Raiz

A entropia no nó raiz será,

$$\mathcal{H}(S) = -\frac{9}{14} \log_2 \left(\frac{9}{14} \right) - \frac{5}{14} \log_2 \left(\frac{5}{14} \right) = 0,940$$

Vamos agora testar cada um dos quatro atributos candidatos.

Candidato 1: Tempo

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Ensolarado	1, 2, 8, 9, 11	2 / 3	0,971
Nublado	3, 7, 12, 13	4 / 0	0 (puro)
Chuvoso	4, 5, 6, 10, 14	3 / 2	0,971

Análise para o Nó Raiz

A entropia no nó raiz será,

$$\mathcal{H}(S) = -\frac{9}{14} \log_2 \left(\frac{9}{14} \right) - \frac{5}{14} \log_2 \left(\frac{5}{14} \right) = 0,940$$

Vamos agora testar cada um dos quatro atributos candidatos.

Candidato 1: Tempo

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Ensolarado	1, 2, 8, 9, 11	2 / 3	0,971
Nublado	3, 7, 12, 13	4 / 0	0 (puro)
Chuvoso	4, 5, 6, 10, 14	3 / 2	0,971

A entropia condicional para o atributo Tempo é,

Análise para o Nó Raiz

A entropia no nó raiz será,

$$\mathcal{H}(S) = -\frac{9}{14} \log_2 \left(\frac{9}{14} \right) - \frac{5}{14} \log_2 \left(\frac{5}{14} \right) = 0,940$$

Vamos agora testar cada um dos quatro atributos candidatos.

Candidato 1: Tempo

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Ensolarado	1, 2, 8, 9, 11	2 / 3	0,971
Nublado	3, 7, 12, 13	4 / 0	0 (puro)
Chuvoso	4, 5, 6, 10, 14	3 / 2	0,971

A entropia condicional para o atributo Tempo é,

$$\mathcal{H}(S, \text{Tempo}) = \frac{5}{14} \cdot 0,971 + \frac{4}{14} \cdot 0 + \frac{5}{14} \cdot 0,971 = 0,694$$

Análise para o Nó Raiz

A entropia no nó raiz será,

$$\mathcal{H}(S) = -\frac{9}{14} \log_2 \left(\frac{9}{14} \right) - \frac{5}{14} \log_2 \left(\frac{5}{14} \right) = 0,940$$

Vamos agora testar cada um dos quatro atributos candidatos.

Candidato 1: Tempo

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Ensolarado	1, 2, 8, 9, 11	2 / 3	0,971
Nublado	3, 7, 12, 13	4 / 0	0 (puro)
Chuvoso	4, 5, 6, 10, 14	3 / 2	0,971

A entropia condicional para o atributo Tempo é,

$$\mathcal{H}(S, \text{Tempo}) = \frac{5}{14} \cdot 0,971 + \frac{4}{14} \cdot 0 + \frac{5}{14} \cdot 0,971 = 0,694$$

O ganho de informação para o atributo Tempo é,

Análise para o Nó Raiz

A entropia no nó raiz será,

$$\mathcal{H}(S) = -\frac{9}{14} \log_2 \left(\frac{9}{14} \right) - \frac{5}{14} \log_2 \left(\frac{5}{14} \right) = 0,940$$

Vamos agora testar cada um dos quatro atributos candidatos.

Candidato 1: Tempo

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Ensolarado	1, 2, 8, 9, 11	2 / 3	0,971
Nublado	3, 7, 12, 13	4 / 0	0 (puro)
Chuvoso	4, 5, 6, 10, 14	3 / 2	0,971

A entropia condicional para o atributo Tempo é,

$$\mathcal{H}(S, \text{Tempo}) = \frac{5}{14} \cdot 0,971 + \frac{4}{14} \cdot 0 + \frac{5}{14} \cdot 0,971 = 0,694$$

O ganho de informação para o atributo Tempo é,

$$\text{Ganho}(S, \text{Tempo}) = 0,940 - 0,694 = 0,246$$

Análise para o Nó Raiz

Candidato 2: Temperatura

Análise para o Nó Raiz

Candidato 2: Temperatura

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Quente	1, 2, 3, 13	2 / 2	1,0
Ameno	4, 8, 10, 11, 12, 14	4 / 2	0,918
Frio	5, 6, 7, 9	3 / 1	0,811

Análise para o Nó Raiz

Candidato 2: Temperatura

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Quente	1, 2, 3, 13	2 / 2	1,0
Ameno	4, 8, 10, 11, 12, 14	4 / 2	0,918
Frio	5, 6, 7, 9	3 / 1	0,811

A entropia condicional para o atributo Temperatura é,

Análise para o Nó Raiz

Candidato 2: Temperatura

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Quente	1, 2, 3, 13	2 / 2	1,0
Ameno	4, 8, 10, 11, 12, 14	4 / 2	0,918
Frio	5, 6, 7, 9	3 / 1	0,811

A entropia condicional para o atributo Temperatura é,

$$\mathcal{H}(S, \text{Temperatura}) = \frac{4}{14} \cdot 0,811 + \frac{6}{14} \cdot 0,918 + \frac{4}{14} \cdot 1 = 0,901$$

Análise para o Nó Raiz

Candidato 2: Temperatura

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Quente	1, 2, 3, 13	2 / 2	1,0
Ameno	4, 8, 10, 11, 12, 14	4 / 2	0,918
Frio	5, 6, 7, 9	3 / 1	0,811

A entropia condicional para o atributo Temperatura é,

$$\mathcal{H}(S, \text{Temperatura}) = \frac{4}{14} \cdot 0,811 + \frac{6}{14} \cdot 0,918 + \frac{4}{14} \cdot 1 = 0,901$$

O ganho de informação para o atributo Temperatura é,

Análise para o Nó Raiz

Candidato 2: Temperatura

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Quente	1, 2, 3, 13	2 / 2	1,0
Ameno	4, 8, 10, 11, 12, 14	4 / 2	0,918
Frio	5, 6, 7, 9	3 / 1	0,811

A entropia condicional para o atributo Temperatura é,

$$\mathcal{H}(S, \text{Temperatura}) = \frac{4}{14} \cdot 0,811 + \frac{6}{14} \cdot 0,918 + \frac{4}{14} \cdot 1 = 0,901$$

O ganho de informação para o atributo Temperatura é,

$$\text{Ganho}(S, \text{Temperatura}) = 0,940 - 0,901 = 0,039$$

Análise para o Nó Raiz

Candidato 3: Umidade

Análise para o Nó Raiz

Candidato 3: Umidade

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Alta	1, 2, 3, 4, 8, 12, 14	3 / 4	0,985
Normal	5, 6, 7, 9, 10, 11, 13	6 / 1	0,592

Análise para o Nó Raiz

Candidato 3: Umidade

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Alta	1, 2, 3, 4, 8, 12, 14	3 / 4	0,985
Normal	5, 6, 7, 9, 10, 11, 13	6 / 1	0,592

A entropia condicional para o atributo Umidade é,

Análise para o Nó Raiz

Candidato 3: Umidade

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Alta	1, 2, 3, 4, 8, 12, 14	3 / 4	0,985
Normal	5, 6, 7, 9, 10, 11, 13	6 / 1	0,592

A entropia condicional para o atributo Umidade é,

$$\mathcal{H}(S, \text{Umidade}) = \frac{7}{14} \cdot 0,985 + \frac{7}{14} \cdot 0,592 = 0,492 + 0,296 = 0,788.$$

Análise para o Nó Raiz

Candidato 3: Umidade

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Alta	1, 2, 3, 4, 8, 12, 14	3 / 4	0,985
Normal	5, 6, 7, 9, 10, 11, 13	6 / 1	0,592

A entropia condicional para o atributo Umidade é,

$$\mathcal{H}(S, \text{Umidade}) = \frac{7}{14} \cdot 0,985 + \frac{7}{14} \cdot 0,592 = 0,492 + 0,296 = 0,788.$$

O ganho de informação para o atributo Umidade é,

Análise para o Nó Raiz

Candidato 3: Umidade

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Alta	1, 2, 3, 4, 8, 12, 14	3 / 4	0,985
Normal	5, 6, 7, 9, 10, 11, 13	6 / 1	0,592

A entropia condicional para o atributo Umidade é,

$$\mathcal{H}(S, \text{Umidade}) = \frac{7}{14} \cdot 0,985 + \frac{7}{14} \cdot 0,592 = 0,492 + 0,296 = 0,788.$$

O ganho de informação para o atributo Umidade é,

$$\text{Ganho}(S, \text{Umidade}) = 0,940 - 0,788 = 0,152$$

Análise para o Nó Raiz

Candidato 4: Vento

Análise para o Nó Raiz

Candidato 4: Vento

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Fraco	1, 3, 4, 5, 8, 9, 10, 13	6 / 2	0,811
Forte	2, 6, 7, 11, 12, 14	3 / 3	1,000

Análise para o Nó Raiz

Candidato 4: Vento

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Fraco	1, 3, 4, 5, 8, 9, 10, 13	6 / 2	0,811
Forte	2, 6, 7, 11, 12, 14	3 / 3	1,000

A entropia condicional para o atributo Vento é,

Análise para o Nó Raiz

Candidato 4: Vento

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Fraco	1, 3, 4, 5, 8, 9, 10, 13	6 / 2	0,811
Forte	2, 6, 7, 11, 12, 14	3 / 3	1,000

A entropia condicional para o atributo Vento é,

$$\mathcal{H}(S, \text{Vento}) = \frac{8}{14} \cdot 0,811 + \frac{6}{14} \cdot 1,000 = 0,463 + 0,429 = 0,892.$$

Análise para o Nó Raiz

Candidato 4: Vento

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Fraco	1, 3, 4, 5, 8, 9, 10, 13	6 / 2	0,811
Forte	2, 6, 7, 11, 12, 14	3 / 3	1,000

A entropia condicional para o atributo Vento é,

$$\mathcal{H}(S, \text{Vento}) = \frac{8}{14} \cdot 0,811 + \frac{6}{14} \cdot 1,000 = 0,463 + 0,429 = 0,892.$$

O ganho de informação para o atributo Vento é,

Análise para o Nó Raiz

Candidato 4: Vento

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Fraco	1, 3, 4, 5, 8, 9, 10, 13	6 / 2	0,811
Forte	2, 6, 7, 11, 12, 14	3 / 3	1,000

A entropia condicional para o atributo Vento é,

$$\mathcal{H}(S, \text{Vento}) = \frac{8}{14} \cdot 0,811 + \frac{6}{14} \cdot 1,000 = 0,463 + 0,429 = 0,892.$$

O ganho de informação para o atributo Vento é,

$$\text{Ganho}(S, \text{Vento}) = 0,940 - 0,892 = 0,048$$

Análise para o Nó Raiz

Resumo dos cálculos para o nó raiz:

Análise para o Nó Raiz

Resumo dos cálculos para o nó raiz:

Atributo	$\mathcal{H}(S A)$	Ganho
Tempo	0,694	0,247
Umidade	0,788	0,152
Vento	0,892	0,048
Temperatura	0,911	0,029

Análise para o Nó Raiz

Resumo dos cálculos para o nó raiz:

Atributo	$\mathcal{H}(S A)$	Ganho
Tempo	0,694	0,247
Umidade	0,788	0,152
Vento	0,892	0,048
Temperatura	0,911	0,029

O atributo Tempo é o melhor candidato para o nó raiz, pois apresenta o maior ganho de informação.

Análise para o Nó Raiz

Resumo dos cálculos para o nó raiz:

Atributo	$\mathcal{H}(S A)$	Ganho
Tempo	0,694	0,247
Umidade	0,788	0,152
Vento	0,892	0,048
Temperatura	0,911	0,029

O atributo Tempo é o melhor candidato para o nó raiz, pois apresenta o maior ganho de informação.

- **Nublado** (4 Sim, 0 Não) $\Rightarrow$ folha Sim (puro, encerrado).

Análise para o Nó Raiz

Resumo dos cálculos para o nó raiz:

Atributo	$\mathcal{H}(S A)$	Ganho
Tempo	0,694	0,247
Umidade	0,788	0,152
Vento	0,892	0,048
Temperatura	0,911	0,029

O atributo Tempo é o melhor candidato para o nó raiz, pois apresenta o maior ganho de informação.

- **Nublado** (4 Sim, 0 Não) $\Rightarrow$ folha Sim (puro, encerrado).
- **Ensolarado** (2 Sim, 3 Não) $\Rightarrow$ precisa crescer.

Análise para o Nó Raiz

Resumo dos cálculos para o nó raiz:


Atributo	$\mathcal{H}(S A)$	Ganho
Tempo	0,694	0,247
Umidade	0,788	0,152
Vento	0,892	0,048
Temperatura	0,911	0,029

O atributo Tempo é o melhor candidato para o nó raiz, pois apresenta o maior ganho de informação.

- **Nublado** (4 Sim, 0 Não) $\Rightarrow$ folha Sim (puro, encerrado).
- **Ensolarado** (2 Sim, 3 Não) $\Rightarrow$ precisa crescer.
- **Chuvoso** (3 Sim, 2 Não) $\Rightarrow$ precisa crescer.

Construção de uma Árvore de Decisão

Árvore de decisão parcial:



Análise para o Nível 1A – Ramo Ensolarado

Dia	Tempo	Temperatura	Umidade	Vento	Jogar Tênis
1	Ensolarado	Quente	Alta	Fraco	Não
2	Ensolarado	Quente	Alta	Forte	Não
8	Ensolarado	Ameno	Alta	Fraco	Não
9	Ensolarado	Frio	Normal	Fraco	Sim
11	Ensolarado	Ameno	Normal	Forte	Sim

Análise para o Nível 1A – Ramo Ensolarado

Dia	Tempo	Temperatura	Umidade	Vento	Jogar Tênis
1	Ensolarado	Quente	Alta	Fraco	Não
2	Ensolarado	Quente	Alta	Forte	Não
8	Ensolarado	Ameno	Alta	Fraco	Não
9	Ensolarado	Frio	Normal	Fraco	Sim
11	Ensolarado	Ameno	Normal	Forte	Sim

Subconjunto $S_{\text{Ens}} = \{1, 2, 8, 9, 11\}$ com 2 Sim e 3 Não.

Análise para o Nível 1A – Ramo Ensolarado

Dia	Tempo	Temperatura	Umidade	Vento	Jogar Tênis
1	Ensolarado	Quente	Alta	Fraco	Não
2	Ensolarado	Quente	Alta	Forte	Não
8	Ensolarado	Ameno	Alta	Fraco	Não
9	Ensolarado	Frio	Normal	Fraco	Sim
11	Ensolarado	Ameno	Normal	Forte	Sim

Subconjunto $S_{\text{Ens}} = \{1, 2, 8, 9, 11\}$ com 2 Sim e 3 Não.

$$\mathcal{H}(S_{\text{Ens}}) = -\frac{2}{5} \log_2 \left(\frac{2}{5} \right) - \frac{3}{5} \log_2 \left(\frac{3}{5} \right) \approx 0,971.$$

Análise para o Nível 1A – Ramo Ensolarado

Dia	Tempo	Temperatura	Umidade	Vento	Jogar Tênis
1	Ensolarado	Quente	Alta	Fraco	Não
2	Ensolarado	Quente	Alta	Forte	Não
8	Ensolarado	Ameno	Alta	Fraco	Não
9	Ensolarado	Frio	Normal	Fraco	Sim
11	Ensolarado	Ameno	Normal	Forte	Sim

Subconjunto $S_{\text{Ens}} = \{1, 2, 8, 9, 11\}$ com 2 Sim e 3 Não.

$$\mathcal{H}(S_{\text{Ens}}) = -\frac{2}{5} \log_2 \left(\frac{2}{5} \right) - \frac{3}{5} \log_2 \left(\frac{3}{5} \right) \approx 0,971.$$

Restam analisar os atributos Temperatura, Umidade e Vento.

Análise para o Nível 1A – Ramo Ensolarado

Candidato 1: Temperatura

Análise para o Nível 1A – Ramo Ensolarado

Candidato 1: Temperatura

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Quente	1, 2	0 / 2	0
Ameno	8, 11	1 / 1	1,000
Frio	9	1 / 0	0

Análise para o Nível 1A – Ramo Ensolarado

Candidato 1: Temperatura

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Quente	1, 2	0 / 2	0
Ameno	8, 11	1 / 1	1,000
Frio	9	1 / 0	0

$$\mathcal{H}(S_{\text{Ens}} \mid \text{Temp}) = \frac{2}{5} \cdot 0 + \frac{2}{5} \cdot 1 + \frac{1}{5} \cdot 0 = 0,400.$$

Análise para o Nível 1A – Ramo Ensolarado

Candidato 1: Temperatura

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Quente	1, 2	0 / 2	0
Ameno	8, 11	1 / 1	1,000
Frio	9	1 / 0	0

$$\mathcal{H}(S_{\text{Ens}} \mid \text{Temp}) = \frac{2}{5} \cdot 0 + \frac{2}{5} \cdot 1 + \frac{1}{5} \cdot 0 = 0,400.$$

$$\text{Ganho}(S_{\text{Ens}}, \text{Temp}) = 0,971 - 0,400 = \mathbf{0,571}.$$

Análise para o Nível 1A – Ramo Ensolarado

Candidato 2: Umidade

Análise para o Nível 1A – Ramo Ensolarado

Candidato 2: Umidade

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Alta	1, 2, 8	0 / 3	0 (puro)
Normal	9, 11	2 / 0	0 (puro)

Análise para o Nível 1A – Ramo Ensolarado

Candidato 2: Umidade

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Alta	1, 2, 8	0 / 3	0 (puro)
Normal	9, 11	2 / 0	0 (puro)

$$\mathcal{H}(S_{\text{Ens}} \mid \text{Umidade}) = \frac{3}{5} \cdot 0 + \frac{2}{5} \cdot 0 = 0.$$

Análise para o Nível 1A – Ramo Ensolarado

Candidato 2: Umidade

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Alta	1, 2, 8	0 / 3	0 (puro)
Normal	9, 11	2 / 0	0 (puro)

$$\mathcal{H}(S_{\text{Ens}} \mid \text{Umidade}) = \frac{3}{5} \cdot 0 + \frac{2}{5} \cdot 0 = 0.$$

$$\text{Ganho}(S_{\text{Ens}}, \text{Umidade}) = 0,971 - 0 = \mathbf{0,971}.$$

Análise para o Nível 1A – Ramo Ensolarado

Candidato 2: Umidade

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Alta	1, 2, 8	0 / 3	0 (puro)
Normal	9, 11	2 / 0	0 (puro)

$$\mathcal{H}(S_{\text{Ens}} \mid \text{Umidade}) = \frac{3}{5} \cdot 0 + \frac{2}{5} \cdot 0 = 0.$$

$$\text{Ganho}(S_{\text{Ens}}, \text{Umidade}) = 0,971 - 0 = \mathbf{0,971}.$$

Ganho máximo possível: ambos os filhos já são puros.

Análise para o Nível 1A – Ramo Ensolarado

Candidato 3: Vento

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Fraco	1, 8, 9	1 / 2	0,918
Forte	2, 11	1 / 1	1,000

Análise para o Nível 1A – Ramo Ensolarado

Candidato 3: Vento

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Fraco	1, 8, 9	1 / 2	0,918
Forte	2, 11	1 / 1	1,000

$$\mathcal{H}(S_{\text{Ens}} \mid \text{Vento}) = \frac{3}{5} \cdot 0,918 + \frac{2}{5} \cdot 1,000 \approx 0,950.$$

Análise para o Nível 1A – Ramo Ensolarado

Candidato 3: Vento

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Fraco	1, 8, 9	1 / 2	0,918
Forte	2, 11	1 / 1	1,000

$$\mathcal{H}(S_{\text{Ens}} \mid \text{Vento}) = \frac{3}{5} \cdot 0,918 + \frac{2}{5} \cdot 1,000 \approx 0,950.$$

$$\text{Ganho}(S_{\text{Ens}}, \text{Vento}) = 0,971 - 0,950 = \mathbf{0,021}.$$

Análise para o Nível 1A – Ramo Ensolarado

Resumo dos cálculos para nível 1A – ramo ensolarado:

Análise para o Nível 1A – Ramo Ensolarado

Resumo dos cálculos para nível 1A – ramo ensolarado:

Atributo	Ganho
Umidade	0,971
Temperatura	0,571
Vento	0,020

Análise para o Nível 1A – Ramo Ensolarado

Resumo dos cálculos para nível 1A – ramo ensolarado:

Atributo	Ganho
Umidade	0,971
Temperatura	0,571
Vento	0,020

O atributo **Umidade** é o melhor candidato para o nó raiz, pois apresenta o maior ganho de informação.

Análise para o Nível 1A – Ramo Ensolarado

Resumo dos cálculos para nível 1A – ramo ensolarado:

Atributo	Ganho
Umidade	0,971
Temperatura	0,571
Vento	0,020

O atributo Umidade é o melhor candidato para o nó raiz, pois apresenta o maior ganho de informação.

- **Umidade = Alta** $\Rightarrow$ 0 Sim / 3 Não $\Rightarrow$ folha Não.

Análise para o Nível 1A – Ramo Ensolarado

Resumo dos cálculos para nível 1A – ramo ensolarado:


Atributo	Ganho
Umidade	0,971
Temperatura	0,571
Vento	0,020

O atributo Umidade é o melhor candidato para o nó raiz, pois apresenta o maior ganho de informação.

- **Umidade = Alta** $\Rightarrow$ 0 Sim / 3 Não $\Rightarrow$ folha Não.
- **Umidade = Normal** $\Rightarrow$ 2 Sim / 0 Não $\Rightarrow$ folha Sim.

Construção de uma Árvore de Decisão

Árvore de decisão parcial:



Análise para o Nível 1B – Ramo Chuvoso

Dia	Tempo	Temperatura	Umidade	Vento	Jogar Tênis
4	Chuvoso	Ameno	Alta	Fraco	Sim
5	Chuvoso	Frio	Normal	Fraco	Sim
6	Chuvoso	Frio	Normal	Forte	Não
10	Chuvoso	Ameno	Normal	Fraco	Sim
14	Chuvoso	Ameno	Alta	Forte	Não

Análise para o Nível 1B – Ramo Chuvoso

Dia	Tempo	Temperatura	Umidade	Vento	Jogar Tênis
4	Chuvoso	Ameno	Alta	Fraco	Sim
5	Chuvoso	Frio	Normal	Fraco	Sim
6	Chuvoso	Frio	Normal	Forte	Não
10	Chuvoso	Ameno	Normal	Fraco	Sim
14	Chuvoso	Ameno	Alta	Forte	Não

Subconjunto $S_{Ch} = \{4, 5, 6, 10, 14\}$ com 3 Sim e 2 Não.

Análise para o Nível 1B – Ramo Chuvoso

Dia	Tempo	Temperatura	Umidade	Vento	Jogar Tênis
4	Chuvoso	Ameno	Alta	Fraco	Sim
5	Chuvoso	Frio	Normal	Fraco	Sim
6	Chuvoso	Frio	Normal	Forte	Não
10	Chuvoso	Ameno	Normal	Fraco	Sim
14	Chuvoso	Ameno	Alta	Forte	Não

Subconjunto $S_{Ch} = \{4, 5, 6, 10, 14\}$ com 3 Sim e 2 Não.

$$\mathcal{H}(S_{Ch}) = -\frac{3}{5} \log_2 \left(\frac{3}{5} \right) - \frac{2}{5} \log_2 \left(\frac{2}{5} \right) \approx 0,971.$$

Análise para o Nível 1B – Ramo Chuvoso

Dia	Tempo	Temperatura	Umidade	Vento	Jogar Tênis
4	Chuvoso	Ameno	Alta	Fraco	Sim
5	Chuvoso	Frio	Normal	Fraco	Sim
6	Chuvoso	Frio	Normal	Forte	Não
10	Chuvoso	Ameno	Normal	Fraco	Sim
14	Chuvoso	Ameno	Alta	Forte	Não

Subconjunto $S_{Ch} = \{4, 5, 6, 10, 14\}$ com 3 Sim e 2 Não.

$$\mathcal{H}(S_{Ch}) = -\frac{3}{5} \log_2 \left(\frac{3}{5} \right) - \frac{2}{5} \log_2 \left(\frac{2}{5} \right) \approx 0,971.$$

Restam analisar os atributos Temperatura, Umidade e Vento.

Análise para o Nível 1B – Ramo Chuvoso

Candidato 1: Temperatura

Análise para o Nível 1B – Ramo Chuvoso

Candidato 1: Temperatura

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Ameno	4, 10, 14	2 / 1	0,918
Frio	5, 6	1 / 1	1,000

Análise para o Nível 1B – Ramo Chuvoso

Candidato 1: Temperatura

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Ameno	4, 10, 14	2 / 1	0,918
Frio	5, 6	1 / 1	1,000

$$\mathcal{H}(S_{Ch} \mid \text{Temp}) = \frac{3}{5} \cdot 0,918 + \frac{2}{5} \cdot 1,000 \approx 0,950.$$

Análise para o Nível 1B – Ramo Chuvoso

Candidato 1: Temperatura

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Ameno	4, 10, 14	2 / 1	0,918
Frio	5, 6	1 / 1	1,000

$$\mathcal{H}(S_{Ch} \mid \text{Temp}) = \frac{3}{5} \cdot 0,918 + \frac{2}{5} \cdot 1,000 \approx 0,950.$$

$$\text{Ganho}(S_{Ch}, \text{Temp}) = 0,971 - 0,950 = \mathbf{0,021}.$$

Análise para o Nível 1B – Ramo Chuvoso

Candidato 2: Umidade

Análise para o Nível 1B – Ramo Chuvoso

Candidato 2: Umidade

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Alta	4, 14	1 / 1	1,000
Normal	5, 6, 10	2 / 1	0,918

Análise para o Nível 1B – Ramo Chuvoso

Candidato 2: Umidade

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Alta	4, 14	1 / 1	1,000
Normal	5, 6, 10	2 / 1	0,918

$$\mathcal{H}(S_{Ch} | Umid) = \frac{2}{5} \cdot 1,000 + \frac{3}{5} \cdot 0,918 \approx 0,950.$$

Análise para o Nível 1B – Ramo Chuvoso

Candidato 2: Umidade

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Alta	4, 14	1 / 1	1,000
Normal	5, 6, 10	2 / 1	0,918

$$\mathcal{H}(S_{Ch} | Umid) = \frac{2}{5} \cdot 1,000 + \frac{3}{5} \cdot 0,918 \approx 0,950.$$

$$\text{Ganho}(S_{Ch}, Umid) = 0,971 - 0,950 = \mathbf{0,021}.$$

Análise para o Nível 1B – Ramo Chuvoso

Candidato 3: Vento

Análise para o Nível 1B – Ramo Chuvoso

Candidato 3: Vento

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Fraco	4, 5, 10	3 / 0	0 (puro)
Forte	6, 14	0 / 2	0 (puro)

Análise para o Nível 1B – Ramo Chuvoso

Candidato 3: Vento

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Fraco	4, 5, 10	3 / 0	0 (puro)
Forte	6, 14	0 / 2	0 (puro)

$$\mathcal{H}(S_{Ch} \mid \text{Vento}) = \frac{3}{5} \cdot 0 + \frac{2}{5} \cdot 0 = 0.$$

Análise para o Nível 1B – Ramo Chuvoso

Candidato 3: Vento

Valor	Dias	Sim/Não	$\mathcal{H}(S_v)$
Fraco	4, 5, 10	3 / 0	0 (puro)
Forte	6, 14	0 / 2	0 (puro)

$$\mathcal{H}(S_{Ch} \mid \text{Vento}) = \frac{3}{5} \cdot 0 + \frac{2}{5} \cdot 0 = 0.$$

$$\text{Ganho}(S_{Ch}, \text{Vento}) = 0,971 - 0 = \mathbf{0,971}.$$

Ganho máximo possível: ambos os filhos já são puros.

Análise para o Nível 1B – Ramo Chuvoso

Resumo dos cálculos para nível 1B – ramo chuvoso:

Análise para o Nível 1B – Ramo Chuvoso

Resumo dos cálculos para nível 1B – ramo chuvoso:

Atributo	Ganho
Vento	0,971
Temperatura	0,021
Umidade	0,021

Análise para o Nível 1B – Ramo Chuvoso

Resumo dos cálculos para nível 1B – ramo chuvoso:

Atributo	Ganho
Vento	0,971
Temperatura	0,021
Umidade	0,021

O atributo Vento é o melhor candidato para o nó raiz, pois apresenta o maior ganho de informação.

Análise para o Nível 1B – Ramo Chuvoso

Resumo dos cálculos para nível 1B – ramo chuvoso:

Atributo	Ganho
Vento	0,971
Temperatura	0,021
Umidade	0,021

O atributo Vento é o melhor candidato para o nó raiz, pois apresenta o maior ganho de informação.

- **Vento = Fraco** $\Rightarrow$ 3 Sim / 0 Não $\Rightarrow$ folha Sim.

Análise para o Nível 1B – Ramo Chuvoso

Resumo dos cálculos para nível 1B – ramo chuvoso:


Atributo	Ganho
Vento	0,971
Temperatura	0,021
Umidade	0,021

O atributo Vento é o melhor candidato para o nó raiz, pois apresenta o maior ganho de informação.

- **Vento = Fraco** $\Rightarrow$ 3 Sim / 0 Não $\Rightarrow$ folha Sim.
- **Vento = Forte** $\Rightarrow$ 0 Sim / 2 Não $\Rightarrow$ folha Não.

Construção de uma Árvore de Decisão

Árvore de decisão final:



Divisão para Atributos Numéricos

- Para atributos numéricos, o processo de divisão é um pouco diferente, pois não temos um conjunto finito de valores discretos para dividir os dados;
- O algoritmo de construção da árvore de decisão irá testar diferentes pontos de corte (*thresholds*) para todos os atributos numéricos, e calcular o ganho de informação para cada situação;
 - Grupo Verdadeiro: $t \leq \text{limiar}$
 - Grupo Falso: $t > \text{limiar}$
- Neste caso, o *split* é binário, ou seja, cada nó irá dividir os dados em apenas dois grupos:
 - Selecionar o melhor (*threshold*) para cada atributo numérico;
 - Selecionar o melhor atributo numérico, ou seja, aquele que apresenta o maior ganho de informação.
- Escolha do limiar:
 - Ordenar por ordem crescentes os valores do atributo numérico;
 - Testar pontos de corte entre cada par de valores consecutivos, ou seja, calcular o ganho de informação para cada ponto de corte possível;

Critérios de Parada

- Alguns critérios de parada possíveis:
 - 1 Todos os exemplos em um nó pertencem à mesma classe (nó puro);
 - 2 O número de exemplos em um nó é menor do que um valor mínimo pré-definido (exemplo: 5);
 - 3 Nenhuma divisão dos dados resulta em um ganho de informação positivo;
 - 4 A profundidade da árvore atinge um limite pré-definido (exemplo: 10).
- Os critérios 2, 3 e 4 são utilizados para evitar o sobreajuste (*overfitting*);
- É possível realizar o *pruning* da árvore após a construção, ou seja, remover ramos que não contribuem significativamente para a precisão do modelo, com base em um conjunto de validação.

Implementação de uma Árvore de Decisão

- Estrutura de Dados para um nó da árvore;
- Cálculo de impureza (Gini ou Entropia);
- Busca exaustiva pelo melhor par (atributo, limiar) para cada nó interno;
- Construção recursiva da árvore, aplicando os critérios de parada;
- Treinamento da árvore (utilização da função de construção recursiva);
- Predição para um novo exemplo.

Implementação de uma Árvore de Decisão

Algoritmo 1 Estrutura de dados: nó da árvore

```
1: estrutura No
2:   atributo                                ▸ índice da feature testada (NIL em folhas)
3:   limiar                                   ▸ valor de corte (NIL em folhas)
4:   ramo_esq                                ▸ subárvore para  $x[\text{atributo}] \leq \text{limiar}$ 
5:   ramo_dir                                ▸ subárvore para  $x[\text{atributo}] > \text{limiar}$ 
6:   classe                                  ▸ rótulo predito (apenas em folhas)
7: fim estrutura

8: função ÉFOLHA(no)
9:   retornar no.classe  $\neq$  NIL
10: fim função
```

Implementação de uma Árvore de Decisão

Algoritmo 2 Cálculo de impureza

```
1: função IMPUREZA( $y$ , critério)
2:   se  $|y| = 0$  então
3:     retornar 0
4:   fim se
5:   para cada classe  $c \in C$ ,  $p_c \leftarrow \frac{|\{i : y_i = c\}|}{|y|}$ 
6:   se critério = GINI então
7:     retornar  $1 - \sum_{c \in C} p_c^2$ 
8:   senão se critério = ENTROPIA então
9:     retornar  $-\sum_{c \in C} p_c \log_2 p_c$ 
10:  fim se
11: fim função
```

Implementação de uma Árvore de Decisão

Algoritmo 3 Busca exaustiva pelo melhor par (atributo, limiar)

```
1: função MELHORSPLIT( $X, y, \text{critério}$ )
2:    $(n, d) \leftarrow$  dimensões de  $X$ 
3:    $I_{\text{pai}} \leftarrow \text{IMPUREZA}(y, \text{critério})$ 
4:    $g^* \leftarrow 0$ ;  $f^* \leftarrow \text{NIL}$ ;  $t^* \leftarrow \text{NIL}$ 
5:   para  $f \leftarrow 0$  até  $d - 1$  faça
6:      $V \leftarrow$  valores únicos ordenados da coluna  $X[:,f]$ 
7:      $T \leftarrow \{ (V_k + V_{k+1})/2 : k = 1, \dots, |V| - 1 \}$  ▷ pontos médios
8:     para cada  $t \in T$  faça
9:        $E \leftarrow \{i : X[i,f] \leq t\}$ ;  $D \leftarrow \{i : X[i,f] > t\}$ 
10:      se  $|E| = 0$  ou  $|D| = 0$  então
11:        continuar ▷ partição degenerada
12:      fim se
13:       $I_{\text{filhos}} \leftarrow \frac{|E| \cdot \text{IMPUREZA}(y[E], \text{critério}) + |D| \cdot \text{IMPUREZA}(y[D], \text{critério})}{n}$ 
14:       $g \leftarrow I_{\text{pai}} - I_{\text{filhos}}$ 
15:      se  $g > g^*$  então
16:         $g^* \leftarrow g$ ;  $f^* \leftarrow f$ ;  $t^* \leftarrow t$ 
17:      fim se
18:    fim para
19:  fim para
20:  retornar  $(f^*, t^*, g^*)$ 
21: fim função
```

Implementação de uma Árvore de Decisão

Algoritmo 4 Construção recursiva da árvore

```
1: função CONSTRUIR( $X, y, p, \text{max\_prof}, \text{min\_amostras}, \text{critério}$ )
2:   se  $y$  é puro ou  $|y| < \text{min\_amostras}$  ou ( $\text{max\_prof} \neq \text{NIL}$  e  $p \geq \text{max\_prof}$ )
   então
3:     retornar NO.FOLHA(CLASSEMAJORITÁRIA( $y$ ))  $\triangleright$  critério de parada
4:   fim se
5:   ( $f, t, g$ )  $\leftarrow$  MELHORSPLIT( $X, y, \text{critério}$ )
6:   se  $f = \text{NIL}$  ou  $g = 0$  então
7:     retornar NO.FOLHA(CLASSEMAJORITÁRIA( $y$ ))  $\triangleright$  nenhum split útil
8:   fim se
9:    $E \leftarrow \{i : X[i, f] \leq t\}; \quad D \leftarrow \{i : X[i, f] > t\}$ 
10:   $\text{esq} \leftarrow$  CONSTRUIR( $X[E], y[E], p + 1, \text{max\_prof}, \text{min\_amostras}, \text{critério}$ )
11:   $\text{dir} \leftarrow$  CONSTRUIR( $X[D], y[D], p + 1, \text{max\_prof}, \text{min\_amostras}, \text{critério}$ )
12:  retornar NO.INTERNO( $f, t, \text{esq}, \text{dir}$ )
13: fim função

14: função CLASSEMAJORITÁRIA( $y$ )
15:   retornar  $\arg \max_{c \in C} |\{i : y_i = c\}|$ 
16: fim função
```

Implementação de uma Árvore de Decisão

Algoritmo 5 Treinamento da árvore

```
1: função FIT( $X, y, \text{max\_prof}, \text{min\_amostras}, \text{critério}$ )  
2:    $\text{raiz} \leftarrow \text{CONSTRUIR}(X, y, 0, \text{max\_prof}, \text{min\_amostras}, \text{critério})$   
3:   retornar  $\text{raiz}$   
4: fim função
```

Algoritmo 6 Predição de uma única amostra

```
1: função PREDIZERAMOSTRA( $x, \text{no}$ )  
2:   se  $\text{no}$  é folha então  
3:     retornar  $\text{no.classe}$   
4:   fim se  
5:   se  $x[\text{no.atributo}] \leq \text{no.limiar}$  então  
6:     retornar PREDIZERAMOSTRA( $x, \text{no.ramo\_esq}$ )  
7:   senão  
8:     retornar PREDIZERAMOSTRA( $x, \text{no.ramo\_dir}$ )  
9:   fim se  
10: fim função
```
