

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS (CMPF)
DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA (DETEC)

SISTEMAS INTELIGENTES

Introdução às Redes Neurais Artificiais

Prof. Pedro Thiago Valério de Souza
UFERSA – Campus Pau dos Ferros
pedro.souza@ufersa.edu.br

Introdução

- Redes Neurais Artificiais são modelos computacionais inspirados no sistema nervoso de seres vivos;
- Possuem a capacidade de aquisição e manutenção do conhecimento;
- Podem ser definidas como um conjunto de unidades de processamento, denominadas de neurônios;
- Os neurônios são interligados entre si de forma a gerar uma estrutura de rede;

Introdução

Características Principais:

- Adaptação por experiência: A rede é capaz de armazenar o conhecimento através da apresentação sucessiva de exemplos relacionados ao problema;
- Capacidade de aprendizado: Através de um método de treinamento, a rede consegue extrair as informações entre as diversas variáveis que compõem o problema;
- Habilidade de generalização: Após treinada, a rede é capaz de generalizar o conhecimento adquirido, estimando respostas para casos desconhecidos;
- Organização de dados: A rede é capaz de se organizar internamente visando possibilitar o agrupamento de padrões que possuem particularidades entre si;
- Armazenamento distribuído: O conhecimento a respeito de um problema é realizado de forma distribuída entre as ligações da rede;
- Facilidade de prototipagem: implementação fácil via *software* ou via *hardware*;

Introdução

Potenciais Áreas de Aplicação:

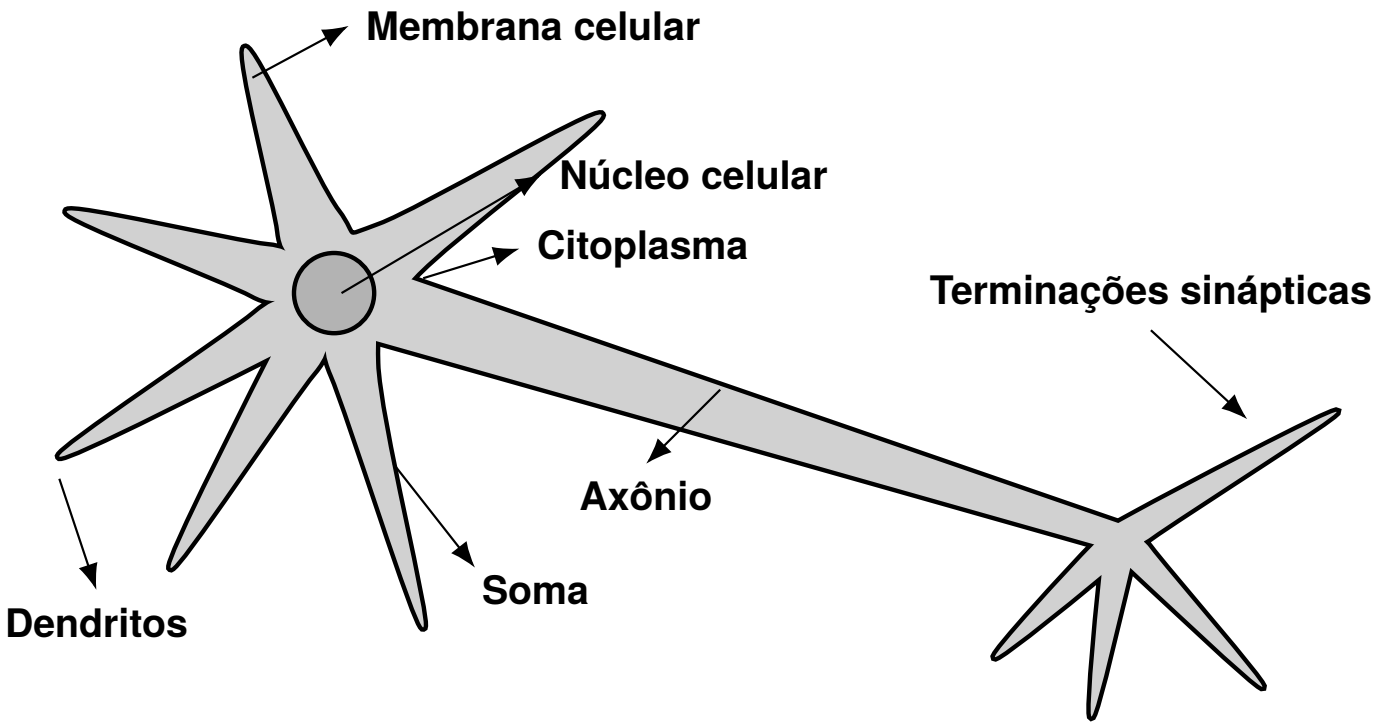
- Aproximador universal de funções;
- Reconhecimento/classificação de padrões;
- Agrupamento de dados (clusterização);
- Sistemas de previsão;
- Otimização de sistemas.

Neurônio Biológico

- A definição do neurônio biológico é importante para a definição do neurônio artificial;
- São as unidades elementares de processamento do cérebro humano;
- São unidades de processamento paralelo;
- São capazes de conduzir impulsos nervosos;

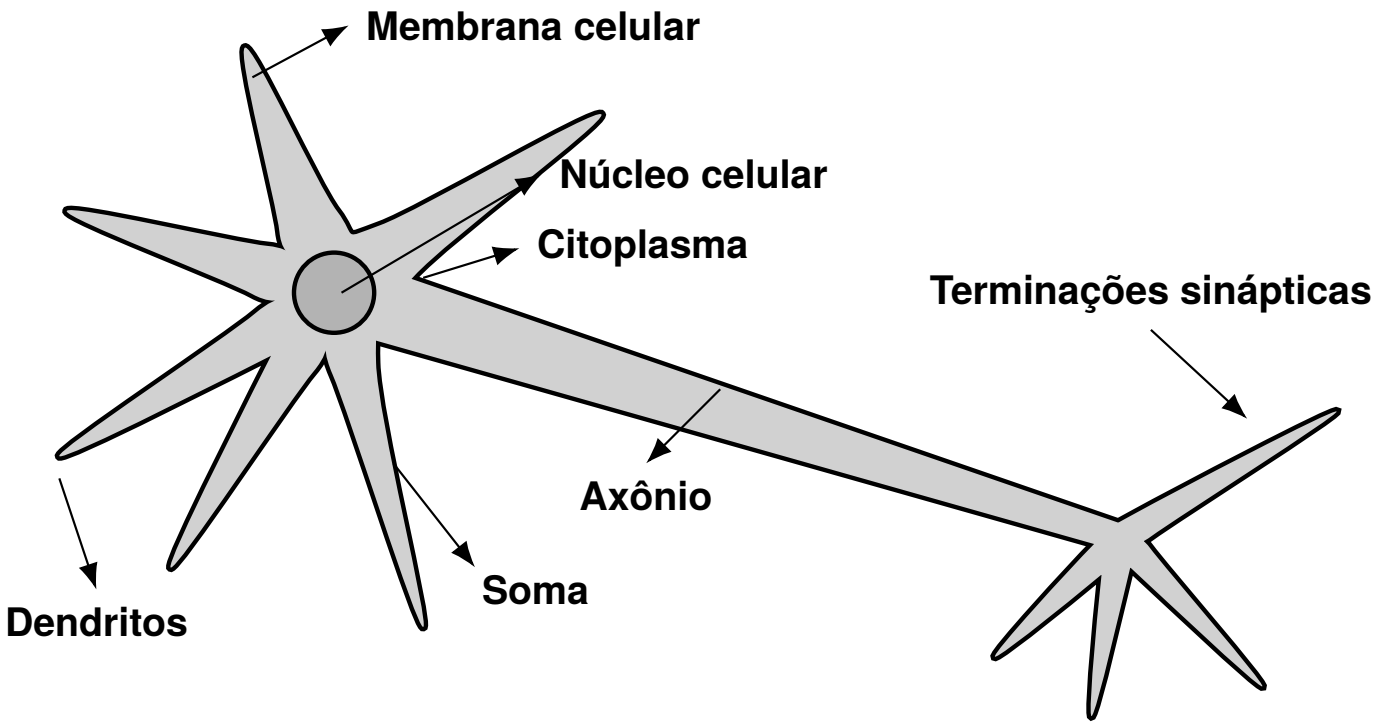
Neurônio Biológico

- **Composição de um neurônio biológico:**
  - Dendritos;
  - Corpo Celular (soma);
  - Axônio;



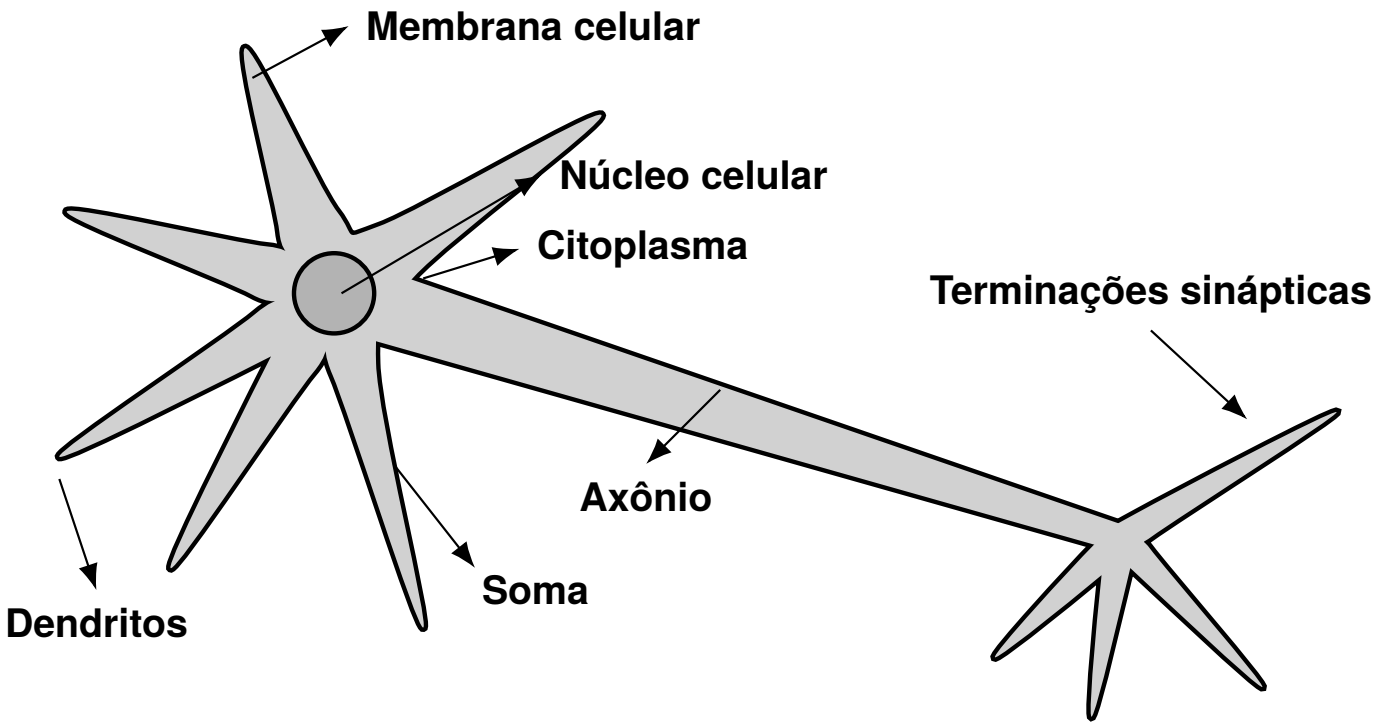
Neurônio Biológico

- **Composição de um neurônio biológico:**
  - Os dendritos têm como função captar os estímulos vindos de outros neurônios;



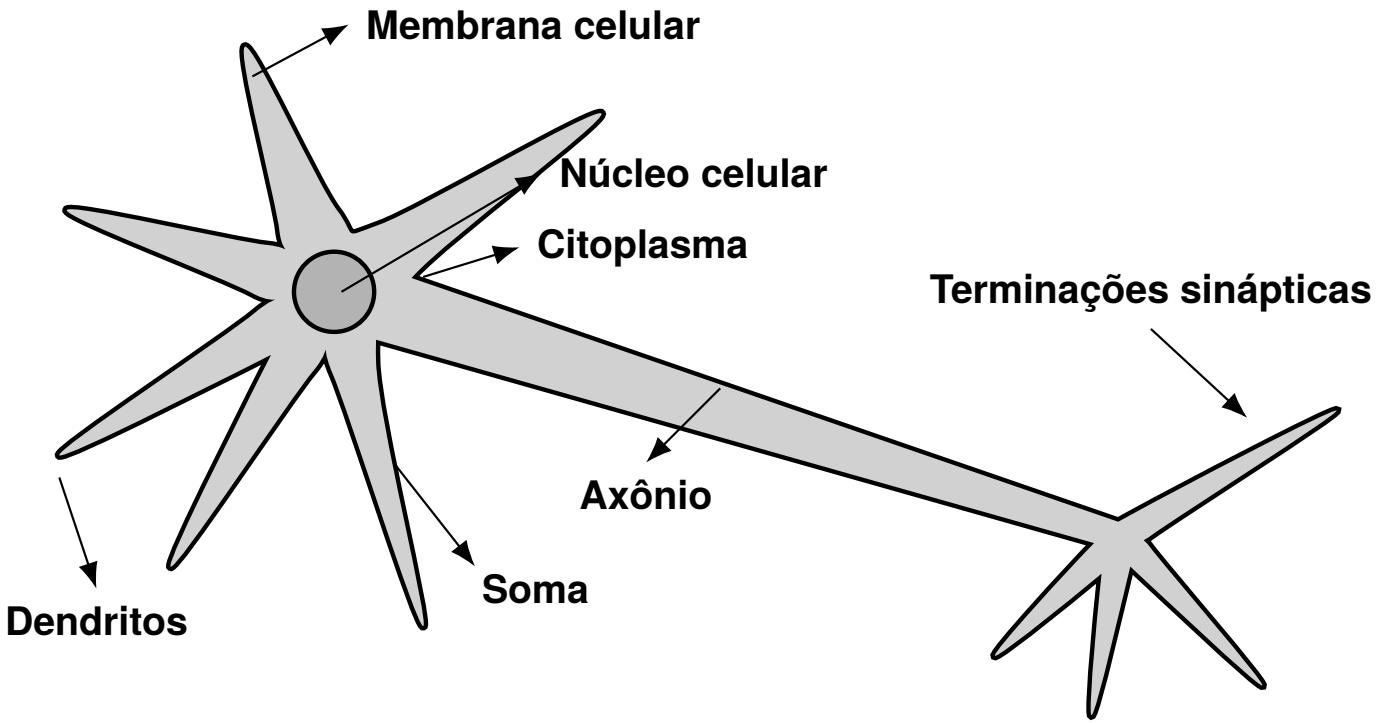
Neurônio Biológico

- **Composição de um neurônio biológico:**
  - O soma é responsável por realizar a função de processamento do neurônio;
  - Ele é responsável por gerar um potencial de ativação e determinar se um neurônio poderá disparar um sinal elétrico ao longo do axônio;



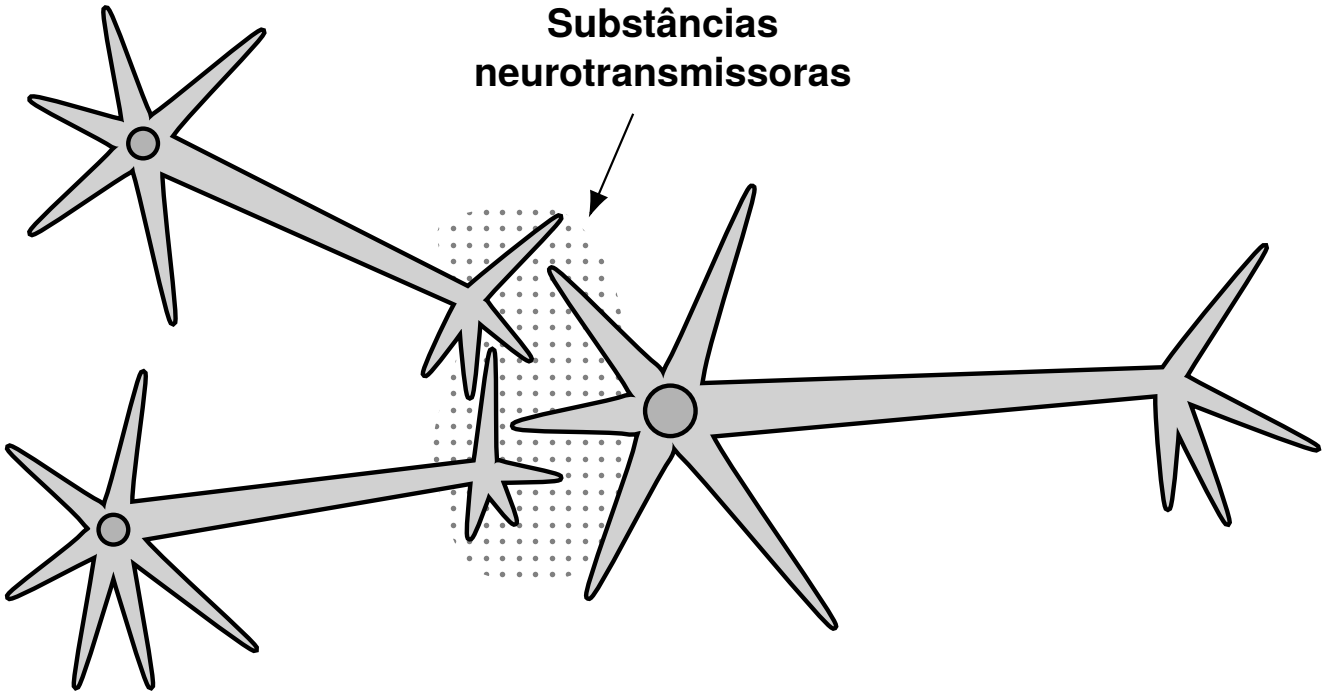
Neurônio Biológico

- **Composição de um neurônio biológico:**
  - O axônio é responsável por conduzir o sinal elétrico do neurônio para outros neurônios;



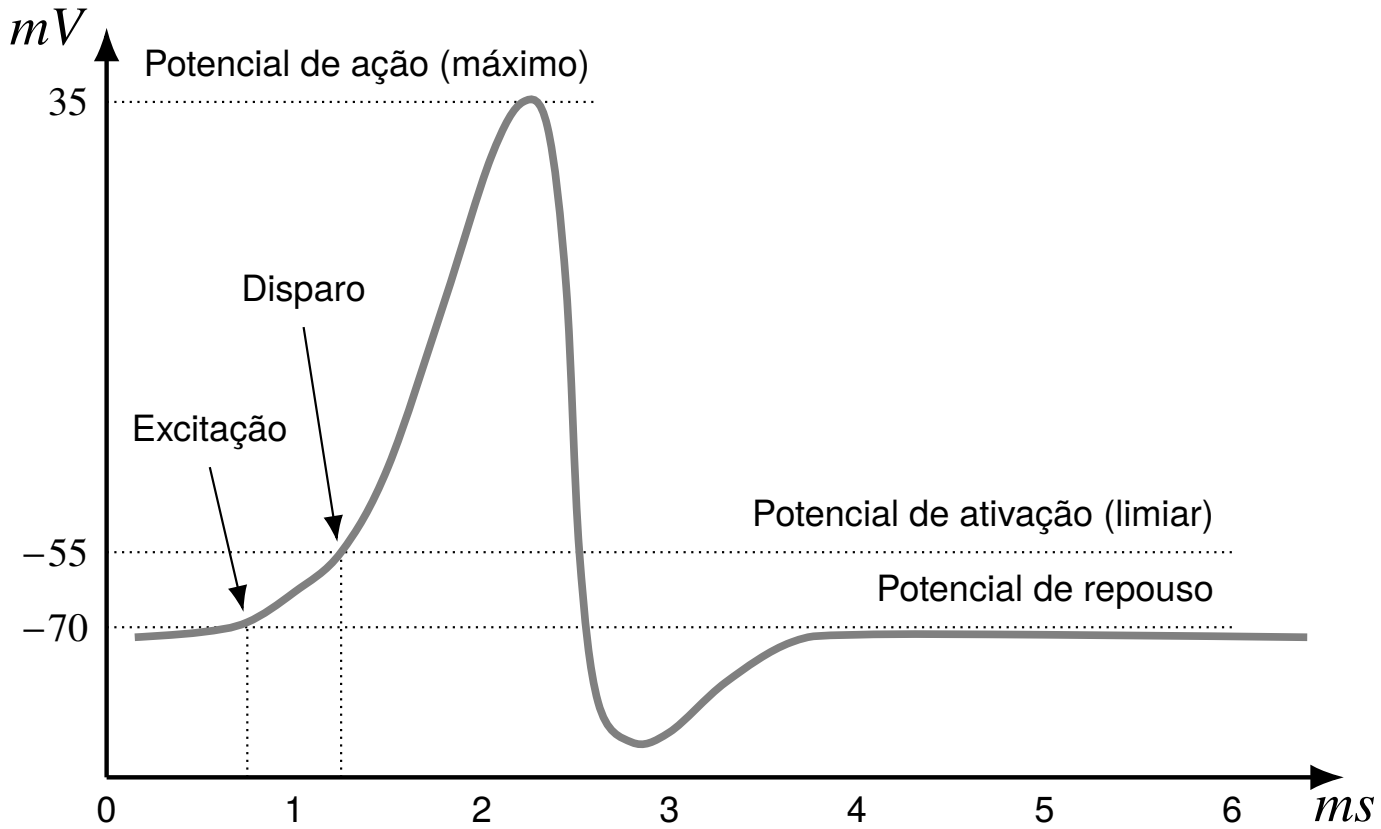
Neurônio Biológico

- A ligação entre dois neurônios é denominada de sinapse;
- A sinapse é responsável por armazenar o conhecimento;



Neurônio Biológico

- O disparo de um neurônio depende do potencial de ativação obtido no soma;
- Caso o potencial de ativação seja maior que um determinado limiar (limiar de disparo), ocorre o disparo de um sinal elétrico que será transmitido ao longo do axônio do neurônio;

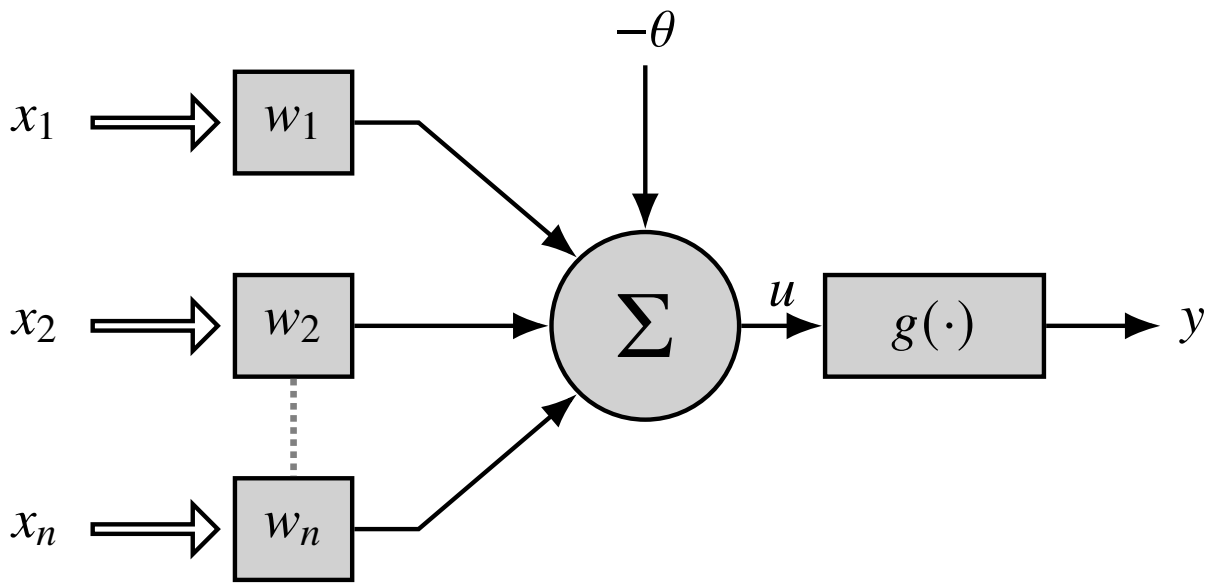


Neurônio Artificial

- São unidades básicas de processamento de uma rede neural;
- Constituem-se de modelos simplificados dos neurônios biológicos;
- Características:
  - Tipicamente não lineares;
  - Realizam funções simples, como coletar as entradas, realizar um processamento e gerar a saída.

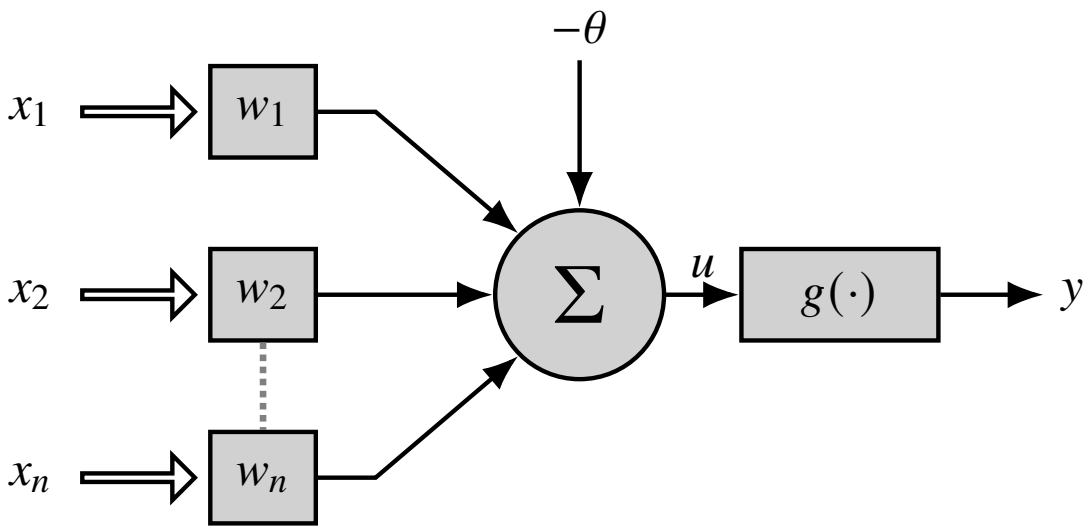
Neurônio Artificial

- Modelo de neurônio mais usual: Modelo de McCulloch-Pitts (MCP);
  - Proposto em 1943;
  - Arquitetura simples – a saída é determinada por um produto escalar entre o vetor de entrada e um vetor de pesos;
  - Representação:



Neurônio Artificial

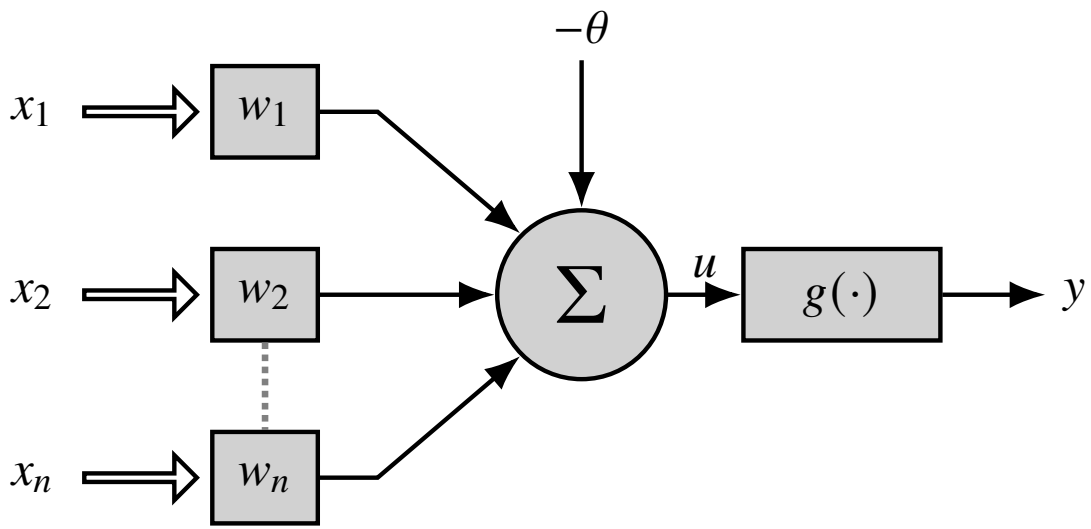
Modelo MCP de neurônio artificial – elementos básicos:



- Sinais de entrada $\{x_1, x_2, \ldots, x_n\}$:
  - Sinais provindos do meio externo;
  - Equivalente aos dendritos em um neurônio biológico;

Neurônio Artificial

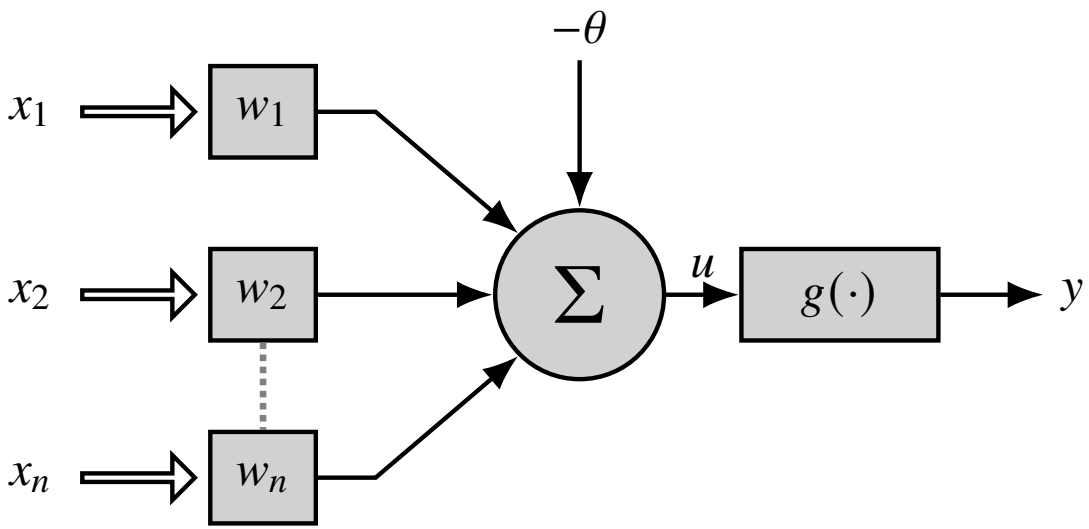
Modelo MCP de neurônio artificial – elementos básicos:



- Pesos sinápticos $\{w_1, w_2, \ldots, w_n\}$:
  - Ponderam cada entrada, permitindo quantificar a relevância de cada entrada na solução do problema;
  - Armazenam o conhecimento adquirido no processo de aprendizagem.

Neurônio Artificial

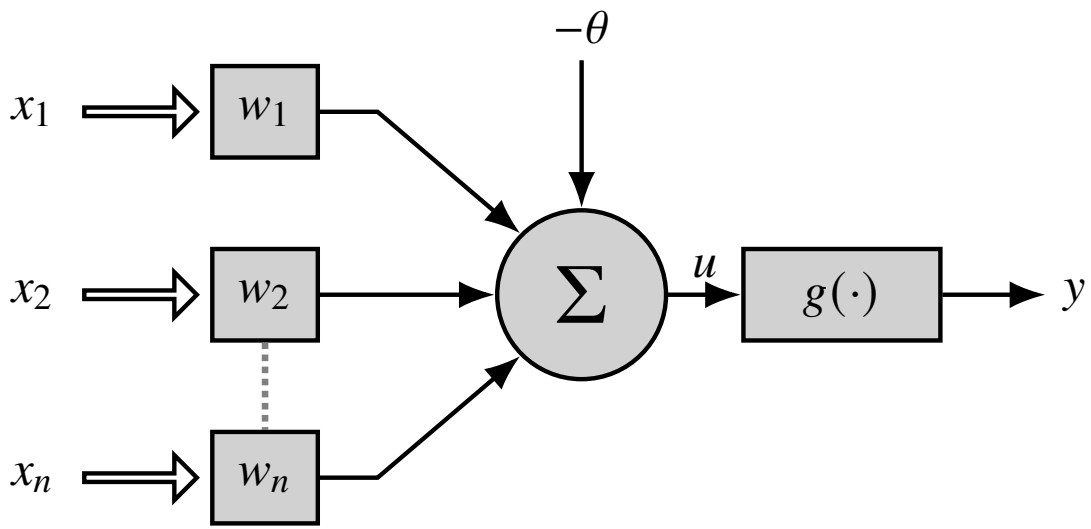
Modelo MCP de neurônio artificial – elementos básicos:



- Combinador linear $\{\Sigma\}$:
  - Agrega todos os sinais de entrada ponderados;
  - Produz um potencial de ativação (u);
  - Equivale ao soma do neurônio biológico.

Neurônio Artificial

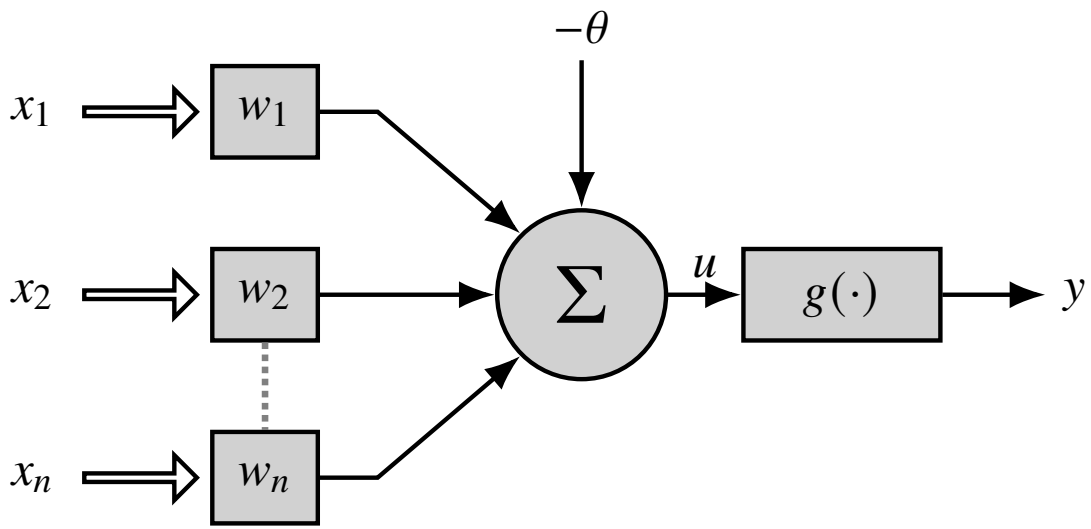
Modelo MCP de neurônio artificial – elementos básicos:



- Limiar de ativação $\{\theta\}$:
  - Variável que especifica quando o potencial de ativação será suficiente para ativar o neurônio;
  - Também denominado de *bias*.

Neurônio Artificial

Modelo MCP de neurônio artificial – elementos básicos:

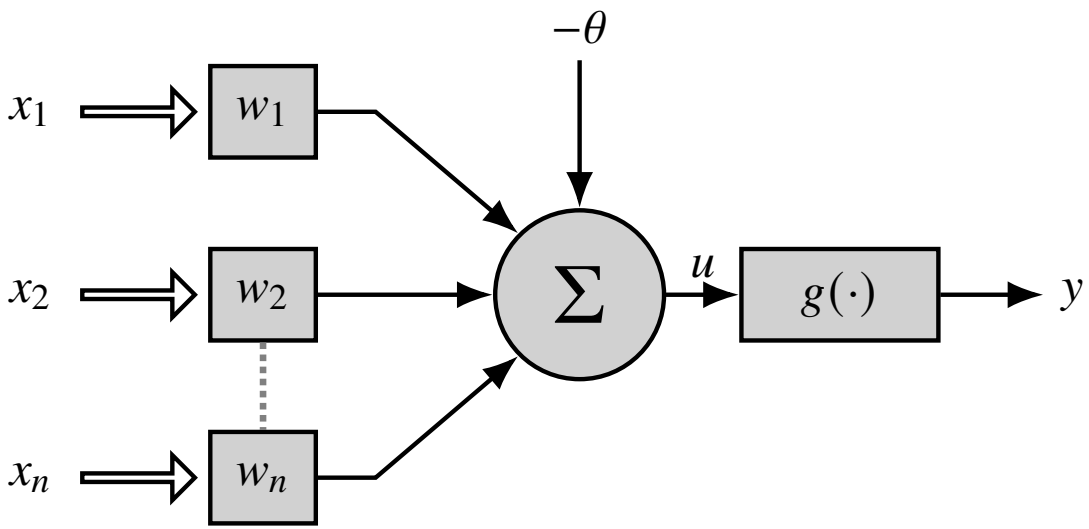


- Potencial de ativação $\{u\}$: Resultado obtido na saída do combinador linear;

$$u = \sum_{i=1}^{n} w_i x_i - \theta$$

Neurônio Artificial

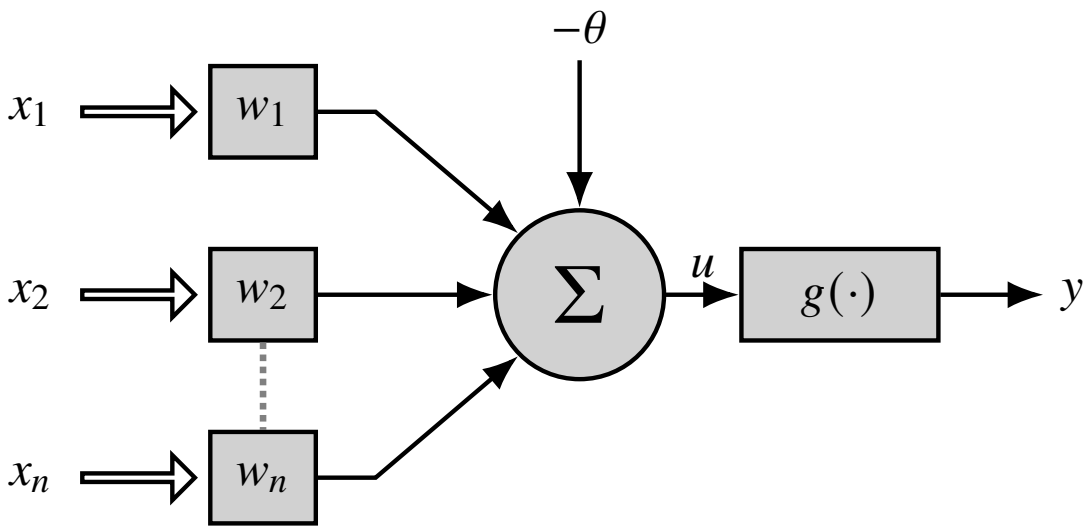
Modelo MCP de neurônio artificial – elementos básicos:



- Função de ativação $\{g(\cdot)\}$:
  - Limita a saída do neurônio a valores razoáveis;
  - A sua escolha depende da aplicação.

Neurônio Artificial

Modelo MCP de neurônio artificial – elementos básicos:

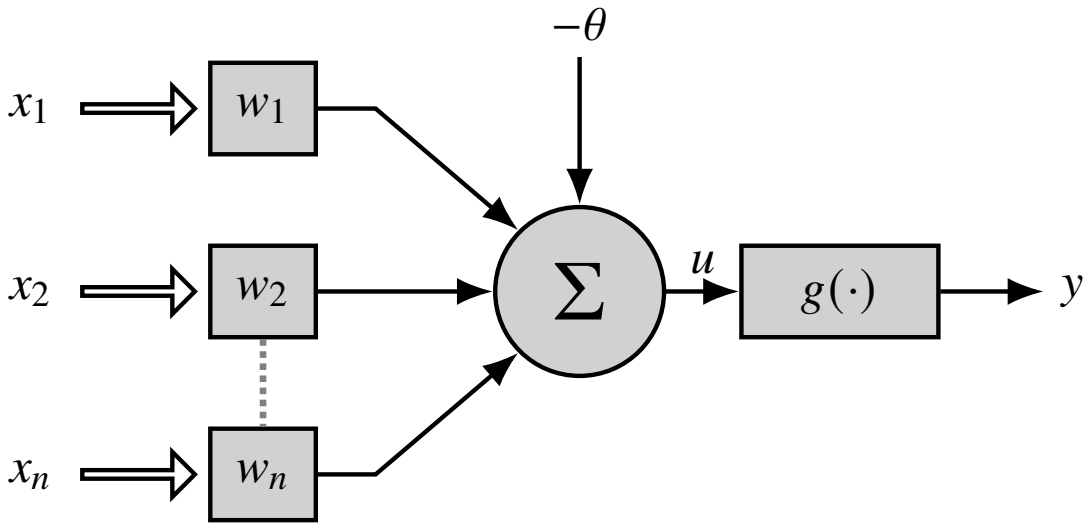


- Saída $\{y\}$: Consiste no valor final do neurônio, podendo ser utilizado como entrada em outros neurônios.

$$y = g(u) = g\left(\sum_{i=1}^{n} w_i x_i - \theta\right)$$

Neurônio Artificial

Modelo MCP de neurônio artificial – expressões vetoriais:



$$u = \sum_{i=1}^{n} w_i x_i - \theta = \mathbf{w}^T \mathbf{x}$$

$$y = g(u) = g(\mathbf{w}^T \mathbf{x})$$

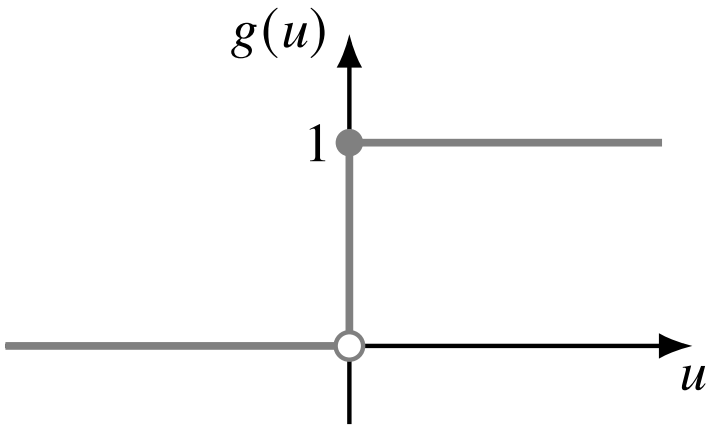
$$\mathbf{w} = \begin{bmatrix} \theta & w_1 & w_2 & \cdots & w_n \end{bmatrix}^T$$

$$\mathbf{x} = \begin{bmatrix} -1 & x_1 & x_2 & \cdots & x_n \end{bmatrix}^T$$

Funções de Ativação

- **Funções de ativação parcialmente diferenciáveis:**
  - Função Degrau:

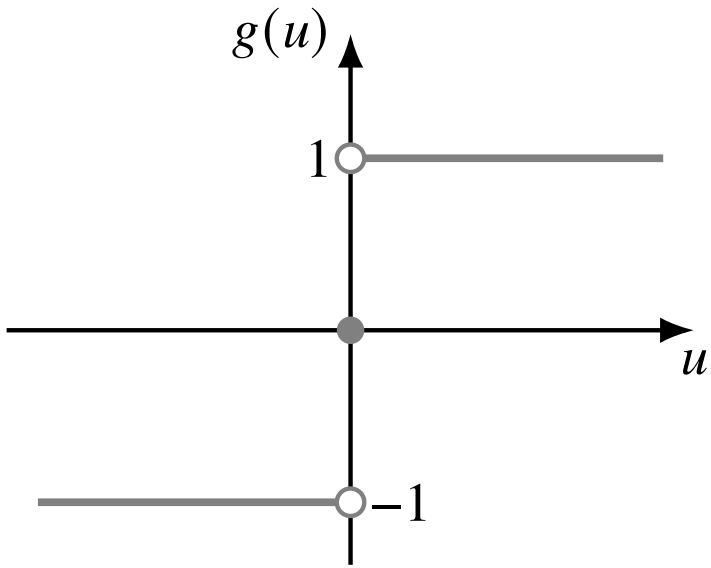
$$g(u) = \begin{cases} 1, & u \geq 0 \\ 0, & u < 0 \end{cases}$$



Funções de Ativação

- **Funções de ativação parcialmente diferenciáveis:**
  - Função Sinal:

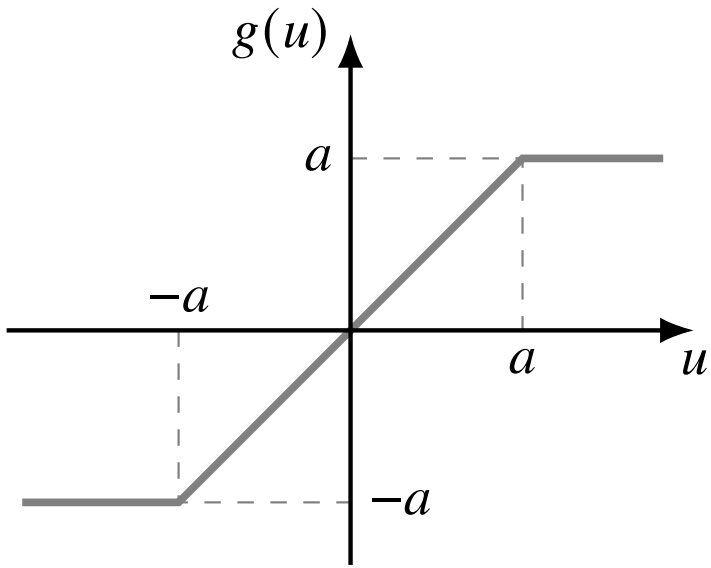
$$g(u) = \text{sign}(u) = \begin{cases} +1, & u > 0 \\ 0, & u = 0 \\ -1, & u < 0 \end{cases}$$



Funções de Ativação

- **Funções de ativação parcialmente diferenciáveis:**
  - Função rampa simétrica:

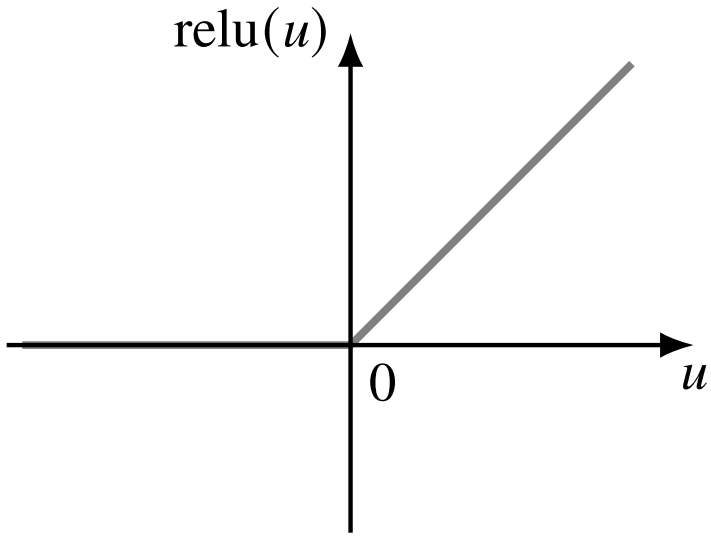
$$g(u) = \begin{cases} a, & u > a \\ u, & -a \leq u \leq a \\ -a, & u < -a \end{cases}$$



Funções de Ativação

- **Funções de ativação parcialmente diferenciáveis:**
  - Linear retificada (ReLU):

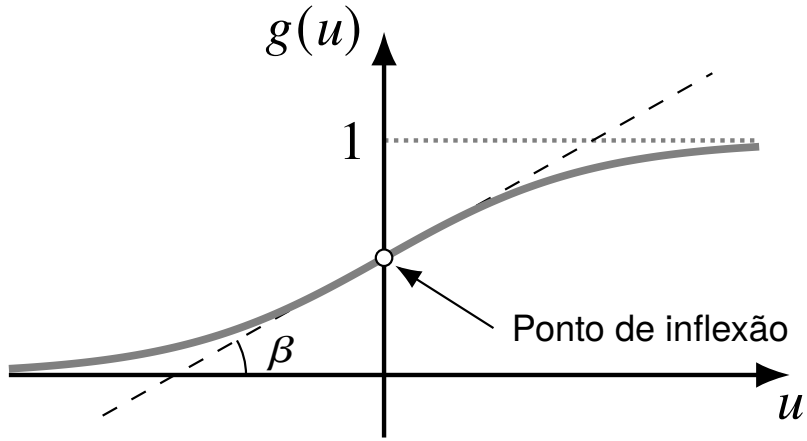
$$g(u) = \begin{cases} u, & u \geq 0 \\ 0, & u < 0 \end{cases}$$



Funções de Ativação

- **Funções de ativação completamente diferenciáveis:**
  - Função logística:

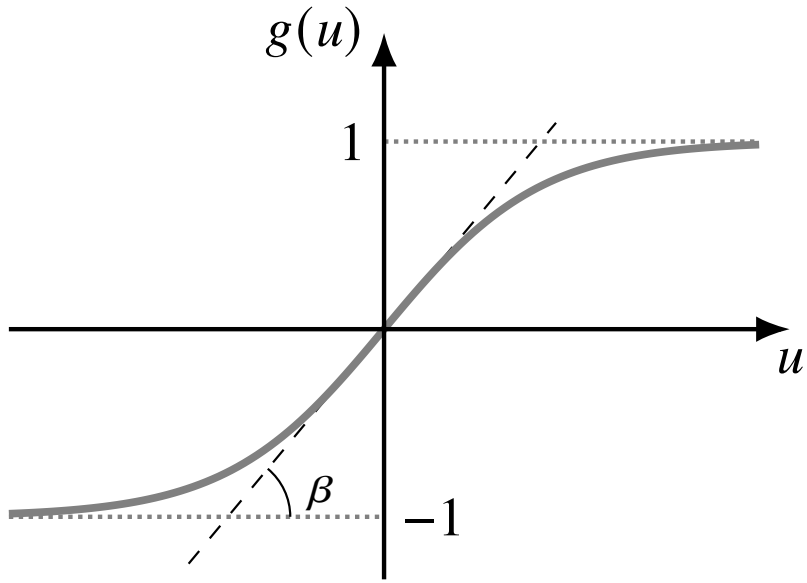
$$g(u) = \frac{1}{1 + e^{-\beta u}}$$



Funções de Ativação

- **Funções de ativação completamente diferenciáveis:**
  - Função tangente hiperbólica:

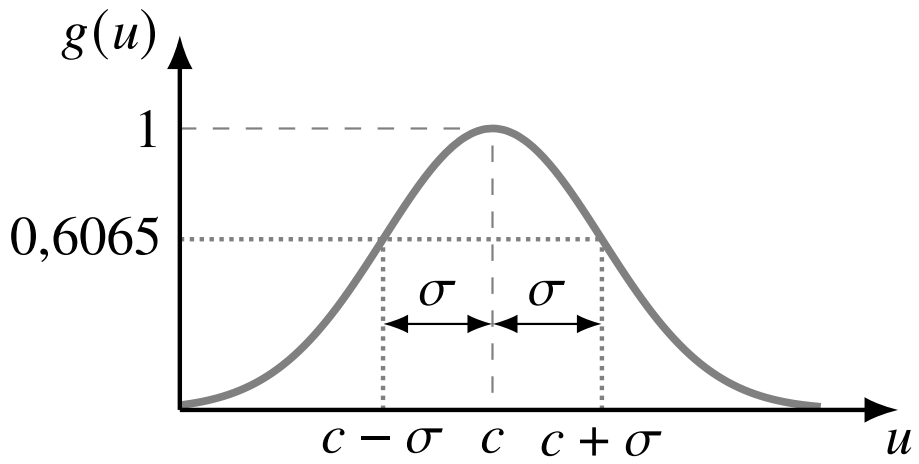
$$g(u) = \frac{1 - e^{-\beta u}}{1 + e^{-\beta u}}$$



Funções de Ativação

- **Funções de ativação completamente diferenciáveis:**
  - Função gaussiana:
    - c: é o ponto médio (central);
    - σ^2: é a variância (dispersão).

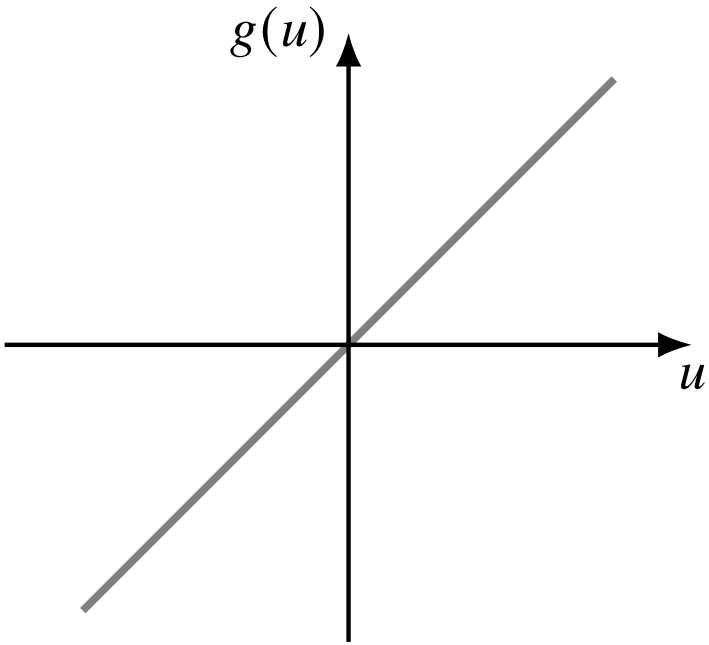
$$g(u) = \exp\left[-\frac{(u-c)^2}{2\sigma^2}\right]$$



Funções de Ativação

- **Funções de ativação completamente diferenciáveis:**
  - Função linear:

$$g(u) = u$$

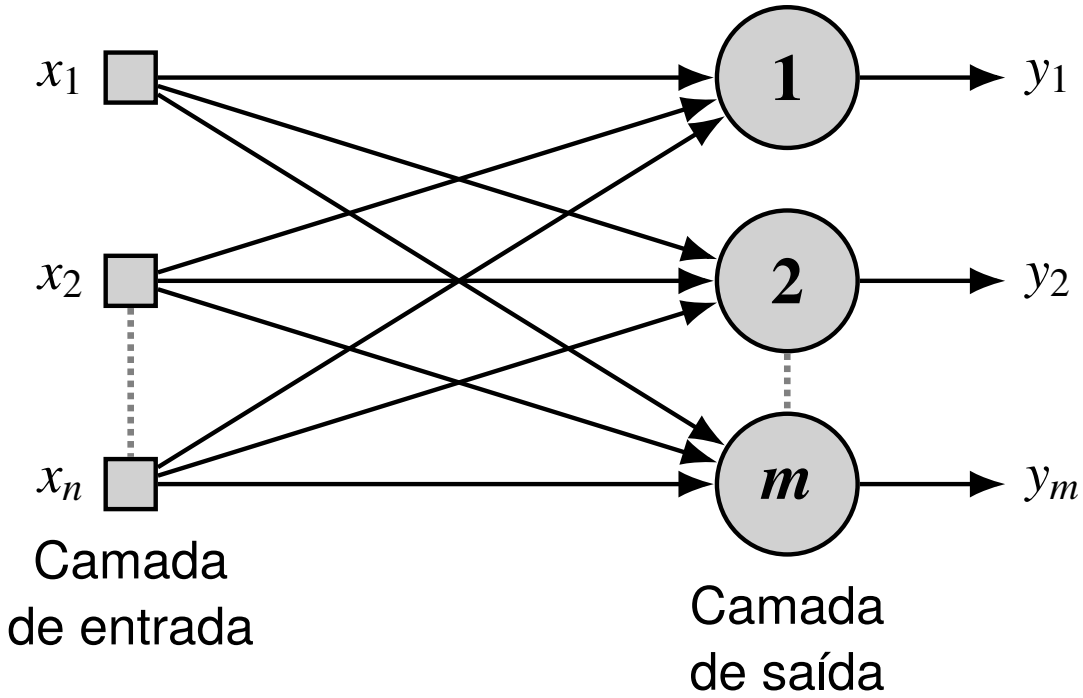


Arquiteturas de Redes Neurais Artificiais

- Redes *feedforward* de camada simples;
- Redes *feedforward* de múltiplas camadas;
- Redes recorrentes;
- Redes reticuladas.

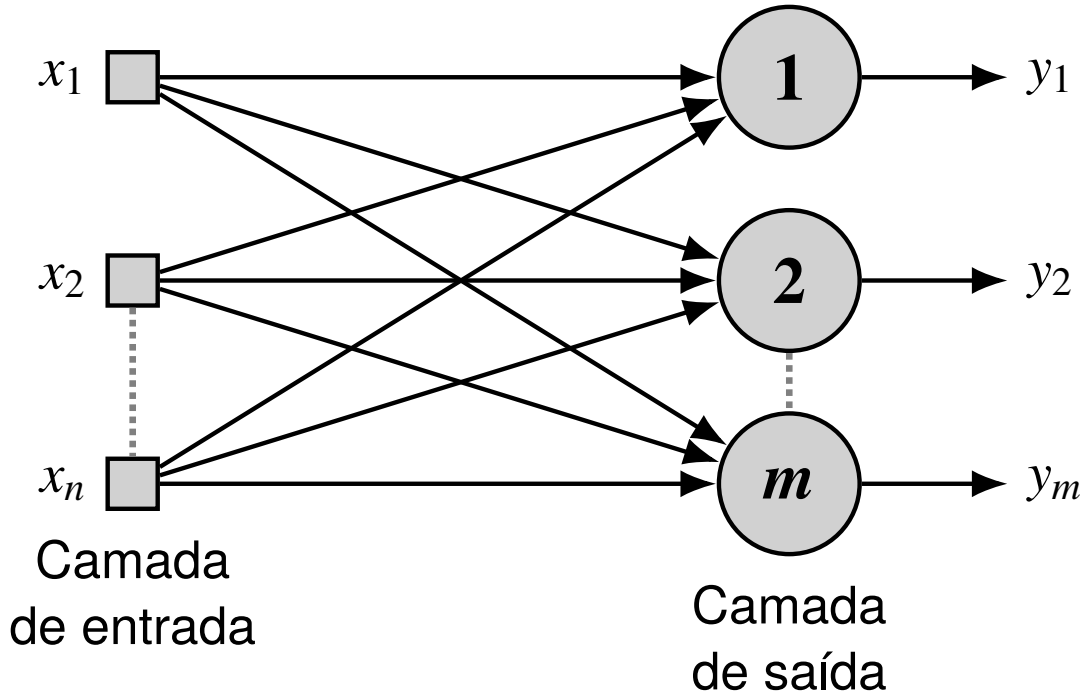
Arquiteturas de Redes Neurais Artificiais

- **Redes *feedforward* de camada simples:**
  - Possui apenas a camada de entrada e a camada de saída;
  - Fluxo em apenas uma direção (*entradas* → *saídas*);



Arquiteturas de Redes Neurais Artificiais

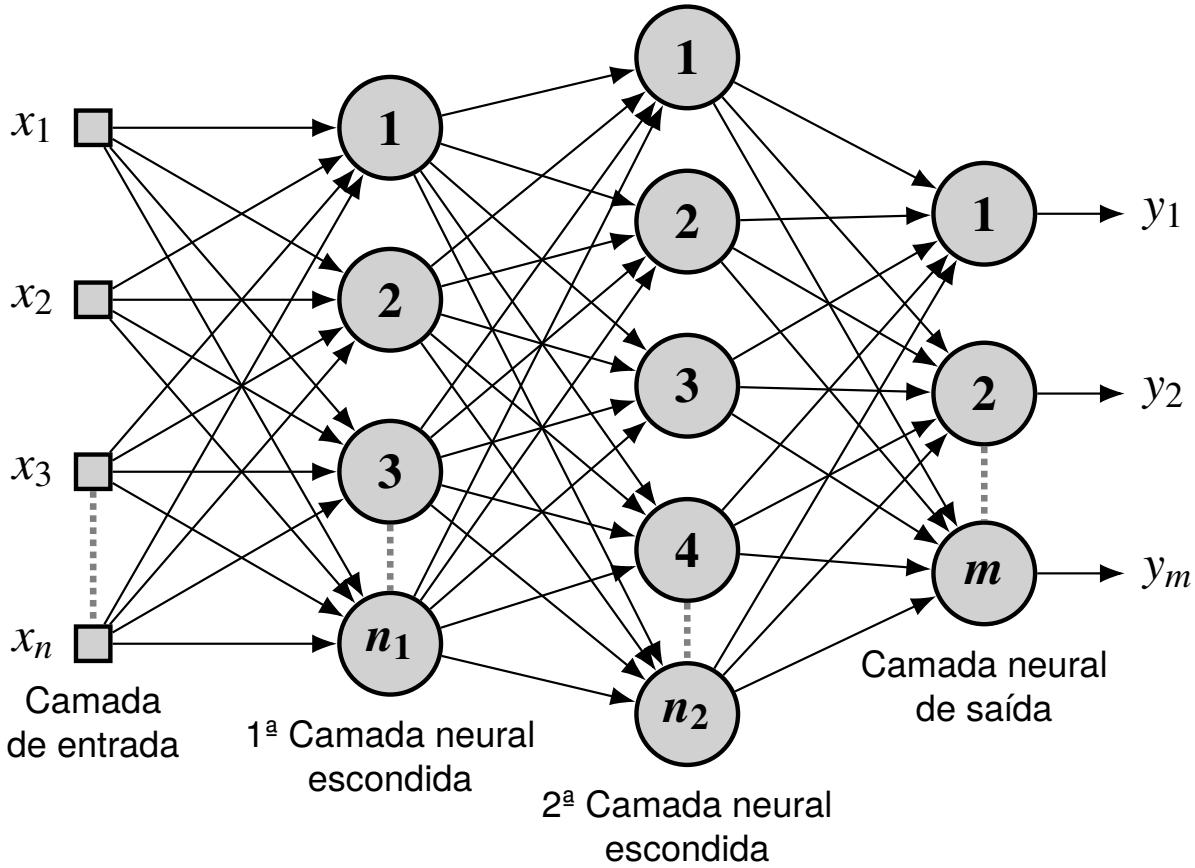
- **Redes *feedforward* de camada simples:**



- A quantidade de saídas é igual ao número de neurônios na camada de saída;
- Aplicações: classificação de padrões e filtragem linear;
- Principais redes: *Perceptron* e *Adaline*.

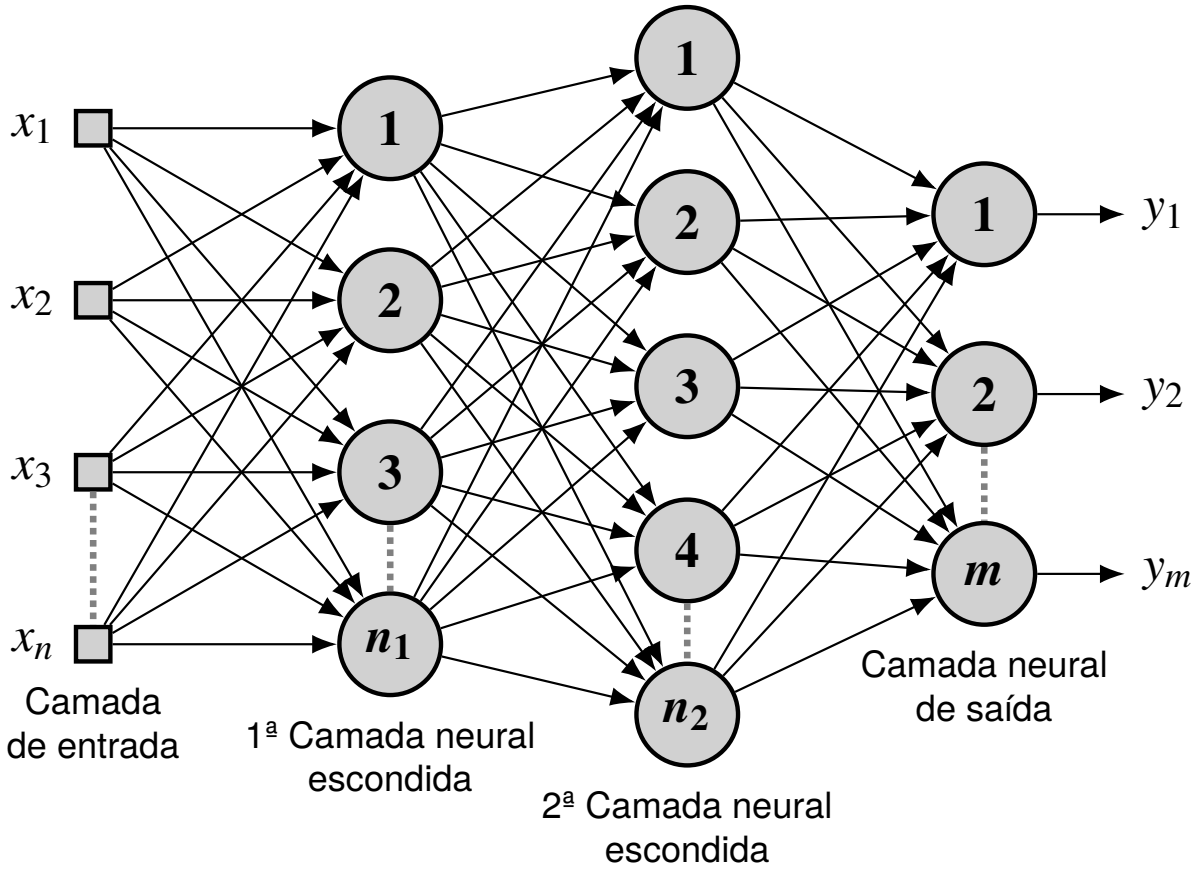
Arquiteturas de Redes Neurais Artificiais

- **Redes *feedforward* de múltiplas camadas:**
  - Caracterizada pela presença das camadas de entrada, saída e das camadas ocultas;



Arquiteturas de Redes Neurais Artificiais

- **Redes *feedforward* de múltiplas camadas:**
  - Fluxo em apenas uma direção (*entradas* → *saídas*);
  - Aplicações: aproximação de funções, classificação de padrões, identificação de sistemas, otimização, robótica, controle de processos, etc.

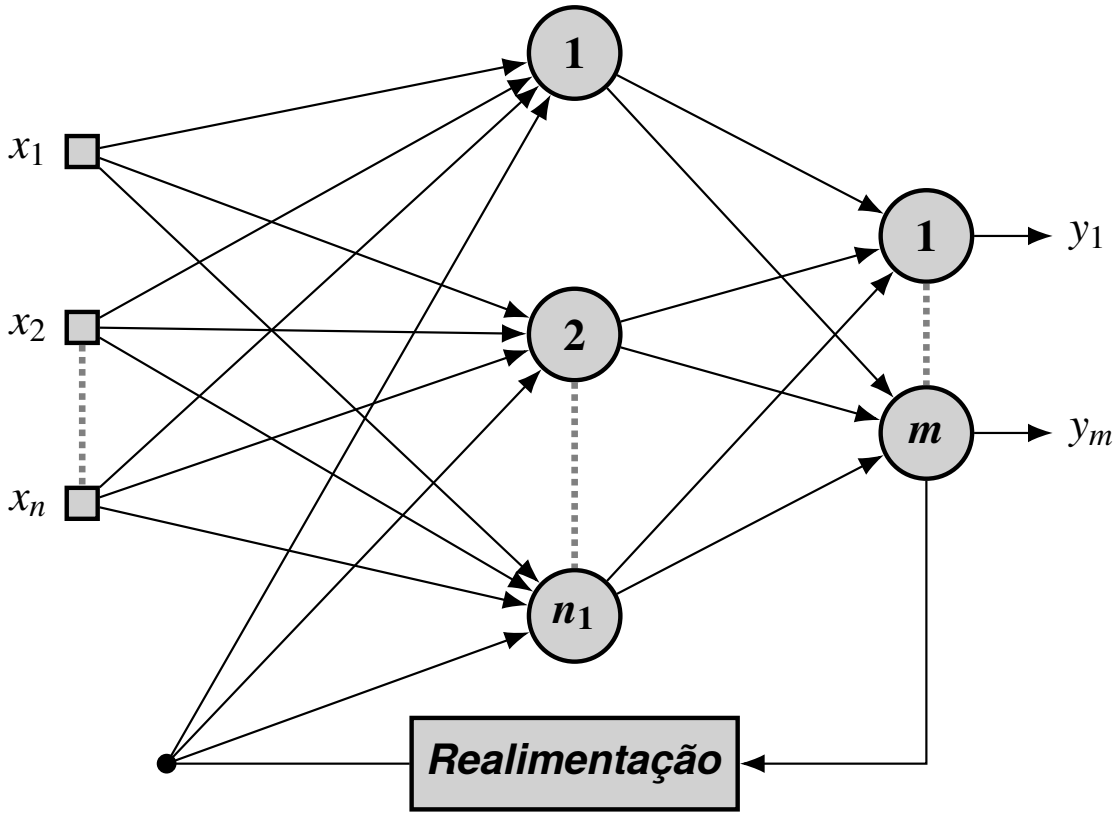


Arquiteturas de Redes Neurais Artificiais

- **Redes *feedforward* de múltiplas camadas:**
  - Principais redes: *Perceptron* de múltiplas camadas (MLP), redes de função de base radial (RBF) e redes convolucionais (CNN);
  - Determinação do número de camadas ocultas e do número de neurônios por camada:
    - Complexidade do problema a ser mapeado;
    - Qualidade e quantidade dos dados no treinamento.
  - Observação: A quantidade de saídas é igual ao número de neurônios na camada de saída;

Arquiteturas de Redes Neurais Artificiais

- **Rede recorrente (ou realimentada):**
  - As saídas da rede são realimentadas como entrada para outros neurônios;



- A saída atual da rede depende da entrada atual e das saídas passadas;
- Aplicações: processamento dinâmico (previsão de séries temporais, identificação de sistemas, controle de processos);
- Principais redes: Hopfield e RNN.

Arquiteturas de Redes Neurais Artificiais

- **Rede em estrutura reticulada:**
  - Possui uma disposição espacial dos neurônios;
  - Aplicações: problemas de agrupamento, reconhecimento de padrões, otimização, grafos, etc.
  - Principal rede: Rede de Kohonen.

