

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS (CMPF)
DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA (DETEC)

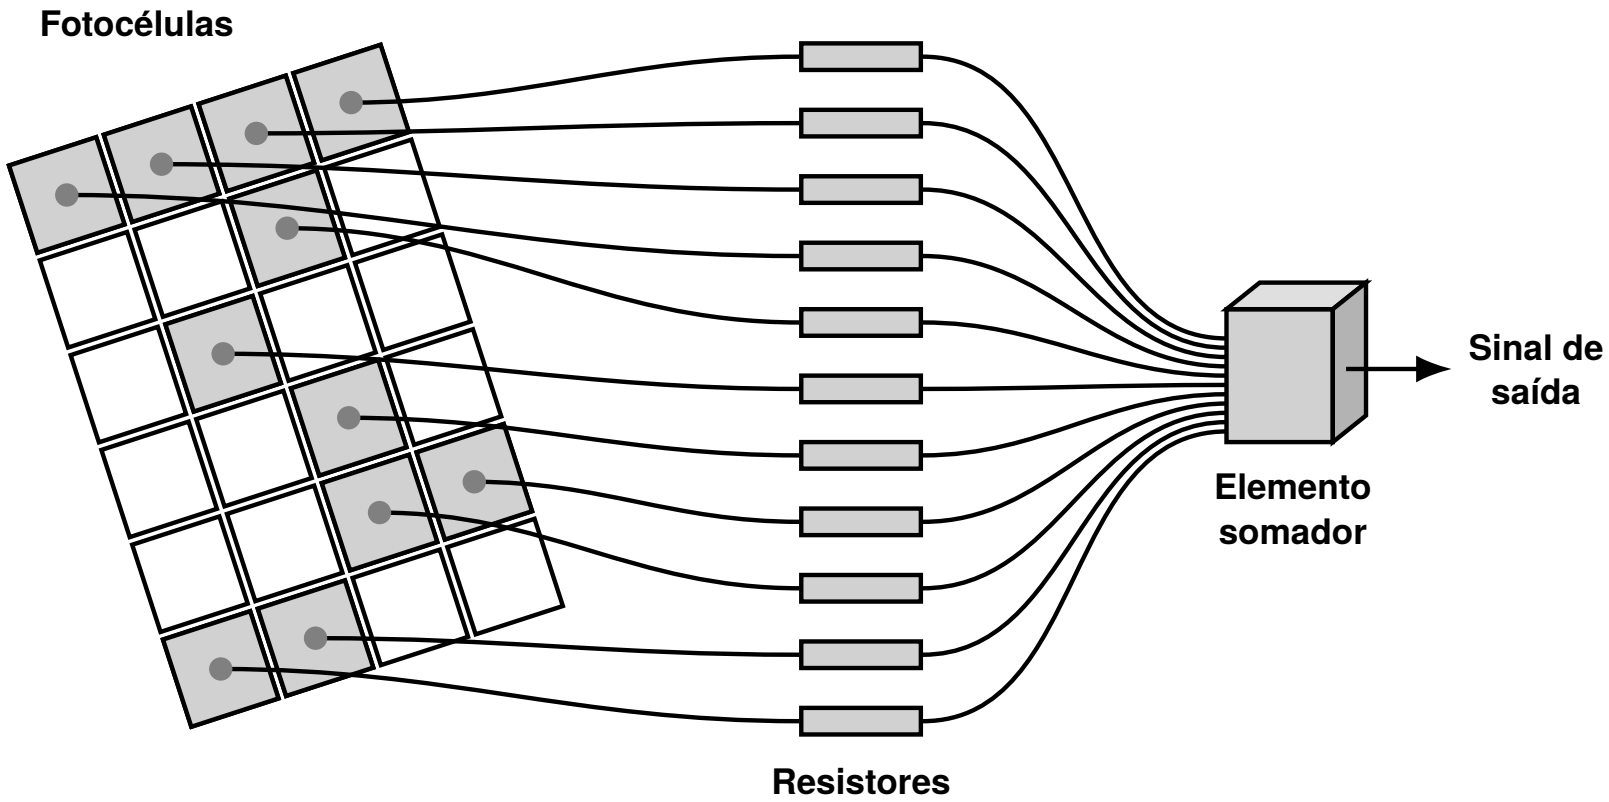
SISTEMAS INTELIGENTES

Redes *Perceptron*

Prof. Pedro Thiago Valério de Souza
UFERSA – Campus Pau dos Ferros
pedro.souza@ufersa.edu.br

Conceitos Fundamentais da Rede *Perceptron*

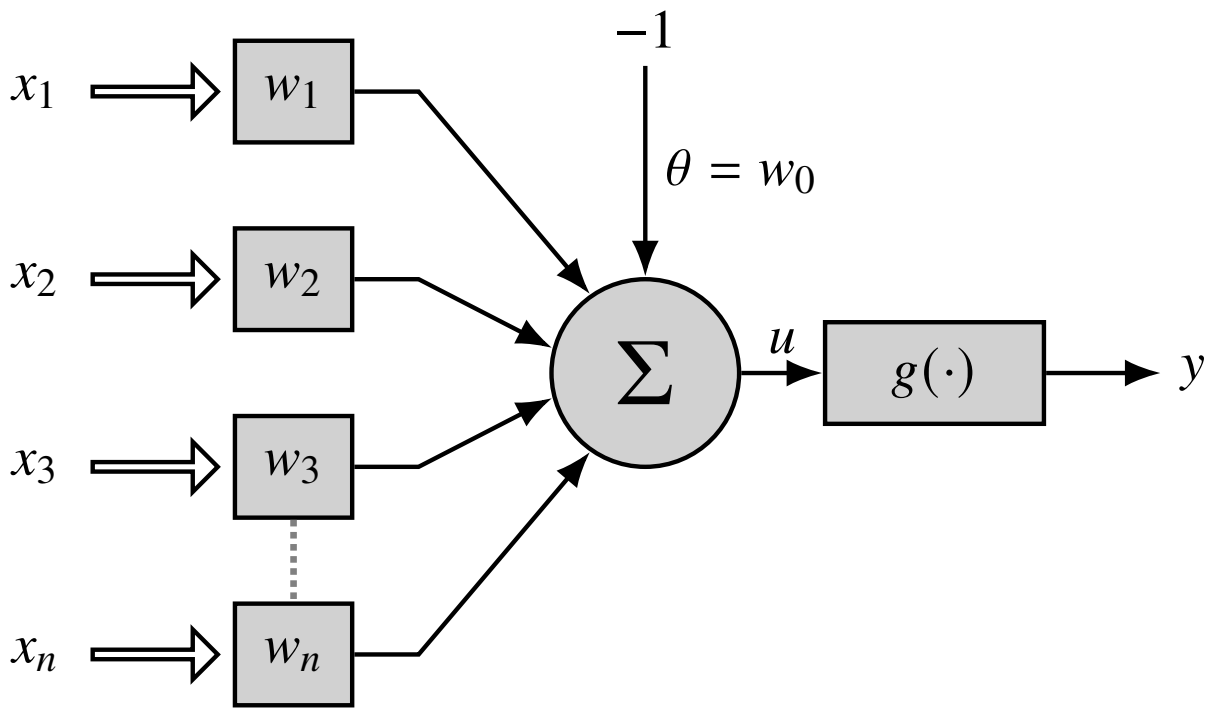
- Rede neural proposta por Rosenblatt (1958);
- Configuração mais simples de uma rede neural artificial;
- Modelo computacional inspirado na retina humana;
  - Proposta inicial para identificar padrões geométricos;
- Concepção inicial:



Conceitos Fundamentais da Rede *Perceptron*

Características gerais da rede *Perceptron*:

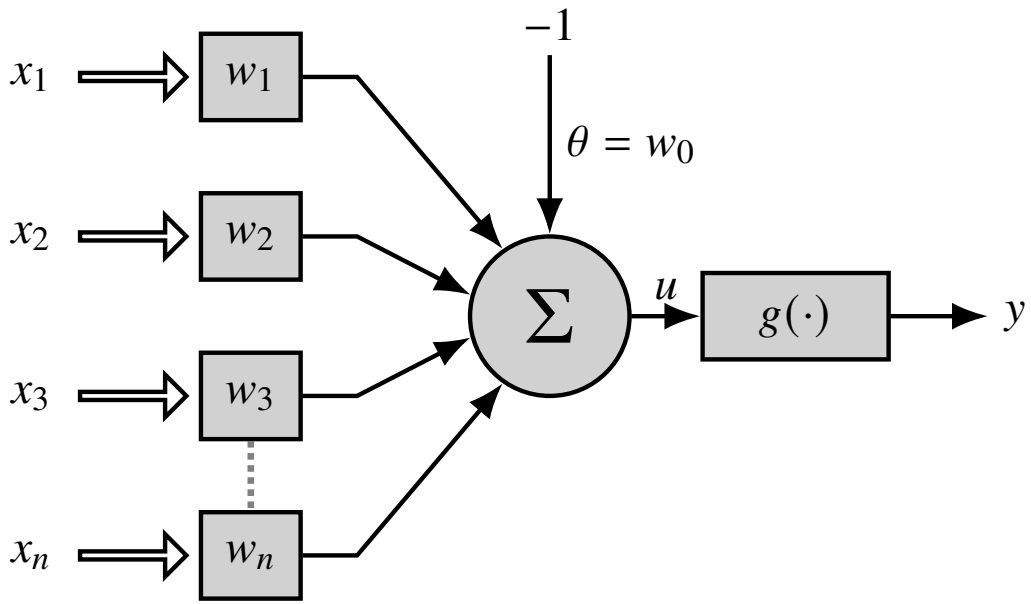
- Arquitetura *feedforward* de camada única;
- Quantidade de entradas: n entradas;
- Apenas uma saída;



Conceitos Fundamentais da Rede *Perceptron*

Características gerais da rede *Perceptron*:

- Vetor de pesos sinápticos: valores reais;
- Vetor de entradas: valores reais ou binários;



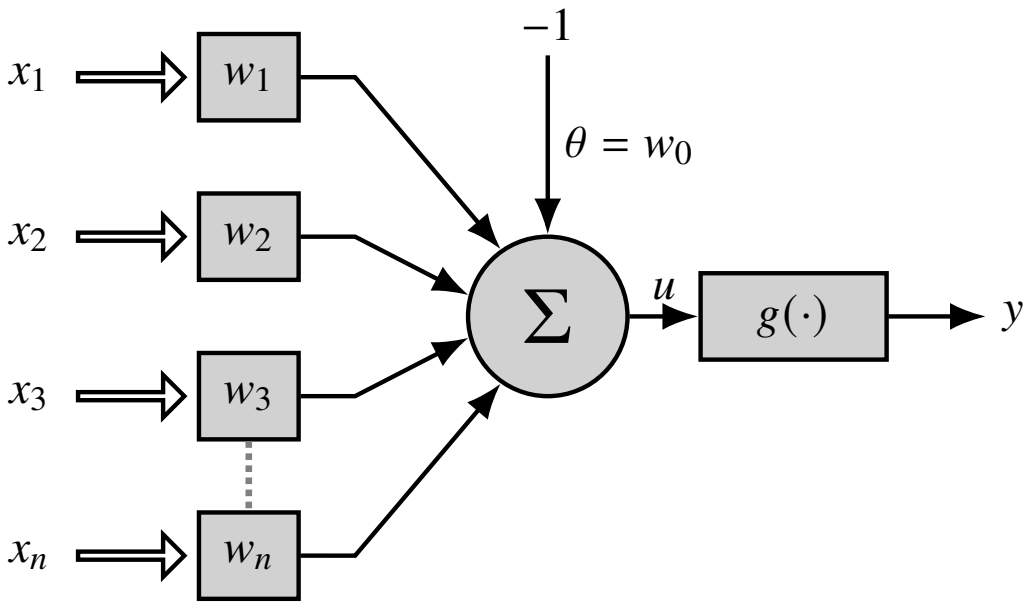
$$\mathbf{w} = \begin{bmatrix} \theta & w_1 & w_2 & \cdots & w_n \end{bmatrix}^T$$

$$\mathbf{x} = \begin{bmatrix} -1 & x_1 & x_2 & \cdots & x_n \end{bmatrix}^T$$

Conceitos Fundamentais da Rede *Perceptron*

Características gerais da rede *Perceptron*:

- Expressões de saída da rede *Perceptron*:



$$u = \sum_{i=0}^{n} w_i x_i = \mathbf{w}^T \mathbf{x}$$

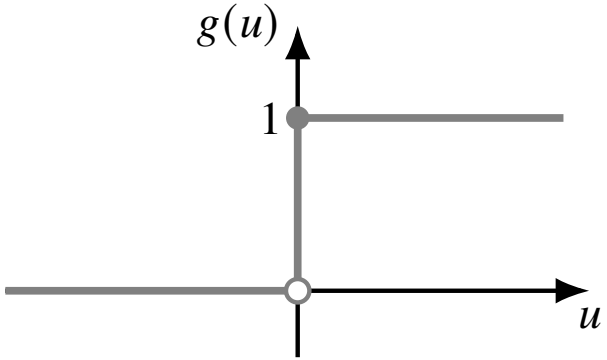
$$y = g(u)$$

Conceitos Fundamentais da Rede *Perceptron*

Características gerais da rede *Perceptron*:

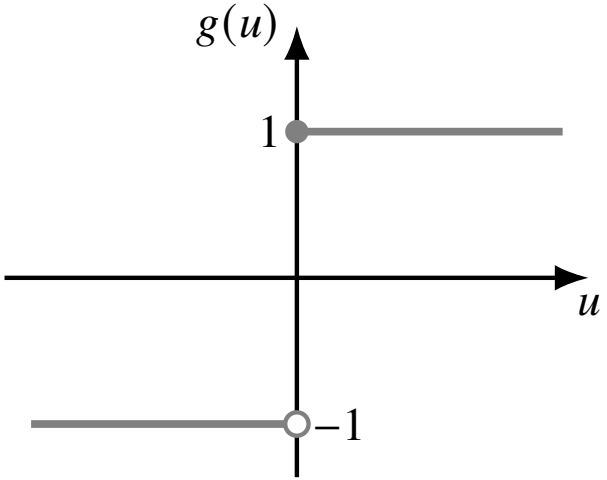
- Funções de ativação usuais:
  - Função degrau unitário:

$$g(u) = \mathbf{1}(u) = \begin{cases} 1, & u \geq 0 \\ 0, & u < 0 \end{cases}$$



  - Função sinal:

$$g(u) = \text{sinal}(u) = \begin{cases} +1, & u \geq 0 \\ -1, & u < 0 \end{cases}$$



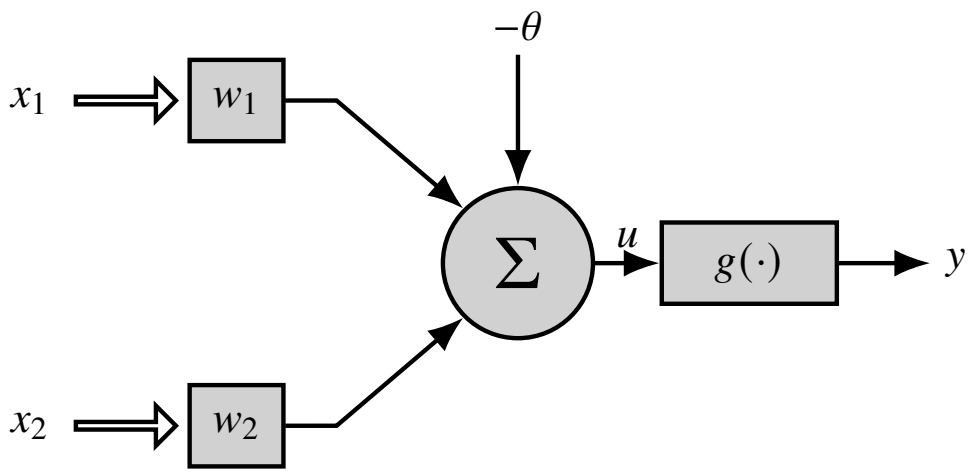
Conceitos Fundamentais da Rede *Perceptron*

Características gerais da rede *Perceptron*:

- Saída: apenas valores binários;
- Processo de treinamento: supervisionado;
  - Necessita dos pares entrada e saída desejada;
  - Conjunto de treinamento: p amostras de treinamento;
- Regra de aprendizado: algoritmo de Hebb;
- Utilização principal: classificação de padrões;
  - Saídas possíveis para a rede *Perceptron* (assumindo função de ativação sinal): $\{-1, 1\}$;
  - Dadas duas classes a serem classificadas, denominadas A e B, poderíamos fazer o seguinte mapeamento:
    - Classe A: saída 1;
    - Classe B: saída -1;

Análise Matemática da Rede *Perceptron*

- A rede *Perceptron* atua como um discriminador linear entre duas classes;
- Análise para uma rede com apenas duas entradas:



- Análise da saída:

$$\mathbf{w} = \begin{bmatrix} \theta & w_1 & w_2 \end{bmatrix}^T$$

$$\mathbf{x} = \begin{bmatrix} -1 & x_1 & x_2 \end{bmatrix}^T$$

$$u = \mathbf{w}^T \mathbf{x}$$

$$y = g(u) = \begin{cases} +1, & u \geq 0 \\ -1, & u < 0 \end{cases}$$

Análise Matemática da Rede *Perceptron*

- De forma sucinta:

$$u = w_1 x_1 + w_2 x_2 - \theta \qquad y = \begin{cases} +1, & u \geq 0 \\ -1, & u < 0 \end{cases}$$

ou seja,

$$y = \begin{cases} +1, & w_1 x_1 + w_2 x_2 - \theta \geq 0 \\ -1, & w_1 x_1 + w_2 x_2 - \theta < 0 \end{cases}$$

$$w_1 x_1 + w_2 x_2 - \theta \geq 0 \Leftrightarrow (x_1, x_2) \in A$$

$$w_1 x_1 + w_2 x_2 - \theta < 0 \Leftrightarrow (x_1, x_2) \in B$$

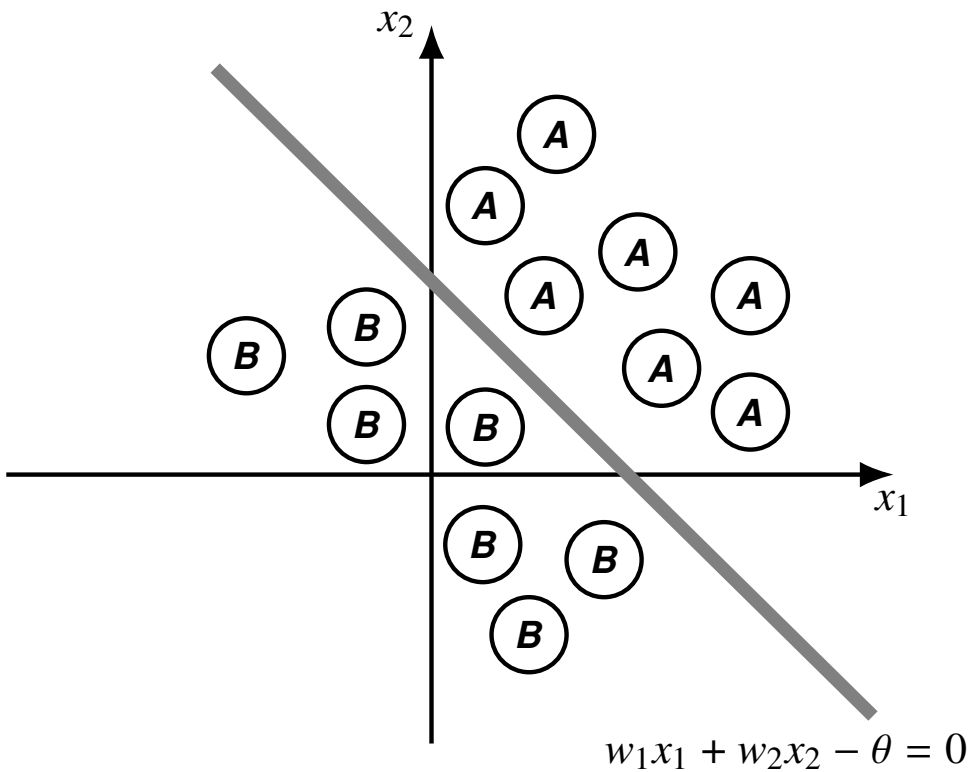
- Essas desigualdades definem uma fronteira de decisão dada pela equação da reta:

$$w_1 x_1 + w_2 x_2 - \theta = 0$$

  - Para $w_2 > 0$, pontos acima da reta (i.e. $w_1 x_1 + w_2 x_2 - \theta \geq 0$) correspondem à classe A;
  - Para $w_2 > 0$, pontos abaixo da reta (i.e. $w_1 x_1 + w_2 x_2 - \theta < 0$) correspondem à classe B;

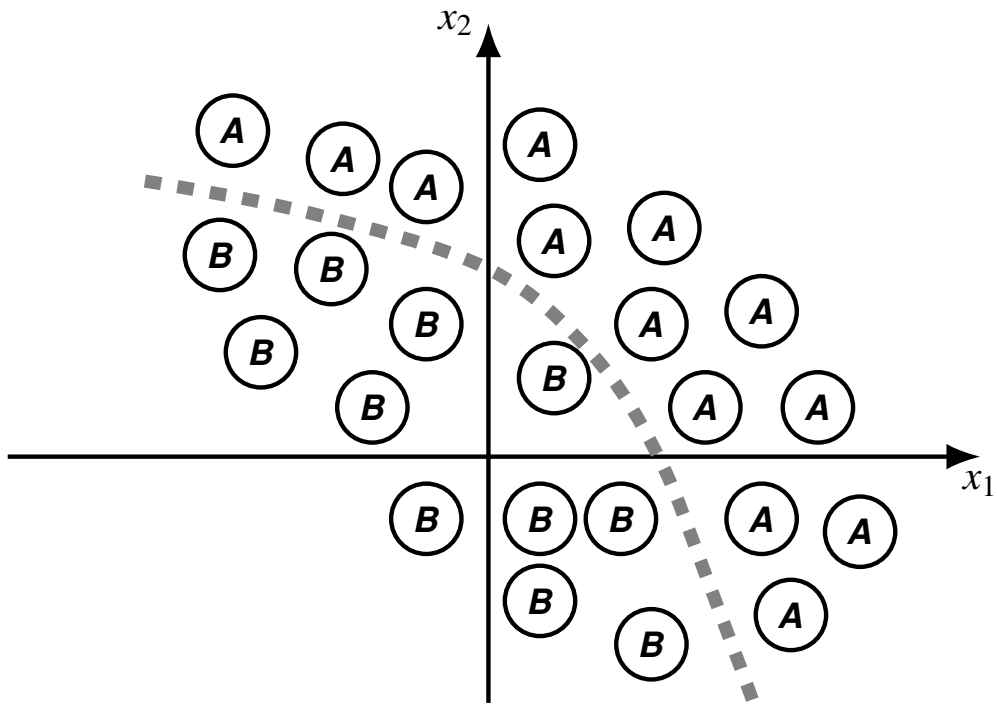
Análise Matemática da Rede *Perceptron*

- Superfície de separação gerada pela rede *Perceptron*;
- O objetivo da rede *Perceptron* é gerar um hiperplano de separação entre duas classes que sejam linearmente separáveis;



Análise Matemática da Rede *Perceptron*

- Teorema da convergência do *Perceptron*: se as classes forem linearmente separáveis, o treinamento converge para uma solução em um número finito de iterações;
  - Padrões que não são linearmente separáveis não podem ser classificados corretamente pela rede *Perceptron*;
  - Limita a utilização deste tipo de rede a um conjunto pequeno de aplicações;



Treinamento da Rede *Perceptron*

- Aplicação de passos de forma a ajustar os pesos sinápticos da rede neural;
- Utiliza a regra de aprendizado de Hebb:
  - Treinamento supervisionado;
  - Princípio do treinamento:
    - Se a saída da rede *Perceptron* não coincidir com a saída desejada, os pesos sinápticos serão ajustados proporcionalmente aos sinais de entrada;
    - Caso contrário (a saída da rede é igual à saída desejada), os pesos sinápticos permanecerão inalterados;

Treinamento da Rede *Perceptron*

- A regra de Hebb pode ser resumida na seguinte expressão:

$$w_i^{\text{atual}} = w_i^{\text{anterior}} + \eta \left(y_d^{(k)} - y \right) x_i^{(k)}, \qquad i = 0, 1, \ldots, n, \qquad k = 1, 2, \ldots, p$$

em que:

- w_i^{atual} é o novo valor do peso sináptico associado à i-ésima entrada;
- w_i^{anterior} é o valor antigo do peso associado à i-ésima entrada;
- $x_i^{(k)}$ é a i-ésima entrada da k-ésima amostra do conjunto de treinamento;
- $y_d^{(k)}$ é a k-ésima resposta desejada associada à entrada $\mathbf{x}^{(k)}$ do conjunto de treinamento;
- y é a saída do *Perceptron* após a aplicação da entrada $\mathbf{x}^{(k)}$;
- η é a taxa de aprendizado;

Treinamento da Rede *Perceptron*

- Representação vetorial:

$$\mathbf{w}^{\text{atual}} = \mathbf{w}^{\text{anterior}} + \eta \left(y_d^{(k)} - y \right) \mathbf{x}^{(k)}$$

em que:

$$\mathbf{w} = \begin{bmatrix} \theta & w_1 & w_2 & \cdots & w_n \end{bmatrix}^T$$

$$\mathbf{x}^{(k)} = \begin{bmatrix} -1 & x_1^{(k)} & x_2^{(k)} & \cdots & x_n^{(k)} \end{bmatrix}^T$$

Treinamento da Rede *Perceptron*

- O processo de ajuste dos pesos sinápticos segue até que a saída da rede *Perceptron* seja igual à saída desejada para todas as amostras do conjunto de treinamento;
- Influência da taxa de aprendizado (η):
  - Exprime o quão rápido será o processo de treinamento da rede neural;
    - Para valores baixos, os ajustes do hiperplano são pequenos e suaves, mas o treinamento tende a ser mais lento;
    - Para valores altos, os ajustes são maiores e o hiperplano pode oscilar bastante entre as iterações;
  - Valores típicos: $0 < \eta < 1$;

Treinamento da Rede *Perceptron*

Algoritmo 1: *Perceptron* — fase de treinamento

Obter o conjunto de amostras de treinamento $\left\{\mathbf{x}^{(k)}\right\}$

Associar a saída desejada $\left\{y_d^{(k)}\right\}$ a cada amostra obtida

Iniciar o vetor $\mathbf{w}$ com valores aleatórios pequenos

Especificar a taxa de aprendizado η

Especificar o número máximo de épocas $N_{\max}$

Iniciar o contador de número de épocas: *época* $\leftarrow 0$

repita

  erro $\leftarrow$ "inexiste"

  para cada *amostra de treinamento* $\left\{\mathbf{x}^{(k)}, y_d^{(k)}\right\}$ **faça**

    $u \leftarrow \mathbf{w}^T \mathbf{x}^{(k)}$

    $y \leftarrow \text{sinal}(u)$

    se $y \neq y_d^{(k)}$ **então**

      $\mathbf{w} \leftarrow \mathbf{w} + \eta \left(y_d^{(k)} - y\right) \mathbf{x}^{(k)}$

      erro $\leftarrow$ "existe"

    fim

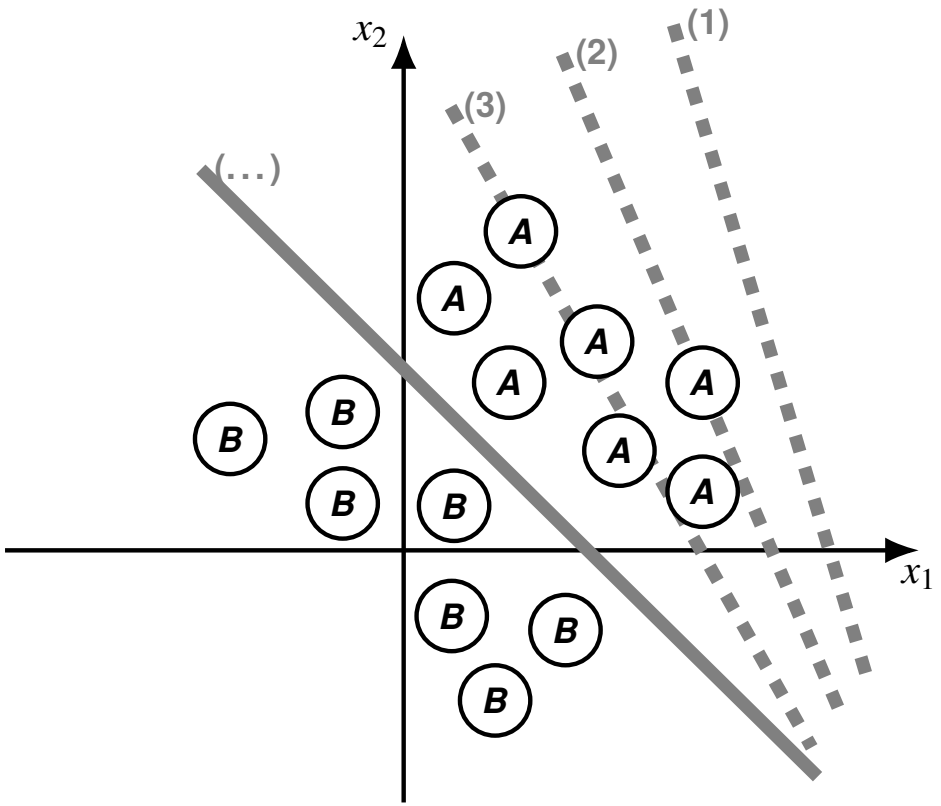
  fim

  época $\leftarrow$ *época* $+1$

até *erro* $=$ *"inexiste"* ***ou*** *época* $= N_{\max}$

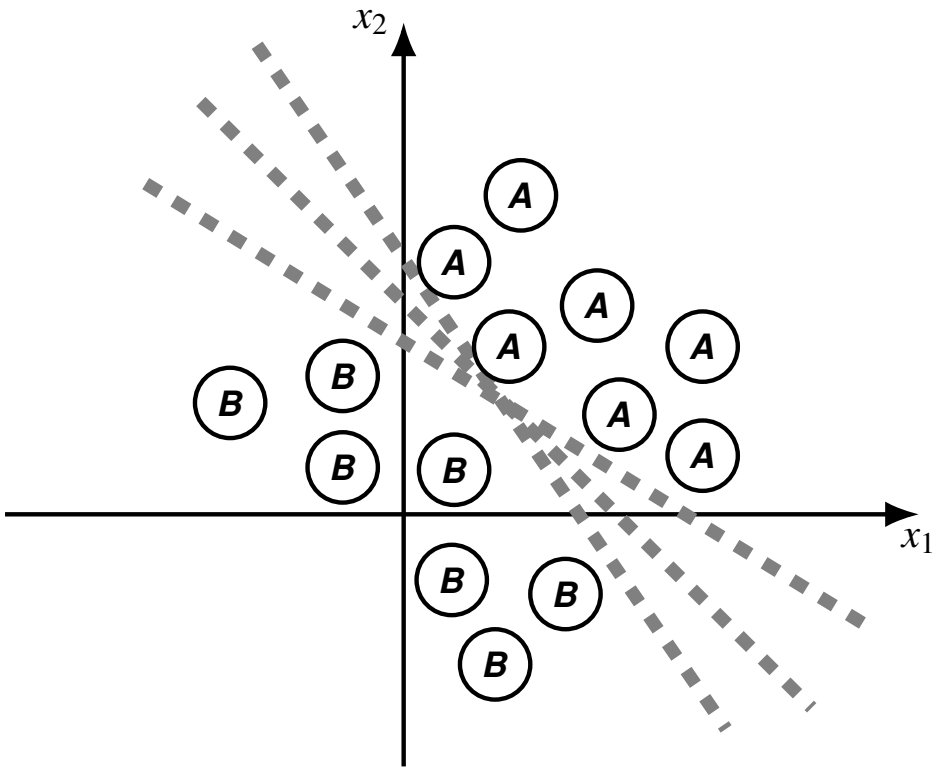
Treinamento da Rede *Perceptron*

- A variável *época* é responsável por contabilizar quantas épocas são necessárias para o treinamento da rede;
- O processo de treinamento da rede *Perceptron* consiste em mover um hiperplano de separação que permite dividir duas classes;



Treinamento da Rede *Perceptron*

- Existe uma infinidade de hiperplanos que separam duas classes linearmente separáveis;
  - Os pesos sinápticos obtidos após o treinamento não são únicos;



Operação da Rede *Perceptron*

- Após treinada (obtidos os valores dos pesos), a rede *Perceptron* está apta a realizar a tarefa de classificação dos padrões:

Algoritmo 2: *Perceptron* — fase de classificação

Obter uma nova amostra a ser classificada $\{\mathbf{x}\}$
Utilizar o vetor $\mathbf{w}$ ajustado durante o treinamento
$u \leftarrow \mathbf{w}^T \mathbf{x}$
$y \leftarrow \text{sinal}(u)$
se $y = +1$ **então**
  amostra $\mathbf{x} \in \{\text{Classe A}\}$
fim
se $y = -1$ **então**
  amostra $\mathbf{x} \in \{\text{Classe B}\}$
fim

Aspectos Práticos das Redes *Perceptron*

- O treinamento não convergirá se o problema for não linearmente separável (os pesos oscilarão indefinidamente);
  - Deve-se limitar o processo de aprendizagem por um número máximo de épocas de treinamento;
- Quando a faixa de separabilidade entre as duas classes for estreita, deve-se utilizar uma taxa de aprendizado pequena, para que a busca do hiperplano ocorra de forma suave;
- A quantidade de épocas necessárias para a convergência da rede depende:
  - Dos valores iniciais do vetor de pesos da rede;
  - Da disposição das amostras de treinamento;
  - Da taxa de aprendizado;
- A normalização das entradas contribui para incrementar o desempenho do treinamento;
- Recomenda-se embaralhar a ordem de apresentação dos exemplos no processo de treinamento.