

UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO (UFERSA)
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS (CMPF)
DEPARTAMENTO DE ENGENHARIAS E TECNOLOGIA (DETEC)

SISTEMAS INTELIGENTES

Redes *Adaline*

Prof. Pedro Thiago Valério de Souza
UFERSA – Campus Pau dos Ferros
pedro.souza@ufersa.edu.br

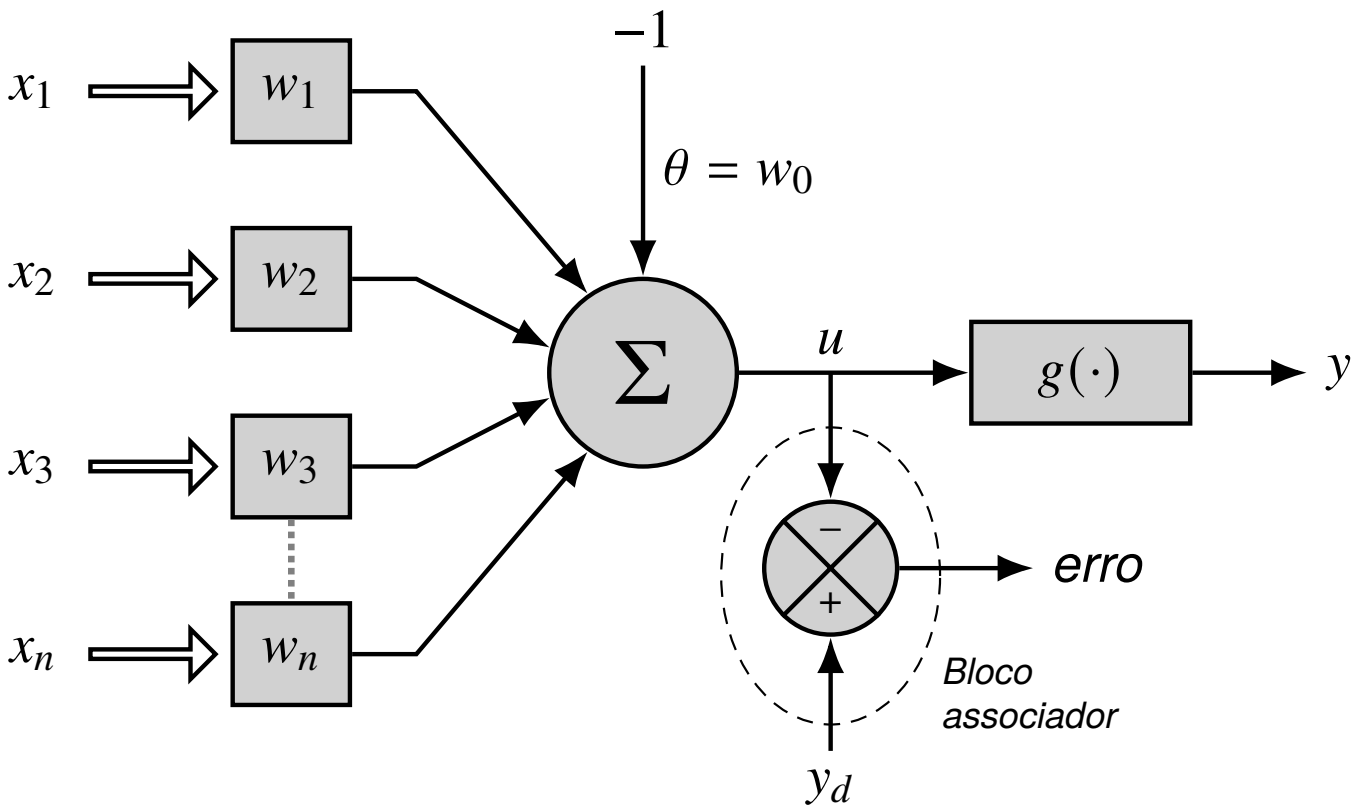
Conceitos Fundamentais da Rede *Adaline*

- Rede neural proposta por Widrow e Hoff em 1960;
  - *Adaline*: *ADAptive LINear Element* (elemento linear adaptativo);
- Aplicação inicial: chaveamento de circuitos telefônicos;
  - Uma das primeiras aplicações industriais de uma RNA;
- Principais contribuições da rede *Adaline*:
  - Desenvolvimento do algoritmo de aprendizado denominado regra Delta;
    - Base da regra Delta generalizada (*backpropagation*), utilizada no treinamento de redes mais avançadas, como a rede *Perceptron* de múltiplas camadas;
  - Aplicações em diversos problemas práticos envolvendo processamento de sinais analógicos;

Conceitos Fundamentais da Rede *Adaline*

Características gerais da rede *Adaline*:

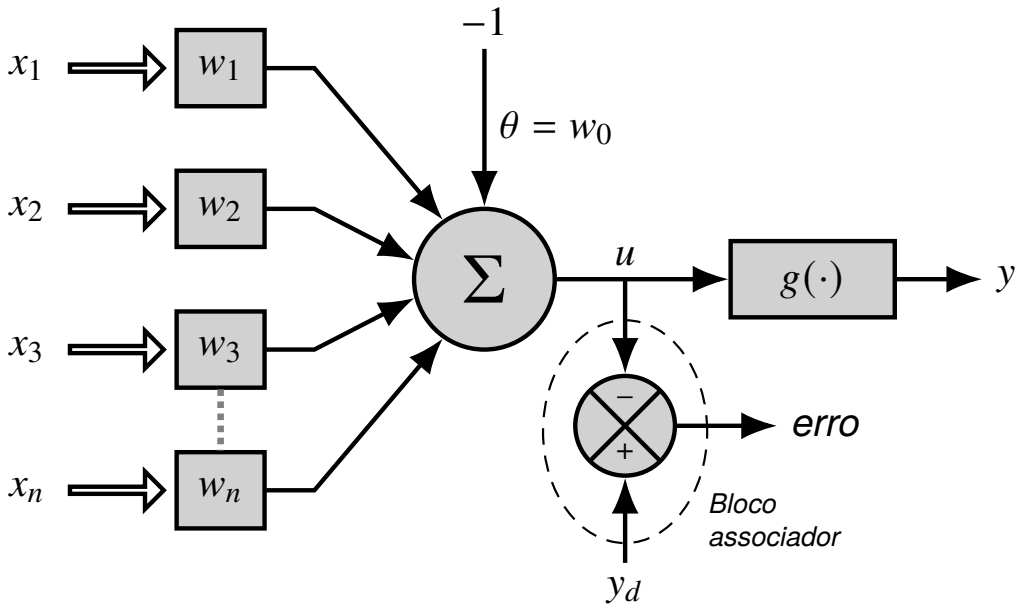
- Arquitetura *feedforward* de camada única;
- Quantidade de entradas: n entradas;
- Apenas uma saída;
  - Redes com mais de uma saída: *Madaline*;



Conceitos Fundamentais da Rede *Adaline*

Características gerais da rede *Adaline*:

- Vetor de pesos sinápticos: valores reais;
- Vetor de entradas: valores binários ou reais;



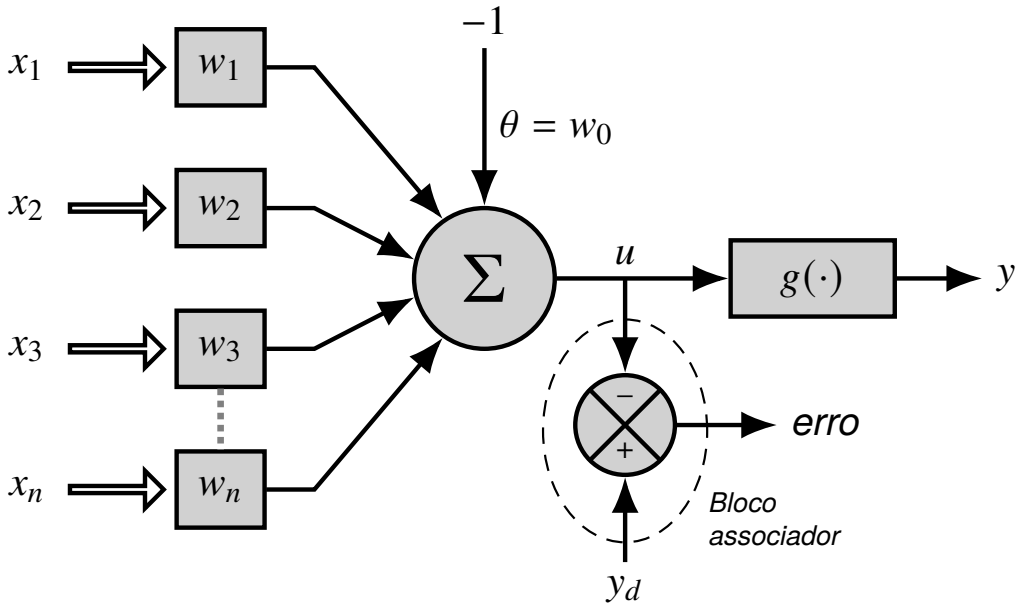
$$\mathbf{w} = \begin{bmatrix} \theta & w_1 & w_2 & \cdots & w_n \end{bmatrix}^T$$

$$\mathbf{x} = \begin{bmatrix} -1 & x_1 & x_2 & \cdots & x_n \end{bmatrix}^T$$

Conceitos Fundamentais da Rede *Adaline*

Características gerais da rede *Adaline*:

- Expressões de saída da rede *Adaline*:



$$u = \sum_{i=0}^{n} w_i x_i = \mathbf{w}^T \mathbf{x}$$

$$y = g(u)$$

Conceitos Fundamentais da Rede *Adaline*

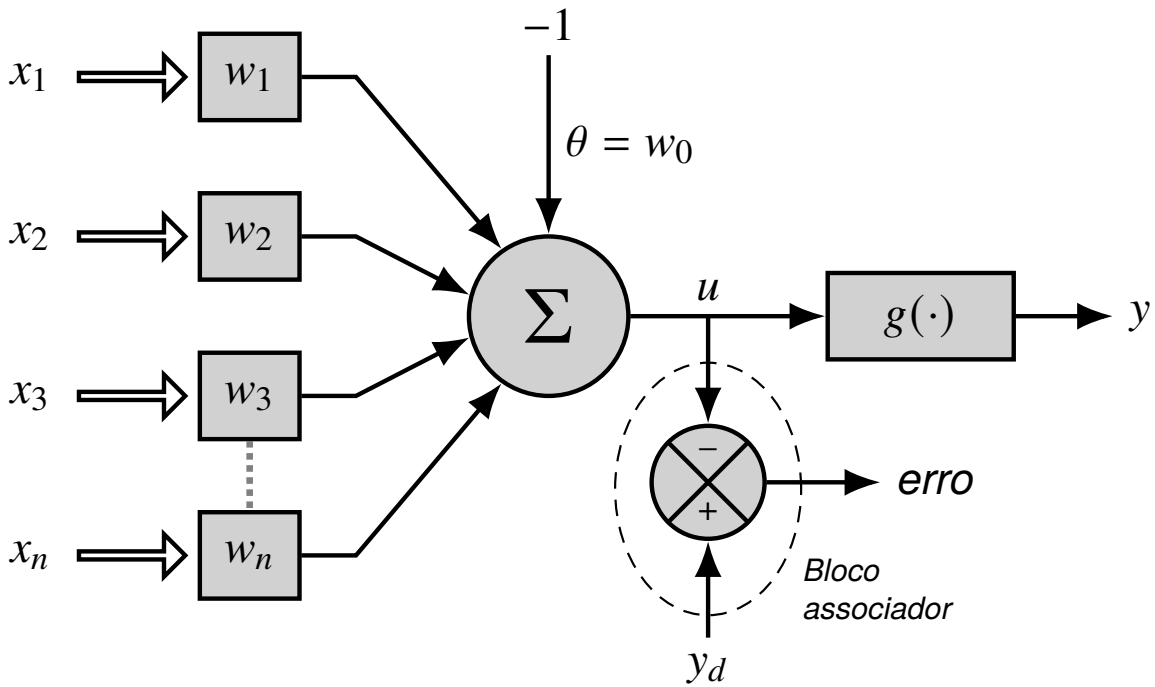
Características gerais da rede *Adaline*:

- Funções de ativação usuais: degrau unitário ou função sinal;
- Saída: apenas valores binários;
- Processo de treinamento: supervisionado;
- Regra de aprendizado: regra Delta (LMS ou algoritmo de Widrow-Hoff);
  - Principal diferença entre a rede *Perceptron* e a rede *Adaline*;
- Utilização principal: classificação de padrões;

Conceitos Fundamentais da Rede *Adaline*

Características gerais da rede *Adaline*:

- Função do bloco associador: gerar um sinal de erro necessário para o processo de treinamento;
  - Diferença entre a saída desejada e o potencial de ativação (e não a saída y da rede);



$$erro = y_d - u$$

Processo de Treinamento da Rede *Adaline*

Ideia básica do processo de treinamento da rede *Adaline*:

- Ajustar os pesos do neurônio de forma a minimizar o erro entre a saída desejada $\{y_d\}$ e as respostas do combinador linear $\{u\}$, considerando-se, para tanto, todas as p amostras do conjunto de treinamento;
- Consiste na minimização de uma função de custo:
  - Erro quadrático médio (EQM):

$$E_{qm}(\mathbf{w}) = \frac{1}{2p}\sum_{k=1}^{p}\left(y_d^{(k)} - u^{(k)}\right)^2, \qquad u^{(k)} = \mathbf{w}^T\mathbf{x}^{(k)}$$

Processo de Treinamento da Rede *Adaline*

Ideia básica do processo de treinamento da rede *Adaline*:

- Matematicamente, temos:

$$\min_{\mathbf{w}} E_{qm}(\mathbf{w}) = \min_{\mathbf{w}} \frac{1}{2p} \sum_{k=1}^{p} \left(y_d^{(k)} - \mathbf{w}^T \mathbf{x}^{(k)} \right)^2$$

- Principal método: algoritmo do gradiente descendente;
  - Os pesos são ajustados no sentido oposto ao do gradiente da função de custo:

$$\mathbf{w}^{\text{atual}} = \mathbf{w}^{\text{anterior}} - \eta \frac{\partial E_{qm}(\mathbf{w})}{\partial \mathbf{w}}$$

Processo de Treinamento da Rede *Adaline*

- Gradiente da função de custo em relação aos pesos sinápticos:

$$\frac{\partial E_{qm}(\mathbf{w})}{\partial \mathbf{w}} = -\frac{1}{p}\sum_{k=1}^{p}\left(y_d^{(k)} - u^{(k)}\right)\mathbf{x}^{(k)}$$

- A aplicação do método do gradiente leva às seguintes equações de atualização dos pesos sinápticos:
  - Modo *batch* (*off-line*): ajuste único ao final de cada época, considerando todas as amostras;

$$\mathbf{w}^{\text{atual}} = \mathbf{w}^{\text{anterior}} + \frac{\eta}{p}\sum_{k=1}^{p}\left(y_d^{(k)} - u^{(k)}\right)\mathbf{x}^{(k)}$$

  - Modo *on-line*: ajuste realizado após a apresentação de cada amostra:

$$\mathbf{w}^{\text{atual}} = \mathbf{w}^{\text{anterior}} + \eta\left(y_d^{(k)} - u^{(k)}\right)\mathbf{x}^{(k)}, \qquad k = 1, 2, \ldots, p$$

Processo de Treinamento da Rede *Adaline*

- Influência da taxa de aprendizado (η): determina a rapidez do treinamento da rede neural;
  - Valores baixos: treinamento lento, porém estável;
  - Valores altos: treinamento mais rápido, porém sujeito a oscilações e até à divergência;
  - Valores típicos: $0 < \eta < 1$;
- Critério de parada: em função do erro quadrático médio (EQM);

$$E_{qm}(\mathbf{w}) = \frac{1}{2p} \sum_{k=1}^{p} \left(y_d^{(k)} - u^{(k)} \right)^2$$

  - Considera-se que o algoritmo convergiu quando a variação do EQM entre duas épocas sucessivas for suficientemente pequena, ou seja:

$$\left| E_{qm}\left(\mathbf{w}^{\text{atual}}\right) - E_{qm}\left(\mathbf{w}^{\text{anterior}}\right) \right| \leq \varepsilon$$

em que ε é a precisão requerida;

Processo de Treinamento da Rede *Adaline*

Algoritmo 1: *Adaline* — fase de treinamento (modo *on-line*)

Obter o conjunto de amostras de treinamento $\left\{\mathbf{x}^{(k)}\right\}$

Associar a saída desejada $\left\{y_d^{(k)}\right\}$ a cada amostra obtida

Iniciar o vetor $\mathbf{w}$ com valores aleatórios pequenos

Especificar a taxa de aprendizado η e a precisão requerida ε

Especificar o número máximo de épocas $N_{\max}$

Iniciar o contador de número de épocas: *época* $\leftarrow 0$

repita

  $E_{\text{anterior}} \leftarrow E_{qm}(\mathbf{w})$

  para cada *amostra de treinamento* $\left\{\mathbf{x}^{(k)}, y_d^{(k)}\right\}$ **faça**

    $u \leftarrow \mathbf{w}^T \mathbf{x}^{(k)}$

    $\mathbf{w} \leftarrow \mathbf{w} + \eta \left(y_d^{(k)} - u\right) \mathbf{x}^{(k)}$

  fim

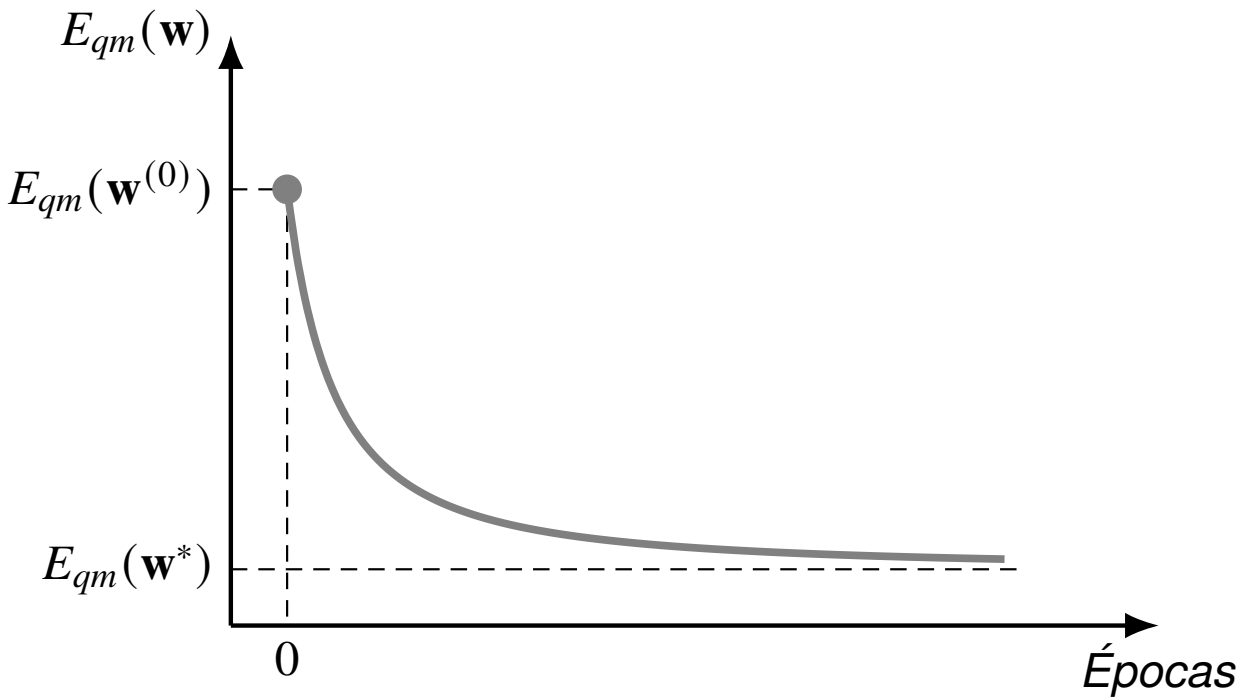
  época $\leftarrow$ *época* $+1$

  $E_{\text{atual}} \leftarrow E_{qm}(\mathbf{w})$

até $|E_{\text{atual}} - E_{\text{anterior}}| \leq \varepsilon$ ***ou*** *época* $= N_{\max}$

Processo de Treinamento da Rede *Adaline*

- Curva do erro quadrático médio em função das épocas de treinamento:
  - Para uma taxa de aprendizado adequada, trata-se de uma função monotonamente decrescente;
  - O EQM converge para o valor mínimo $E_{qm}(\mathbf{w}^*)$, associado ao vetor de pesos ótimo $\mathbf{w}^*$;



Operação da Rede *Adaline*

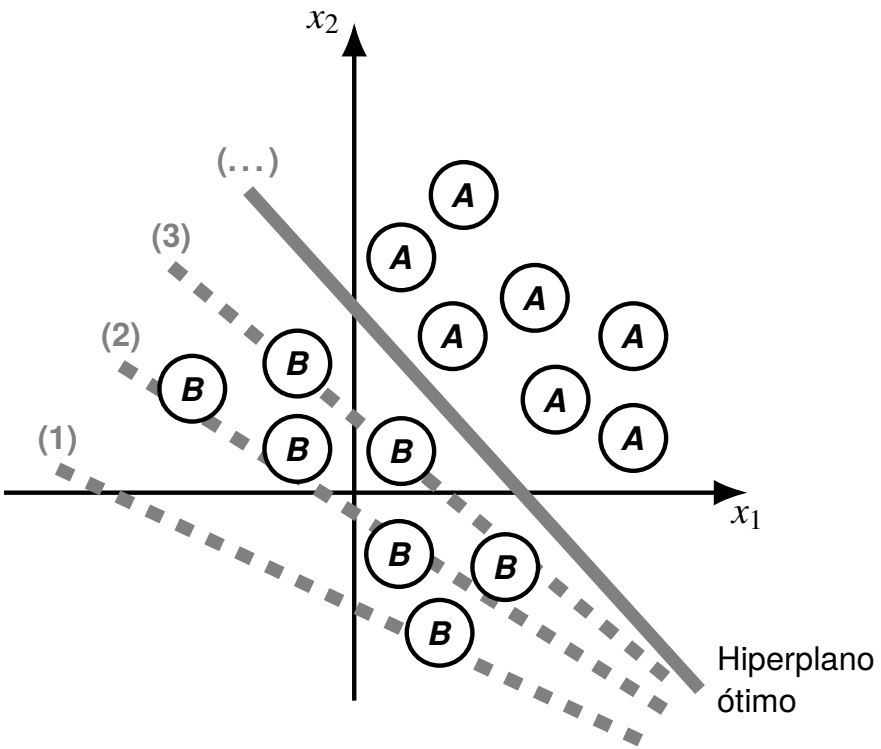
- Após treinada (obtidos os valores dos pesos), a rede *Adaline* está apta a realizar a tarefa de classificação dos padrões:

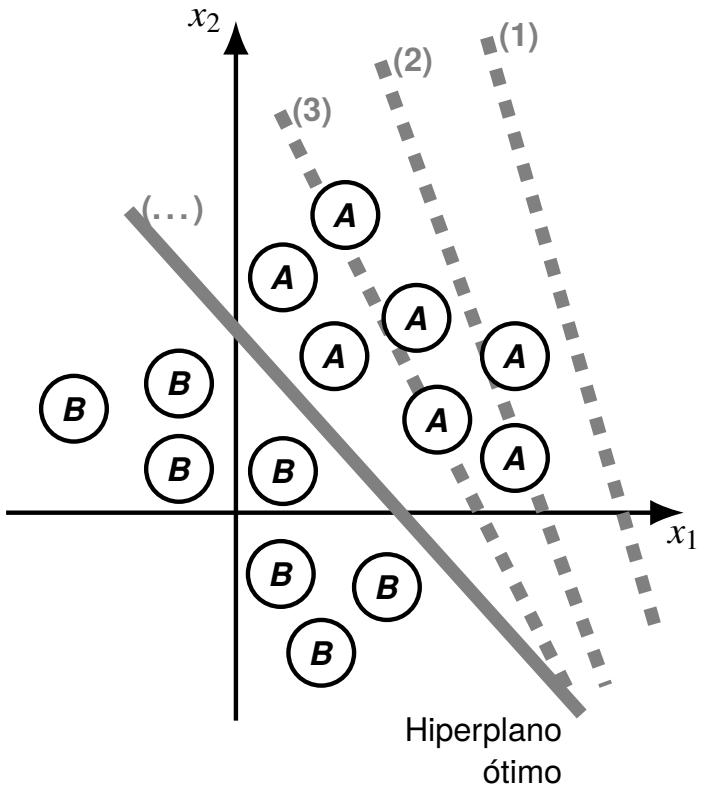
Algoritmo 2: *Adaline* — fase de classificação

Obter uma nova amostra a ser classificada $\{\mathbf{x}\}$
Utilizar o vetor $\mathbf{w}$ ajustado durante o treinamento
$u \leftarrow \mathbf{w}^T \mathbf{x}$
$y \leftarrow \text{sinal}(u)$
se $y = +1$ **então**
  amostra $\mathbf{x} \in \{\text{Classe A}\}$
fim
se $y = -1$ **então**
  amostra $\mathbf{x} \in \{\text{Classe B}\}$
fim

Comparação das Redes *Adaline* e *Perceptron*

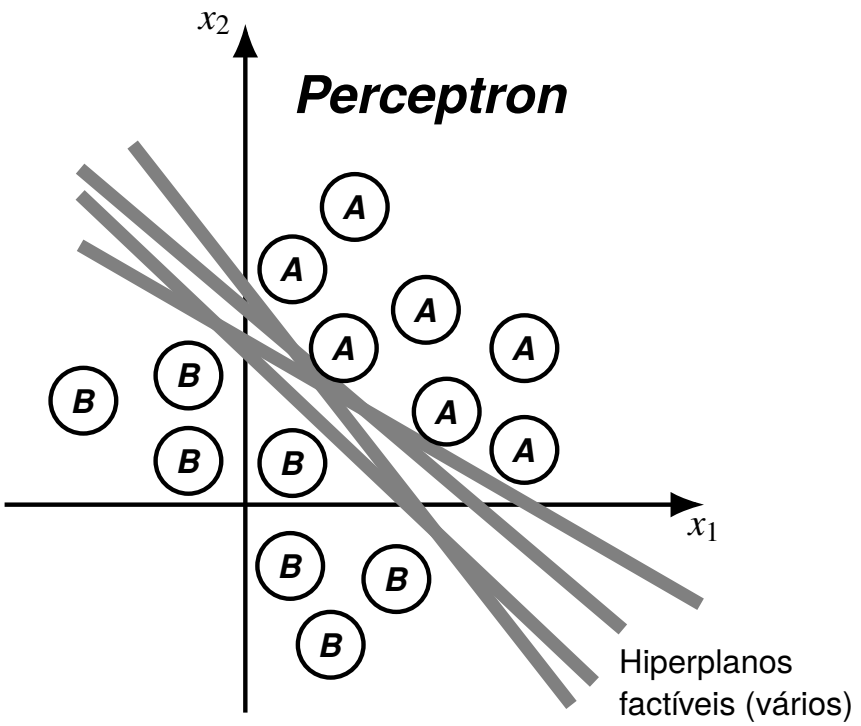
- O processo de treinamento da rede *Adaline* visa mover um hiperplano de separação de forma a minimizar o erro quadrático em relação a todas as amostras do conjunto de treinamento;
  - Independentemente dos pesos iniciais, o hiperplano obtido tende a ser sempre o mesmo, pois $E_{qm}(\mathbf{w})$ é uma função quadrática (convexa) dos pesos e, em geral, possui um único ponto de mínimo $\mathbf{w}^*$;

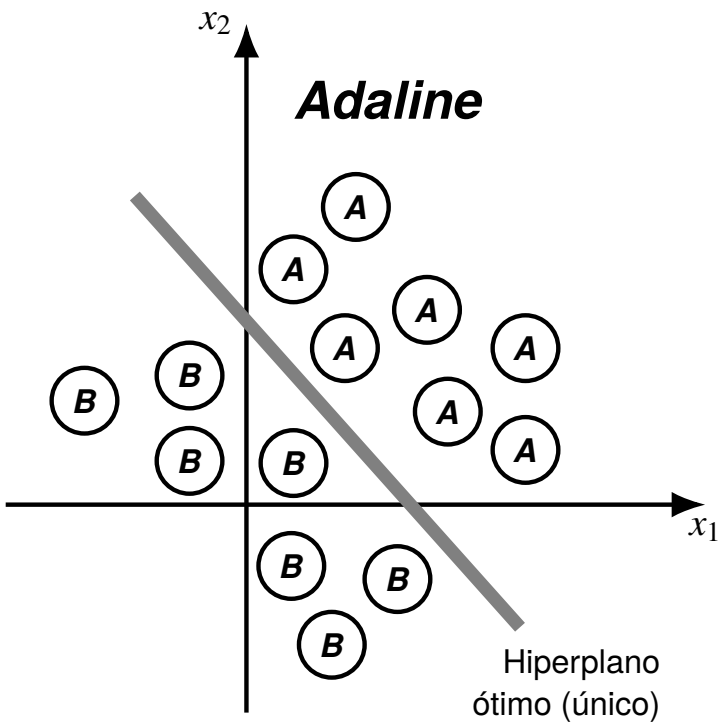




Comparação das Redes *Adaline* e *Perceptron*

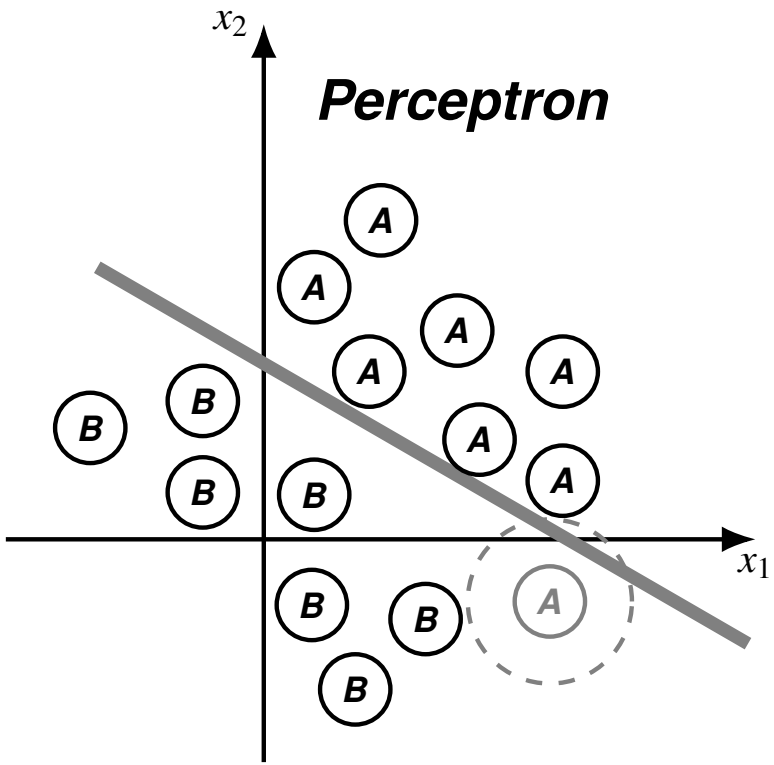
- Posição do hiperplano de separação:
  - Rede *Perceptron*: admite qualquer hiperplano factível, isto é, que separe corretamente as amostras de treinamento;
  - Rede *Adaline*: admite apenas um hiperplano de separação, aquele que minimiza o EQM nas amostras de treinamento;

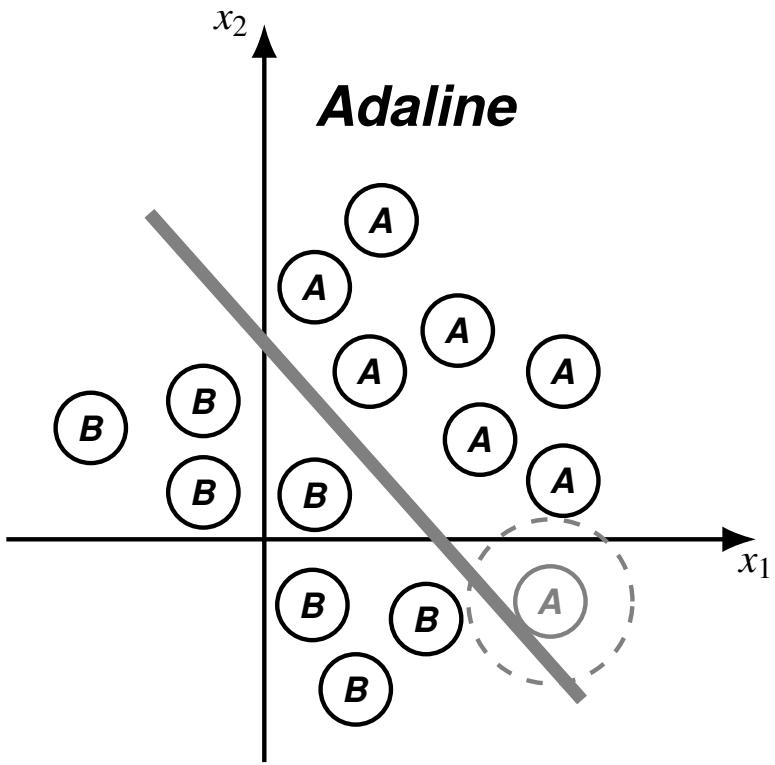




Comparação das Redes *Adaline* e *Perceptron*

- Imunidade ao ruído:
  - A rede *Adaline* tende a ser mais robusta que a rede *Perceptron* diante de amostras acometidas por ruído aditivo;
  - Como o hiperplano é posicionado de forma a minimizar o erro em relação a todas as amostras, ele tende a ficar mais equilibrado entre as duas classes;





Aspectos Práticos das Redes *Adaline*

- A rede *Adaline* é indicada para a separação de classes linearmente separáveis;
  - Diferentemente do *Perceptron*, mesmo que as classes não sejam linearmente separáveis, a regra Delta converge, pois o critério de parada depende da precisão ε, e não da classificação correta de todas as amostras;
    - Porém, o desempenho da rede será insatisfatório, já que a fronteira de decisão continua sendo linear;
  - Por minimizar o EQM, e não o número de erros de classificação, o hiperplano obtido não garante a classificação correta de todas as amostras de treinamento, mesmo em problemas linearmente separáveis;

Aspectos Práticos das Redes *Adaline*

- O valor da taxa de aprendizado deve ser especificado com cuidado, seguindo as mesmas recomendações da rede *Perceptron*;
- A quantidade de épocas necessárias para a convergência varia de acordo com:
  - Os valores iniciais dos pesos;
  - A disposição das amostras de treinamento;
  - O valor da taxa de aprendizado;
- A disposição final do hiperplano confere à rede *Adaline* maior robustez a eventuais ruídos que possam afetar as amostras a serem classificadas;
- A normalização das entradas contribui para incrementar o desempenho do treinamento.